

Activitat 1: Exploració i preprocés de dades

Enunciat

Anàlisi Estadística - Semestre 2024.2

Índex

1 Preparació del conjunt de dades	3
1.1 Carregar el fitxer de dades	3
1.2 Noms de les columnes	3
2 Normalització de formats en variables categòriques	3
3 Inconsistències en variables quantitatives	3
4 Valors invàlids o atípics	3
4.1 Valors invàlids	4
4.2 Valors atípics	4
5 Imputació	4
6 Correlacions	4
6.1 Matriu de correlacions	4
6.2 Càlcul de correlacions	4
7 Anàlisi descriptiva i visual	4
7.1 Taula resum de tendència central i variabilitat d'HR segons SD (Sleep Disorder)	4
7.2 Gràfica de mitjanes segons HR i Occupation	4
8 Arxiu final	4
9 Puntuació de l'activitat	5

Introducció

El conjunt de dades de salut del son i estil de vida (<https://www.kaggle.com/datasets/uom190346a/sleep-health-and-lifestyle-dataset>) consta de diverses files i 13 variables, que cobreixen una àmplia gamma de variables relacionades amb el son i els hàbits diaris. Inclou dades sobre diverses persones, incloent els estils de vida i la qualitat del son.

Les variables del conjunt de dades són:

- Person.ID: un identificador per a cada individu.
- Gender: el gènere de la persona.
- Age: l'edat de la persona en anys.
- Occupation: ocupació o professió de la persona.
- Sleep.Duration (hores): el nombre d'hores que la persona dorm al dia.

- Quality.of.Sleep (escala: 1-10): una valoració subjectiva de la qualitat del son, que oscil·la entre 1 i 10.
- Physical.Activity.Level (minuts/dia): el nombre de minuts que la persona realitza diàriament una activitat física.
- Stress.Level (escala: 1-10): una valoració subjectiva del nivell d'estrès experimentat per la persona, que va de l'1 al 10.
- BMI.Category: la categoria d'IMC de la persona (p. ex., baix pes, normal, sobrepès).
- Blood.Pressure: la mesura de la pressió arterial de la persona, indicada com a pressió sistòlica sobre pressió diastòlica.
- Heart.rate (bpm): la freqüència cardíaca en repòs de la persona en batecs per minut.
- Daily.Steps: el nombre de passos que fa una persona al dia.
- Sleep.Disorder: la presència o absència d'un trastorn del son en la persona (Cap, Insomni, Apnea del son).

En aquesta activitat realitzarem l'anàlisi exploratòria i el preprocés d'aquest conjunt de dades per a preparar-lo per l'anàlisi que es realitzarà en l'activitat següent.

Criteris de verificació i de normalització de les variables:

A continuació es mostren els criteris amb què s'han de netejar les dades del conjunt:

- Reviseu la naturalesa de les variables (text, categòrica, numèrica). En cas que el tipus de variable que ha atorgat R no coincideixi amb el tipus que li correspondria estadísticament, s'haurà de corregir.
- Els noms de les ocupacions comencen amb majúscula. Si hi ha categories amb el mateix concepte i diferent noms, s'han d'unificar els noms.
- En les variables de tipus numèric, el separador decimal és el punt.
- Els valors perduts han de tenir el valor NA.
- Les variables numèriques amb valors NA s'han d'imputar segons les indicacions que es donen més avall.
- Els valors de pressió sistòlica i diastòlica han d'estar emmagatzemats en dues variables per separat de tipus numèric.

A tenir en compte per fer l'activitat:

- Es valora la precisió dels termes utilitzats (cal utilitzar de manera precisa la terminologia de l'estadística).
- Es valora també la concisió a la resposta. No es tracta de fer explicacions gaire llargues o documents molt extensos. Cal explicar-ne el resultat i argumentar la resposta a partir dels resultats obtinguts de manera clara i concisa.
- Mostreu en el document només allò que és imprescindible i que dona resposta a la pregunta plantejada. No cal que mostreu tot el procés d'exploració que heu realitzat.
- No es poden realitzar llistats complets del conjunt de dades a la solució. Això generaria un document amb centenars de pàgines i dificulta la revisió del text. Per comprovar les funcionalitats del codi sobre les dades, es poden fer servir les funcions head i tail que només mostren unes línies del fitxer de dades.
- Com a objectiu secundari, aquesta activitat pretén que desenvolupeu el coneixement del llenguatge R, aprofitant al màxim les seves característiques. En aquest sentit, sempre que sigui possible, useu codi optimitzat i elegant. Per exemple, per aplicar un mateix codi a diferents variables, useu les funcions de la família apply. Eviteu la inspecció visual (manual) sempre que sigui possible. Per a mostrar les taules, podeu usar la llibreria kableExtra.

Requisits per al lliurament:

- Cal lliurar el fitxer Rmd i el fitxer de sortida (PDF o html). El fitxer de sortida ha d'incloure: el codi i el resultat de l'execució del codi (pas a pas).
 - Per facilitar la correcció, els fitxers s'han de lliurar per separat a l'aula. És a dir, no pugeu un fitxer comprimit sinó cada fitxer per separat.
 - Cal respectar la mateixa numeració dels apartats que l'enunciat.
-

1 Preparació del conjunt de dades

1.1 Carregar el fitxer de dades

Llegir el fitxer de dades `sleephealth.csv`.

1.2 Noms de les columnes

Mostreu els noms de les columnes del fitxer. A continuació canvieu els noms de les variables més llargues: `Person.ID` → `ID`, `Sleep.Duration` → `SH`, `Quality.of.Sleep` → `SQ`, `Physical.Activity.Level` → `PHY`, `Stress Level` → `Stress`, `BMI.Category` → `BMI`, `Blood.Pressure` → `BP`, `Heart.Rate` → `HR`, `Daily.Steps` → `Steps`, `Sleep.Disorder` → `SD`. Posteriorment us demanarem que canvieu el format de la columna `BP`.

2 Normalització de formats en variables categòriques

Reviseu els formats de les variables categòriques. Corregiu les inconsistències si n'hi ha.

3 Inconsistències en variables quantitatives

Reviseu els valors de les variables quantitatives i apliqueu les transformacions de format necessàries. Si hi ha valors buits, substituïu-los per `NA`.

Pel que fa a les variables pressió sistòlica i diastòlica, cal que les emmagatzemeu per separat en dues columnes de tipus numèric: `BPsyst`, `BPdias`.

Si trobeu valors extrems o erronis en alguna variable quantitativa, o bé `NAs`, ho tractarem en apartats posteriors.

Estructureu aquest apartat en més subapartats si ho considereu oportú.

4 Valors invàlids o atípics

En aquest apartat revisem els valors de les variables numèriques. En primer lloc, si hi ha valors invàlids en alguna variable, substituïu-los per `NAs`. A continuació, comproveu si hi ha valors atípics i si ho considereu oportú, també substituïu-los per `NAs`. Justifiqueu la vostra elecció. Realitzeu aquestes anàlisis en dos subapartats diferents. En l'apartat següent, es realitzarà la imputació dels `NAs`.

4.1 Valors invàlids

4.2 Valors atípics

5 Imputació

Realitzeu la imputació de les variables que tinguin NAs, usant el mètode d'imputació basat en els k veïns més propers (k=3). Alhora d'imputar, només useu les variables numèriques (excepte ID). En acabar la imputació, mostreu en una taula els valors imputats.

6 Correlacions

6.1 Matriu de correlacions

Calculeu les correlacions entre les variables numèriques i mostreu una matriu amb el resultat. Interpreteu el resultat.

6.2 Càlcul de correlacions

Implementeu una funció pròpia que calculi la correlació de Pearson entre dues variables (sense usar llibreries d'R que ho calculin). Valideu que la vostra implementació és correcta comparant el resultat amb la funció *cor* d'R.

7 Anàlisi descriptiva i visual

A continuació, realitzarem una anàlisi descriptiva d'algunes variables d'interès del conjunt de dades. Seguiu les indicacions dels subapartats següents.

7.1 Taula resum de tendència central i variabilitat d'HR segons SD (Sleep Disorder)

Mostreu en una taula les dades de tendència central (mitjana) i dispersió (desviació estàndard) de les variables SH, SQ, HR i Stress, agregades segons SD (Sleep Disorder). Per a poder desenvolupar aquest apartat, podeu usar funcions de la llibreria dplyr (summarise, group_by, reframe) i kable (per mostrar la taula).

7.2 Gràfica de mitjanes segons HR i Occupation

A continuació, realitzeu un gràfic de línies que mostri el valor de la mitjana d'HR segons Occupation i segons cada tipus de SD. Per a organitzar la informació, mostreu en l'eix X el tipus de SD i cada línia del gràfic que correspongui a una ocupació diferent, usant colors diferents per cada ocupació. Ordeneu les categories en l'eix X per a millor claredat. Podeu usar la funció ggplot (de la llibreria ggplot2).

8 Arxiu final

Un cop realitzat el preprocessament sobre el fitxer, deseu el resultat de les dades en un fitxer csv anomenat sleephealth_processed.csv.

9 Puntuació de l'activitat

- Apartat 1: 10%
- Apartat 2: 10%
- Apartat 3: 10%
- Apartat 4: 10%
- Apartat 5: 10%
- Apartat 6: 20%
- Apartats 7,8: 20%
- Qualitat del codi i de l'informe: 10%