

Models predictius

Enunciat

Semestre 2024.2

Índice

1	Regressió lineal	2
1.1	Estudi de correlació lineal	2
1.2	Estudi comparatiu entre barris de Barcelona	2
1.3	Generació dels conjunts d'entrenament i de test	3
1.4	Estimació del model de regressió lineal amb predictors quantitatius	3
1.5	Estimació del model de regressió lineal amb predictors quantitatius i qualitius	3
1.6	Diagnosi del model.	3
1.7	Predicció del model	3
2	Regressió logística.	4
2.1	Preparació de les dades	4
2.2	Estimació del model de regressió logística amb el conjunt d'entrenament	4
2.3	Càlcul de les OR (Odds-Ràtio)	4
2.4	Matriu de confusió	4
2.5	Predicció	4
2.6	Bondat de l'ajust i corba ROC	5
2.7	Model de regressió logística multinomial	5
3	Resum executiu. Conclusions de l'anàlisi	5

Introducció

En aquesta activitat usarem el conjunt de dades de preus dels lloguers a la ciutat de Barcelona, recollits per la plataforma immobiliària Fotocasa l'any 2021. A més del preu de la renda, s'han registrat dades de cada habitatge com el nombre d'habitacions, banys, si té o no ascensor, terrassa, entre altres. També es té informació sobre el barri en el qual estan situades. L'objectiu principal d'aquest estudi és esbrinar quins són els factors que més influeixen a l'hora de determinar el preu de lloguer d'un pis. Aquest tipus d'anàlisi és molt útil tant per a les agències i plataformes immobiliàries, com per a qualsevol persona que està interessada a mudar-se a Barcelona.

L'arxiu conté informació sobre més de 8000 immobles.

Les dades s'han extret de la base de dades disponible en la plataforma Kaggle: Barcelona_Fotocasa_HousingPrices.

- price: Preu de renda.
- rooms: Nombre d'habitacions.
- bathroom: Nombre de banys.
- lift: Indica si l'habitatge té ascensor o no.
- terrace: Indica si l'habitatge té terrassa o no.
- square_meters: Superfície en metres quadrats.
- real_state: Tipus d'habitatge.
- neighborhood: Barri o zona.

Primer s'estudiaran les possibles relacions lineals entre el preu del lloguer i les diferents variables independents. En la segona part de l'activitat es buscaran els factors que intervenen perquè el preu per metre quadrat sigui més elevat.

1 Regressió lineal

1.1 Estudi de correlació lineal

Calculeu la correlació lineal entre totes les variables quantitatives de l'estudi. Mostreu la matriu de correlació i ordenar els valors de manera decreixent, és a dir del valor més alt de r , *coeficient de correlació lineal*, al més baix. Interpreteu.

1.2 Estudi comparatiu entre barris de Barcelona

Per a cada tipus d'habitatge, representeu gràficament la variació de preus segons el barri. Interpreteu. Posteriorment representeu en una taula la mitja i la mitjana dels preus del lloguer, segons tipus d'habitatge i barri.

1.3 Generació dels conjunts d'entrenament i de test

Ara separarem el conjunt de dades en dues parts: el conjunt d'entrenament (training) i el conjunt de prova (testing). En els següents apartats, ajustarem el model de regressió lineal amb el conjunt d'entrenament, i avaluarem la precisió amb el conjunt de prova.

Es demana generar els conjunts de dades per a entrenar el model (training) i per a testar-lo (testing). Es pot fixar la grandària de la mostra d'entrenament a un 80% de l'original.

1.4 Estimació del model de regressió lineal amb predictors quantitatius

Estimeu per mínims quadrats ordinaris un model lineal que expliqui el preu del lloguer en funció de totes les variables emprades per a calcular la matriu de correlacions en l'apartat anterior.

1.4.1 Comprovació de colinealitat

Una vegada ajustat el model es demana comprovar la presència o no de colinealitat. A la vista dels resultats, exclouries alguna variable del model. Raona la teva resposta.

1.5 Estimació del model de regressió lineal amb predictors quantitatius i qualitatius

S'afegirà al model de l'apartat anterior les variables qualitatives `real_state` i `neighborhood`, així com les variables dicotòmiques `lift` i `terrace`. En el cas del factor `neighborhood`, es prendrà com a referència el barri de *Sarria-Sant Gervasi*.

Una vegada aplicat el model i sobre la base dels resultats, decideu quines de les variables explicatives proposades fins al moment han de quedar-se en el model de regressió lineal. Per a prendre aquesta decisió ha de considerar-se a més de la rellevància o no de les variables, l'existència o no de problemes de colinealitat comprovada en l'apartat anterior, així com el valor del coeficient de determinació ajustat. Interpreteu.

Nota: Generalment, valors d'un FIV superiors a 10 donen indicis d'un problema de multicolinealitat, si bé la seva magnitud depèn del model ajustat, però altres autors consideren valors per sobre de 4

1.6 Diagnosi del model.

Per a la diagnosi es tria el model final construïdo en l'apartat anterior. Es demana generar un histograma amb els residus (valors observats menys els predits pel model) i posteriorment altres dos gràfics: un amb els valors ajustats enfront dels residus (que ens permetrà veure si la variància és constant) i el gràfic quantil-quantil que compara els residus del model amb els valors d'una variable que es distribueix normalment (QQ plot). Interpreteu els resultats.

1.7 Predicció del model

Segons el model final, calculeu les prediccions del preu de lloguer d'un pis a Barcelona, utilitzant la base de dades de test. Representeu els valors predits front els valors observats. Avalueu la precisió del model mitjançant l'arrel quadrada de l'error quadràtic mitjà (RMSE). Interpreteu.

2 Regressió logística.

2.1 Preparació de les dades

Es vol estudiar quins són els factors que més influeixen en el preu per metre quadrat de lloguer dels habitatges a la ciutat de Barcelona.

Primer es crearà una nova variable anomenada `square_meters_price`. Aquesta nova variable està relacionada amb els valors de la variable `price` i `square_meters`. Posteriorment es convertirà a variable dicotòmica `square_meters_price_re`. Es recodificarà de la manera següent: “preu per metre quadrat inferior a 20 euros” pren el valor 0 i “preu superior o igual a 20” el valor 1. Per a evitar problemes de multicolinealitat, una vegada creada aquesta variable dicotòmica, no es tindran en compte els factors `price` i `squared\_meters`, per a la creació dels models. De la mateixa forma, tampoc es tindrà en compte `square_meters_price`. Per al model de regressió logística, es prendrà com a variable dependent `square_meters_price_re`.

De manera anàloga als models lineals, separarem el conjunt de dades en dues parts: el conjunt d’entrenament (training) i el conjunt de prova (testing). Ajustarem el model de regressió logística amb el conjunt d’entrenament, i avaluarem la precisió amb el conjunt de prova. Es pot fixar la grandària de la mostra d’entrenament a un 80% de l’original.

2.2 Estimació del model de regressió logística amb el conjunt d’entrenament

Prenent com a base, training, estimeu el model de regressió logística sent la variable dependent `squared_meters_price_re` i prenent la resta de variables de la base de dades training, com a factors explicatius, tenint en compte les consideracions esmentades, per a evitar problemes de multicolinealitat.

Respecte a les variables `neighborhood` i `real_state`, es prendran com a valors de referència *Ciutat Vella* i *flat*. A la vista dels resultats, explica si eliminaries o no algun dels factors del model.

2.3 Càlcul de les OR (Odss-Ràtio)

Calculeu les OR corresponents i interpreteu les que considereu més rellevants. Resumir quines de les variables poden considerar-se factors de risc o protecció.

2.4 Matriu de confusió

A continuació analitzeu la matriu de confusió i les mesures de sensibilitat i especificitat. S’assumirà que la predicció del model és 1, si la probabilitat del model de regressió logística és superior o igual a 0.5 i 0 en cas contrari. Calculeu la predicció del model contra el conjunt de prova (testing).

2.5 Predicció

Identifiqueu els habitatges més cars, és a dir aquelles la probabilitat de les quals d’estar classificades amb el valor “1”, sigui superior al 50%, segons el model de prediccions contra el conjunt de prova (testing). Posteriorment mostreu en una taula el barri i tipus d’habitatge, al qual pertanyen.

2.6 Bondat de l'ajust i corba ROC

Avalueu l'eficàcia del model segons el test Chi-quadrat. En aquest cas el valor de l'estadístic Chi-quadrat observat és igual a la diferència de devianzas (nul·la-residual). Calculeu la probabilitat associada a l'estadístic del contrast utilitzant la funció **pchisq**.

Una vegada avaluada l'eficàcia, dibuixeu la corba ROC i calculeu l'àrea sota la corba. Discutiu el resultat.

2.7 Model de regressió logística multinomial

Es crearà un model de regressió logística multinomial, per a classificar el tipus d'habitatges. Per a això es prendrà com a variable dependent **real_state** i les variables explicatives **price**, **rooms**, **bathroom** i **square_meters**. Analitzeu la precisió del model, comparant la predicció del model contra el conjunt de prova (testing). Interpreteu.

3 Resum executiu. Conclusions de l'anàlisi

Resumiu les conclusions de l'estudi en una taula, indicant les respostes a les preguntes de recerca plantejades. Cada fila de la taula, es correspondrà a un apartat. S'haurà d'indicar de manera concisa, la pregunta, els resultats estadístics i breu conclusió.

Exemple corresponent a l'apartat 1.1: la pregunta de recerca plantejada, els resultats de coeficient de correlació més rellevants i conclusions. Per a això es poden emprar tres o quatre columnes. El format de la taula és lliure, però SI ha d'adjuntar-se en l'informe, com un apartat més, tal com indica l'enunciat. NO es pot lliurar com a taula separada.

Puntuació dels apartats

- Apartats 1.1 y 1.2 (5%)
- Apartats 1.3 y 1.4 (10%)
- Apartats 1.5 y 1.6 (10%)
- Apartat 1.7 (5%)
- Apartat 2.1 (5%)
- Apartat 2.2 (10%)
- Apartat 2.3 (5%)
- Apartat 2.4 (10%)
- Apartat 2.5 (10%)
- Apartat 2.6 (5%)
- Apartat 2.7 (10%)
- Apartat 3 (10%)
- Qualitat de l'informe dinàmic (5%)