
Models de regressió logística

PID_00276227

Montserrat Guillén Estany
María Teresa Alonso Alonso

Temps mínim de dedicació recomanat: 4 hores



Montserrat Guillén Estany

María Teresa Alonso Alonso

La revisió d'aquest recurs d'aprenentatge UOC ha estat coordinada per la professora: Teresa Sancho Vinuesa

Segona edició: setembre 2020

© d'aquesta edició, Fundació Universitat Oberta de Catalunya (FUOC)

Av. Tibidabo, 39-43, 08035 Barcelona

Autoria: Montserrat Guillén Estany, María Teresa Alonso Alonso

Producció: FUOC

Tots els drets reservats

Cap part d'aquesta publicació, incloent-hi el disseny general i la coberta, no pot ser copiada, reproduïda, emmagatzemada o transmesa de cap manera ni per cap mitjà, tant si és elèctric com mecànic, òptic, de gravació, de fotocòpia o per altres mètodes, sense l'autorització prèvia per escrit del titular dels drets.

Índex

Introducció.....	5
1. Models lineals generalitzats (MLG).....	9
2. Estimació per màxima versemblança.....	12
3. Models de regressió logística binària.....	13
3.1. Interpretació dels <i>odds-ratio</i> i els coeficients del model	17
3.1.1. <i>Odds-ratio</i>	17
3.1.2. Coeficients del model	18
3.2. Interacció i confusió	23
3.2.1. Interpretació de l'OR en presència d'interacció	27
3.3. Selecció de variables	28
3.4. Bondat de l'ajust	30
3.4.1. Test basat en la <i>devianza</i> D. Test de raó de versemblança	31
3.4.2. Estadístic khi quadrat de Pearson	33
3.4.3. Test d'Hosmer-Lemeshow	34
3.5. Prediccions del model	36
3.5.1. Matriu de confusió	37
3.5.2. Corba ROC (<i>receiver operating characteristic</i>)	39
4. Altres models lineals generalitzats.....	41
Resum.....	42
Exercicis d'autoavaluació.....	43
Solucionari.....	45
Bibliografia.....	46

Introducció

Els **models de regressió** són models estadístics en els quals es desitja conèixer la relació entre una variable dependent, que pot ser quantitativa o qualitativa, i una o més variables explicatives independents, o covariables, siguin qualitatives o quantitatives.

D'entre les diferents opcions que hi ha per definir un model de regressió destaquen el model de regressió lineal i el model de regressió logística. Tenint en compte el tipus de variable que desitgem estimar (variable dependent o resposta) aplicarem un model o un altre. Si la variable dependent és una variable contínua, el model de regressió més freqüentment utilitzat és la regressió lineal, i si la variable d'interès és qualitativa, s'utilitza la logística.

- **Variable dependent contínua:** regressió lineal.
- **Variable dependent qualitativa:**¹ regressió logística.

⁽¹⁾Especialment útil si és dicotòmica o *dummy*.

Un exemple senzill de regressió lineal simple és el que relaciona el pes d'una persona amb la seva alçada. En aquest cas es considera que el pes (variable dependent quantitativa, variable resposta, explicada o efecte) és conseqüència de l'alçada (variable independent, variable tractament, explicativa o causa), a part de molts altres factors. En un model de regressió lineal simple, solament hi ha una variable dependent i una independent. S'estableix que la relació és una recta (anomenada *recta de regressió*) i que a partir d'un conjunt de dades l'estimació de la recta permet fer prediccions. La predicció del pes d'una persona en funció de la seva alçada s'obté mitjançant la recta estimada i tenint en compte que aquest pes correspon al valor que pren la recta en el punt concret de l'alçada. En aquest exemple, queda palès que la predicció és un «valor esperat» que s'obté de l'ajust a un model molt simple que han proporcionat unes dades històriques.

El pas de la regressió lineal simple a la regressió lineal múltiple sorgeix de la necessitat d'incorporar més factors en l'explicació de la variable dependent. A l'exemple de pes i alçada es poden tenir en compte característiques com ara la quantitat diària mitjana de calories diàries ingerides, el sexe o si es fa algun tipus d'activitat física habitualment. Per tant, amb un model de regressió lineal múltiple, com que es consideren més factors, es pot fer una predicció més precisa que en un model simple, si es coneix la informació sobre aquestes característiques. En el model múltiple, hi ha una variable dependent i diverses independents.

El terme **error** recull tots els factors que influeixen en el valor observat de la variable dependent no recollits per la variables explicatives i se suposa que té una mitjana nul·la (els errors de vegades són positius i altres vegades negatius). En la inferència sobre els models de regressió lineal, se suposa que el terme d'error segueix un comportament normal. La predicció que proporciona el model de regressió lineal és un valor esperat de la resposta, en funció dels valors de les variables explicatives.

Una de les restriccions que tenen els models de regressió lineal simple o múltiple és precisament la linealitat. Aquesta hipòtesi pot ser excessivament restrictiva quan la realitat no ho és. Per això, els models no lineals estableixen relacions causa-efecte més complexes, que no solament impliquen un repte per a l'elecció de la forma de la relació (parabòlica, exponencial, polinomial, etc.) sinó que, a la vegada, compliquen l'estimació del model.

La segona de les restriccions importants dels models de regressió lineal clàssics és considerar que la variable dependent té un comportament continu, és a dir, pren valors amb decimals. Aquest és el cas del pes, que podria arribar a mesurar-se amb molta precisió. No obstant això, a la pràctica hi ha nombrosos fenòmens que no poden mesurar-se de manera tan específica, sigui per la seva pròpia naturalesa o perquè ja han estat registrats com a variables no contínues.

En el text següent s'introdueix el model de regressió logística, que supleix les limitacions del model de regressió lineal comentades anteriorment.

Així doncs, el **model de regressió logística** és una tècnica estadística, per mitjà de la qual s'analitzen les relacions d'associació entre una variable dependent qualitativa o politòmica (admet diverses categories de resposta) i una o diverses variables independents (regressores o predictors), que poden ser quantitatives o categòriques. Aquest tipus de regressió és especialment interessant si la variable que volem estimar és dicotòmica o *dummy*.

Un exemple d'una variable no contínua és prendre una decisió entre concedir un crèdit a un client o no. En aquest cas tenim una variable dicotòmica, és a dir, una variable que únicament pot prendre dos valors («Sí concedir el crèdit» i «No concedir el crèdit»).

Com a variables explicatives podem tenir en compte el nivell salarial mesurat de manera discreta, amb valors 1, 2, 3 o 4, estat civil, sexe o nombre de fills, entre d'altres.

Taula 1. Dades de sol·licitud de préstecs d'una entitat bancària

ID	Edat	Sexe	Estat civil	Nombre de fills	Nivell salarial	Crèdit sol·licitat	Préstec	Motiu
56	46	H	C	2	3	20.000	65.000	Vehicle
76	34	D	S	0	2	5.000	0	Estudis
96	52	H	C	2	4	350.000	0	Reformes

Font: exemple del mòdul «Introducció a l'estadística».

Aquests models poden apropar-se més a la realitat de molts fenòmens, ja que la relació entre les variables s'assembla més a una corba que a una recta.

Tal com ja ocorria en els models de regressió lineal clàssics, les variables explicatives poden ser de qualsevol tipus, és a dir, contínues, qualitatives dicotòmiques, politòmiques o discretes. No obstant això, serà la naturalesa de la variable dependent la que determini quin model predictiu cal utilitzar.

1. Models lineals generalitzats (MLG)

Els models lineals generalitzats van ser inicialment formulats el 1972 i 1974 per dos professors anglesos, John Nelder i Robert Wedderburn, respectivament. No obstant això, posteriorment Peter McCullagh en va ser l'impulsor, el qual el 1983 va publicar juntament amb John Nelder el llibre *Generalized Linear Models*.

La possibilitat d'utilitzar una creixent potència computacional en una dècada en la qual es va popularitzar l'ús d'ordinadors personals va permetre que els nous models poguessin estar a l'abast d'investigadors de tots els àmbits, des de la medicina i la biologia a les ciències socials, l'economia i el màrqueting. Això va permetre una ràpida expansió d'aquests models.

Els **models lineals generalitzats** aconsegueixen unificar un gran nombre de models estadístics predictius, incloent la regressió lineal, la regressió logística (quan la resposta és dicotòmica) i la regressió de Poisson (quan la resposta és un valor que explica el nombre de vegades que ocorre un fenomen).

Els models lineals generalitzats tenen tres components:

- 1) El predictor lineal.
- 2) El comportament aleatori de la variable dependent.
- 3) Una funció que dona una correspondència entre el predictor lineal i el valor esperat de la variable dependent, que es denomina *link* o *funció de lligadura*.

Solament pot considerar-se que un model lineal generalitzat està ben definit si:

- El predictor lineal és una combinació lineal entre els paràmetres i les variables explicatives.
- El comportament estocàstic de la variable dependent està dins d'un conjunt concret de distribucions denominat *la família exponencial*.
- La funció de lligadura té certes propietats (com ara ser contínua, monòtona i derivable).

Taula 2. Exemples d'MLG

Variable dependent	Variables explicatives	Naturalesa de la variable dependent	Distribució	Models lineals generalitzats possibles
El consumidor decideix comprar o no comprar un producte	Sexe, edat, nivell d'estudis, zona de residència, etc.	Dicotòmica (pren dos valors, sí o no)	Bernoulli	Model de regressió logística, model <i>probit</i> , etc.
Atorgar un crèdit o no	Edat, nivell salarial, estat civil, nombre de fills	Dicotòmica (pren dos valors, sí o no)	Bernoulli	Model de regressió logística, model <i>probit</i> , etc.
Nombre de dies que es pernocta en una ciutat durant un viatge vacacional	Edat, nacionalitat, nivell socioeconòmic	Discreta (els valors possibles són: 0, 1, 2, 3, etc.)	Poisson	Model de Poisson

Els impulsors dels models lineals generalitzats van proposar un mètode de mínims quadrats reponderat iteratiu per a l'estimació de la màxima versemblança dels paràmetres del model. D'aquesta manera s'obtenen les estimacions i els seus errors per a l'obtenció dels respectius intervals de confiança amb un nombre petit d'iteracions, i encara que hi ha altres possibles vies d'estimació, aquesta segueix sent la més àmpliament utilitzada.

Lectura recomanada

R. W. Wedderburn (1974). «Quasi-likelihood functions, generalized linear models, and the Gauss-Newton method». *Biometrika* (vol. 61, núm. 3, pàg. 439-447). Oxford: Oxford University Press.

Exemple de model lineal generalitzat

El fabricant de perfums El meu aroma favorit vol conèixer com són els consumidors que tenen major propensió a comprar una fragància que llançarà pròximament.

Per això, tria un conjunt de cent cinquanta persones a les quals pregunta si voldrien comprar-lo o no.

La resposta és dicotòmica. Els factors que influeixen en aquesta decisió i que es consideraran són l'edat, el sexe, la situació laboral i els ingressos nets mensuals. Vegem en primer lloc que, si bé la variable dependent és dicotòmica, les variables explicatives tenen una naturalesa diferent. L'edat és una variable quantitativa discreta, el sexe és qualitativa (per tant, es codifica per exemple prenent el valor 1 si és una dona i 0 si és un home), la situació laboral considera tres possibilitats: treballador per compte propi o aliè, aturat o altres (jubilat, estudiant, etc.), i finalment la variable ingressos nets mensuals es considera contínua. Per a la situació laboral s'estableix ser treballador per compte propi o aliè com la categoria de referència i, per tant, es defineixen dues variables dicotòmiques: estar parat (SL1) pren el valor 1 i 0 en cas contrari, i estar en qualsevol altra situació excepte aturat o treballant (SL2), que es codifica com a 1 i es dona un 0 si és un treballador per compte propi o aliè o està a l'atur.

Modelitzarem aquest problema mitjançant la definició de tres components:

1) El component denominat **predictor lineal** d'aquest model és:

$$b_0 + b_1 * edat_i + b_2 * dona_i + b_3 * SL1_i + b_4 * SL2_i + b_5 * ingressos_i$$

És important destacar que:

- En aquest exemple tenim sis paràmetres (els paràmetres b_i), que són els que estimarem.
- Cada participant en aquest estudi de mercat té unes característiques pròpies d'edat, sexe, situació laboral i ingressos, per això s'utilitza el subíndex «i», que indica que s'utilitza el valor observat d'aquesta variable per l'i-èsima persona preguntada. Sol posar-se al costat del model la indicació $i = 1:150$, la qual cosa vol dir que hi ha un predictor lineal diferent per a cadascun dels participants de l'estudi. En general, es parla d' N participants.
- Una vegada s'hagin estimat els paràmetres, es podrà calcular el predictor lineal per a qualsevol tipus de consumidor, si es coneix la seva edat, sexe, situació laboral i ingressos, encara que no n'hi hagi cap exactament com aquest en l'estudi inicial.

2) El **component aleatori**: en aquest cas és una variable que pren dos possibles valors «Sí compraria» o «No compraria». Se sol indicar amb la lletra Y per ser una variable dependent i el subíndex « i » per indicar que es refereix a l' i -èssim participant. Aquest es pot codificar amb un 1 en el cas afirmatiu i 0 en cas negatiu.

D'aquesta manera, per a cada participant tenim una variable aleatòria Bernoulli:

$$Y_i = \begin{cases} 0 & \text{Amb probabilitat } (1 - p_i) \\ 1 & \text{Amb probabilitat } p_i \end{cases}$$

Respecte a aquest component, cal destacar que la probabilitat de comprar o no és única per a cada persona i particular, per aquest motiu s'utilitza una probabilitat amb el subíndex « i ».

A més, per tractar-se d'una variable dicotòmica, el valor esperat de la variable correspon exactament a la probabilitat de comprar. És a dir, l'esperança matemàtica de comprar per a cada participant es calcula com:

$$E(Y_i) = 0 * (1 - p_i) + 1 * p_i = p_i$$

En definitiva, el valor que es predirà és la probabilitat que la variable dependent prengui el valor 1, és a dir:

$$E(Y_i) = 0 * (1 - p_i) + 1 * p_i = P(Y_i = 1)$$

3) El tercer component és una **funció de lligadura** que fa correspondre a la probabilitat de comprar de cada individu un valor del predictor lineal. Aquesta funció compleix les condicions exigibles en el model lineal generalitzat. És a dir, ha de ser una funció monòtona (creixent o decreixent), contínua i diferenciable. L'elecció de la funció de lligadura determinarà finalment el tipus de model lineal generalitzat que s'hagi establert.

$$E(Y_i) = p_i = f(b_0 + b_1 * edat_i + b_2 * dona_i + b_3 * SL1_i + b_4 * SL2_i + b_5 * ingressos_i)$$

En el cas d'un **model de regressió logística** l'elecció seria la següent:

$$P(Y_i = 1) = \frac{\exp(b_0 + b_1 * edat_i + b_2 * dona_i + b_3 * SL1_i + b_4 * SL2_i + b_5 * ingressos_i)}{1 + \exp(b_0 + b_1 * edat_i + b_2 * dona_i + b_3 * SL1_i + b_4 * SL2_i + b_5 * ingressos_i)}$$

Tots els models lineals generalitzats es defineixen mitjançant els tres components considerats i, per tant, es determinen tenint en compte:

- Quines són les variables que participen en la determinació del predictor lineal?
- Quina distribució estadística s'utilitza per a la variable dependent?
- Quina és la funció de lligadura?

2. Estimació per màxima versemblança

Per a l'estimació dels coeficients del model de regressió logística i dels seus errors estàndard es recorre al càlcul d'estimacions de màxima versemblança, és a dir, estimacions que maximitzin la probabilitat d'obtenir els valors de la variable dependent Y proporcionats per les dades de la mostra.

La **funció de versemblança** es defineix a partir de les dades observades, del predictor lineal i de la funció de lligadura, a més del comportament estocàstic de la variable dependent.

Aquesta funció es basa en la independència de les observacions, per tant, implica que les respostes observades no tenen factors que les afectin i que puguin induir una dependència entre aquestes.

Per exemple, en el cas de l'exemple de la perfumeria anterior no seria adequat que dues persones opinessin alhora sobre la fragància perquè la resposta d'una podria influir en la de la seva companya.

Intuïtivament, la funció de versemblança és aquella que associa a cada vector de paràmetres possibles la probabilitat d'observar les dades disponibles, si aquests paràmetres fossin certs. Per tant, a l'exemple que hem considerat, es tindria una funció de sis variables, cadascuna de les quals té un domini determinat a la recta real i el seu recorregut serà l'interval $[0, 1]$, atès que el resultat és una probabilitat.

El procediment d'estimació d'un model lineal generalitzat consisteix a trobar els paràmetres que fan més gran la probabilitat final. Així doncs, el resultat és un únic valor estimat per a cada paràmetre al qual s'associa un error estàndard.

La idea bàsica en la maximització de la versemblança pot explicar-se metafòricament com la d'un explorador que busca les coordenades del cim d'una muntanya. Al cim hi ha el màxim i ha de trobar aquell punt de les coordenades del mapa on està. Per això, inicia un recorregut a partir d'un lloc inicial i va ascendint per la muntanya fins a trobar un lloc en el qual ja no és possible pujar més amunt. En aquest moment, les coordenades donen el punt exacte del màxim.

El procediment iteratiu que van proposar Nelder i Wedderburn es basa en aquest principi i precisament la forma de definir els models lineals generalitzats garanteix que es pot trobar aquest màxim amb poques iteracions.

3. Models de regressió logística binària

Un cas particular dels models lineals generalitzats són els models de regressió logística, en què la variable dependent és de naturalesa dicotòmica i segueix una distribució binomial.

Es diu que una variable aleatòria és **binomial** quan solament té dos possibles resultats: «èxit» i «fracàs», i la probabilitat de cadascun d'aquests és constant en una sèrie de repeticions.

Es caracteritza per la probabilitat d'èxit, representada per p , i per la probabilitat de fracàs, que es representa per q . Ambdues probabilitats estan relacionades per la relació $p + q = 1$.

De vegades, s'usa el quocient p/q , denominat *odds*, que indica quant més probable és l'èxit que el fracàs.

Els **models de regressió logística binària** són models de regressió que permeten estudiar si una variable binomial depèn o no d'una altra o altres variables (no necessàriament binomials).

És freqüent trobar situacions en què les variables objecte d'estudi són de naturalesa dicotòmica o binomial. Per exemple, en l'estudi de nous fàrmacs, per trobar la probabilitat que aquests medicaments siguin efectius en pacients amb determinades característiques; en economia, per predir si una acció incrementarà o reduirà el seu valor; en psicologia, per conèixer si la resposta a un estímul serà positiva o negativa; en salut pública, per conèixer l'estat de salut (bo o dolent), etc.

Exemple de model de regressió logística binària

Suposem que volem estudiar l'efecte que una sèrie de variables independents tenen sobre la percepció del nostre estat de salut, com per exemple, l'edat, el sexe, l'IMC (índex de massa corporal), el consum d'alcohol i el tabac. S'ha de construir un model que descrigui la relació entre la variable dependent dicotòmica (bona o mala salut) i una o diverses variables independents explicatives (també denominades covariables, regressores o predictores), siguin quantitatives o categòriques.

Podem definir la variable dependent dicotòmica Y com:

$$Y_i = \begin{cases} 0 & \text{Percepció de No bona salut} \\ 1 & \text{Percepció de Sí bona salut} \end{cases}$$

on la variable pren el valor 1 amb probabilitat π i el valor 0 amb probabilitat $(1 - \pi)$.


Objectius del model

- Determinar l'existència o absència de relació entre una o més variables independents i la variable dependent, percepció de salut.
- Mesurar la magnitud d'aquesta relació.
- Estimar o predir la probabilitat que l'estat de salut sigui bo o dolent, en funció dels valors que adoptin les variables independents.

Quan es classifica el valor de la variable dependent com a 0 i 1, per determinar la relació entre aquest succés (percepció de l'estat de salut) i una o més variables independents, es podria caure en l'error d'utilitzar un model de regressió lineal i estimar els coeficients pel procediment de mínims quadrats. No obstant això, encara que això és possible matemàticament, els resultats obtinguts serien absurds. Efectivament, el valor de la funció obtinguda per a diferents valors de les variables independents ens donaria resultats, en general, diferents de 0 i 1, ja que aquesta restricció no s'imposa en la regressió lineal, en la qual la resposta pot prendre qualsevol valor.

Com es pot observar a la figura 1, la relació entre la variable dependent dicotòmica (0 i 1) i la variable independent no està definida per una recta, sinó que segueix una forma sigmoide, pròpia de la funció logística.

Figura 1. Funció logística



Equació del model

El model de regressió logística binària determina la probabilitat que la variable aleatòria Y prengui el valor 1 (èxit):

$$P(Y = 1/X) = \frac{e^{b_0 + \sum_{i=1}^n (b_i x_i)}}{1 + e^{b_0 + \sum_{i=1}^n (b_i x_i)}}$$

sent $P(Y = 1/X)$ la probabilitat que Y prengui el valor 1, en presència de les variables independents X .

Els paràmetres d'aquesta equació són:

- b_0 : constant del model o terme independent.
- n : nombre de variables independents o covariables.
- b_i : coeficients de les covariables.

Si dividim l'expressió anterior pel seu complementari, és a dir, si es construeix el seu *odds*, s'obté l'expressió:

$$\frac{P(Y = 1/X)}{1 - P(Y = 1/X)} = e^{b_0 + \sum_{i=1}^n (b_i x_i)}$$

Al nostre exemple, la probabilitat de percebre «Sí bona salut», entre la probabilitat de percebre «No bona salut».

Si ara fem la seva transformació logarítmica amb el logaritme neperià, obtenim una equació lineal que és més fàcil de manejar i comprendre.

$$\ln \left(\frac{P(Y = 1/X)}{1 - P(Y = 1/X)} \right) = b_0 + \sum_{i=1}^n (b_i x_i)$$

A l'esquerra de la igualtat hi ha el *logit*, és a dir, el logaritme neperià de l'*odds* de la variable dependent. El terme a la dreta de la igualtat és l'expressió d'una recta, idèntica a la del model general de regressió lineal.

Com s'ha comentat a l'apartat anterior, per a l'estimació dels coeficients del model i dels seus errors estàndard es recorre al càlcul d'estimacions de màxima versemblança, és a dir, estimacions que maximitzin la probabilitat d'obtenir els valors de la variable dependent Y , proporcionats per les dades de la mostra.

Aquestes estimacions no són de càlcul directe, tal com ocorre en el mètode de mínims quadrats. Per al càlcul d'estimacions de màxima versemblança es recorre a mètodes iteratius, com el mètode de Newton-Raphson per al càlcul de zeros de funcions.

Seguim amb el nostre exemple. Suposem que volem estudiar l'efecte del sexe i consum d'alcohol en la nostra percepció de salut.

Com a variables independents tenim:

- *Sexe*: pren els valors 0 si és home i 1 si és dona.
- *Bevedor*: pren els valors 0 (Poc/Res), 1 (Ocasionalment) i 2 (Freqüentment).

Com a variable dependent tenim: percepció d'estat de salut.

$$Y_i = \begin{cases} 0 & \text{Percepció de No bona salut} \\ 1 & \text{Percepció de Sí bona salut} \end{cases}$$

Al programa estadístic R, la funció que s'usa per a aquest tipus de models és la funció «glm()».

Els arguments d'aquesta funció són dos: fórmula i família (binomial, Poisson, etc.).

```
bevedor_Rel=relevel(data_salut$bevedor, ref = '0')

model.logist1=glm(formula=salut~sexe+factor(bevedor_Rel),family=binomial(link=logit))
summary(model.logist1)
##
## Call:
## glm(formula = salut ~ sexe + factor(bevedor_Rel), family = binomial(link = logit))
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -1.9851    0.5480    0.5629    0.7040    0.7814
##
## Coefficients:
##      0              Estimate Std. Error z value Pr(>|z|)
## (Intercept)      1.26858      0.06027  21.049 < 2e-16 ***
## sexe2            -0.23868      0.06230  -3.831 0.000128 ***
## factor(bevedor_Rel)1  0.55151      0.06288   8.771 < 2e-16 ***
## factor(bevedor_Rel)2  0.49377      0.15984   3.089 0.002007 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 7177.9  on 7356  degrees of freedom
## Residual deviance: 7059.2  on 7353  degrees of freedom
## AIC: 7067.2
##
## Number of Fisher Scoring iterations: 4
```

On es mostra la taula amb l'estimació de la constant i els coeficients del model (*Estimate*), els seus errors estàndard (*Std. Error*), el valor de l'estadístic de Wald (*z value*) i el *p*-valor associat $\Pr(>|z|)$, la *null deviance*, la *residual deviance* i l'AIC, dels quals parlarem a continuació.

D'altra banda, s'ha explicat més amunt que els paràmetres del model s'estimen maximitzant la funció de versemblança, mitjançant el mètode de Newton-Raphson. Les iteracions que apareixen (*Number of Fisher Scoring iterations*) es deuen al fet que cal resoldre les equacions de forma iterativa. En aquest cas, han calgut quatre iteracions per estimar els paràmetres.

Segons els resultats obtinguts, es mostren els valors estimats dels coeficients del model i es construeix el *logit*:

$$\ln \left(\frac{P(Y=1/X)}{1-P(Y=1/X)} \right) = 1,27 - 0,238 * \text{sexe} + 0,55 * \text{beu 1} + 0,49 * \text{beu 2}$$

Es pot observar que tant la variable *sexe* com la variable *bevedor* són significatives perquè $\Pr(>|z|) < 0,05$. Aquesta informació la proporciona l'estadístic de Wald.

D'altra banda, hi ha els errors estàndard associats amb els coeficients (*Std. Error*), amb els quals es construeixen els intervals de confiança (IC).

Els IC ens orienten sobre els possibles valors que pot prendre el veritable valor del paràmetre. Com més ample sigui l'interval, més ineficient és l'estimació del paràmetre.

Per calcular els IC al programa R, s'utilitza la funció `confint`:

```
confint(model.logist1)
## Waiting for profiling to be done...
##              2.5 %      97.5 %
## (Intercept)   1.1512601  1.3875492
## sexe2        -0.3609674 -0.1167008
## factor(bevedor_Rel)1  0.4283962  0.6749056
## factor(bevedor_Rel)2  0.1891390  0.8169365
```

Per poder interpretar els resultats obtinguts anteriorment, primer hem de definir els *odds* i els *odds-ratio*.

3.1. Interpretació dels *odds-ratio* i els coeficients del model

3.1.1. *Odds-ratio*

Els *odds* són la raó de la probabilitat d'ocurrència d'un succés entre la probabilitat de la seva no ocurrència.

En aquesta expressió, el model està expressat en termes del *log-odds*:

$$\ln \left(\frac{P(Y=1/X)}{1-P(Y=1/X)} \right) = 1,27 - 0,238 * \text{sexe} + 0,55 * \text{beu } 1 + 0,49 * \text{beu } 2$$

Si s'escriu en termes d'*odds*, es té:

$$\frac{P(Y=1/X)}{1-P(Y=1/X)} = \frac{e^{b_0 + \sum_{i=1}^n (b_i x_i)}}{1 + e^{b_0 + \sum_{i=1}^n (b_i x_i)}}$$

Es calculen els diferents valors de les probabilitats per a les quatre combinacions entre la variable dependent Y i la independent X :

$$\frac{P(Y=1/X=1)}{1-P(Y=1/X=1)} = \frac{e^{b_0+b_1}}{1+e^{b_0+b_1}}$$

$$\frac{P(Y=1/X=0)}{1-P(Y=1/X=0)} = \frac{e^{b_0}}{1+e^{b_0}}$$

$$\frac{P(Y=0/X=1)}{1-P(Y=0/X=1)} = \frac{1}{1+e^{b_0+b_1}}$$

$$\frac{P(Y=0/X=0)}{1-P(Y=0/X=0)} = \frac{1}{1+e^{b_0}}$$

Els *odds-ratio* (OR) es calculen com la raó entre els *odds*, on la variable resposta Y està present entre els individus, és a dir, pren el valor $Y=1$, i la variable independent X pot estar present o no, és a dir, prendre els valors $X=1$ i $X=0$.

$$\text{OR} = \frac{\frac{P(Y=1/X=1)}{1-P(Y=1/X=1)}}{\frac{P(Y=1/X=0)}{1-P(Y=1/X=0)}} = e^{b_1}$$

- Un $\text{OR} = 1$ implica que no hi ha associació entre la variable resposta i la covariable.

- Un OR inferior a la unitat s'interpreta com un factor de protecció, és a dir, el succés és menys probable en presència d'aquesta covariable.
- Un OR major a la unitat s'interpreta com un factor de risc, és a dir, el succés és més probable en presència d'aquesta covariable.

Suposem que volem calcular l'OR per a la covariable (*sexe*), a partir de les dades recollides en la taula de contingència següent:

```
table(salut, sexe)
##           sexe
## salut      H    D
## Sí bona salut 3072 2879
## No bona salut  594  812
```

En aquest cas tenim dues variables: *sexe* i *percepció de salut*.

- *Salut*: variable dependent de la percepció de salut amb valors «Sí bona salut» i «No bona salut».
- *Sexe*: és la covariable amb valors H (home) i D (dona).

S'observa que, entre els homes, n'hi ha 594 que pensen que tenen mala salut enfront de 3.072 que pensen que la seva salut és bona. Respecte a les dones, n'hi ha 812 enfront de 2.879. Si ho passem a percentatges, es tindria per al cas dels homes un 83,8 % que percep bona salut enfront d'un 16,2 % que no; i, en les dones, un 78 % enfront d'un 22 %.

Si calculem l'*odds* de percebre mala salut respecte a percebre bona salut, es té:

- *Odds* (homes) = $16,2/83,8 = 0,193$. Per tant, de cada 10 homes que perceben bona salut, 2 no la perceben.
- *Odds* (dones) = $22/78 = 0,282$. És a dir, de cada 10 dones que perceben bona salut, 3 no la perceben.

Així doncs, la percepció sobre la seva salut del gènere femení és pitjor que la del masculí. Quant pitjor?

Si calculem l'OR a partir de la fórmula donada anteriorment es té:

$$OR = \frac{0,282}{0,193} = 1,46$$

Expressat en termes de probabilitat significaria que la probabilitat de trobar una dona que pensi que té una mala salut, sobre una que no, és d'1,46 vegades respecte al cas dels homes. Per tant, la probabilitat és un 46 % major pel que fa a la dels homes.

Fixeu-vos que com que el valor de l'OR és major que 1, significaria que el fet de ser dona és un factor de risc per a la percepció que tenim sobre la nostra salut.

És molt important, en la interpretació dels resultats, que no estem parlant que una persona estigui malalta o no, sinó de com aquesta se sent.

3.1.2. Coeficients del model

A l'hora d'interpretar els **coeficients del model** cal tenir en compte dues coses: la relació funcional entre la variable dependent i les independents, i la unitat de canvi per a les variables independents. A més, la interpretació dels coeficients també dependrà de quin tipus de variables independents tinguem: dicotòmiques, politòmiques o contínues.

Un primer pas útil és analitzar el signe dels paràmetres i comprovar si els signes estimats són aquells que la intuïció prèvia o la teoria indicaven.

Un paràmetre positiu significa que un augment en la variable que està associada a aquest paràmetre implica un augment en la probabilitat de la resposta del succés analitzat. Per contra, si un paràmetre és negatiu, quan el factor predictiu (variable independent) augmenta la probabilitat del succés modelat disminueix.

Els models de regressió logística utilitzats a la pràctica sempre han de contenir un terme constant. El valor de la constant no és directament interpretable. S'utilitza com un valor mitjà i correspon al logaritme natural (o logaritme neperià) de la probabilitat del succés quan tots els regressors són iguals a zero.

1) Cas 1: variable independent dicotòmica

Suposem que amb les dades sobre la percepció de l'estat de salut volem veure la relació entre aquesta variable i el sexe.

Com a primer pas s'introduirà en el model solament la variable explicativa *sexe*. Això és el que es denomina *anàlisi crua*, és a dir, sense ajustar per cap altra variable explicativa més. Posteriorment, s'estimarà l'OR cru.

```
model.logist2=glm(formula=salut~sexe,family=binomial(link=logit))
summary(model.logist2)

##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  1.64320    0.04482  36.661 < 2e-16 ***
## sexe2       -0.37751    0.05990  -6.302 2.93e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

En els resultats obtinguts s'observa que el signe del coeficient associat al *sexe* és negatiu, la qual cosa significa que la percepció de salut de les dones és pitjor que la dels homes.

Si volem conèixer la magnitud d'aquesta relació, hem de calcular l'OR.

Utilitzant el programa R, s'executarà l'ordre de comandament `exp()`, amb el qual es calcularà l'exponencial dels coeficients obtinguts anteriorment.

```
exp(coefficients(model.logist2))
## (Intercept)      sexe2
##    5.1717172    0.6855685
```

Juntament amb l'estimador de l'OR, és important utilitzar els intervals de confiança (IC) per obtenir informació addicional sobre el paràmetre. Els IC per als coeficients del model es calculen assumint que la distribució dels paràmetres estimats és aproximadament normal. D'aquesta manera, per calcular els IC dels OR n'hi ha prou amb aplicar la funció exponencial $\exp()$ als IC dels coeficients estimats en el model.

```
exp(confint(model.logist2))
## Waiting for profiling to be done...
##           2.5 %    97.5 %
## (Intercept) 4.7408181 5.651618
## sexe2       0.6094711 0.770800
```

Es té un OR per a la variable *sexe* de 0,68, de manera que l'ocurrència de percebre una bona salut en les dones és 0,68 vegades menor, en relació amb els homes.

A més, com que l'IC per a l'OR de *sexe* és (0,61; 0,77), es pot dir que la bona salut entre les dones en la població d'estudi és entre 0,61 i 0,77 vegades menys probable que en els homes.

2) Cas 2: variable independent politèmica

En aquest cas, la variable independent té més de dues categories o, cosa que és el mateix, pren més de dos valors.

Al nostre exemple teníem el tipus de bevedor, que pren els valors 0 (Poc/Res), 1 (Ocasionalment) i 2 (Freqüentment).

R crea tres variables dicotòmiques que indiquen si la persona és un tipus de bevedor o un altre (variables *dummy* o fictícies).

Quan ajustem el model, R està suposant que el valor de la primera variable és 0 i, per tant, està comparant els altres dos grups amb poc/res bevedor.

Si s'efectua l'anàlisi crua, s'obté:

```
model.logist3=glm(formula=salut~factor(bevedor_Rel),family=binomial(link=logit))
summary(model.logist3)
## Coefficients:
##           Estimate Std. Error z value Pr(>|z|)
## (Intercept)      1.10804     0.04243  26.117 < 2e-16 ***
## factor(bevedor_Rel)1  0.61136     0.06094  10.031 < 2e-16 ***
## factor(bevedor_Rel)2  0.57691     0.15825   3.645 0.000267 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
exp(coefficients(model.logist3))
##           (Intercept) factor(bevedor_Rel)1 factor(bevedor_Rel)2
##           3.028417      1.842933      1.780520
```

L'*odds-ratio* estimat per a bevedor_Rel 1 és d'1,84, per la qual cosa podem concloure que la probabilitat de percebre una bona salut per a persones que beuen moderadament, si es compara amb els no bevedors, és 1,84 vegades major.

De manera anàloga, la probabilitat que les persones que consumeixen molt alcohol pensen que tenen una bona salut, respecte als no bevedors, és 1,78 vegades major.

En conseqüència, l'ocurrència de percebre una bona salut en les persones que consumeixen alcohol és major en relació amb les que no consumeixen. Es pot dir que les persones que consumeixen alcohol són més optimistes respecte a la seva salut, encara que en realitat sigui el contrari.

3) Cas 3: variable independent contínua

Quan s'utilitza una variable predictora contínua, la interpretació del paràmetre estimat depèn de les unitats en les quals es mesura.

$$\ln \left(\frac{P(Y=1/X)}{1-P(Y=1/X)} \right) = b_0 + \sum_{i=1}^n b_i x_i$$

El coeficient b_i representa el canvi en l'*ln (odds)* quan la variable X canvia en una unitat, o equivalentment, e^{b_i} indica la variació en l'*odds* quan la variable X canvia en una unitat.

Si en comptes de variar en una unitat ho fa en c unitats, llavors el canvi vindrà donat per e^{c*b_i} .

Establím la relació entre l'índex de massa corporal i la percepció de salut.

```
model.logist5=glm(formula=salut~data_salut$imc,family=binomial(link=logit)
summary(model.logist5)

## Coefficients:
##           Estimate Std. Error z value Pr(>|z|)
## (Intercept)      4.120383    0.195110   21.12  <2e-16 ***
## data_salut$imc -0.107795    0.007637  -14.12  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
exp(coefficients(model.logist5))
##           (Intercept) data_salut$imc
```

```
##          61.5828259      0.8978114
```


A la vista dels resultats, es pot concloure que, per cada unitat que augmenta l'IMC, l'*odds* de percebre una bona salut és 0,89 vegades menor.

Si l'IMC augmenta en 10 unitats, l'*odds* serà $0,89^{10} = 0,31$ vegades menor.

Es poden veure els resultats a la figura 2.

```
predic=predict(model.logist5,type="response")
plot(imc,predic)
```

Figura 2. Resultats



La corba és decreixent ja que l'*odds-ratio* és menor que 1.

Cal anar amb compte a l'hora d'interpretar els resultats per a IMC alts i molt baixos, ja que estan basats en molt poques observacions i els resultats obtinguts anteriorment podrien estar esbiaixats.

4) Cas multivariable: variables independents contínues i categòriques

Fins ara hem vist com ajustar models de regressió logística amb una sola variable independent. A aquests models se'ls anomena univariats i són vàlids en poques ocasions.

En la majoria dels casos, per comprendre millor el fenomen estudiat, cal construir un model multivariant. L'objectiu és ajustar l'efecte de cada variable en el model d'acord amb l'efecte de la resta de les variables independents. Per tant, cada coeficient del model proporciona una estimació del logaritme de l'*odds* ajustat per les altres variables incloses en el model.

Al nostre exemple, prenem les variables independents: *sexe* i *edat*.

Es té l'equació del model:

$$\ln \left(\frac{P(Y=1/X)}{1-P(Y=1/X)} \right) = b_0 + b_1x_1 + b_2x_2$$

on: $x_1 = \text{sexe}$ i $x_2 = \text{edat}$.

```
model.logist6=glm(formula=salut~sexe+edat,family=binomial(link=logit))
summary(model.logist6)
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   3.797233    0.120809  31.432 < 2e-16 ***
## sexe2        -0.395887    0.061899  -6.396 1.6e-10 ***
## edat         -0.051446    0.002512 -20.478 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
exp(coefficients(model.logist6))
## (Intercept)      sexe2      edat
## 44.5776750    0.6730829    0.9498552
```

El paràmetre b_1 és molt similar al del model univariable. Això es deu al fet que l'edat mitjana en homes i dones és molt similar (39,15 i 39,32, respectivament). Per tant, quan ajustem per edat no canvia l'*odds* de la percepció de salut per sexe.

A l'hora d'interpretar els paràmetres del model cal tenir en compte si es compleix l'existència o no d'interacció i confusió.

3.2. Interacció i confusió

La interacció i la confusió són dos conceptes importants quan usen els models de regressió multivariants.

Hi ha **confusió** quan l'associació entre la variable resposta o dependent i la variable independent triada (el factor d'interès) difereix significativament segons si es considera, o no, una altra variable explicativa. A aquesta última variable se la denomina *variable de confusió per a l'associació*. És a dir, la variable està associada, al mateix temps, a la variable dependent o resposta i al factor d'interès. Quan aquestes dues associacions estan presents, la relació entre la variable resposta i el factor és confosa.

Hi ha **interacció** quan l'associació entre la variable resposta o dependent i el factor d'interès varia segons els diferents nivells d'una altra o altres variables explicatives o covariables. És a dir, la covariable modifica l'efecte del factor.

Volem estudiar l'existència d'interacció al nostre exemple anterior, tenint en compte les variables independents *sexe* i *edat* com a predictores de la percepció d'una bona salut:

```
model.logist7=glm(formula=salut~sexe+edat+sexe:edat,family=binomial(link=logit))
summary(model.logist7)

## glm(formula = salut ~ sexe + edat + sexe:edat, family = binomial(link = logit))
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -2.3857   0.3889   0.5161   0.6780   1.1544
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  3.653489   0.170571  21.419  <2e-16 ***
## sexe2       -0.135450   0.230287  -0.588   0.556
## edat        -0.048200   0.003721 -12.952  <2e-16 ***
## sexe2:edat   -0.005918   0.005046  -1.173   0.241
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Si s'observa la taula de coeficients per columnes es té:


- Estimació dels coeficients associats a cada variable (*Estimate*), errors estàndard (*Std. error*), valor de l'estadístic de Wald (*z value*) i el *p-value* associat ($Pr(>|z|) = p\text{-value}$).
- La variable *sexe* no és significativa. Aquesta informació la proporciona l'estadístic de Wald i el seu *p-value* associat ($p\text{-value} = 0,556 > 0,05$).
- A més, es conclou que el terme d'interacció «sexe2:edat» no és estadísticament significatiu ($p\text{-value} = 0,241$).

D'altra banda, si representem el *logit* del model, enfront de l'edat, segons la variable *sexe*, es té:

```
pred6=predict(model.logist6,type="link")
plot(edat,pred6,type="n",main="NO interaccio")
points(edat[sexe==1],pred6[sexe==1],col=2)
points(edat[sexe==2],pred6[sexe==2],col=4)
```

Figura 3. Resultats del *logit* del model, enfront de l'edat, segons la variable *sexe*

No interacció



S'observa que les rectes són paral·leles per a cada nivell del factor, per la qual cosa l'associació entre la percepció de salut i sexe no varia per l'edat, és a dir, aquesta variable no modifica l'efecte del factor sexe. Per tant, no hi ha interacció.

Una manera de detectar una variable de confusió és veure si els paràmetres estimats per al factor d'interès canvien substancialment quan s'introdueix la covariable en el model.

Aquest criteri no es pot aplicar al cas de la interacció, ja que la inclusió d'un terme d'interacció, especialment si una de les variables és contínua, normalment dona lloc a canvis en els paràmetres estimats. Això és així encara que la interacció no sigui significativa.

Al nostre exemple, per saber si l'edat és una variable de confusió pel que fa al sexe, veurem si el valor del paràmetre del sexe canvia molt quan s'introdueix l'edat.

Model univariable:

```
## Coefficients:
##           Estimate Std. Error z value Pr(>|z|)
## (Intercept)  1.64320    0.04482  36.661 < 2e-16 ***
## sexe2       -0.37751    0.05990  -6.302 2.93e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
## Coefficients:
##           Estimate Std. Error z value Pr(>|z|)
## (Intercept)  3.797233    0.120809  31.432 < 2e-16 ***
## sexe2       -0.395887    0.061899  -6.396 1.6e-10 ***
## edat        -0.051446    0.002512 -20.478 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

Es pot observar que la diferència és molt petita (−0,37751 i −0,395887), per la qual cosa podem concloure que no hi ha confusió.

D'acord amb els valors obtinguts, l'edat no és una variable de confusió ni tampoc no és un efecte modificador.

Si en comptes d'utilitzar la covariable *edat* s'usa el *pes*, tenim:

```
model.logist7b=glm(formula=salut~sexe+pes,family=binomial(link=logit))
summary(model.logist7b)
##
## Coefficients:
##           Estimate Std. Error z value Pr(>|z|)
## (Intercept)  3.712536    0.218700  16.975 <2e-16 ***
## sexe2       -0.825937    0.076422 -10.808 <2e-16 ***
## pes         -0.026188    0.002671  -9.803 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

exp(coefficients(model.logist7b))
## (Intercept)      sexe2      pes
## 40.9575330    0.4378247    0.9741522
```

Quan introduïm el *pes*, el paràmetre estimat de sexe passa de −0,377 a −0,825, un descens de més del 50 %. Per tant, el valor del coeficient del sexe canvia molt quan s'introdueix el *pes*.

A més, com es pot comprovar a sota, la variable *pes* està relacionada amb la variable dependent *percepció de salut* i també amb el factor *sexe*. Tot això ens indica que el *pes* és una variable de confusió.

```
logistical=glm(salut~pes,family=binomial(link=logit))
```

Vegeu també

A l'apartat «Selecció de variables» s'amplia la informació de l'estadístic de Wald.

```
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)  2.032881   0.153471  13.246 < 2e-16 ***
## pes         -0.008431   0.002137  -3.946 7.96e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

logistica2=glm(sexe~pes,family=binomial(link=logit))
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept) 10.437470   0.240520  43.40 <2e-16 ***
## pes         -0.151629   0.003493 -43.41 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Ara estudiarem l'existència d'interacció. Per això, s'analitzarà el model **amb interacció**.

```
model.logist8=glm(formula=salut~sexe+pes+sexe:pes,family=binomial(link=logit))
summary(model.logist8)


## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)  2.561521   0.306033   8.370 < 2e-16 ***
## sexe2        1.236831   0.393019   3.147 0.00165 **
## pes         -0.011713   0.003836  -3.053 0.00226 **
## sexe2:pes    -0.028984   0.005438  -5.330 9.81e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

S'observa que l'estimador d'interacció *sexe:pes* és estadísticament significatiu.

De manera anàloga al cas anterior, es representarà en un gràfic del *logit* del model enfront del pes, segons sigui home o dona.

Figura 4. Resultats del *logit* del model enfront del pes

Sí interacció



Es pot observar que les rectes no són paral·leles i que la percepció de salut en funció del pes és diferent per als homes i per a les dones. Aquestes estan més afectades pel pes.

En resum, per avaluar si una variable és de confusió, es compara el coeficient estimat amb el factor de risc dels models que contenen i no contenen la co-variable.

Qualsevol canvi important en el coeficient del factor suggereix que la variable és de confusió. Si això passa, encara que la interacció no sigui estadísticament significativa, la variable ha de sortir del model. En el nostre cas, s'hauria d'eliminar la variable *pes*.

D'altra banda, una variable és un «efecte modificador» solament quan el terme d'interacció afegit al model és estadísticament significatiu.

Les interaccions no han d'eliminar-se del model, tret que alguna de les variables sigui de confusió.

3.2.1. Interpretació de l'OR en presència d'interacció

Abans hem vist que, quan hi ha interacció entre el factor d'interès i una altra variable, el paràmetre estimat per al factor de risc depèn del valor de la variable que interactua amb aquest. Per tant, no podem obtenir l'OR simplement mitjançant l'exponencial del valor estimat.

Els passos que cal seguir es detallen a continuació:

- 1) Escriure l'equació del *logit* per als dos nivells del factor de risc.
- 2) Calcular la diferència entre els *logit*.
- 3) Calcular l'exponencial del valor obtingut.

Per exemple, considerem un model que conté solament dues variables i la seva interacció. Anomenem *f* al factor, *x* a la covariable i *f* * *x* a la interacció.

$$\ln \left(\frac{P(Y=1/X)}{1-P(Y=1/X)} \right) = b_0 + b_1f + b_2x + b_3f * x$$

Es calcula l'OR per als nivells d'*f*, que anomenarem *f*₁ i *f*₀.

$$\ln 1 \left(\frac{P(Y=1/X)}{1-P(Y=1/X)} \right) = b_0 + b_1f_1 + b_2x + b_3f_1 * x$$

$$\ln 0 \left(\frac{P(Y=1/X)}{1-P(Y=1/X)} \right) = b_0 + b_1f_0 + b_2x + b_3f_0 * x$$

Es resta:

$$\ln 1 \left(\frac{P(Y=1/X)}{1-P(Y=1/X)} \right) - \ln 0 \left(\frac{P(Y=1/X)}{1-P(Y=1/X)} \right) = b_1(f_1 - f_0) + b_3x(f_1 - f_0)$$

Per tant:

$$OR = \exp ((b_1(f_1 - f_0) + b_3x(f_1 - f_0)))$$

Si ho apliquem al nostre exemple anterior, prenent la interacció *sexe*pes*, es té:

$$OR = \exp (1,23 - 0,029x).$$

3.3. Selecció de variables

Del conjunt de les variables que tenim en el nostre estudi, quines han d'introduir-se en el model?

Es busca el model més senzill que ajusti bé les dades. Cal tenir en compte que un major nombre de variables en el model implicarà errors estàndard més grans.

En el model final també han de considerar-se els termes d'interacció que s'introduiran.

Les **estratègies** de selecció de variables més usades són seqüencials:

- **Selecció cap a endavant**, en la qual en cada etapa s'afegeix la millor variable predictora encara no seleccionada.
- **Eliminació cap a enrere**, en la qual partint del conjunt complet de variables predictores es va eliminant en cada etapa la pitjor, fins que totes les variables que queden en el model són pertinents.
- **Modelització pas a pas**, en la qual es combinen les dues estratègies anteriors.

Una vegada triada l'estratègia, tenim un model preliminar i s'ha de determinar si les variables incloses són significatives o no. Això implica la formulació de tests d'hipòtesi, o, quan escaigui, la realització del contrast d'independència khi quadrat, per determinar si les variables explicatives o independents del model estan relacionades significativament amb la variable dependent o resposta.

Es poden fer contrastos no solament sobre cada coeficient estimat, sinó també per comparar models.

1) Test de Wald: contrast d'hipòtesis de nul·litat dels paràmetres

S'aplica a cadascuna de les variables del model i solament pot ser usat per testar un únic paràmetre.

Es basa a contrastar si és zero o no un determinat coeficient estimat b_i , per a la variable x_i .

$$H_0 = b_i = 0$$

$$H_1 = b_i \neq 0$$

On l'estadístic del contrast segueix una distribució $N(0, 1)$.

$$z = \frac{b_i}{\hat{S}_{b_i}}$$

Aplicat al nostre exemple i prenent el `model.logist1`, es té el resum següent:

```
model.logist1=glm(formula=salut~sexe+factor(bevedor_Rel),family=binomial(link=logit))
summary(model.logist1)
##
## Call:
## glm(formula = salut ~ sexe + factor(bevedor_Rel), family = binomial(link = logit))
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -1.9851    0.5480    0.5629    0.7040    0.7814
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)      1.26858    0.06027  21.049 < 2e-16 ***
## sexe2            -0.23868    0.06230  -3.831 0.000128 ***
## factor(bevedor_Rel)1  0.55151    0.06288   8.771 < 2e-16 ***
## factor(bevedor_Rel)2  0.49377    0.15984   3.089 0.002007 **
```

on es presenten la taula de coeficients (*Estimate*), els errors estàndard (*Std. error*), el valor de l'estadístic de Wald (*z value*) i el *p-valor* associat (*Pr(>|z|)*). Es pot observar que el *p-valor* és menor de 0,05, per la qual cosa les variables triades són significatives.

2) AIC: criteri d'informació d'Akaike

Un criteri utilitzat habitualment per determinar quines variables han d'introduir-se en el model és l'anomenat *AIC*.²

⁽²⁾ Acrònim de l'anglès, *Akaike information criterion*.

Algunes vegades no sabem quines variables són més rellevants en el model. En el cas de la regressió logística es considera la variable més important aquella que dona lloc al canvi més gran en l'índex AIC, el qual està basat en la *devianza* i el nombre de paràmetres del model. Primer s'ajusta el model amb solament la constant i es compara amb el model que resulta d'introduir cadascuna de les variables. Aquella variable que dona lloc a un valor de l'AIC més petit és considerada la més important i s'introdueix en el model.

A continuació, es compara el model inicial amb una variable amb el model posterior que resulta d'introduir una altra variable més i així successivament. A més, en cada nou pas es comprova que les variables que s'han introduït en el pas anterior segueixen sent significatives quan s'introdueix una nova variable. Una vegada s'han triat totes les variables importants, cal comprovar les interaccions entre aquestes. Recordem que la interacció entre dues variables significa que l'efecte d'una d'aquestes no és constant per a tots els nivells de

l'altra. La decisió final sobre si un terme d'interacció ha de ser inclòs en el model ha de basar-se en consideracions tant estadístiques com científiques. Seleccionades les variables i les seves interaccions, caldrà comprovar els models amb els test de bondat de l'ajust, que es veuran posteriorment.

Tornant a l'exemple vist a l'apartat «Models de regressió logística binària», es tenia el model següent:

```
model.logist1=glm(formula=salut~sexe+factor(bevedor_Rel),family=binomial(link=logit))
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    1.26858    0.06027   21.049 < 2e-16 ***
## sexe2         -0.23868    0.06230   -3.831 0.000128 ***
## factor(bevedor_Rel)1  0.55151    0.06288    8.771 < 2e-16 ***
## factor(bevedor_Rel)2  0.49377    0.15984    3.089 0.002007 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 7177.9  on 7356  degrees of freedom
## Residual deviance: 7059.2  on 7353  degrees of freedom
## AIC: 7067.2
##
## Number of Fisher Scoring iterations: 4
```

En la sortida d'R apareix l'AIC amb la *residual deviance*: **AIC = 7.067,2**.

Si ho comparem amb l'obtingut quan hem pres el model solament amb la variable independent *sexe*:

```
model.logist2=glm(formula=salut~sexe,family=binomial(link=logit))
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    1.64320    0.04482   36.661 < 2e-16 ***
## sexe2         -0.37751    0.05990   -6.302 2.93e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 7177.9  on 7356  degrees of freedom
## Residual deviance: 7137.8  on 7355  degrees of freedom
## AIC: 7141.8
```

S'obté un **AIC de 7.141,8**, major al calculat anteriorment, per la qual cosa el primer model ajusta millor les dades.

3.4. Bondat de l'ajust

Es diu que un model presenta un bon ajust a les dades si els valors que prediu reflecteixen de manera adequada els valors observats. Si el model presenta un mal ajust, aquest no pot ser utilitzat per extreure conclusions ni fer prediccions.

Una manera de mesurar l'adequació d'un model és proporcionant mesures globals de **bondat d'ajust** mitjançant tests estadístics.

Hi ha diverses mesures d'ajust global per comparar la diferència entre els valors predits i els valors observats. Tres de les més utilitzades són el test basat en la *devianza* D , l'estadístic χ^2 de Pearson i el test d'Hosmer-Lemeshow. Els dos primers es basen en els patrons de les covariables i poden ser usats en els models lineals generalitzats (MLG) en general. El tercer es basa en probabilitats estimades i s'aplica en el cas d'un MLG amb distribució binomial, és a dir, un model de regressió logística.

3.4.1. Test basat en la *devianza* D . Test de raó de versemblança

Aquest test té com a objectiu comparar dos models de regressió logística, el denominat model complet (*full model*) i el que es coneix com a model reduït (*reduced model*).

La hipòtesi nul·la testada en el test estableix que els paràmetres corresponents a les variables que formen part del model complet, però no del model reduït, valen zero.

Per comprendre el que s'ha dit anteriorment, considerem tres models expressats en la seva formulació *logit*:

- 1) **Model 1:** $\text{logit } 1 = b_0 + b_1x_1 + b_2x_2$
- 2) **Model 2:** $\text{logit } 2 = b_0 + b_1x_1 + b_2x_2 + b_3x_3$
- 3) **Model 3:** $\text{logit } 3 = b_0 + b_1x_1 + b_2x_2 + b_3x_3 + b_4x_1x_3 + b_5x_2x_3$

Tal com pot veure's, el model 2 és una extensió del model 1, d'igual manera que el model 3 ho és del 2.

En cas de voler comparar el model 2 amb el model 1, aquest últim exerciria el paper de «model reduït», mentre que el model 2 seria el «model complet». De manera anàloga, si volguéssim comparar el model 3 amb el model 2, aquest model 2 seria el «model reduït», mentre que el model 3 seria el «model complet».

Suposem que volem comparar el model 2 amb l'1.

El **test de la raó de versemblança** planteja com a hipòtesi nul·la que $b_3 = 0$, és a dir, que el paràmetre del component que forma part del model 2, però no del model 1, és zero.

Per tant, es té:

$$H_0: b_3 = 0$$

$$H_1: b_3 \neq 0$$

L'estadístic del contrast es construeix a partir de la diferència de les *devianza* entre els models que volem comparar.

Es defineix la **devianza** del model (estadístic D) com una mesura del grau de diferència entre les freqüències observades i les predites pel model de la variable dependent. Aquest estadístic mesura en quin grau el model s'ajusta a les dades. Quant menor sigui el seu valor, millor serà l'ajust.

Es calcula a partir de la transformació logarítmica de la funció de versemblança del model (**log likelihood function**).

Es defineix la funció de versemblança de la manera següent:

$$L(\beta) = p_i^{\sum y_i} \cdot (1 - p_i)^{n - \sum y_i}$$

on:

- $P(Y_i = 1) = p_i$
- $P(Y_i = 0) = (1 - p_i)$
- n : grandària de la mostra

Donada la transformació logarítmica:

$$\ln L(\beta) = \sum y_i \cdot \ln(p_i) + \left(n - \sum y_i\right) \cdot \ln(1 - p_i)$$

Es té: **devianza** = $D = -2 \ln L(\beta)$.

Per comprovar si una variable millora el model, es compara el valor de D amb i sense la variable independent inclosa en el model, usant el **test de la raó de versemblança**. Aquest test utilitza l'estadístic G, que es construeix a partir de la diferència de les *devianza* entre els models que volem comparar.

$$G = D(\text{model sense la variable}) - D(\text{model amb la variable}),$$

o el que és el mateix,

$$D(\text{model reduït}) - D(\text{model complet})$$

L'estadístic G així construït té una distribució asimptòtica khi quadrat, amb r graus de llibertat igual al nombre de paràmetres que, en el model complet, han d'igualar-se a zero perquè aquest model complet coincideixi amb el model reduït.

- Si es compara el model 2 amb l'1, els graus de llibertat serien $r = 1$.
- Si es compara el model 3 amb el 2, els graus de llibertat serien $r = 2$.

Per tant, la hipòtesi nul·la serà rebutjada per al nivell de significació α quan $D \geq \chi^2_r$, que és equivalent al fet que el p -valor del contrast sigui menor que el nivell α fixat.

Reprenent l'exemple sobre la percepció de la salut, prenent com a variable independent sexe, es tenia el resum del model (*summary*) següent:

```
model.logist2=glm(formula=salut~sexe,family=binomial(link=logit))
summary(model.logist2)
##
## Call:
## glm(formula = salut ~ sexe, family = binomial(link = logit))
##
## Null deviance: 7177.9 on 7356 degrees of freedom
## Residual deviance: 7137.8 on 7355 degrees of freedom
```

El valor de la *devianza* per al model solament inclou la constant (*null deviance*) seguida dels seus graus de llibertat, i el valor de la *devianza* per al model ajustat (*residual deviance*) i els seus graus de llibertat. Perquè el model sigui bo, la *devianza* residual ha de ser menor que la *devianza* nul·la. En aquest cas la *null deviance* és 7.177,9, però quan s'inclou la variable *sexe*, la *residual deviance* és 7.137,8, la qual cosa ens diu que amb aquesta variable el model millora.

Per poder valorar millor l'eficàcia del model, s'analitzarà el contrast de la raó de versemblança. L'estadístic G que mesura la diferència entre les dues *devianzes* (del model amb i sense incloure la variable), serà:

$$G = 7.177,9 - 7.137,8 = 40,113$$

El programa R ho calcula de la manera següent:

```
anova(model.logist2,test="Chisq")
## Analysis of Deviance Table
##
## Model: binomial, link: logit
##
## Response: salut
##
## Terms added sequentially (first to last)
##
##      Df Deviance Resid. Df Resid. Dev  Pr(>Chi)
## NULL              7356      7177.9
## sexe  1    40.113      7355      7137.8 2.397e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

La sortida del programa ens proporciona una taula on veiem per files certs resultats per al model nul i per al model ajustat. Per columnes, ens apareixen en primer terme els graus de llibertat (*Df*) de la distribució asimptòtica de l'estadístic G; seguit de *Deviance*, que mostra la variació en la *devianza* quan es comparen els dos models; a continuació *Resid. Df* i *Resid. Dev*, que corresponen respectivament als graus de llibertat i valor de l'estadístic de la *devianza* de cada model; i finalment *Pr (>Chi)*, el p -valor del contrast, que en aquest cas és significatiu.

3.4.2. Estadístic khi quadrat de Pearson

Aquest estadístic χ^2 pot calcular-se com la suma dels quadrats:

$$\chi^2 = \sum_{j=1}^J r_j^2$$

on r_j són els *Pearson residuals* (residus de Pearson).

$$r_j = \frac{y_j - m_j * p_j}{\sqrt{m_j * p_j * (1 - p_j)}}$$

on:

- m_j : nombre d'individus que comparteixen el mateix patró de covariables, és a dir, la mateixa combinació de variables explicatives.
- j : nombre de patrons diferents.

L'estadístic χ^2 té la mateixa distribució asimptòtica que la de la diferència de les *deviance* entre els models que volem comparar (estadístic G), és a dir, una khi quadrat amb els mateixos graus de llibertat.

Per tant, la hipòtesi nul·la serà rebutjada per al nivell de significació α quan $D \geq \chi^2_r$.

Per fer aquesta anàlisi amb el programa R, primer es calcula l'estadístic com la suma de quadrats dels residus de Pearson i després la significació del test.

Com s'aprecia, el test segueix sent significatiu per al model anterior.

```
sum(residuals(model.logist2,type="pearson")^2)
## [1] 7357
1-pchisq(sum(residuals(model.logist2,type="pearson")^2),1)
## [1] 0
```

3.4.3. Test d'Hosmer-Lemeshow

Si una de les variables explicatives és contínua, no han d'usar-se els test descrits anteriorment, sinó el test d'Hosmer-Lemeshow.

Aquest test consisteix a comparar els valors previstos (esperats) pel model amb els valors observats.

Ambdues distribucions, esperada i observada, també es contrasten mitjançant una prova χ^2 .

La **hipòtesi nul·la** (H_0) del test indica que no hi ha diferències entre els valors observats i els valors pronosticats, per tant, el rebuig d' H_0 indicaria que el model no està ben ajustat.

El valor observat és la dada que tenim, mentre que l'esperat és el valor esperat teòric calculat mitjançant el model construït.

Encara que no explicarem aquí els fonaments matemàtics, conceptualment aquest test consisteix a dividir el recorregut de valors de la variable dependent dicotòmica Y en una sèrie d'interval·ls. Aquests interval·ls han de contenir un nombre d'observacions suficientment gran (cinc o més). Es tracta d'explicar interval per interval el valor esperat i l'observat per a cadascun dels dos resultats possibles de la variable dependent dicotòmica.

Funció per al test d'Hosmer-Lemeshow

En la llibreria Resource Selection hi ha una funció que ajusta aquest test.

Es prendrà com a exemple el model amb la variable contínua *IMC* i la variable categòrica *sexe*.

```
model=glm(formula=salut2~sexe+imc,family=binomial(link=logit))
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  4.968533   0.214406   23.17  <2e-16 ***
## sexe2       -0.649257   0.063516  -10.22  <2e-16 ***
## imc         -0.128286   0.007951  -16.13  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
library(ResourceSelection)
hoslem.test(salut2,fitted(model))

## Hosmer and Lemeshow goodness of fit (GOF) test
##
## data:  salut2, fitted(model)
## X-squared = 12.129, df = 8, p-value = 0.1455
```

El *p*-valor és de 0,1455, la qual cosa indicaria que el model ajusta bé les dades.

Cada vegada que s'inclou o elimina una variable hem de comparar el nou model amb l'anterior fins que totes les variables importants estiguin en el model final.

Un model de regressió logística pot resultar inadequat per diferents raons.

Una d'aquestes és la invalidesa del component lineal del model. Aquesta situació és freqüent quan certes variables explicatives o termes d'interacció no són inclosos en el model quan haurien de ser-ho, o també quan no s'hi fan transformacions que permetin millorar l'ajust a les dades. L'existència d'*outliers* també pot ser determinant en un mal ajust.

Recordeu que el model logístic no assumeix **linealitat** entre la variable dependent i una covariable, però sí respecte al *logit* de l'*odds* de la variable dependent.

Si no es complís aquesta assumptió, la relació entre aquesta covariable i la variable dependent estaria infraestimada.

Una manera de comprovar si alguna de les covariables no compleix aquesta assumptió de linealitat respecte al *logit* és dibuixar els gràfics de dispersió.

3.5. Prediccions del model

Una vegada estimats els coeficients del model, és possible conèixer la probabilitat que la variable dependent triada prengui el valor 1, en presència de les variables independents X .

$$P(Y = 1/X) = \frac{e^{b_0 + \sum_{i=1}^n (b_i x_i)}}{1 + e^{b_0 + \sum_{i=1}^n (b_i x_i)}}$$

Per calcular aquestes probabilitats en R, s'usa l'ordre de comandament `predict()`.

Per exemple, es vol predir la probabilitat de percepció de bona salut en el cas de ser dona i tenir un IMC de 28.

```
model=glm(formula=salut2~sexe+imc,family=binomial(link=logit))
pred<-predict(model, data.frame(sexe="1",imc=28),type="response")
pred
##          1
## 0.7984337
```

D'acord amb el model, s'obté una probabilitat de 0,8.

A més, cada vegada que s'executa el comandament `glm()`, per a cada individu de la mostra s'obté un valor de la probabilitat predita pel model. Aquestes probabilitats queden emmagatzemades en un vector d'R que és el component `fitted.values` del model.

```
head(model$fitted.values)
##          1          2          3          4          5          6
## 0.8595336 0.8069657 0.8642668 0.8613820 0.8648676 0.8037482
```

Una de les principals aplicacions d'un model logístic és classificar les observacions en funció del valor que prengui el predictor, és a dir, l'equació del model ens proporciona una probabilitat que ens permet predir a partir d'aquesta un valor de la variable dependent Y per a cada subjecte, que anomenarem Y_{pred} (Y predict).

Per aconseguir aquesta classificació, cal establir un llindar (*threshold*) de probabilitat a partir del qual es considerarà que Y_{pred} prendrà el valor 0 o 1.

Per exemple: es considera com a llindar una probabilitat de 0,05 i es creen dos grups segons si el valor predit està per damunt o per sota d'aquell. Llavors:

- Subjectes que la seva $P(Y = 1/X) > 0,05$, es classificarien en grup 1, on $Y_{\text{pred}} = 1$.
- Subjectes que la seva $P(Y = 1/X) \leq 0,05$, es classificarien en grup 2, on $Y_{\text{pred}} = 0$.

3.5.1. Matriu de confusió

Com hem vist anteriorment, l'equació del model ens proporciona una probabilitat ajustada pel model que ens permet predir a partir d'aquesta un valor de la variable dependent Y per a cada subjecte, que anomenarem Y_{pred} (Y predict).

Per construir la **matriu de confusió** utilitzem els casos del conjunt de dades original (que pot denominar-se *conjunt d'aprenentatge* o *training set*). Per a cada cas es té una resposta observada i es pot predir la probabilitat ajustada pel model.

La matriu de confusió permet comparar aquests dos valors. Per exemple, un individu en el conjunt de dades pot tenir una resposta igual a 1, i la probabilitat estimada pel model pot ser 0,9, o el que és el mateix, un 90 %. Aquest cas és força plausible. Però pot ocórrer que la resposta sigui 1, mentre que la predicció del model sigui molt baixa, diguem del 20 %. En aquest cas, la predicció del model seria sorprenent.

A l'exemple del fabricant de perfums, vist a l'apartat «Models lineals generalitzats (MLG)», considerem una persona que tria comprar la fragància però que té unes característiques totalment allunyades dels consumidors més habituals. Això li donaria una probabilitat estimada de compra de solament el 20 %. Podem dir que la probabilitat que compri el producte és d'1 contra 4.

En la majoria dels conjunts de dades, quan es comparen prediccions i observacions, podem trobar casos concrets en els quals l'observació i la probabilitat previstes no són concordants. Aquests són errors del model. Pot succeir que es doni el cas contrari al que s'acaba de comentar, una molt alta probabilitat de triar la resposta afirmativa; no obstant això, s'observa el contrari.

En models de regressió lineal, era raonable discutir la correlació entre observacions i prediccions en termes d'estadístic R^2 , el coeficient de determinació. No obstant això, en models generalitzats les correlacions no tenen el mateix sentit.

En un model de regressió logística, quan s'observa la probabilitat predita pel model no se sap si el valor és massa alt o massa baix. Normalment un bon llindar de discriminació és el del 50 %. Això correspon a un *odds* igual a 1, la qual cosa significa que les dues opcions de resposta són equiprobables. Fixat aquest llindar, es considera que si la resposta és positiva i la probabilitat estimada és superior al 50 %, llavors el model ha encertat la resposta.

D'igual manera, si la resposta és negativa i la probabilitat és inferior al 50 %, el model també ha aconseguit encertar la resposta. No obstant això, quan la probabilitat no es correspon amb allò que s'observa, es tracta de casos en els quals el model no encerta la resposta.

Vegem un exemple de taula de confusió:

Taula 3. Exemple de matriu de confusió. Nombre de casos

	Probabilitat predita inferior al 50 %	Probabilitat predita superior o igual al 50 %	Total
Observat: Sí	50	10	60
Observat: No	30	60	90
Total	80	70	150

Del total de 150 casos, veiem que 110 estan correctament classificats, ja que el model prediu la resposta correcta per als 50 participants que sí que comprarien el producte i tenen una probabilitat predita elevada, i per als 60 que no el comprarien i tenen una probabilitat baixa. Això significa que el percentatge general de classificació correcta és igual a $110/150 = 73,33\%$, la qual cosa és excel·lent. No obstant això, hi ha un nombre de casos que no tenen la resposta esperada. Per exemple, hi ha 30 casos que no trien «comprar el producte», però la probabilitat és alta i el model prediu que és probable que hagin fet aquesta elecció. D'altra banda, hi ha 10 casos que responen que comprarien el producte però el model prediu que la seva probabilitat de compra és inferior al 50 %.

Perquè un model de regressió logística amb finalitats predictives tingui èxit, el nombre de casos que es classifiquen correctament ha de ser alt, mentre que el nombre de casos que es classifiquen incorrectament ha de ser baix.

El nombre de resultats denominats *falsos positius* correspon a casos en els quals la predicció de la probabilitat de la resposta afirmativa és elevada, però la resposta observada és negativa. En aquest exemple hi ha 30 falsos positius. Els falsos positius no són bons a la pràctica.

Al nostre exemple, és possible que s'hagi fet una campanya publicitària per arribar a les persones que tenen intenció de comprar. No obstant això, no es produeix la resposta desitjada. Els falsos positius poden conduir, en aquest exemple, al fracàs dels esforços comercials. Si usem el model per predir el comportament d'aquests clients i tractem de vendre'ls la «nova fragància» sense èxit, incorrerem en uns costos publicitaris que podrien ser estalviats.

El nombre de respostes corresponents als falsos negatius correspon al nombre de casos en què el model prediu que el client té una probabilitat de compra baixa. No obstant això, els participants sí que han triat comprar-lo. Al nostre exemple, els clients que han triat comprar la fragància davant una predicció de fer-ho baixa, inferior al 50 %, corresponen a un total de 10 casos. Aquest model té solament uns quants falsos negatius. I si s'utilitzés amb finalitats predictives, significa que solament hi hauria uns quants clients que, tot i no respondre al perfil del comprador, comprarien el producte.

Idealment, un model perfecte en termes de capacitat predictiva no tindria ni falsos positius ni falsos negatius en la taula de confusió. Però hi ha altres mesures que també solen tenir-se en compte. La **sensibilitat** és la proporció dels

classificats correctament entre els veritables participants que han donat una resposta afirmativa. L'**especificitat** és la proporció de casos correctament classificats entre les respostes negatives. A la taula 3, la sensibilitat és $50/(50 + 10) = 83,33 \%$ i l'especificitat és $60/(60 + 30) = 66,67 \%$.

3.5.2. Corba ROC (*receiver operating characteristic*)

La corba ROC és un gràfic de la sensibilitat enfront d'1 menys l'especificitat. Cada punt en la corba correspon a un nivell llindar de discriminació en la matriu de confusió. És a dir, així com a l'exemple anterior s'havia considerat un llindar del 50 %, es construeixen totes les matrius canviant aquest llindar des de l'1 fins al 99 %, i es va calculant la sensibilitat i 1 menys l'especificitat. El millor model en termes d'ajust seria aquell model que tingués una corba ROC el més a prop possible de la cantonada superior esquerra de la gràfica. Un model no discriminant tindria una corba ROC plana, a prop de la diagonal.

L'**anàlisi ROC** proporciona una manera de seleccionar models possiblement òptims i subòptims basat en la qualitat de la classificació a diferents nivells o llindars. Per tenir una regla objectiva de comparació de les corbes ROC, es calcula l'àrea sota la corba, simplement anomenada AUROC (*area under the ROC*). El model l'àrea del qual sigui superior és el preferit.


En general:

- Si $AUROC \leq 0,5$, el model no ajuda a discriminar.
- Si $0,6 \leq AUROC < 0,8$, el model discrimina de manera adequada.
- Si $0,8 \leq AUROC < 0,9$, el model discrimina de forma excel·lent.
- Si $AUROC \geq 0,9$, el model discrimina de manera excepcional.

A l'exemple sobre la percepció de la salut podem visualitzar la corba ROC de la manera següent:

```
model=glm(formula=salut2~sexe+imc,family=binomial(link=logit))
library(pROC)
prob=predict(model, data_salut, type="response")
r=roc(salut,prob, data=data_salut)
## Setting levels: control = 0, case = 1
## Setting direction: controls < cases
plot (r)
```

Figura 5. Corba ROC



```
auc(r)
## Area under the curve: 0.6412
```

A la vista dels resultats obtinguts, el model no discrimina molt bé les dades.

Un dels elements pràctics més importants és saber seleccionar el **llindar de classificació** (*threshold*) més adequat perquè el model sigui útil des d'un punt de vista predictiu. Això vol dir que potser no és el més adequat fixar un punt de tall en el 50 %. Per això, convé fixar-se en aquell punt que proporciona una major distància entre la corba ROC i la diagonal. Aquest nivell de llindar de classificació és el que dona una major sensibilitat i especificitat en el model, és a dir, una major capacitat de classificar correctament els participants en l'estudi.

4. Altres models lineals generalitzats

Els models lineals generalitzats (MLG) cobreixen els models estadístics més utilitzats, com ara la regressió lineal per a les respostes distribuïdes normalment, el model logístic per a dades binàries i els models *probit* i de Poisson.

A continuació s'expliquen els dos models, el model *probit* i el model de Poisson.

1) Model *probit*

El model *probit* s'utilitza per a casos en els quals la resposta és dicotòmica i es vol una alternativa al model de regressió logística. Encara que hi ha una equivalència entre els paràmetres de tots dos models demostrada per Amemiya (1981) –si es divideixen per 1,6 els coeficients del model *logit*, s'obtenen els del model *probit*–, encara hi ha vegades en les quals es prefereix el model *logit* perquè és millor per a casos en els quals hi ha més observacions extremes i es vol insistir en la interpretació dels *odds*.

En el model *probit*, l'especificació és la següent:

$$\text{Prob}(Y_i = 1) = \int_{-\infty}^{\beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki}} \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du$$

2) Model de Poisson

El model de Poisson s'utilitza per a casos en els quals la variable dependent és el nombre de vegades en les quals passa algun succés. S'especifica com segueix:

$$E(Y_i) = \exp(\beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki})$$

En aquest cas se suposa que la distribució de probabilitat d' Y_i és una distribució de Poisson. La interpretació dels paràmetres es fa en termes del seu signe. Quan un paràmetre és positiu, això significa que si la seva característica associada augmenta, llavors també ho fa el nombre esperat de vegades que té lloc el fenomen analitzat. En cas contrari, si el paràmetre és negatiu, llavors quan aquesta variable augmenta disminueix el nombre esperat que s'està modelitzant.

Un exemple concret de model de Poisson és el de veure quantes nits pernocten els turistes que acudeixen a una ciutat. Si s'obté que l'edat té un coeficient positiu, llavors s'espera que a major edat més elevat sigui el nombre de nits que s'espera que passin els turistes a la ciutat. Si, per exemple, el coeficient associat a una nacionalitat fos negatiu, s'interpretaria que els turistes d'aquesta nacionalitat s'espera que passin menys nits a la ciutat que els que provenen d'altres països, suposant que tinguessin la resta de les característiques iguals.

Resum

En aquest mòdul s'ha presentat la regressió logística (RL) com a part del conjunt de mètodes estadístics denominats *models lineals generalitzats* (MLG).

L'RL és adequada quan la variable de resposta Y és politòmica (admet diverses categories de resposta, com ara «empitjora molt», «empitjora», «es manté», «millora», «millora molt»), però és especialment útil quan la variable de resposta és dicotòmica, és a dir, quan hi ha dues possibles respostes.

L'RL és una tècnica de regressió molt emprada en la producció científica contemporània. Contesta preguntes, com per exemple: es pot predir amb antelació si un client que sol·licita un préstec a un banc serà un client morós?, una empresa entrarà en fallida?, es pot predir per endavant que un pacient corri risc de patir una malaltia?, és útil una campanya publicitària?, etc.

Al llarg d'aquest material s'ha presentat l'RL com a mètode d'anàlisi aplicada a la recerca basada en un conjunt de dades. Per això, s'ha resolt un cas pràctic amb dades reals sobre la percepció de l'estat de salut, com a fil conductor. En primer lloc, es presenten els conceptes teòrics fonamentals, com ara l'equació del model, la funció logística, la noció d'*odds* i *odds-ratio*, el *logit*. Posteriorment, s'explica com estimar els coeficients del model i es va resolent el cas pràctic, prenent primer un model amb variables senzilles, per després aplicar-lo a diferents tipus i nombre de variables més complexes. Finalment, s'expliquen els mètodes de bondat i ajust del model, i també els mètodes de predicció.

La identificació del millor model de regressió logística es fa mitjançant la comparació de models utilitzant el test de raó de versemblança, que indica, a partir de les dades de la mostra, quant més probable és un model enfront de l'altre. Un criteri comunament utilitzat per determinar quines variables han d'introduir-se en el model és l'anomenat *AIC* (*akaike information criterion*).

En cada cas, es mostren els principals estadístics que ofereix la sortida del programa R, i també les conclusions obtingudes dels mateixos.

Exercicis d'autoavaluació

1. Es porta a terme un model de regressió logística on la variable que es codifica com a 1 és patir una malaltia i com a 0 el no patir-la. Què ens indica que un determinat factor tingui un OR d'1,3?

- a) Que estem davant un factor de protecció.
- b) Que estem davant un factor de risc.
- c) No influeix.
- d) Estem davant un factor de risc però sempre que la variable sigui significativa.
- e) Cap de les respostes anteriors és correcta.

2. Es porta a terme un model de regressió logística on la variable que es codifica com a 1 és patir una malaltia i com a 0 el no patir-la. Què ens indica que un determinat factor significatiu tingui un OR de 0,5?

- a) Que estem davant un factor de protecció.
- b) Que estem davant un factor de risc.
- c) No influeix.
- d) Les OR han de ser majors que 1.
- e) Cap de les respostes anteriors és correcta.

3. El contrast que emprava la regressió logística per veure si les variables són significatives és...

- a) el test T.
- b) el test de Wald.
- c) el coeficient d'Spearman.
- d) el coeficient de correlació lineal.
- e) Cap de les respostes anteriors és correcta.

4. Per què és útil el model de regressió logística?

- a) Perquè permet estimar els factors de risc del fenomen estudiat.
- b) Perquè permet comprovar si hi ha relació entre les variables.
- c) Perquè permet usar tant variables qualitatives com quantitatives.
- d) Totes les respostes anteriors són correctes.
- e) Cap de les respostes anteriors és correcta.

5. Es vol valorar si un model ajusta bé o no les dades. Aquest model conté factors continus i qualitius. Quin test triaríeu?

- a) El gràfic Classplot.
- b) El test d'Hosmer-Lemeshow.
- c) El test de Wald.
- d) El test de raó de versemblança.
- e) El test de Kruskal-Wallis.

6. Si quan determinem el model obtenim un 60 % d'*outliers*, la nostra impressió serà la següent:

- a) El model és bo.
- b) El model no és bo.
- c) No té res a veure amb la qualitat del model.
- d) Cap de les respostes anteriors és correcta.
- e) Totes les respostes anteriors són correctes.

7. Si haguéssiu de decidir quines variables influeixen més en l'èxit d'una campanya publicitària, quina tècnica triaríeu?

- a) L'anàlisi d'anova.
- b) El contrast d'hipòtesi.
- c) El model de regressió logística, ja que aquest inclou contrastos i, a més, ens permet modelitzar i predir.

- d) L'anàlisi clúster.
- e) Cap de les respostes anteriors és correcta.

8. L'estimació dels paràmetres del model es fa mitjançant el mètode de...

- a) màxima versemblança.
- b) mínims quadrats.
- c) màxims quadrats.
- d) mínims quadrats ponderats.
- e) Cap de les respostes anteriors és correcta.

9. Les variables independents d'un model de regressió logística poden ser...

- a) contínues.
- b) dicotòmiques.
- c) categòriques.
- d) Totes les respostes anteriors són correctes.
- e) Cap de les respostes anteriors és correcta.

10. L'anàlisi *probit* és un model conceptualment similar a...

- a) l'anàlisi discriminant.
- b) l'anàlisi factorial.
- c) la regressió logística.
- d) Totes les respostes anteriors són correctes.
- e) Cap de les respostes anteriors és correcta.

Solucionari

Exercicis d'autoavaluació

1. d

2. a

3. b

4. d

5. b

6. b

7. c

8. a

9. d

10. c

Bibliografia

Amemiya, T. (1981). «Qualitative response models: A survey». *Journal of Economic Literature* (vol. 19, núm. 4, pàg. 1483-1536).

Artís, M.; Clar, M.; Barrio, T.; Guillén, M.; Suriñach, J. (2000). *Tòpics d'econometria*. Barcelona: Editorial UOC.

Dobson, A. J.; Barnett, A. (2008). *An introduction to generalized linear models*. Cleveland: CRC Press.

Faraway, J. J. (2016). *Extending the linear model with R: generalized linear, mixed effects and nonparametric regression models* (vol. 124). Cleveland: CRC Press.

Guillen, M. (2014). «Regression with Categorical Dependent Variables». A: E. W. Frees; R. Derrig; G. Meyer (ed.). *Predictive Modeling Applications in Actuarial Science* (vol. I). Cambridge: Cambridge University Press.

Harrell, F. (2015). *Regression modeling strategies: with applications to linear models, logistic and ordinal regression, and survival analysis*. Berlín: Springer.

Hilbe, J. M. (1994). «Generalized linear models». *The American Statistician* (vol. 48, núm. 3, pàg. 255-265).

Kabacoff, R. (2015). *R in action: data analysis and graphics with R*. Nova York: Manning Publications.

McCullagh, P.; Nelder, J. A. (1989). «Generalized Linear Models». *Monograph on Statistics and Applied Probability* (núm. 37).

Nelder, J. A.; Baker, R. J. (1972). «Generalized linear models». *Encyclopaedia of Statistical Sciences*. Nova Jersey: John Wiley & Sons.

Turner, H. (2008). «Introduction to generalized linear models». *Rapport technique*. Viena: Universidad de Economía de Viena.

Wedderburn, R. W. (1974). «Quasi-likelihood functions, generalized linear models, and the Gauss-Newton method». *Biometrika* (vol. 61, núm. 3, pàg. 439-447).