

Anàlisi estadística - Activitat 4

Enunciat

Semestre 2024.2

Índex

1	Preprocessament	2
1.1	Variables value_eur i club_name	2
1.2	Valors absents	2
2	Estadística inferencial	3
2.1	Contrast d'hipòtesi per a la diferència de mitjanes	3
3	Model de regressió	3
3.1	Escala de variable value	3
3.2	Regressió lineal múltiple	3
4	ANOVA unifactorial	4
4.1	Visualització gràfica	4
4.2	Hipòtesi nul·la i alternativa	4
4.3	Model	4
4.4	Aprofundint en ANOVA	4
4.5	Efectes dels nivells del factor i força de relació	4
5	Comparacions múltiples	4
6	ANOVA multifactorial	5
6.1	Anàlisi visual dels efectes principals i possibles interaccions	5
6.2	Càlcul del model	5
6.3	Interpretació dels resultats	5
7	Resum executiu	5

Introducció

El conjunt de dades female_play_net.csv inclou informació de jugadores de futbol basat en el conjunt de dades female_players.csv disponible en la plataforma Kaggle: <https://www.kaggle.com/datasets/stefanoleon992/ea-sports-fc-24-complete-player-dataset?resource=download>.

Aquest conjunt de dades conté l'estil de joc del videojoc de consola FIFA 15, 16, 17, 18, 19, 20, 21, 22, 23, i EA Sports FC 24, així com estadístiques reals de les jugadores de futbol.

Les principals variables que utilitzarem en aquesta activitat són:

- value_eur: valor de mercat de la jugadora en Euros.
- club_name: nom del club en el qual juga.
- league_id i league_name: codi i nom de la lliga en la qual juga.

- `club_position`: posició de joc de la jugadora.
- `overall`: puntuació de la jugadora del 0 a 100.
- `potential`: potencial de la jugadora del 0 a 100.
- `age`: edat de la jugadora.
- `wage_eur`: salari de la jugadora setmanal en EUR.
- `release_clause_eur`: clàusula de rescissió de la jugadora en Euros.
- `nation_team_id`: jugadora de la selecció del país. Identificador de la selecció nacional

La resta d'informació es pot consultar en <https://www.sofifa.com>

En aquesta activitat s'analitzarà si el valor de mercat està influenciat per la lliga i si juga amb la selecció nacional. Per a fer-ho, s'apliquen diferents tipus d'anàlisi, revisant el contrast d'hipòtesi de dues mostres i després realitzant anàlisi ANOVA.

Notes importants a tenir en compte per al lliurament de l'activitat:

- És necessari lliurar el fitxer Rmd i el fitxer de sortida (PDF o html). El fitxer de sortida ha d'incloure el codi i el resultat de la seva execució (pas a pas). S'ha d'incloure un índex o taula de continguts. I s'ha de respectar la numeració dels apartats de l'enunciat.
- No realitzeu llistats dels conjunts de dades, ja que aquests poden ocupar diverses pàgines. Si voleu comprovar l'efecte d'una instrucció sobre un conjunt de dades podeu usar la funció **head** i **tail** que mostren les primeres o últimes files del conjunt de dades.

1 Preprocessament

1.1 Variables `value_eur` i `club_name`

Carregueu el fitxer de dades “female_play_net.csv”. Consulteu els tipus de dades de la variable `value_eur` i si és necessari, apliqueu les transformacions apropiades. Esbrineu possibles inconsistències en els valors de `value_eur`. En cas que existeixin inconsistències, corregiu-les. **Nota:** Si els valors de `value_eur` estan en lliures s'han de passar a euros. Considereu la següent taxa de canvi ($1EUR = 0,85£$).

Elimineu la lletra W i últim espai en blanc del nom de l'equip de football `club_name`.

1.2 Valors absents

En aquest apartat, realitzarem tractament per a valors absents. Adoptarem la següent estratègia:

- Seleccionar únicament les observacions per a les quals la variable `league_name` no és un valor absent. Denominar al conjunt de dades `female_full`.
 - Comproveu quantes observacions tenen valors absents i reflexioneu breument sobre com de preocupant és el problema de valors absents en aquestes dades.
 - En cas de valors absents de la variable `value_eur` en el conjunt de dades `female_full`, realitzeu imputació considerant la mediana de la variable `value_eur` entre les jugadores del mateix equip al qual pertanyi l'observació amb valor absent.
 - Elimineu `_eur` en el nom de les variables del conjunt de dades `female_full`.
-

2 Estadística inferencial

2.1 Contrast d'hipòtesi per a la diferència de mitjanes

Podem acceptar que les **jugadores que juguen en posicions d'atac tenen un major valor de mercat que la resta de jugadores**? Responeu a la pregunta utilitzant un nivell de confiança del 95%.

Nota: Com a jugadores d'atac, s'han de considerar aquelles que juguen en les posicions “ST”, “CF”, “RW”, “LW”, “RWB” o “LWB”. S'han de realitzar els càlculs manualment. No es poden usar funcions de R que calculin directament el contrast com a `t.test` o similar. Si que es poden usar funcions com `mean`, `sd`, `qnorm`, `pnorm`, `qt` i `pt`.

Seguiu els passos que es detallen a continuació

2.1.1 Escriviu la hipòtesi nul·la i l'alternativa

2.1.2 Justificació del test a aplicar

2.1.3 Càlculs

Realitzeu els càlculs de l'estadístic de contrast, valor crític i p valor a un nivell de confiança del 95%.

2.1.4 Interpretació del test

3 Model de regressió

Volem investigar quines variables expliquen el valor de mercat de les jugadores. Estimeu un model de regressió lineal múltiple que tingui com a variables explicatives: `overall`, `potential`, `age`, `wage` i `release_clause`.

3.1 Escala de variable `value`

En aquest apartat volem determinar si la variable dependent `value` l'analitzem en escala original o escala logarítmica.

Realitzeu un gràfic de la funció de densitat de la variable `value` i un gràfic quantil-quantil (`qqplot`) per a la distribució normal. A partir de mètodes visuals podem assumir que la variable segueix una distribució normal? Justifiqueu la resposta.

Realitzar els mateixos passos amb la variable a escala logarítmica. Podem considerar ara que la variable transformada segueix una distribució normal?

3.2 Regressió lineal múltiple

Ajustar el model de regressió per a la variable dependent `value` en escala logarítmica. Denomineu a la variable dependent `lvalue`.

Interpreteu el model lineal ajustat. Com és la qualitat de l'ajust? Expliqueu breument la contribució de les variables explicatives en el model.

3.2.1 Multicolinealitat

Analitzeu possibles problemes de multicolinealitat (alta correlació entre variables explicatives) mitjançant la interpretació de la matriu de correlacions i del factor d'inflació de la variància (`vif`). Es pot utilitzar la funció `vif` de la llibreria `car`.

4 ANOVA unifactorial

A continuació es realitzarà una anàlisi de variància, on es desitja comparar el valor de mercat de les jugadores entre les principals lligues.

L'anàlisi de variància consisteix a avaluar si la variabilitat d'una variable dependent pot explicar-se a partir d'una o diverses variables independents, denominades factors.

En el supòsit que ens ocupa, ens interessa avaluar si la variabilitat de la variable `lvalue` pot explicar-se pel tipus de lliga.

Hi ha dues preguntes bàsiques a respondre:

- Existeixen diferències en el valor de mercat (en escala logarítmica) entre les diferents lligues?
- Si existeixen diferències, entre quines lligues es donen aquestes diferències?

Per a realitzar aquest exercici, compararem entre sis lligues: SuperL, PrimeraD, FeminineD, Bundesliga, NWSL i la resta de lligues. Denomineu `league` a la variable categòrica amb aquests sis grups de lligues.

4.1 Visualització gràfica

Mostreu gràficament la distribució de `lvalue` segons `league` representant els valors mitjans per a cada categoria. Es pot utilitzar la funció `ggline` de la llibreria `ggpubr`.

4.2 Hipòtesi nul · la i alternativa

Escriuiu la hipòtesi nul · la i l'alternativa.

4.3 Model

Realitzeu l'anàlisi de variància (ANOVA), utilitzant la funció `aov` i `lm`. Interpreteu el resultat de l'anàlisi.

4.4 Aprofundint en ANOVA

A partir dels resultats del model retornat per `aov`, identifiqueu les variables SST (Total Sum of Squares), SSW (Within Sum of Squares), SSB (Between Sum of Squares) i els graus de llibertat. A partir d'aquests valors, calculeu manualment el valor F, el valor crític (a un nivell de confiança del 95%), i el valor p. Interpreteu els resultats i expliqueu el significat de les variables SST, SSW i SSB.

4.5 Efectes dels nivells del factor i força de relació

Proporcioneu l'estimació de l'efecte dels nivells del factor `league`. Interpreteu els resultats.

Calculeu la part de la variabilitat del valor de mercat (en *log*) explicada per l'efecte dels nivells (força de relació). És a dir, calculeu $\eta^2 = \frac{SSB}{SST}$ del model. Interpreteu els resultats.

5 Comparacions múltiples

Independentment del resultat obtingut en l'apartat anterior, realitzeu un test de comparació múltiple entre els grups amb correcció de Bonferroni. Aquest test s'aplica quan el test ANOVA retorna rebutjar la hipòtesi nul · la d'igualtat de mitjanes. Per tant, procedirem com si el test ANOVA hagués donat com a resultat el rebuig de la hipòtesi nul · la.

Calculeu les comparacions entre grups amb la correcció Bonferroni. Podeu utilitzar la funció `pairwise.t.test`. Interpreteu els resultats.

6 ANOVA multifactorial

A continuació, es desitja avaluar l'efecte sobre `lvalue` de la lliga combinat amb si la jugadora és internacional. Seguiu els passos que s'indiquen a continuació.

6.1 Anàlisi visual dels efectes principals i possibles interaccions

Creeu una variable dicotòmica que indiqui si la jugadora és internacional a partir de si la jugadora té identificador en el seu equip nacional o no. Denomineu la variable `international`.

Dibuixeu en un gràfic la variable `value (log)` en funció de `league` i en funció de `international`. El gràfic ha de permetre avaluar si hi ha interacció entre els dos factors. Per això, es recomana seguir aquests passos:

1. Agrupeu el conjunt de dades per `league` i per `international`. Calculeu la mitjana del valor per a cada grup. Mostreu el conjunt de dades en forma de taula (data frame), on es mostri la mitjana de cada grup segons `league` i `international`, la desviació estàndard i el nombre d'observacions.
2. Mostreu en un gràfic el valor mitjà de la variable `lvalue` per a cada factor. Interpreteu el resultat sobre si només hi ha efectes principals o hi ha interacció entre els factors. Si hi ha interacció, expliqueu com s'observa aquesta interacció en el gràfic.

6.2 Càlcul del model

Realitzeu l'anàlisi de la variància multifactorial sobre `lvalue` per a la combinació de `league` i `international`. Podeu utilitzar la funció `aov`.

6.3 Interpretació dels resultats

7 Resum executiu

Escriviu un resum executiu com si haguéssiu de comunicar a una audiència no tècnica. Per exemple, podria ser un equip de managers, als quals els hi ha d'informar sobre les diferències en el valor de mercat de les jugadores.

Puntuació dels apartats

- Apartat 1: 10%
- Apartat 2: 10%
- Apartat 3: 10%
- Apartat 4: 30%
- Apartat 5: 10%
- Apartat 6: 20%
- Apartat 7 i qualitat de l'informe: 10%