
Anàlisi de la variància (ANOVA)

PID_00276232

Ferran Reverter



Universitat
Oberta
de Catalunya

Ferran Reverter

L'encàrrec i la creació d'aquest recurs d'aprenentatge UOC han estat coordinats per la professora: Teresa Sancho Vinuesa

Primera edició: setembre 2020

© d'aquesta edició, Fundació Universitat Oberta de Catalunya (FUOC)

Av. Tibidabo, 39-43, 08035 Barcelona

Autoria: Ferran Reverter

Producció: FUOC

Tots els drets reservats

Cap part d'aquesta publicació, incloent-hi el disseny general i la coberta, no pot ser copiada, reproduïda, emmagatzemada o transmesa de cap manera ni per cap mitjà, tant si és elèctric com mecànic, òptic, de gravació, de fotocòpia o per altres mètodes, sense l'autorització prèvia per escrit del titular dels drets.

Índex

1. Anàlisi de la variància d'un factor	5
1.1. Disseny aleatoritzat completament	6
1.2. Model estadístic	8
1.3. Estimació dels efectes	10
1.4. Mecànica de l'ANOVA	10
1.5. Taula ANOVA	11
1.5.1. Per què funciona l'ANOVA?	12
1.6. Contrastos	14
1.7. Contrastos múltiples	16
1.7.1. Test de Bonferroni	16
1.8. Comprovació de les suposicions del model	18
1.8.1. Avaluació del compliment dels supòsits de modelització	19
1.8.2. Avaluació de la normalitat	21
1.8.3. Avaluació del compliment de la constància de la variància (homoscedasticitat)	22
1.8.4. Correcció de l'incompliment de les condicions	23
1.8.5. Formulació del model estadístic per analitzar les dades de l'experiment anterior	25
1.8.6. Avaluació de les suposicions de modelització (normalitat i homoscedasticitat)	25
1.8.7. Transformació de la variable resposta (nombre de bacteris per cm ²) per prosseguir l'anàlisi de les dades	26
1.8.8. Verificació de l'adequació	27
1.8.9. Avaluar si hi ha diferències significatives entre els tractaments	29
1.8.10. Estimació dels paràmetres del model	29
1.8.11. Es pot recomanar un tractament que millori els tractaments usuals?	30
1.9. Test de remostreig per l'ANOVA	31
1.10. Test no paramètric basat en rangs	33
2. Anàlisi de la variància de dos factors	35
2.1. Efectes principals i interacció	35
2.2. Parametrització del model lineal de dos factors	39
2.3. Anàlisi de la variància en dissenys equilibrats	40
2.4. Dissenys amb efectes aleatoris	46
Bibliografia	49

1. Anàlisi de la variància d'un factor

Un experiment es caracteritza per les unitats experimentals en observació, els tractaments als quals seran exposades, la manera com els tractaments s'assignen a les unitats i els mesuraments de la variable resposta en cadascuna de les unitats. Els estudis experimentals permeten, a diferència dels estudis observacionals, comparar de manera controlada tractaments sobre una variable resposta d'interès, i aquesta és la variable numèrica que es pretén modelitzar. En els estudis observacionals també hi ha tractaments, però l'assignació de cada unitat experimental a un tractament no està controlada per l'investigador.

Estudis experimentals es presenten sovint en la recerca biomèdica.

Els estudis observacionals són aquells en què els investigadors observen l'efecte d'un factor de risc, una prova de diagnòstic, un tractament o una altra intervenció sense tractar de canviar qui hi està exposat i qui no. Els estudis de cohorts així com els estudis de casos i controls són dos tipus d'estudis observacionals.

1) Estudi de cohort: per a finalitats de recerca, una cohort és qualsevol grup de persones que estan vinculades d'alguna manera. Per exemple, una cohort de naixement inclou totes les persones nascudes dins d'un període de temps determinat. Els investigadors comparen el que passa als membres de la cohort que han estat exposats a una variable particular amb el que passa als altres membres que no hi han estat exposats.

2) Estudi de casos i controls: aquí els investigadors identifiquen les persones amb un problema de salut existent («cas») i un grup similar sense el problema («control»), i després els comparen pel que fa a una exposició o exposicions.

De vegades, els estudis observacionals són l'única manera que els investigadors poden explorar certes preguntes. Per exemple, en un estudi de condicions de seguretat en el treball, no seria ètic dissenyar un assaig controlat aleatori que exposés deliberadament els treballadors a una situació potencialment nociva. No obstant això, els resultats dels estudis observacionals estan oberts a controvèrsies per la seva naturalesa. Corren el risc de contenir biaixos de confusió. Per exemple, un estudi de cohort podria trobar que les persones que feien ioga regularment eren menys propenses a les malalties cardíques que les que no en practicaven. Però el vincle es pot explicar pel fet que les persones que fan ioga

Exemple d'estudi experimental

Comparació de l'efecte de tres tractaments aprimadors entre grups de ratolins de laboratori amb obesitat. Una variable resposta d'interès pot ser el percentatge de teixit adipós després del tractament. En un estudi experimental l'equip investigador pot garantir l'homogeneïtat dels grups que seran tractats, amb l'ànim de reduir possibles causes que interfereixin en la resposta més enllà del factor tractament.

també fan més exercici i segueixen dietes més saludables. En altres paraules, encara que una cohort es defineix per una característica o exposició comuna, també pot compartir altres característiques equívokes que afecten el resultat.

Un experiment és aleatoritzat (*randomized* en anglès) si el mètode d'assignació dels tractaments a les unitats experimentals implica un esquema probabilístic conegut. Com veurem més endavant, un experiment pot tenir diverses característiques aleatòries, a més de l'assignació dels tractaments a les unitats. L'aleatorització és un dels elements més importants d'un experiment ben dissenyat. És necessari distingir entre un esquema casual i un d'aleatoritzat d'assignació dels tractaments. La introducció de més aleatorietat en un experiment pot semblar una mesura perversa. Després de tot, sempre lluitem contra l'error aleatori experimental. No obstant això, l'assignació aleatòria de tractaments té dues conseqüències útils:

- L'aleatorització protegeix contra els factors de confusió.
- L'aleatorització pot constituir la base per a la inferència.

A la pràctica, l'aleatorització s'utilitza relativament poc per a la inferència, principalment a causa dels costos i les dificultats computacionals, però en l'actualitat el seu ús va en augment d'acord amb l'auge de la computació. No obstant això, l'èxit de l'aleatorització en la protecció contra la confusió és tan aclaparador que és gairebé recomanada universalment. Definim la confusió com quelcom que passa quan l'efecte d'un factor o tractament no pot ser distingit del d'un altre factor o tractament.

1.1. Disseny aleatoritzat completament

El disseny aleatoritzat completament és el disseny més simple per comparar diversos tractaments, és a dir, un factor amb diversos nivells. En general, en l'ANOVA d'un factor els diferents tractaments corresponen als diferents nivells del factor.

Per exemple, en la comparació d'un fàrmac per reduir la tensió arterial podem estar interessats a comparar l'efecte del fàrmac en quatre concentracions diferents; aleshores direm que tenim el factor fàrmac a quatre nivells.

Tenim N unitats experimentals (sia persones, ratolins, peces...) i g tractaments o nivells d'un factor. L'esquema d'un experiment aleatoritzat completament consisteix a:

- Seleccionar les grandàries mostrals $n_1, n_2, \dots, n_g$ amb $n_1 + n_2 + \dots + n_g = N$.

- Triar n_1 unitats aleatòriament per al tractament 1, triar n_2 unitats aleatòriament d'entre les $N - n_1$ per al tractament 2, i així successivament.

Aquest procediment dona com resultat un disseny aleatoritzat completament; totes les disposicions possibles de les N unitats en g grups amb grandàries n_1 fins a n_g són igualment probables. En cas que $n_1 = n_2 = \dots = n_g = n$, direm que el disseny està equilibrat.

L'aleatorització completa solament es refereix a l'assignació de tractaments a les unitats; en el disseny de l'experiment també es requereixen la selecció dels tractaments, les unitats experimentals i la variable resposta.

Exemple 1

Un factor important en la selecció de programari per a sistemes de processament de textos i gestió de bases de dades és el temps requerit per aprendre a manejar un sistema en particular. Amb la finalitat d'avaluar tres sistemes de gestió de bases de dades, una empresa va dissenyar una prova per veure quantes hores de capacitació es necessitaven perquè els operadors fossin competents en cadascun dels tres sistemes. Per a això, es van seleccionar divuit operadors, i cadascun es va assignar a l'atzar a un dels sistemes de programari, per la qual cosa van quedar sis operadors per sistema. Els temps es recopilen en la taula següent.

Sistema 1	20	17	15	19	14	13
Sistema 2	18	17	14	29	13	12
Sistema 3	23	23	20	21	19	20

Comencem amb una descriptiva amb què visualitzem la distribució dels temps segons el tipus de programari.


```
y<- c(20,17,15,19,14,13,
      18,17,14,20,13,12,
      23,25,20,21,19,20)
fact<-as.factor(c(rep(1,6),rep(2,6),rep(3,6)))
df<-data.frame(y,fact)
```

Obtenim la mitjana de les dades:

```
mean(y,data=df)
## [1] 17.77778
```

i amb la funció `tapply` obtindrem les mitjanes en cada tractament:

```
tapply(y,fact,mean,data=df)
## 1 2 3
## 16.33333 15.66667 21.33333
boxplot(y~fact,data=df,xlab="Software",ylab="Tiempo hasta la capacitación (h)")
```



Observem descriptivament que hi ha aparentment un efecte del factor, tipus de programari, sobre el temps necessari per adquirir capacitat. El programari del tipus 3 requereix un esforç major per adquirir capacitat. En canvi, sembla que els tipus 1 i 2 requereixen un esforç en temps semblant. És objecte del disseny i anàlisi d'experiments verificar si aquestes diferències que observem són significatives i, en cas de ser-ho, determinar quins són els nivells significativament diferents i obtenir l'estimació dels efectes sobre la variable resposta.

1.2. Model estadístic

Comencem amb dos models bàsics. Tenim g tractaments i N unitats experimentals. Denotem per y_{ij} la resposta j -èsima en el tractament i -èsim. Per tant, $i = 1, \dots, g$, i $j = 1, \dots, n_i$.

El model complet considera que cada tractament té la seva mitjana μ_i . A més, s'assumeix que l'error aleatori és independent i està distribuït normalment amb variància constant, però cada tractament amb la seva pròpia mitjana:

$$y_{ij} \sim N(\mu_i, \sigma^2)$$

De manera equivalent, podem escriure el model així:

$$y_{ij} = \mu_i + e_{ij}$$

en què e_{ij} denoten els **errors** que són variables aleatòries independents, amb distribució normal de mitjana zero i variància σ^2 . Un segon model correspon a un model reduït. Aquest model assumeix que tots els tractaments tenen la

mateixa mitjana, per la qual cosa hi ha una única mitjana. També considereu que l'error aleatori és independent i distribuït normalment amb variància constant,

$$y_{ij} \sim N(\mu, \sigma^2)$$

De manera equivalent, podem escriure el model així:

$$y_{ij} = \mu + e_{ij}$$

en què y_{ij} denoten els **errors** que són variables aleatòries independents, amb distribució normal de mitjana zero i variància σ^2 . Observeu que el model reduït és un cas especial o restringit del model complet que correspon al cas en què totes les μ_i són iguals.

Usualment, la mitjana dels tractaments s'expressa:

$$\mu_i = \mu + \alpha_i$$

en què μ es denomina mitjana general i α_i denota l'efecte del tractament i -èsim. Amb aquesta formulació, el model reduït correspon al cas en què tots els α_i són iguals, per exemple, a zero. Aquesta formulació pot semblar ara una complicació innecessària, però més endavant, en el cas dels models factorials generals, veurem que usar-la és convenient.

Com que hi ha g mitjanes μ_i per als g tractaments, pot semblar que amb la formulació dels efectes dels tractaments hi ha un excés de paràmetres, $g + 1$, la μ i les α_i , amb $i = 1, \dots, g$. No obstant això, observem que la diferència entre efectes $\alpha_i - \alpha_j$ correspondrà a la diferència entre les mitjanes $\mu_i - \mu_j$ amb independència de com es defineixi μ .

L'elecció més usual per a μ és la mitjana de la mitjana dels tractaments:

$$\mu = \frac{1}{a} \sum_{i=1}^a \mu_i$$

Amb aquesta elecció, en un disseny equilibrat la suma dels efectes dels tractaments és zero:

$$\sum_{i=1}^a \alpha_i = 0$$

1.3. Estimació dels efectes

Un pas essencial en el modelatge estadístic de les dades és l'estimació dels paràmetres del model. Resulten les estimacions següents:

Mitjana general

$$\hat{\mu} = \bar{y}_{..}$$

Mitjana dels tractaments

$$\hat{\mu}_i = \bar{y}_{i.}$$

Efectes

$$\hat{\alpha}_i = \bar{y}_{i.} - \bar{y}_{..}$$

En l'anàlisi estàndard d'un disseny aleatoritzat completament estem interessats en les respostes mitjanes dels grups de tractament. Una manera òbvia de començar és decidir si les mitjanes són totes iguals o si algunes són diferents. En termes de models, ens preguntem si les dades poden ser descrites adequadament pel model d'una sola mitjana general ($y_{ij} = \mu + e_{ij}$, model reduït) o si necessitem el model de mitjanes separades per cada tractament ($y_{ij} = \mu + \alpha_i + e_{ij}$, model complet).

1.4. Mecànica de l'ANOVA

A continuació considerem el model d'un factor amb a tractaments i n rèpliques en cada nivell; per tant, els índexs són $i = 1, \dots, a$ i $j = 1, \dots, n$. D'acord amb això, l'ANOVA d'un factor resol el contrast d'hipòtesi següent:

$$\begin{aligned} H_0: & \alpha_1 = \alpha_2 = \dots = \alpha_a = 0 \\ H_1: & \alpha_i \neq \alpha_j \text{ per a algun } i \neq j \end{aligned}$$

Acceptar H_0 implica que el factor no és significatiu; per contra, acceptar H_1 implica que el factor és significatiu. Almenys hi ha dos nivells els efectes dels quals són significativament diferents. En cas d'acceptar H_1 , haurem de cercar entre quins nivells hi ha les diferències. L'ANOVA respon solament a la pregunta de si hi ha diferències o no, però no respon entre quins nivells estan aquestes diferències; per a això haurem d'usar altres tests addicionals, com veurem més endavant.

Notació de punts

En el context de l'ANOVA és habitual utilitzar aquesta notació per denotar l'índex sobre el qual es fa mitjana. Per exemple, en el cas de l'ANOVA d'un factor indiquem amb y_{ij} l'observació efectuada en la rèplica j del nivell i del factor. Si volem indicar la mitjana en el nivell i del factor, haurem de fer mitjana de les observacions en aquest nivell, és a dir, sumar j des d'1 fins a n_i i dividir per n_i . Com que estem sumant sobre l'índex j , la manera de denotar l'índex sobre el qual sumem és amb un punt; per tant, indiquem $y_{i.}$, i, com que es tracta d'una mitjana, afegim la barra i resulta $\bar{y}_{i.}$. Posem un altre exemple: la mitjana general resultarà de sumar per a tots els nivells i per a totes les rèpliques; per tant, com que sumem respecte dels dos índexs, ho indicarem amb dos punts, això és, $y_{..}$. I, com que es tracta d'una mitjana, afegirem la barra i resultarà $\bar{y}_{..}$.

Parlant estrictament, ANOVA és un procediment de càlcul per descompondre la variabilitat en un conjunt de dades en dues quantitats, una associada a una estructura de dades amb diferents mitjanes i una altra residual. ANOVA parteix de la igualtat

$$y_{ij} - \bar{y}_{..} = (\bar{y}_i - \bar{y}_{..}) + (y_{ij} - \bar{y}_i)$$

Elevant al quadrat, resulta:

$$(y_{ij} - \bar{y}_{..})^2 = (\bar{y}_i - \bar{y}_{..})^2 + (y_{ij} - \bar{y}_i)^2 + 2(\bar{y}_i - \bar{y}_{..})(y_{ij} - \bar{y}_i)$$

Podem sumar en els dos costats mitjançant j . Observem que $\sum_{j=1}^n (i_{ij} - \bar{i}_i) = 0$, i obtenim:

$$\sum_{j=1}^n (y_{ij} - \bar{y}_{..})^2 = n(\bar{y}_i - \bar{y}_{..})^2 + \sum_{j=1}^n (y_{ij} - \bar{y}_i)^2$$

Ara, si sumem en els dos costats mitjançant i obtenim:

$$\sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_{..})^2 = n \sum_{i=1}^a (\bar{y}_i - \bar{y}_{..})^2 + \sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_i)^2$$

I resulta la descomposició fonamental de l'ANOVA. A l'esquerra, la suma de quadrats total (SST), que es descompon a la dreta com la suma de quadrats dels tractaments (SSA) més la suma de quadrats de l'error (SSE):

$$SST = SSA + SSE$$

Per a un conjunt de dades donat (i per tant l' SST fixada), tenir major diferències entre les mitjanes de grups implica una major SSA , que, alhora, implica tenir una menor SSE . Cal assenyalar que és mitjançant la descomposició de la variabilitat total (d'aquí el nom d'anàlisi de la variància) que resollem un contrast d'hipòtesi que es planteja sobre mitjanes.

1.5. Taula ANOVA

Els càlculs ANOVA es resumeixen mitjançant una taula amb cinc columnes: una per a les fonts de variabilitat, una altra per als graus de llibertat associats a les sumes de quadrats (gl), una altra per a les sumes de quadrats (SS), una altra per als quadrats mitjans (MS) i una altra per al valor de l'estadístic F .

Fonts	gl	SS	MS	F
Tractaments	$a - 1$	SSA	$MSA = SSA / (a - 1)$	$F = MSA / MSE$
Error	$N - a$	SSE	$MSE = SSE / (N - a)$	

1.5.1. Per què funciona l'ANOVA?

El quadrat mitjà de l'error és una variable aleatòria que depèn de l'error aleatori associat a les dades. Si repetíssim l'experiment, aconseguiríem diferents mostres dels errors aleatoris i, per tant, diferents avaluacions en el mostreig del quadrat mitjà de l'error. Es pot calcular teòricament el valor esperat del quadrat mitjà de l'error E (MSE) i comprovar que coincideix amb la variància de l'error σ^2 , és a dir,

$$E(MSE) = \sigma^2$$

Cal remarcar que l' MSE ens proporciona una estimació centrada de la variància σ^2 . A més, el quadrat mitjà dels tractaments és també una variable aleatòria, l'esperança de la qual es pot demostrar:

$$E(MSA) = \sigma^2 + \frac{n}{a-1} \sum_{i=1}^a \alpha_i^2$$

Podem concloure que si la hipòtesi nul·la H_0 és certa ($\alpha_i = 0$, $i = 1, \dots, a$), ambdues esperances $E(MSE)$ i $E(MSA)$ coincideixen. És a dir, les quantitats MSE i MSA seran estimadors centrats de σ^2 . Si és certa la hipòtesi nul·la H_0 , esperem que MSE i MSA tinguin valors similars i, per tant,

$$F = \frac{MSA}{MSE} \approx 1$$

Al contrari, si la hipòtesi nul·la H_0 és falsa, hi ha alguns $\alpha_i \neq 0$, i la $E(MSA)$ serà major que σ^2 . Per tant, el quocient F tendirà a ser major que 1. Així, rebutjarem la hipòtesi nul·la H_0 per a valors suficientment grans de F . Tenint en compte que en la hipòtesi nul·la H_0 coneixem la distribució de referència de la F , que és la d'una F de Fisher amb $a - 1$ i $N - a$ graus de llibertat, ens és fàcil determinar la regió crítica del test una vegada fixat un nivell de significació.

Exemple 1 (continuació)

Recordem l'exemple anterior, en el qual es va plantejar un disseny d'un factor per decidir usar un programari per al processament de textos i gestió de bases de dades. Amb la finalitat d'avaluar tres sistemes de gestió de bases de dades, una empresa va dissenyar una prova per veure quantes hores de capacitació es necessitaven perquè els operadors fossin competents en cadascun dels tres sistemes.

Descriure el disseny experimental associat i formular el model estadístic corresponent

La formulació del disseny experimental és:

$$y_{ij} = \mu + \alpha_i + e_{ij}, \text{ amb } \sum_{i=1}^3 \alpha_i = 0$$

en què $i = 1, \dots, 3$ i $j = 1, \dots, 6$, y_{ij} és l'observació per al nivell i i la rèplica j , μ és la mitjana general, α_i és l'efecte del nivell i i e_{ij} és l'error aleatori. Assumim que $e_{ij} \sim N(0, \sigma^2)$, on σ^2 és constant per a tots els nivells del factor.

Començarem creant un `data frame` amb les dades de l'enunciat:

```
y<- c(20,17,15,19,14,13,
      18,17,14,20,13,12,
      23,25,20,21,19,20)
fact<-as.factor(c(rep(1,6),rep(2,6),rep(3,6)))
df<-data.frame(y,fact)
str(df)
## 'data.frame': 18 obs. of 2 variables:
## $ y : num 20 17 15 19 14 13 18 17 14 20 ...
## $ fact: Factor w/ 3 levels "1","2","3": 1 1 1 1 1 1 2 2 2 2 ...
head(df)
## y fact
## 1 20 1
## 2 17 1
## 3 15 1
## 4 19 1
## 5 14 1
## 6 13 1
round(mean(df$y),3)
## [1] 17.778
```

És important assegurar-nos que la variable que conté el `factor` és de tipus `factor`, la qual cosa podem verificar amb la funció `str` de R.

Obtenir l'estimació de tots els paràmetres del model

Aviat comentarem funcions R més directes per obtenir l'estimació dels paràmetres d'un model, però ara com ara ens conformarem amb el càlcul a partir de les fórmules corresponents.

La mitjana general μ s'estima amb la mitjana de les dades, això és, $\hat{\mu} = \bar{y}_{..} = 17.778$.

I els efectes dels tractaments s'estimen mitjançant $\hat{\alpha}_i = \bar{y}_{i.} - \bar{y}_{..}$. Per tant,

$$\hat{\alpha}_1 = \bar{y}_{1.} - \bar{y}_{..} = 16.333 - 17.778 = -1.445$$

$$\hat{\alpha}_2 = \bar{y}_{2.} - \bar{y}_{..} = 15.667 - 17.778 = -2.111$$

$$\hat{\alpha}_3 = \bar{y}_{3.} - \bar{y}_{..} = 21.333 - 17.778 = 3.555$$

Observem que $\sum_{i=1}^3 \hat{\alpha}_i = 0$, com cal esperar perquè es tracta d'un disseny equilibrat. Naturalment, encara falta l'estimació d'un altre paràmetre del model, la variància de l'error (σ^2). Si bé a partir de la fórmula

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^g \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2}{N - g}$$

podem obtenir una estimació d'aquest paràmetre, a continuació veurem la manera d'obtenir-la a partir de la taula de l'anàlisi de la variància.

Podem preguntar-nos si el factor tipus de programari és significatiu en el sentit que el temps necessari per a la capacitació és afectat per aquest factor. Per tant, plantejem el contrast d'hipòtesi

$$H_0: \alpha_1 = \alpha_2 = \alpha_3 = 0$$

$$H_1: \alpha_i \neq \alpha_j \text{ per a algun } i \neq j$$

Per calcular la taula ANOVA associada a aquest problema, primer hem d'ajustar el model mitjançant la funció `lm`:

```
results<-lm(y~fact,data=df)
```

Podem extreure la taula ANOVA així:

```
taov<-anova(results)
taov
## Analysis of Variance Table
##
## Response: y
## Df Sum Sq Mean Sq F value Pr(>F)
## fact 2 115.11 57.556 7.5731 0.005326 **
## Residuals 15 114.00 7.600
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Obtenim un p -valor 0.005, clarament inferior a un nivell de significació del 5 %. Per tant, acceptem la hipòtesi alternativa i concloem que el factor és significatiu. És a dir, el tipus de programari afecta el temps necessari per adquirir la capacició. A continuació la tasca serà determinar en quins nivells del factor hi ha les diferències.

Val la pena recordar que la taula ANOVA, i en concret el valor de MSE , ens proporciona una estimació de la variància de l'error $\hat{\sigma}^2 = 7.6$.

1.6. Contrastos

Formalment, un contrast és una combinació lineal de les mitjanes o dels

efectes $\sum_{i=1}^a w_i \alpha_i$, on $\sum_{i=1}^a w_i = 0$. Denotarem un contrast per $w(\{\alpha_i\})$.

És probable que els contrastos més comuns siguin les comparacions per parelles, en les quals comparem la resposta mitjana en un tractament amb la resposta mitjana en un segon tractament. Per a una comparació per parelles, un coeficient del contrast és 1, mentre que el segon coeficient del contrast és -1, i tots els altres coeficients dels contrastos són 0. Per exemple, en un disseny amb quatre nivells en el qual $a = 4$, un contrast amb coeficients (0, 1, 0, -1) compara els efectes dels tractaments 2 i 4.

Plantegem contrastos sobre les mitjanes observades dels tractaments o sobre els efectes per fer inferència sobre les mitjanes o els efectes poblacionals.

Les mitjanes mostrals dels grups $\bar{y}_i$ són un estimador centrat de les $\mu_i = \mu + \alpha_i$. Per tant, qualsevol combinació lineal de les mitjanes mostrals dels tractaments és un estimador centrat de la corresponent combinació lineal de les μ_i . En particular, un contrast definit en les mitjanes mostrals és un estimador centrat del contrast corresponent de les mitjanes dels tractaments. Per tant,

$$E(w(\{y_i\})) = w(\{\alpha_i\})$$

D'altra banda, la variància de y_i és $\frac{\sigma^2}{n}$, i les mitjanes mostrals dels tractaments són independents. Per tant, resulta que la variància d'un contrast sobre les mitjanes mostrals és:

$$\text{var}(w(\{y_i\})) = \frac{\sigma^2}{n} \sum_{i=1}^a w_i^2$$

Normalment no coneixem σ^2 , així que usem l'estimació que obtenim dels quadrats mitjans de l'error, MSE , de la taula ANOVA.

Llavors, un interval de confiança per al contrast $w(\{\alpha_i\})$ de nivell de confiança $(1 - \epsilon)100\%$ té la forma

$$w(\{y_i\}) \pm t_{N-a, \epsilon/2} \sqrt{MSE/n} \sqrt{\sum_{i=1}^a w_i^2}$$

Aquest plantejament també funciona en el cas dels tests d'hipòtesi. Si tenim una hipòtesi nul·la $H_0: w(\{\alpha_i\}) = \delta$, usualment interessa $\delta = 0$. Llavors, podem usar un test basat en l'estadístic t per resoldre el test:

$$t = \frac{w(\{y_i\}) - \delta}{\sqrt{MSE/n} \sqrt{\sum_{i=1}^a w_i^2}}$$

En la hipòtesi nul·la, l'estadístic t segueix una distribució t de Student de $N - a$ graus de llibertat.

En el cas concret de les comparacions per parelles, això és,

$$\begin{aligned} H_0: & \alpha_i - \alpha_j = 0 \\ H_1: & \alpha_i - \alpha_j \neq 0 \end{aligned}$$

L'estadístic t té la forma

$$t = \frac{(y_i - y_j) - 0}{\sqrt{MSE/n} \sqrt{2}}$$

En la hipòtesi nul·la, l'estadístic t segueix una distribució t de Student de $N - a$ graus de llibertat.

Amb la pràctica es conclou que la parella d'efectes α_i i α_j (o, en equivalència, la parella de mitjanes μ_i i μ_j) són diferents estadísticament si

$$|\bar{y}_i - \bar{y}_j| > LSD$$

en què la quantitat LSD, denominada *least significant difference*, és donada per

$$LSD = t_{N-a, \epsilon/2} \sqrt{2MSE/n}$$

En aquest resum hem proporcionat les fórmules per a dissenys equilibrats, és a dir, amb el mateix nombre de rèpliques, n , en cada tractament.

Exemple 1 (continuació)

Amb la funció `pairwise.t.test` del paquet `stat` podem obtenir els p -valors de totes les comparacions per parelles.

```
library(stats)
pairwise.t.test(df$y, df$fact, p.adj=c("none"))
##
## Pairwise comparisons using t tests with pooled SD
##
## data: df$y and df$fact
##
## 1 2
## 2 0.6813 -
## 3 0.0067 0.0028
##
## P value adjustment method: none
```

Veiem que hi ha diferències entre els nivells 1 i 2 i el nivell 3. No obstant això, cal remarcar que, en el cas d'un disseny amb a tractaments, hi ha $a(a-1)/2$ comparacions per parelles de tractaments diferents. Si estem interessats a fer tots els contrastos per parelles, cal emprar tècniques d'inferència simultània per ajustar els p -valors obtinguts mitjançant el test anterior.

1.7. Contrastos múltiples

1.7.1. Test de Bonferroni

Comencem amb un exemple. Suposem que tenim un conjunt de contrastos d'hipòtesis que volem testar simultàniament. La primera idea que se'ns pot ocórrer és fer cada contrast per separat usant un cert nivell de significació ϵ .

A primera vista, això no sembla una mala idea. No obstant això, considerem que tenim vint hipòtesis per testar i un nivell de significació del 5 %. Quina és la probabilitat de declarar almenys un resultat significatiu per atzar?

$$\begin{aligned} P(\text{almenys un resultat significatiu}) &= 1 - P(\text{cap resultat significatiu}) \\ &= 1 - (1 - 0,05)^{20} \sim 0,64 \end{aligned}$$

Per tant, resulta que amb vint contrastos tenim el 64 % de probabilitats d'acceptar almenys un resultat significatiu fins i tot si totes les proves d'hipòtesis no són realment significatives.

Els mètodes per fer front a les comparacions múltiples amb freqüència plantegen ajustar el nivell de significació ϵ d'alguna manera perquè la probabilitat d'observar almenys un resultat significatiu a causa de l'atzar es mantingui per sota del nivell de significació desitjat ϵ .

El mètode de Bonferroni corregeix el nivell de significació al punt de tall $\frac{\epsilon}{n}$, i n és el nombre de contrastos que cal fer. Per exemple, en l'exemple anterior, amb $n = 20$ contrastos i nivell de significació $\epsilon = 0,05$, rebutjaríem hipòtesis nul·les en el test de les quals el p -valor fos inferior a $0,05 / 20 = 0,0025$.

La correcció de Bonferroni tendeix a ser una mica conservadora. Per exemple, si calculem la probabilitat d'acceptar almenys un resultat significatiu per atzar quan usem la correcció, això és,

$$P(\text{almenys un resultat significatiu}) = 1 - P(\text{cap resultat significatiu}) \\ = 1 - (1 - 0,0025)^{20} \sim 0,0488$$

En aquest exemple, estem solament una mica per sota del 0,05 desitjat. En les aplicacions pràctiques, la correcció de Bonferroni podria ser extremadament conservadora, la qual cosa portaria a una taxa alta de falsos negatius (mantenir H_0 quan és falsa).

Exemple 1 (continuació)

Seguim amb l'exemple anterior. Fem les comparacions múltiples amb la correcció de Bonferroni. Usem el paquet `agricolae` i la funció `LSD.test`. Comentem les dues opcions de l'argument `group`. Comencem amb l'opció `FALSE`.

```
library(agricolae)
## Warning: package 'agricolae' was built under R version 3.5.3
LSD.test(results,"fact",group=F,p.adj="bonferroni",console=T)
##
## Study: results ~ "fact"
##
## LSD t Test for y
## P value adjustment method: bonferroni
##
## Mean Square Error: 7.6
##
## fact, means and individual ( 95 %) CI
##
## y std r LCL UCL Min Max
## 1 16.33333 2.804758 6 13.93447 18.73220 13 20
## 2 15.66667 3.141125 6 13.26780 18.06553 12 20
## 3 21.33333 2.250926 6 18.93447 23.73220 19 25
##
## Alpha: 0.05 ; DF Error: 15
## Critical Value of t: 2.693739
##
## Comparison between treatments means
##
## difference pvalue signif. LCL UCL
## 1 - 2 0.6666667 1.0000 -3.620810 4.9541430
## 1 - 3 -5.0000000 0.0202 * -9.287476 -0.7125237
```

```
## 2 - 3 -5.6666667 0.0085 ** -9.954143 -1.3791903
```

En la part superior dels resultats, observem els intervals de confiança per a la mitjana de cada tractament. En la part inferior trobem llistats els contrastos per a totes les comparacions per parelles i també els IC per a les diferències de mitjanes. Els contrastos significatius apareixen marcats amb asteriscos d'acord amb la correcció de Bonferroni.

Si establim l'opció TRUE en l'argument group, obtenim un llistat una mica diferent referent a les comparacions per parelles.

```
LSD.test(results,"fact",group=T,p.adj="bonferroni",console=T)
##
## Study: results ~ "fact"
##
## LSD t Test for y
## P value adjustment method: bonferroni
##
## Mean Square Error: 7.6
##
## fact, means and individual ( 95 %) CI
##
## y std r LCL UCL Min Max
## 1 16.33333 2.804758 6 13.93447 18.73220 13 20
## 2 15.66667 3.141125 6 13.26780 18.06553 12 20
## 3 21.33333 2.250926 6 18.93447 23.73220 19 25
##
## Alpha: 0.05 ; DF Error: 15
## Critical Value of t: 2.693739
##
## Minimum Significant Difference: 4.287476
##
## Treatments with the same letter are not significantly different.
##
## y groups
## 3 21.33333 a
## 1 16.33333 b
## 2 15.66667 b
```

En aquest cas, es fa ús d'una codificació amb lletres. Aquells grups en què no hi ha diferències significatives es codifiquen amb la mateixa lletra. Es distingeixen dos grups: el grup a amb el tractament 3 i el grup b amb els tractaments 1 i 2. Interpretem els resultats de la manera següent. El tipus de programari 3 requereix un temps de capacitació significativament major que els tipus 1 i 2. No hi ha diferències significatives en el temps de capacitació dels tipus 1 i 2.

1.8. Comprovació de les suposicions del model

En resum, mitjançant l'ANOVA analitzem les dades experimentals comparant les respostes mitjanes en els diferents tractaments i, en cas de detectar diferències significatives, procedim a una anàlisi més detallada basada en comparacions per parelles o altres contrastos.

Tots aquests procediments estadístics es basen en la suposició que les dades s'ajusten al model:

$$y_{ij} = \mu + \alpha_i + e_{ij}$$

en què μ , α_i són paràmetres (quantitats fixes però desconegudes) i e_{ij} són variables aleatòries independents i distribuïdes segons una normal de mitjana 0 i variància constant σ^2 . Per tant, serà necessari revisar si aquestes suposicions se satisfan raonablement.

Les tres suposicions bàsiques que hem de validar són que els errors e_{ij} són:

- incorrelacionats (independents en cas de normalitat)
- distribuïts segons una normal
- amb variància constant (no varien amb els tractaments)

La suposició d'independència és la més important i difícil de corregir en cas que no es compleixi. És el disseny de l'experiment, una adequada aleatorització en l'assignació dels tractaments i, en fi, cada pas de l'experiment, que ha d'assegurar-nos que les observacions són independents. En aquest tema ens centrarem en la validació de les altres dues suposicions: normalitat i variància constant. Veurem que la suposició de normalitat, si bé important, pot relaxar-se en cas de mostres grans. La condició de variància constant (també anomenada condició d'homoscedasticitat), si no es compleix, pot afectar les nostres inferències. No obstant això, la falta d'homoscedasticitat es pot corregir en moltes situacions.

A continuació es consideren diferents mètodes de diagnòstic i possibles correccions quan els supòsits de modelització no es compleixen.

Fins a un cert punt podria semblar que «forcem la màquina» perquè estudiarem una sèrie de transformacions amb la finalitat que els nostres models lineals, amb errors distribuïts normalment, siguin aplicables a molts tipus de dades. Cal dir que hi ha altres metodologies que podríem usar en lloc seu, per exemple, els models lineals generalitzats, els mètodes robustos, els mètodes de permutacions o els mètodes no paramètrics basats en rangs. De fet, per a certs tipus de dades, alguns d'aquests mètodes alternatius poden ser considerablement més eficients (per exemple, produir intervals de confiança més curts amb el mateix nivell de confiança) que el model lineal basat en la distribució normal.

1.8.1. Avaluació del compliment dels supòsits de modelització

Pot ser que les suposicions d'independència, distribució normal dels errors amb variància constant, no es compleixin per complet en dades reals. No obstant això, els models lineals produeixen bones inferències sempre que la desviació dels supòsits no sigui massa gran. Per aquest motiu, podem utilitzar mètodes gràfics i descriptius per avaluar el grau de compliment de les suposicions en lloc de testar. Però, com veurem, també disposem de tests estadístics per a aquesta finalitat.

Avaluem el compliment de les suposicions sobre els errors aleatoris basant-nos en els residus. Els residus r_{ij} són donats per la diferència entre el valor observat y_{ij} i el valor ajustat segons el model per a aquesta observació. En el cas de l'ANOVA d'un factor, el valor ajustat per a l'observació y_{ij} és $\bar{y}_{i\cdot}$. Per tant, per a cada dada obtenim un residu donat per

$$r_{ij} = y_{ij} - (\hat{\mu} + \hat{\alpha}_i) = y_{ij} - \bar{y}_{i\cdot}$$

Els residus r_{ij} són una mostra de la variable aleatòria e_{ij} . Segons les suposicions del model, s'assumeix que $e_{ij} \sim N(0, \sigma^2)$; per tant, serà estudiant els residus que podrem validar els supòsits del model.

Exemple 1 (continuació)

Ens hem preguntat si el factor «tipus de programari» era significatiu en el sentit que el temps de capacitació és afectat per aquest factor. Hem plantejat el contrast d'hipòtesi

$$\begin{aligned} H_0: & \alpha_1 = \alpha_2 = \alpha_3 = 0 \\ H_1: & \alpha_i \neq \alpha_j \text{ per a algun } i \neq j \end{aligned}$$

Per resoldre-ho, hem calculat la taula ANOVA:

```
results<-lm(y~fact,data=df)
```

Hem extret la taula ANOVA així:

```
taov<-anova(results)
taov
## Analysis of Variance Table
##
## Response: y
## Df Sum Sq Mean Sq F value Pr(>F)
## fact 2 115.11 57.556 7.5731 0.005326 **
## Residuals 15 114.00 7.600
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Hem obtingut un p -valor 0.005, clarament inferior a un nivell de significació del 5 %. Per tant, acceptem la hipòtesi alternativa i concloem que el factor és significatiu.

Recordem que les mitjanes de cada grup i són:

```
tapply(y,fact,mean,data=df)
## 1 2 3
## 16.33333 15.66667 21.33333
```

Per calcular els residus, recordem que cada residu es calcula: $r_{ij} = y_{ij} - \bar{y}_{i\cdot}$. Per exemple, el residu de l'observació corresponent a la primera rèplica del primer nivell, és a dir, $i = 1$ i $j = 1$ serà:

$$y_{11} - \bar{y}_{1\cdot} = 20 - 16.333 = 3.667$$

Amb la funció `residuals` podem extreure tots els residus de l'objecte de tal manera que de cada observació obtenim el seu residu:

```
residuals(results)
## 1 2 3 4 5 6
## 3.666667 0.666667 -1.333333 2.666667 -2.333333 -3.333333
## 7 8 9 10 11 12
## 2.333333 1.333333 -1.666667 4.333333 -2.666667 -3.666667
## 13 14 15 16 17 18
## 1.666667 3.666667 -1.333333 -0.333333 -2.333333 -1.333333
```


1.8.2. Avaluació de la normalitat

Els qqplot són un procediment gràfic per avaluar la normalitat. Són útils en el diagnòstic de desviacions de la normalitat perquè permeten comparar els quantils de la distribució dels residus de les dades amb els quantils d'una distribució normal estàndard. Si s'aprecien desviacions de la linealitat, això serà indicatiu que la normalitat no es compleix.

Exemple 1 (continuació)

Podem obtenir un qqplot dels residus mitjançant la funció `qqnorm`

```
qqnorm(residuals(results))  
qqline(residuals(results))
```



Observem que la majoria dels residus s'ajusten a la recta, per la qual cosa no hi ha evidència en contra del supòsit de normalitat. Alternativament, podem obtenir el qqplot utilitzant la `plot.lm` i demanant l'*slot* 2, és a dir, `plot(results, which=2)`.

Adicionalment, podem contrastar la normalitat mitjançant el test de Shapiro-Wilk (en el qual la hipòtesi nul·la és la que afirma que la distribució és normal):

```
shapiro.test(residuals(results))  
##  
## Shapiro-Wilk normality test  
##  
## data: residuals(results)  
## W = 0.92953, p-value = 0.1905
```

En vista del p -valor obtingut, mantenim la hipòtesi nul·la i podem acceptar que la variable aleatòria e_{ij} segueix una distribució normal. Cal assenyalar que hem d'aplicar la funció `shapiro.test` als residus, i observem que serà equivocat aplicar-la a les observacions y_{ij} .

1.8.3. Avaluació del compliment de la constància de la variància (homoscedasticitat)

Avaluem la constància de la variància mitjançant un *plot* dels residus r_{ij} en l'eix vertical sobre els valors ajustats (*fitted values*) en l'eix horitzontal. El valor ajustat d'una observació és, en l'ANOVA d'un factor, la mitjana del grup al qual correspon l'observació. Per tant, per a totes les observacions que corresponen al nivell i , el valor ajustat és $\bar{y}_{i\cdot}$.


Per exemple, amb les dades de l'exemple, totes les observacions que corresponen al nivell 2, el valor ajustat és la mitjana del nivell 2: $\bar{y}_{2\cdot} = 15.667$.

En aquest tipus de gràfic de residus apareixeran tires verticals de punts, una tira per cada nivell. Si la variància és constant, l'extensió vertical de les tires serà aproximadament la mateixa. Si la variància no és constant, apareixerà un patró en la dispersió vertical dels residus. És a dir, els nivells de tractament mostraran una disposició dels residus amb diferent dispersió vertical.

Un patró habitual quan no es compleix la suposició de variància constant és el que apareix en el cas que la variància depèn de la mitjana del grup. En general, en aquests casos hi ha un augment de la variància a mesura que la mitjana del grup augmenta. En conseqüència, el gràfic de residus mostra una obertura a la dreta en forma d'embut.

Continuem analitzant les dades de l'exemple. Podem obtenir un gràfic de residus utilitzant la funció `plot.lm` i demanant l'*slot* 1.

```
plot(results, which=1)
```



Observem tres tires verticals de punts que estan situades en les mitjanes de cada grup. Com hem dit, aquestes corresponen als valors ajustats de les observacions. La disposició dels residus mostra una dispersió semblant en cada tira. Per tant, no s'aprecia efecte d'embut.

Adicionalment, podem testar l'homogeneïtat de variàncies mitjançant el test de Bartlett, que és aplicable en cas de normalitat. La hipòtesi nul·la és la d'homogeneïtat de variàncies pels nivells. Això és:

$$H_0 : \alpha_1 = \alpha_2 = \alpha_3 = 0$$

$$H_1 : \alpha_i \neq \alpha_j \text{ per a algun } i \neq j$$

Continuem analitzant les dades de l'exemple. Avaluem l'homogeneïtat de les variàncies.

```
bartlett.test(y~fact,data=df)
##
## Bartlett test of homogeneity of variances
##
## data: y by fact
## Bartlett's K-squared = 0.50494, df = 2, p-value = 0.7769
```

En vista del p -valor, mantenim la hipòtesi nul·la i acceptem que les variàncies són iguals.

1.8.4. Correcció de l'incompliment de les condicions

1) Correcció de la no-normalitat

La no-normalitat, sobretot deguda a l'asimetria, de vegades pot ser disminuïda amb la transformació de la variable resposta a una escala diferent. L'asimetria cap a la dreta és reduïda per una arrel quadrada, un logaritme o una altra transformació a una potència menor que u , mentre que l'asimetria a l'esquerra és reduïda per un quadrat, un cub o una altra transformació a una potència major que u .

2) Correcció de la no-constància de la variància

La manera habitual de solucionar la no-constància de la variància és amb la transformació de la variable resposta. Per a algunes distribucions, hi ha transformacions estàndards que igualen o estableixen la variància. Hi ha una teoria general de les transformacions estabilitzadores de la variància que s'aplica a les distribucions en què la variància depèn de la mitjana.

Quan no tenim una distribució amb una transformació coneguda per estabilitzar la variància (i en general no la tenim), se sol assajar una família de transformacions de potència. El mètode de Box-Cox estableix un procediment per determinar la transformació de potència a partir de les dades. La família de transformacions de Box-Cox són donades per

$$y^{(\lambda)} = \begin{cases} \frac{y^\lambda - 1}{\lambda y^{\lambda-1}} & \lambda \neq 0 \\ y \log(y) & \lambda = 0 \end{cases}$$

en què y és la mitjana geomètrica de la variable resposta.

La tècnica de Box-Cox transforma les dades (variable resposta) explorant un rang de valors de λ i fent una ANOVA per a cada transformació (és a dir, per a cada valor de λ). En cada ANOVA obtenim una suma de quadrats de l'error (SSE) que dependrà de la λ usada, $SSI(\lambda)$. La millor transformació λ^* serà aquella per la qual l' $SSE(\lambda)$ assoleix el mínim.

Per implementar la tècnica de Box-Cox, utilitzarem la funció `boxcox` del paquet `MAS`.

Utilitzem un altre exemple en què serà necessari aplicar la tècnica de Box-Cox.

Exemple 2

La vida útil de les carns emmagatzemades és el temps en què un tall envasat prèviament és sa, nutritiu i vendible. Un paquet normal exposat a l'aire ambiental té una vida aproximada de 48 hores, després de les quals la carn comença a deteriorar-se per contaminació de microbis, degradació del color i encongiment. L'envàs al buit és efectiu per suprimir el desenvolupament de microbis; no obstant això, els altres aspectes continuen essent un problema.

Alguns estudis recents suggereixen les atmosferes controlades de gas com a alternativa als envasos actuals. Dues atmosferes que prometen combinar la capacitat de suprimir el desenvolupament de microbis amb la conservació de les qualitats de la carn són: 1) diòxid de carboni pur (CO_2), i 2) mescles de monòxid de carboni (CO), oxigen (O) i nitrogen (N). Segons aquesta nova informació, un equip investigador planteja la hipòtesi que alguna forma d'atmosfera controlada proporcionaria un entorn d'envasament més efectiu per emmagatzemar carn.

El disseny de l'experiment desenvolupat per l'equip investigador per avaluar la hipòtesi inclou diversos tipus d'envasaments: 1) aire de l'ambient amb un envasament comercial de plàstic; 2) el buit; 3) una mescla de gasos amb 1 % CO , 40 % O i 59 % N , i 4) 100 % CO_2 . Els envasos amb l'aire de l'ambient i al buit serveixen com a tractaments de control, ja que tots dos són estàndards amb l'efectivitat dels quals es pot comparar la dels nous envasaments.

S'usa un disseny aleatoritzat totalment per a l'experiment. A cada conjunt de condicions d'envasament s'assigna a l'atzar talls de la mateixa grandària (75 g). Cada tall s'envasa per separat en les condicions assignades.

S'avalua l'efectivitat de cada tractament per suprimir el desenvolupament bacterià. Després de nou dies d'emmagatzematge a 4 °C en una instal·lació normal, es va mesurar el nombre de bacteris psicotròpics a la carn. Els bacteris psicotròpics es troben a la superfície de la carn i s'associen amb la carn deteriorada. El creixement bacterià s'expressa com el nombre de bacteris (en milions) per centímetre quadrat.

Atmosfera			
Comercial	45,7	9,5	63,1
Al buit	0,2	0,7	0,6
Barreja de gasos	25,1	21,3	10,9
CO_2	0,09	0,25	0,004

1.8.5. Formulació del model estadístic per analitzar les dades de l'experiment anterior


La variable resposta y_{ij} és el nombre de bacteris psicotròpics. El factor és el tractament, que té quatre nivells (envasament comercial, al buit, mescla de gasos i diòxid de carboni), i hi ha tres rèpliques per nivell. Formulem el model lineal


$$y_{ij} = \mu + \alpha_i + e_{ij}$$

amb la restricció $\sum_{i=1}^4 \alpha_i = 0$. Assumim que e_{ij} segueix la distribució $N(0, \sigma^2)$, on σ^2 és constant a través dels grups. Les observacions són independents.

1.8.6. Avaluació de les suposicions de modelització (normalitat i homoscedasticitat)

```
env<-c("Comercial", "Comercial", "Comercial", "Al vacío", "Al vacío",
      "Al vacío", "Mezcla de gases", "Mezcla de gases", "Mezcla de gases",
      "co2", "co2", "co2")
bact<-c(45.7, 9.5, 63.1, 0.2, 0.7, 0.6,
       25, 21, 10, 0.09, 0.25, 0.004)
df<-data.frame(bact, env)
results<-aov(bact~env, data=df)
plot(results, which=c(1,2))
```






```
shapiro.test(residuals(results))
##
## Shapiro-Wilk normality test
##
## data: residuals(results)
## W = 0.81445, p-value = 0.01374
bartlett.test(bact~env,data=df)
##
## Bartlett test of homogeneity of variances
##
## data: bact by env
## Bartlett's K-squared = 28.696, df = 3, p-value = 2.594e-06
```

En vista dels resultats, **no** es compleixen els supòsits de modelització. És necessari aplicar una transformació.

1.8.7. Transformació de la variable resposta (nombre de bacteris per cm²) per prosseguir l'anàlisi de les dades

```
library(MASS)
## Warning: package 'MASS' was built under R version 3.5.3
bct<-boxcox(bact~env,lambda = seq(-1, 1, length = 10),data=df,plotit=T)
```





```
lambda<-bct$x[which.max(bct$y)]
lambda
## [1] 0.1313131
library(psych)
## Warning: package 'psych' was built under R version 3.5.3
gm<-geometric.mean(bact)
gm
## [1] 1.790726
df$bactt<- (bact^lambda-1) / (lambda*gm^(lambda-1))
```

Amb això hem afegit una nova variable al `data.frame` amb la variable resposta corregida.

1.8.8. Verificació de l'adequació

```
results<-aov(bactt~env,data=df)
plot(results,which=c(1,2))
```



```
shapiro.test(residuals(results))
##
## Shapiro-Wilk normality test
##
## data: residuals(results)
## W = 0.89049, p-value = 0.1196
bartlett.test(bactt~env,data=df)
##
```

```
## Bartlett test of homogeneity of variances
##
## data: bactt by env
## Bartlett's K-squared = 2.0049, df = 3, p-value = 0.5714
```

Una vegada estimada la λ òptima, la transformació corregeix clarament els incompliments anteriors.

1.8.9. Avaluar si hi ha diferències significatives entre els tractaments

Una vegada transformada la variable, analitzarem la significació del factor envasat.

```
results<-aov(bactt~env,data=df)
anova(results)
## Analysis of Variance Table
##
## Response: bactt
## Df Sum Sq Mean Sq F value Pr(>F)
## env 3 265.500 88.500 25.401 0.0001927 ***
## Residuals 8 27.873 3.484
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

S'observa que el factor tipus d'envasament és significatiu.

1.8.10. Estimació dels paràmetres del model

```
model.tables(results,type="means")
## Tables of means
## Grand mean
##
## 1.932156
##
## env
## env
## Al vacío co2 Comercial Mezcla de gases
## -1.268 -4.014 7.239 5.771
model.tables(results,type="effects")
## Tables of effects
##
## env
## env
## Al vacío co2 Comercial Mezcla de gases
## -3.200 -5.946 5.307 3.839
anova(results)[2,3]
```

```
## [1] 3.484101
```

1.8.11. Es pot recomanar un tractament que millori els tractaments usuals?

Haurem de fer comparacions múltiples.

```
library(agricolae)
LSD.test(results,"env",group=T,p.adj="bonferroni",console=T)
##
## Study: results ~ "env"
##
## LSD t Test for bactt
## P value adjustment method: bonferroni
##
## Mean Square Error: 3.484101
##
## env, means and individual ( 95 %) CI
##
## bactt std r LCL UCL Min
## Al vacío -1.268048 0.9933341 3 -3.753153 1.217057 -2.406541
## co2 -4.013854 2.2643418 3 -6.498960 -1.528749 -6.514602
## Comercial 7.239082 2.5465278 3 4.753977 9.724188 4.345194
## Mezcla de gases 5.771443 1.1565648 3 3.286337 8.256548 4.459934
## Max
## Al vacío -0.578023
## co2 -2.102466
## Comercial 9.137538
## Mezcla de gases 6.645374
##
## Alpha: 0.05 ; DF Error: 8
## Critical Value of t: 3.478879
##
## Minimum Significant Difference: 5.301992
##
## Treatments with the same letter are not significantly different.
##
## bactt groups
## Comercial 7.239082 a
## Mezcla de gases 5.771443 a
## Al vacío -1.268048 b
## co2 -4.013854 b
HSD.test(results,"env",group=T,console=T)
##
## Study: results ~ "env"
##
## HSD Test for bactt
```

```
##
## Mean Square Error: 3.484101
##
## env, means
##
## bactt std r Min Max
## Al vacío -1.268048 0.9933341 3 -2.406541 -0.578023
## co2 -4.013854 2.2643418 3 -6.514602 -2.102466
## Comercial 7.239082 2.5465278 3 4.345194 9.137538
## Mezcla de gases 5.771443 1.1565648 3 4.459934 6.645374
##
## Alpha: 0.05 ; DF Error: 8
## Critical Value of Studentized Range: 4.52881
##
## Minimum Significant Difference: 4.88055
##
## Treatments with the same letter are not significantly different.
##
## bactt groups
## Comercial 7.239082 a
## Mezcla de gases 5.771443 a
## Al vacío -1.268048 b
## co2 -4.013854 b
```

Observem que els tractaments al buit i amb CO₂ formen un grup homogeni que provoca una reducció significativa del nombre de bacteris respecte als altres tractaments.

1.9. Test de remostreig per l'ANOVA

A vegades, la suposició de normalitat del terme aleatori no és plausible. En aquest cas, és impossible aplicar la prova F en el contrast de la significació dels efectes del tractament. En aquests casos, es poden aplicar tècniques basades en el remostreig.

El procediment bàsic és el següent:

- Calcular el valor de F per a les dades experimentals (anomenem-lo F_{obs}).
- Triar B mostres, cada una de les quals és una permutació aleatòria de les dades originals.
- Per a cada mostra, assignar les primeres observacions n_1 al primer tractament, les següents observacions n_2 al segon tractament, i així successivament.

- Per cada remostreig, calcular F a partir de les dades.
- Si $F > F_{obs}$, incrementar un comptador.
- Calcular p dividint el resultat en el comptador per B després de completar el remostreig.
- Si la hipòtesi nul·la fos certa, p representaria la probabilitat d'obtenir una F tan gran com la que vam obtenir amb les nostres dades experimentals.
- Rebutjar la hipòtesi nul·la si $p < p_{\alpha}$, on α és el nivell de significació.

Exemple 3

Es va fer un experiment per determinar l'efecte de les bombolles d'aire sobre la resistència de l'asfalt. Per a finalitats de l'experiment, les bombolles es controlen en tres nivells: baix (2-4 %), mitjà (4-6 %) i alt (6-8 %). Les dades obtingudes apareixen en la taula següent.

Bombolles d'aire								
Baix	106	90	103	90	79	88	92	95
Mitjà	80	69	94	91	70	83	87	83
Alt	78	80	62	69	76	85	69	85

¿Els diferents nivells de bombolles d'aire afecten de manera significativa en la resistència de l'asfalt? Prendre $\alpha = 0.05$. Resoldre el problema mitjançant un test de remostreig.

Per implementar un test de remostreig en R, podem carregar el paquet de R `coin` i anomenar la funció `oneway_test()`, i mitjançant l'argument `distribution=approximate(nresample=9999)` indicarem que el remostreig es basa en 9.999 permutacions de les observacions.

```
library(coin)
## Warning: package 'coin' was built under R version 3.5.3
## Loading required package: survival
## Warning: package 'survival' was built under R version 3.5.3
df<-data.frame(y=c(106,90,103,90,79,88,92,95,80,69,94,91,70,83,87,83,78,80,62,69,76,85,69,85),
  b= c(rep("1. Bajo",8), rep("2. Medio",8), rep("3. Alto",8) ) )
str(df)
## 'data.frame': 24 obs. of 2 variables:
## $ y: num 106 90 103 90 79 88 92 95 80 69 ...
## $ b: Factor w/ 3 levels "1. Bajo","2. Medio",...: 1 1 1 1 1 1 1 1 2 2 ...
set.seed(1234)
oneway_test(y~b,data=df,distribution=approximate(nresample=9999))
##
## Approximative K-Sample Fisher-Pitman Permutation Test
##
## data: y by b (1. Bajo, 2. Medio, 3. Alto)
## chi-squared = 10.156, p-value = 0.0029
```

Resulta un p -valor de 0.0029, inferior al nivell de significació. Per tant, rebutgem la igualtat dels efectes. Hi ha diferències significatives de la resistència de l'asfalt segons el nivell de bombolles d'aire.

1.10. Test no paramètric basat en rangs

La prova de Kruskal-Wallis no assumeix normalitat en les dades, en oposició a la tradicional ANOVA. Sí que assumeix, en la hipòtesi nul·la, que les dades venen de la mateixa distribució. Una manera comuna de violar aquest supòsit és amb dades heteroscedàstiques.

Siguin $n_1, n_2, \dots, n_k$ les grandàries de cadascun dels tractaments i N el total d'observacions. Per calcular l'estadístic de test, s'ordenen les n observacions de menor a major i se'ls assignen rangs des d'1 fins a n . Si la hipòtesi nul·la és certa, s'espera que el rang mitjà sigui aproximadament igual per als k tractaments; quan aquestes mitjanes són molt diferents, és un indicatiu que H_0 és falsa.

L'estadístic de prova és:


$$K = \frac{12}{N(N+1)} \left(\sum_{i=1}^k \frac{R_i^2}{n_i} \right) - 3(N+1)$$

en què R_i és la suma de rangs de les observacions corresponents al grup i . La distribució en la hipòtesi nul·la de l'estadístic és, aproximadament, χ^2_{k-1} , que requereix un mínim de cinc observacions per mostra.

Exemple 3 (continuació)

Analitzem les dades de l'exemple 3, en el qual s'ha fet un experiment per determinar l'efecte de les bombolles d'aire sobre la resistència de l'asfalt amb el test de Kruskal-Wallis.

```
kruskal.test(y~b,data=df)
##
## Kruskal-Wallis rank sum test
##
## data: y by b
## Kruskal-Wallis chi-squared = 10.578, df = 2, p-value = 0.005047
boxplot(y~b,data=df,xlab="% de burbujas", ylab="Resistencia asfalto")
```



Resulta un p -valor de 0.005, inferior al nivell de significació. Per tant, acceptem que hi ha diferències significatives de la resistència de l'asfalt segons el nivell de bombolles d'aire. El gràfic suggereix que la resistència de l'asfalt decreix a mesura que augmenta el percentatge de bombolles d'aire.

2. Anàlisi de la variància de dos factors

Fins ara hem estat treballant amb dissenys totalment aleatoritzats, en els quals els a tractaments eren assignats a les unitats experimentals. Els tractaments no tenien estructura: eren solament tractaments.

Diem que hi ha una estructura factorial de tractaments quan un experiment combina els nivells de dos o més factors per crear els tractaments. Quan els tractaments són les combinacions dels nivells de dos o més factors, no canviem l'assignació aleatoritzada; la diferència és solament que ara considerem tractaments que tenen una estructura factorial.

En particular, ara considerarem dissenys experimentals amb dos factors. A més, ens centrarem en dissenys equilibrats, és a dir, en experiments amb n observacions en cadascuna de les combinacions dels nivells dels factors.

2.1. Efectes principals i interacció

Utilitzem la notació y_{ijk} per indicar les respostes en un disseny factorial de dos factors. Amb aquesta notació, y_{ijk} és la rèplica k en la condició experimental corresponent a la combinació del nivell i del factor A amb el nivell j del factor B .

Podem organitzar les dades en forma de taula.

	B 1	B 2	B 3
A1	y_{111} $\vdots$ y_{11n}	y_{121} $\vdots$ y_{12n}	y_{131} $\vdots$ y_{13n}
A2	y_{211} $\vdots$ y_{21n}	y_{221} $\vdots$ y_{22n}	y_{231} $\vdots$ y_{23n}
A3	y_{311} $\vdots$ y_{31n}	y_{321} $\vdots$ y_{32n}	y_{331} $\vdots$ y_{33n}
A4	y_{411} $\vdots$ y_{41n}	y_{421} $\vdots$ y_{42n}	y_{431} $\vdots$ y_{43n}

Si oblidem per un moment el factor B i considerem solament el factor A (files en la taula), estarem en un disseny d'un factor. Com en el tema anterior, podríem calcular la variabilitat de la resposta atribuïble al A mitjançant la corresponent suma de quadrats SSA , considerant solament els nivells del factor

A . El valor esperat per a la resposta per a la fila i és: $\mu_i = \mu + \alpha_i$, $\sum_{i=1}^a \alpha_i = 0$.

Podem revertir la funció dels factors A i B i considerar el factor B (columnes en la taula). Com en el tema anterior, podríem calcular la variabilitat de la resposta atribuïble al factor B mitjançant la corresponent suma de quadrats SSB , considerant solament els nivells de B . El valor esperat per a la resposta per

a la columna j és: $\mu_j = \mu + \beta_j$, $\sum_{j=1}^b \beta_j = 0$.

Els efectes α_i i β_j s'anomenen efectes principals dels factors A i B respectivament. Els efectes principals del factor A mesuren la variabilitat deguda solament als nivells del factor A (files en la matriu de dades). Els efectes principals del factor B mesuren la variabilitat deguda solament als nivells del factor B (columnes en la matriu de dades). Anàlogament, les sumes SSA i SSB són les anomenades sumes de quadrats dels efectes principals del factor A i del factor B respectivament.

La variabilitat explicada pels efectes principals és la variabilitat que té lloc per les files o per les columnes de la matriu de dades. Hi ha una altra variabilitat per descriure, que és la variabilitat que té lloc en canviar files i columnes simultàniament. Anomenem aquesta variabilitat la interacció entre els factors A i B , i la denotem mitjançant $SSAB$.

L'efecte principal de les files ens diu com canvia la resposta quan ens movem d'una fila a una altra, fent la mitjana en totes les columnes. L'efecte principal de les columnes ens diu com canvia la resposta quan es passa d'una columna a una altra, fent la mitjana en totes les files.

La interacció ens diu com el canvi en la resposta depèn de columnes quan es mou entre les files, o com el canvi en resposta depèn de files quan es mou entre les columnes. En altres paraules, la interacció entre els factors A i B ens diu el canvi en la resposta mitjana en passar del nivell i_1 del factor A al nivell i_2 del factor A , depenent del nivell de factor B en consideració. No podem dir simplement que en canviar de nivell del factor A —això comporta un cert canvi de la resposta per una quantitat donada— és possible que tinguem una quantitat diferent de canvi segons quin sigui el nivell del factor B .


Exemple 4

Un equip investigador analitza si hi ha diferències en els nivells de calci en plasma (mg Ca ml⁻¹) entre sexes en una espècie d'ocells que han rebut o no un tractament hormonal.

```
conc<-c(16.5, 14.5, 39.1, 32.0,18.4, 11.0, 26.2, 23.8,12.7, 10.8, 21.3,
 28.8,14.0, 14.3, 35.8, 25.0,12.8, 10.0, 40.2, 29.3)
hormone<-rep(c("Treatment","Treatment","No Treatment","No Treatment"),5)
gender<-rep(c("Female","Male"),10)
df<-data.frame(conc,hormone,gender)
```

Podem utilitzar la funció `interaction.plot` per estudiar la interacció dels factors principals.


```
interaction.plot(hormone,gender,conc)
```



En l'eix X apareixen els dos nivells del factor tractament, i en l'eix Y apareix la mitjana de la variable resposta (calci en plasma). Estrictament, el gràfic es basa en les quatre mitjanes per a les quatre condicions experimentals, però s'uneixen mitjançant línies les mitjanes que corresponen al mateix nivell del factor que no està representat en l'eix X. Veiem que tant en mascles com en femelles els nivells de calci són majors en el grup no tractat amb hormona. També observem que les femelles tenen major calci en plasma que els mascles en qualsevol dels dos tractaments. Constatem que el descens de calci en plasma entre sexes és aproximadament el mateix en els dos tractaments. Les línies apareixen paral·leles i direm que no s'aprecia interacció.

Podem intercanviar els factors en la representació de la interacció. Arribem a conclusions similars.

```
interaction.plot(gender, hormone,conc)
```




Exemple 5

Un departament de control de qualitat vol comprovar si la marca del detergent per a roba usat i la temperatura de rentatge afecten la quantitat de brutícia eliminada de la roba, quantitat mesurada en una escala convenient, per exemple, nombre de taques que desapareixen. A aquest efecte, es comparen dues marques de detergent (A i B) i es fixen tres nivells de temperatura (freda, temperada i calenta). A continuació, es divideix la roba a l'atzar en sis piles amb quatre peces per combinació dels nivells.

```
reduccion<-c(4,5,6,5,7,9,8,12,10,12,11,9,6,6,4,4,13,15,12,12,12,13,10,13)
temper<-rep(rep(c("frio", "templada", "caliente"),each=4),2)
deter<-rep(c("A","B"),each=12)
df<-data.frame(reduccion,temper,deter)
```

Representem la interacció.


```
interaction.plot(deter, temper, reduccion)
```



Observem que en aquest exemple hi ha interacció. Veiem que el detergent B té, a temperatura temperada, major eficàcia en la reducció de la brutícia. Les rectes no són paral·leles.

Arribem a la mateixa conclusió si intercanviem els factors en el gràfic d'interacció.

```
interaction.plot(temper, deter, reduccion)
```



Observacions

Fixeu-vos que l'exemple 4 no es correspon amb un disseny completament aleatoritzat, ja que els nivells d'un dels factors (sexe) no han estat assignats aleatòriament. El disseny ha estat el següent: primer s'han triat individus de cada sexe; posteriorment, s'han assignat a l'atzar els tractaments entre els mascles i s'ha fet el mateix entre les femelles. Dit d'una altra manera, es tracta d'un disseny aleatoritzat en el factor sexe (blocs). Això no impedeix analitzar les dades de la mateixa manera que en un disseny completament aleatoritzat, però l'efecte del factor que no s'ha pogut aleatoritzar no pot ser atribuït únicament a aquest factor, sinó a uns altres que poden estar relacionats (confusors).

2.2. Parametrització del model lineal de dos factors

En un disseny experimental de dos factors A i B , el factor A té a nivells, el factor B té b nivells, i hi ha n unitats experimentals assignades a cada combinació factor-nivell. El model és:

$$y_{ijk} = \mu + \alpha_i + \beta_j + \alpha\beta_{ij} + e_{ijk}$$

en què $i = 1, \dots, a$, $j = 1, \dots, b$, $k = 1, \dots, n$, y_{ijk} denota la resposta k en el i -èsim nivell d' A i j -èsim nivell de B , μ la mitjana general, α_i l'efecte del nivell i del factor principal A , β_j l'efecte del nivell j del factor principal B , $\alpha\beta_{ij}$ la interacció del nivell i del factor A amb el nivell j del factor B , e_{ijk} l'error independent i distribuït normalment amb mitjana zero i variància σ^2 . Hi ha un total de $N = nab$ unitats experimentals (observacions). No hem de confondre $\alpha\beta_{ij}$ amb

el producte de α_i per β_j , ja que són idees diferents. L'efecte de la interacció és una mesura de la llunyania en què les mitjanes dels tractaments difereixen de la simple additivitat.

Hi ha ab mitjanes de tractaments diferents, però tenim $1 + a + b + ab$ paràmetres, així que tenim sobreparametrització. Hem de triar un conjunt de restriccions perquè els efectes dels tractaments estiguin ben definits. Les restriccions usuals sobre els paràmetres en els models de dos factors són:

$$\sum_{i=1}^a \alpha_i = 0, \sum_{j=1}^b \beta_j = 0, \sum_{i=1}^a \alpha\beta_{ij} = 0 \quad \forall j, \sum_{j=1}^b \alpha\beta_{ij} = 0 \quad \forall i$$

Les estimacions dels paràmetres són:

- $\hat{\mu} = \bar{y}_{...}$
- $\hat{\alpha}_i = \bar{y}_{i.} - \bar{y}_{...}$
- $\hat{\beta}_j = \bar{y}_{.j} - \bar{y}_{...}$
- $\hat{\alpha}\beta_{ij} = \bar{y}_{ij.} - \bar{y}_{i.} - \bar{y}_{.j} + \bar{y}_{...}$

2.3. Anàlisi de la variància en dissenys equilibrats

L'anàlisi de la variància descansa en un algorisme per a la descomposició de la variabilitat de les dades. Hi ha una font de variabilitat per a cada terme en el model; en una anàlisi de dos factors aquests són el factor A, el factor B, la interacció AB i l'error, de tal manera que la suma de quadrats totals es descompon en la suma de quadrats de cada terme, això és:

$$SS_T = SS_A + SS_B + SS_{AB} + SS_E$$

en què

- $SS_A = bn \sum_i (\bar{y}_{i.} - \bar{y}_{...})^2$
- $SS_B = an \sum_j (\bar{y}_{.j} - \bar{y}_{...})^2$
- $SS_{AB} = n \sum_i \sum_j (\bar{y}_{ij.} - \bar{y}_{i.} - \bar{y}_{.j} + \bar{y}_{...})^2$
- $SS_E = \sum_i \sum_j \sum_k (y_{ijk} - \bar{y}_{ij.})^2$

Ara, la taula ANOVA corresponent al model de dos factors amb interacció és la següent:

Font	SS	gl	MS	F
A	SS_A	$a - 1$	$MS_A = SS_A / (a - 1)$	MS_A / MS_E
B	SS_B	$b - 1$	$MS_B = SS_B / (b - 1)$	MS_B / MS_E
AB	SS_{AB}	$(a - 1)(b - 1)$	$MS_{AB} = SS_{AB} / ((a - 1)(b - 1))$	MS_{AB} / MS_E
Error	SS_E	$(n - 1)ab$	$MS_E = SS_E / ((n - 1)ab)$	

Els tests d'hipòtesi per inferir la significació dels factors requereixen suposicions sobre els errors. Assumim que els errors e_{ijk} són independents i distribuïts normalment amb la variància constant en cadascuna de les condicions experimentals.

Quan les suposicions són veritables, els quocients F definits en la taula ANOVA són estadístics vàlids per resoldre la significació dels factors.

En aquest sentit, per testar la significació del factor A , plantejem la hipòtesi nul·la $H_0: \alpha_1 = \dots = \alpha_a = 0$ enfront de la hipòtesi alternativa que algunes α_i són diferents de zero. Per resoldre el test anterior, usem l'estadístic $F = MS_A / MS_E$ amb $(a - 1)$ i $(n - 1)ab$ graus de llibertat.

Anàlogament, per testar la significació del factor B , plantejem la hipòtesi nul·la $H_0: \beta_1 = \dots = \beta_b = 0$ enfront de la hipòtesi alternativa que algunes β_j són diferents de zero. Per resoldre el test anterior, usem l'estadístic $F = MS_B / MS_E$ amb $(b - 1)$ i $(n - 1)ab$ graus de llibertat.

De manera similar, per testar la hipòtesi que tots els termes d'interacció són nuls, usem l'estadístic $F = MS_{AB} / MS_E$ amb $(a - 1)(b - 1)$ i $(n - 1)ab$ graus de llibertat.

Exemple 5 (continuació)

Ajustem el model de dos factors amb interacció.

```
modelo <- aov(reduccion ~ temper + deter + temper:deter, data = df)
```


Fixeu-vos en l'ús de l'operador per designar el terme de la interacció en la fórmula. També és possible usar l'operador $*$, la qual cosa inclou tant el terme d'interacció com els termes principals. Així, la instrucció anterior és equivalent a

```
modelo <- aov(reduccion ~ temper*deter, data = df)
```

Validació de les suposicions

Per comprovar l'homoscedasticitat, podem fer un gràfic de residus enfront de valors ajustats i, opcionalment, un test de Bartlett per testar si la variància en les sis condicions experimentals és la mateixa. Per aplicar el test de Bartlett, hem de crear una variable nova mitjançant la funció `interaction` amb la qual crear una variable factor amb els creuaments dels nivells dels dos factors.


```
plot(modelo, which = 1)
```



```
condition <- with(df, interaction(temper, deter))
condition
## [1] frío.A frío.A frío.A frío.A templada.A templada.A
## [7] templada.A templada.A caliente.A caliente.A caliente.A caliente.A
## [13] frío.B frío.B frío.B frío.B templada.B templada.B
## [19] templada.B templada.B caliente.B caliente.B caliente.B caliente.B
## Levels: caliente.A frío.A templada.A caliente.B frío.B templada.B
bartlett.test(reduccion ~ condition, data = df)
##
## Bartlett test of homogeneity of variances
##
## data: reduccion by condition
## Bartlett's K-squared = 2.665, df = 5, p-value = 0.7515
```

Veiem que el gràfic de residus suggereix que podria haver-hi una lleugera falta d'homoscedasticitat. Sembla que com més valors de la variable resposta hi ha, major variabilitat dels residus s'aprecia. No obstant això, com que el test de Bartlett no resulta significatiu, acceptarem mantenir l'homoscedasticitat. Podem comprovar la normalitat mitjançant un qqplot i el test de Shapiro.

```
plot(modelo, which = 2) # equivalente a un qqnorm; qqline
```



```
shapiro.test(residuals(modelo))
##
## Shapiro-Wilk normality test
##
## data: residuals(modelo)
## W = 0.95256, p-value = 0.3075
```

En vista de la disposició dels quantils i del p -valor del test de Shapiro, acceptem la hipòtesi de normalitat.

Passem a resoldre els contrastos d'hipòtesis d'interès, a saber:

$$H_0: \alpha_1 = \alpha_2 = \alpha_3 = 0$$

$$H_1: \alpha_i \neq \alpha_j \text{ per a algun } i \neq j$$

$$H_0: \beta_1 = \beta_2 = 0$$

$$H_1: \beta_1 \neq \beta_2$$

$$H_0: \alpha\beta_{11} = \alpha\beta_{12} = \dots = \alpha\beta_{32} = 0$$

$$H_1: \alpha\beta_{ij} \neq \alpha\beta_{i'j'} \text{ per a algun } (i, j) \neq (i', j')$$

Haurem de calcular la taula ANOVA.

```
anova(modelo)
## Analysis of Variance Table
##
## Response: reduccion
## Df Sum Sq Mean Sq F value Pr(>F)
## temper 2 200.333 100.167 48.7297 5.44e-08 ***
## deter 1 20.167 20.167 9.8108 0.005758 **
## temper:deter 2 16.333 8.167 3.9730 0.037224 *
## Residuals 18 37.000 2.056
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Veiem que les F dels factors principals són significatives, i acceptem, per tant, que hi ha efecte de la temperatura i del detergent. També s'aprecia interacció significativa entre els nivells dels factors, la qual cosa concorda amb el patró dels gràfics d'interacció.

És interessant obtenir l'estimació dels paràmetres del model. D'una banda, l'estimació de la variància de l'error resulta de la taula ANOVA a partir dels MS_E i és, per tant:

$$\hat{\sigma}^2 = 2.056.$$

Les mitjanes per nivells i per condicions experimentals són:

```
model.tables(modelo, type = "mean")
## Tables of means
## Grand mean
##
## 9.083333
##
## temper
## temper
## caliente frío templada
## 11.25 5.00 11.00
##
## deter
## deter
## A B
## 8.167 10.000
##
## temper:deter
## deter
## temper A B
## caliente 10.5 12.0
## frío 5.0 5.0
## templada 9.0 13.0
```

I, per obtenir l'estimació dels efectes principals i interaccions, farem:

```
model.tables(modelo, type = "effects")
## Tables of effects
##
## temper
## temper
## caliente frío templada
## 2.167 -4.083 1.917
##
## deter
## deter
## A B
## -0.9167 0.9167
##
## temper:deter
## deter
## temper A B
## caliente 0.1667 -0.1667
## frío 0.9167 -0.9167
## templada -1.0833 1.0833
```

Com que els factors principals han resultat significatius, haurem de fer comparacions per parelles. Per exemple, mitjançant el test de Tukey:

```
library(agricolae)
HSD.test(modelo, "temper", console = TRUE)
##
## Study: modelo ~ "temper"
##
## HSD Test for reduccion
##
## Mean Square Error: 2.055556
##
## temper, means
##
## reduccion std r Min Max
## caliente 11.25 1.4880476 8 9 13
## frío 5.00 0.9258201 8 4 6
```

```
## templada 11.00 2.7255406 8 7 15
##
## Alpha: 0.05 ; DF Error: 18
## Critical Value of Studentized Range: 3.609304
##
## Minimum Significant Difference: 1.829545
##
## Treatments with the same letter are not significantly different.
##
## reduccion groups
## caliente 11.25 a
## templada 11.00 a
## frío 5.00 b
#HSD.test(modelo, "deter", console = TRUE)
#no sería necesario este paso pero nos va bien en la explicación
```

Detectem un grup homogeni, format pels nivells de temperatura calenta i temperada, i un segon grup format pel nivell fred.

En aquest exemple, com que el terme d'interacció és significatiu, per determinar la condició experimental òptima hem de fer comparacions múltiples de la interacció amb la finalitat de determinar la condició experimental òptima.

```
library(agricolae)
modelo1F <- aov(reduccion ~ condition)
HSD.test(modelo1F, "condition", console = TRUE)
##
## Study: modelo1F ~ "condition"
##
## HSD Test for reduccion
##
## Mean Square Error: 2.055556
##
## condition, means
##
## reduccion std r Min Max
## caliente.A 10.5 1.2909944 4 9 12
## caliente.B 12.0 1.4142136 4 10 13
## frío.A 5.0 0.8164966 4 4 6
## frío.B 5.0 1.1547005 4 4 6
## templada.A 9.0 2.1602469 4 7 12
## templada.B 13.0 1.4142136 4 12 15
##
## Alpha: 0.05 ; DF Error: 18
## Critical Value of Studentized Range: 4.49442
##
## Minimum Significant Difference: 3.221872
##
## Treatments with the same letter are not significantly different.
##
## reduccion groups
## templada.B 13.0 a
## caliente.B 12.0 ab
## caliente.A 10.5 ab
## templada.A 9.0 b
## frío.A 5.0 c
## frío.B 5.0 c
```

Observem que l'HSD.test detecta tres grups homogenis: el grup *a*, format pels tractaments temperada.B, calenta.B i calenta.A; el grup *b*, format pels tractaments calenta.B, calenta.A i temperada.A, i el grup *c*, format pels tractaments freda.A i freda.B. El tractament temperada.B no és significativament diferent de calenta.B i calenta.A, però sí que ho és de temperada.A.

2.4. Dissenys amb efectes aleatoris

Els efectes aleatoris són un altre enfocament per dissenyar experiments i modelar dades. Són apropiats quan els tractaments són mostres aleatòries d'una població de tractaments potencials.

Suposem la situació experimental següent. Una empresa disposa de cinquanta màquines que fabriquen caixes de cartró per a conserves i vol entendre la variació en la força dels cartrons. Trien deu màquines a l'atzar entre les cinquanta i fan quaranta cartrons en cada màquina assignant a l'atzar quatre-cents lots de matèria primera per a cartró a les deu màquines. Els cartrons resultants se sotmeten a proves de resistència. Aquestes proves són un disseny aleatoritzat amb deu tractaments i quatre-cents unitats.

Podem plantejar un model lineal d'un factor

$$y_{ij} = \mu + \alpha_i + e_{ij}$$

Els paràmetres μ , α_i es consideren unes constants desconegudes tals que la suma dels efectes és zero. L'objectiu principal és fer inferència sobre els paràmetres. Aquests models s'anomenen d'efectes fixos perquè els efectes dels tractaments es consideren fixos.

Els models d'efectes fixos no són apropiats per al nostre exemple dels cartrons. Continua tenint sentit descompondre la variabilitat de les dades en la mitjana general, l'efecte dels tractaments i l'error, però la suposició d'efectes fixos no té sentit per dues raons. Primera, nosaltres estem interessats a fer inferència sobre tota la població de màquines i no solament sobre les que hem mostrejat. Segona, si plantegegéssim una replicació de l'experiment, tindríem un altre conjunt aleatori de màquines. Per tant, la inferència, per exemple, sobre el paràmetre α_1 en el primer experiment no ens diria res respecte al α_1 del segon experiment, i de fet representarien probablement màquines diferents de la població.

Necessitem una nova modelització. Els components del model són els mateixos:

$$y_{ij} = \mu + A_i + e_{ij}$$

Assumim que els e_{ij} són independents amb distribució normal de mitjana zero i variància σ^2 , com en el cas dels models d'efectes fixos. En els models d'efectes aleatoris considerem que els efectes A_i són variables aleatòries amb distribució normal de mitjana zero i variància σ_A^2 , i que e_{ij} i A_i són variables aleatòries independents (usem lletres llatines per indicar que són efectes aleatoris). En conseqüència, la variable resposta y_{ij} té variància $\sigma_A^2 + 2 \sigma^2$; anomenem σ_A^2 i σ^2 les components de la variància.

Els paràmetres dels models d'efectes aleatoris són la mitjana general μ , la variància de l'error σ^2 i la variància dels efectes σ_A^2 . Els efectes A_i són variables aleatòries, no paràmetres. Per contrastar si el factor aleatori és significatiu, plantejem el contrast d'hipòtesi sobre σ_A^2 , això és:

$$H_0: \sigma_A^2 = 0$$

$$H_1: \sigma_A^2 > 0$$

La taula ANOVA en els models d'un factor amb efectes aleatoris és idèntica a la taula ANOVA d'un factor amb efectes fixos. La taula ANOVA té exactament les mateixes files (factor, residu i total) i les mateixes columnes (font de variació, suma de quadrats, graus de llibertat, quadrats mitjans i F).

Per estimar les components de la variància σ^2 i σ_A^2 , hem de tenir en compte l'esperança matemàtica dels quadrats mitjans de l'error i del factor A. Es verifica:

Factor	$E(MS)$
A	$\sigma^2 + n\sigma_A^2$
Error	σ^2

Per tant, l'estimació de les components de la variància σ^2 i σ_A^2 s'obté igualant els $E(MS)$ amb els quadrats mitjans respectius en la taula ANOVA. Això és:

$$\sigma^2 + n\sigma_A^2 = MS_A$$

$$\sigma^2 = MS_E$$

I, aplicant el mètode dels moments per obtenir les estimacions, aïllem les sigmes:

$$\hat{\sigma}^2 = MS_E$$

$$\hat{\sigma}_A^2 = \frac{MS_A - MS_E}{n}$$

Observacions

Fixeu-vos que ara les diferents observacions de la variable resposta y_{ij} ja no són totes independents. Una cosa és que els errors e_{ij} siguin independents i una altra cosa és que ho sigui la variable resposta y_{ij} . Per a ells, fixem-nos quant val la covariància per a dues dades d'un mateix nivell i :

$$\begin{aligned} \text{cov}(y_{ij}, y_{ij}) &= \text{cov}(\mu + A_i + e_{ij}, \mu + A_i + e_{ij}) = \text{cov}(A_i + e_{ij}, A_i + e_{ij}) = \\ &= \text{cov}(A_i, A_i) + \text{cov}(A_i, e_{ij}) + \text{cov}(e_{ij}, A_i) + \text{cov}(e_{ij}, e_{ij}) = \\ &= \text{cov}(A_i, A_i) = \sigma_A^2 \text{ si la hipòtesi nul·la no és certa } \neq 0 \end{aligned}$$

Observacions

Un experiment que té tants factors amb efectes fixos com factors amb efectes aleatoris es diu que té efectes mixtos. La interacció d'un efecte fix i un efecte aleatori ha de ser tractada com un factor aleatori, ja que una nova mostra aleatòria dels nivells de factor també conduirà a una nova mostra aleatòria d'interaccions.

Bibliografia

Irizarry, R. A.; Love, M .I. (2015). *Data analysis for the life sciences*. Leanpub.

Ugarte, M. D.; Militino, A. F.; Arnholt, R. (2015). *Probability and statistics with R* (2a. ed.). CRC Press / Chapman and Hall. ISBN: 9781466504394.

