
Combinació de models

PID_00296757

Jordi Casas Roma
Julià Minguillón Alfonso

Temps mínim de dedicació recomanat: 2 hores



**Jordi Casas Roma**

Doctor en Informàtica (Universitat Autònoma de Barcelona, UAB, 2014), màster en Intel·ligència Artificial Avançada (Universitat Nacional d'Educació a Distància, UNED, 2011) i llicenciat en Informàtica (Universitat Autònoma de Barcelona, UAB, 2002). Actualment, és professor agregat de la Facultat d'Informàtica, Multimèdia i Telecomunicacions de la Universitat Oberta de Catalunya (UOC). Les seves activitats docents es concentren principalment en mineria de dades, aprenentatge automàtic, *big data* i mineria de gràfics. És el director del màster en Ciència de dades (Data Science) de la Universitat Oberta de Catalunya (UOC). Els seus principals àmbits de recerca inclouen la intel·ligència artificial, l'aprenentatge automàtic, la mineria de grafs i la privacitat de dades. Des del 2020 és líder de grup a ADaS Lab (Applied Data Science Lab) on investiga l'aplicació d'algorismes d'intel·ligència artificial a problemes del món real.

**Julià Minguillón Alfonso**

Professor de la Universitat Oberta de Catalunya (UOC) des de 2001. Centra la seva activitat de recerca en l'anàlisi i desenvolupament d'eines i recursos educatius oberts en entorns virtuals d'aprenentatge. Doctor per la Universitat Autònoma de Barcelona (UAB) amb una tesi doctoral en l'àmbit de l'aprenentatge automàtic. Les seves línies de treball se centren en el desenvolupament d'aplicacions per a la gestió, l'anàlisi i la visualització de dades provinents d'entorns d'aprenentatge virtuals, com el Campus Virtual de la UOC, i de xarxes socials, especialment Wikipedia. És autor de diversos recursos docents de l'àmbit de la ciència de dades relacionades amb la programació i l'anàlisi i visualització de dades. Des de 2024 és el director del programa del màster universitari de Ciència de Dades de la UOC.

Com citar aquest recurs d'aprenentatge amb l'estil Harvard:

Casas Roma, J.; Minguillón Alfonso, J. (2024). *Combinació de models*. [Recurs d'aprenentatge textual]. 1a. ed. Barcelona: Fundació Universitat Oberta de Catalunya (FUOC).

Primera edició: setembre 2024

© d'aquesta edició, Fundació Universitat Oberta de Catalunya (FUOC)

Av. Tibidabo, 39-43, 08035 Barcelona

Autoria: Jordi Casas Roma, Julià Minguillón Alfonso

Producció: FUOC

Tots els drets reservats

Cap part d'aquesta publicació, incloent-hi el disseny general i la coberta, no pot ser copiada, reproduïda, emmagatzemada o transmesa de cap manera ni per cap mitjà, tant si és elèctric com mecànic, òptic, de gravació, de fotocòpia o per altres mètodes, sense l'autorització prèvia per escrit del titular dels drets.

Passats tres anys des de la data de publicació de la primera edició d'aquest material, es considerarà publicat sota llicència Creative Commons (<https://creativecommons.org/licenses/by-nc-nd/4.0/deed.ca>).



Índex

Introducció	5
Objectius	6
1. Contextualització	7
2. Esquemes conceptuals	9
2.1. Combinació paral·lela de classificadors base similars	9
2.2. Combinació seqüencial de classificadors base diferents	12
2.3. Resum	14
3. Algorismes i mètodes	16
3.1. Random Forest	16
3.2. AdaBoost	18
3.3. Gradient Boosting	19
Resum	22
Glossari	23
Bibliografia	24

Introducció

La combinació de classificadors o combinació de models (també conegut com a *ensemble*, en anglès) és una tècnica que combina múltiples models d'aprenentatge automàtic per a millorar el rendiment i la generalització del sistema. En lloc de confiar en un únic model molt potent per a fer la predicció, un *ensemble* utilitza un conjunt de models més febles (i molt diferents entre si) en un esforç per augmentar la precisió i robustesa del sistema global.

La combinació de models s'ha demostrat com una estratègia efectiva per a millorar el rendiment predictiu i la robustesa dels models d'aprenentatge automàtic, i és àmpliament utilitzat en diverses aplicacions i contextos diferents.

Objectius

En els materials didàctics d'aquest mòdul trobarem les eines indispensables per a assimilar els següents objectius:

- 1.** Comprendre el concepte de combinació de models i les seves principals característiques.
- 2.** Conèixer la combinació paral·lela de classificadors, així com els seus principals avantatges i inconvenients.
- 3.** Conèixer la combinació seqüencial de classificadors, així com els seus principals avantatges i inconvenients.
- 4.** Saber aplicar alguns dels principals models d'aquest tipus, com per exemple Random Forest, AdaBoost i Gradient Boosting.

1. Contextualització

La combinació de classificadors o combinació de models (també conegut com a *ensembler*, en anglès) és una tècnica que combina múltiples models d'aprenentatge automàtic per a millorar el rendiment i la generalització del sistema. En lloc de confiar en un únic model per a fer la predicció, un *ensembler* utilitza un conjunt de models més febles o diferents en un esforç per augmentar la precisió i robustesa del sistema global.

Donat un conjunt de M models d'aprenentatge, en què cada model es denota per $M_i, 1 \leq i \leq B$, un *ensembler* combina les prediccions de cada model individual M_i per a obtenir una predicció final basant-se en les prediccions dels models base.

Per a un problema de classificació, l'*ensembler* pot combinar les prediccions utilitzant tècniques com votació majoritària, votació ponderada o mitjanat. Per exemple, en el cas de votació majoritària, l'*ensembler* seleccionaria la classe que hagi estat predita per la majoria dels models base, resolent els possibles empats d'alguna manera.

En el cas d'un problema de regressió, l'*ensembler* podria fer una mitjana (de manera ponderada o no) de les prediccions dels models base per a obtenir la predicció final.

En relació amb la notació d'aquest text, emprarem la següent notació per a referir-nos al conjunt d'entrada de dades:

$$D_{n,m} = \begin{pmatrix} d_1 = & a_{1,1} & a_{1,2} & \cdots & a_{1,m} & c_1 \\ d_2 = & a_{2,1} & a_{2,2} & \cdots & a_{2,m} & c_2 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ d_n = & a_{n,1} & a_{n,2} & \cdots & a_{n,m} & c_n \end{pmatrix}$$

on:

- n és nombre d'elements o instàncies,
- m el nombre d'atributs del conjunt de dades o també la seva dimensionalitat,

- d_i indica cadascuna de les instàncies del joc de dades,
- $a_{i,j}$ indica cadascun dels atributs descriptius, i
- c_i indica l'atribut objectiu o classe a predir per a cada element.

És important destacar que l'atribut objectiu o classe a predir (c_i) únicament existeix (o aplica) en els mètodes supervisats. En el cas dels mètodes no supervisats, el conjunt de dades segueix el mateix patró i notació, excepte per a l'atribut de classe (c_i) que no existeix (o no s'emptra) en el cas dels conjunts no etiquetats.

2. Esquemes conceptuals

En l'actualitat, l'estat de l'art en mineria de dades combina dues aproximacions diferents. La primera consisteix en el desenvolupament de nous algorismes (la qual cosa ocorre molt ocasionalment), o bé en l'ajust fi dels paràmetres d'algun algorisme conegut, habitualment per a adaptar-lo a la naturalesa concreta d'unes dades o del problema a resoldre. En aquest sentit, els avanços en l'àrea de mineria de dades estan assegurats i alhora limitats per l'anomenat «*No free lunch theorem*» (Wolpert, 1996), el qual postula que no existeix un algorisme *a priori* que sigui superior a la resta per a qualsevol conjunt de dades.

La segona aproximació per a crear millors models consisteix a combinar classificadors més o menys senzills per a crear un molt més complex, de manera que la decisió presa sigui una combinació de centenars o milers de decisions parcials. Òbviament, els classificadors usats com a base per a construir el classificador combinat han de ser tan diversos com sigui possible, amb l'esperança que els errors comesos per un classificador base concret siguin minoritaris respecte a la resta, de manera que els errors puntuals no alterin una decisió basada en l'opinió correcta de la majoria. Una revisió recent dels treballs en aquesta àrea de recerca pot trobar-se en el treball de Wozniak *et al.*, 2014.

Hi ha dues opcions per a la construcció de classificadors combinats. La primera, que combina classificadors treballant en paral·lel, és quan tots els classificadors base utilitzen el mateix model o algorisme (per exemple, arbres de decisió), així que caldrà manipular el conjunt d'entrenament original per a generar diferents classificadors base i poder prendre una decisió conjunta a partir de la decisió parcial de cadascun d'ells. La segona opció consisteix a combinar classificadors base molt diferents (per exemple, arbres de decisió i xarxes neuronals) de forma seqüencial, de manera que cada classificador utilitzi els resultats d'un classificador anterior, intentant capturar alguna característica clau de la naturalesa de les dades o del problema a resoldre.

2.1. Combinació paral·lela de classificadors base similars

Com s'ha comentat, una opció és generar una gran quantitat de classificadors base construïts a partir de l'alteració del conjunt d'entrenament original. Tots aquests classificadors base són molt semblants, en estar basats en lleugeres variacions del conjunt d'entrenament, però no són idèntics, sinó que propor-

Lectura complementària

David H. Wolpert (1996). «The lack of a priori distinctions between learning algorithms». *Neural computation*, vol. 8(7) p. 1341-1390.

Lectura complementària

Michal Wozniak, Manuel Graña, Emilio Corchado (2014). «A survey of multiple classifier systems as hybrid systems». *Information Fusion*, vol. 16, p. 3-17.
<https://doi.org/10.1016/j.inffus.2013.04.006>.

cionen diversitat al classificador combinat, el qual combina (mitjançant un esquema de votació) les classificacions parcials per a prendre una decisió.

Hi ha dues tècniques bàsiques per a la creació del classificador combinat, en funció de com es genera el conjunt d'entrenament de cada classificador parcial i del pes assignat a cadascun d'ells en la votació final, anomenades *bagging* i *boosting*.

2.1.1. *Bagging*


La idea bàsica del *bagging* és utilitzar el conjunt d'entrenament original per a generar centenars o milers de conjunts similars usant mostreig amb reemplaçament. És a dir, d'un conjunt D de n elements es poden triar $n' \leq n$ a l'atzar, i hi ha la possibilitat de triar un mateix element més d'una vegada (per això «amb reemplaçament»). Normalment $n' = n$, per la qual cosa en cada nou conjunt generat hi haurà elements repetits del conjunt original.

Encara que no és tan habitual, els conjunts generats també poden emprar una dimensionalitat $m' \leq m$, de manera que no totes les mateixes variables disponibles existeixin en els conjunts generats. Això pot ajudar a reduir el grau de colinealitat entre variables, fent emergir variables rellevants que poden quedar sempre descartades davant d'una altra variable.

Una vegada s'han construït els conjunts d'entrenament parcials, es construeix un classificador per a cadascun d'ells, i l'opció més típica són els arbres de decisió. De fet, tenint en compte la naturalesa del classificador combinat, no cal crear classificadors base molt precisos, ja que l'objectiu és que els errors comesos per cada classificador base quedin minimitzats enfront de la decisió de la majoria. Per tant, en el cas d'arbres de decisió, el que és habitual és crear classificadors més petits (és a dir, limitats en profunditat), reduint així el cost computacional de tot el conjunt.

En el cas del *bagging*, la decisió final es pren per majoria, donant el mateix pes a totes les decisions parcials. És a dir, la classe resultant del classificador combinat és aquella que apareix més vegades entre les decisions parcials preses pels classificadors base. La figura 1 representa el procés de creació del classificador combinat utilitzant B classificadors parcials.

Una manera de mesurar l'error comès pel classificador combinat es coneix com a *Out-Of-Bag*, atès que l'error estimat és la mitjana de tots els errors parcials comesos per cada classificador base per a tots aquells elements no emprats en el conjunt d'entrenament utilitzat per a construir-lo. D'aquesta manera no cal separar les dades d'entrada en un conjunt d'entrenament i un altre de test, sinó que s'usen tots per a construir el classificador combinat. No obstant això, si es disposa de prou dades, és sempre recomanable utilitzar un conjunt de tests per a validar el classificador combinat.

Figura 1. Diagrama d'un classificador combinat basat en *bagging*

2.1.2. Boosting

La idea del *boosting* és lleugerament diferent. Es parteix també de classificadors base molt senzills (també anomenats febles), els quals se suposa que, almenys, cometen menys errors que encerts, és a dir, que funcionen lleugerament millor que un classificador aleatori.

Es comença construint un primer classificador base emprant el conjunt d'entrenament original. Com que el classificador és feble (per exemple, un arbre de decisió de profunditat limitada), es cometen uns quants errors per al conjunt d'entrenament. Llavors, per a construir el següent classificador base, el que es fa és ponderar els elements del conjunt d'entrenament, de manera que aquells que han estat classificats erròniament pel classificador anterior tinguin més pes i, d'una manera o una altra, tinguin més pes també en el procés de creació del següent classificador base. El classificador combinat és la combinació de la predicció del primer classificador base més la del segon, ponderades d'acord amb algun esquema de pesos que tingui en compte la precisió de cada classificador. Aquest classificador combinat també cometrà uns errors que s'usaran per a donar més pes a aquells elements erròniament classificats, construint un tercer classificador combinat, etc.


És a dir, en cada etapa es construeix un classificador nou que combina una sèrie de decisions successives que tendeixen a enfocar-se en aquells elements més difícils de classificar, intentant que cada etapa corregeixi els errors de l'anterior, però sense espatllar les decisions correctes ja preses. Per a això, la seqüència de pesos dels successius classificadors parcials sol ser descendent,

Lectura complementària

Yoav Freund, Robert E. Schapire (1996). «Experiments with a new boosting algorithm». In Proc. of the 13th Int. Conf. on Machine Learning, vol. 96, p. 148-156

de manera que el procediment és per a quan el següent classificador ja no aporta res respecte de l'anterior. Aquest esquema, mostrat a la figura 2, permet múltiples variacions, i la més coneguda és la descrita per Freund i Schapire el 1996, anomenada AdaBoost.

Figura 2. Diagrama d'un classificador combinat basat en *boosting*. S'assumeix que $D_1 = D$.



És important destacar que el procés de creació del classificador combinat és seqüencial, atès que per a realitzar una nova iteració i obtenir un nou classificador combinat cal haver avaluat els B classificadors base anteriors. No obstant això, una vegada s'ha aconseguit el classificador combinat final, l'avaluació es fa també en paral·lel, ja que en una primera etapa es genera la decisió parcial per a cadascun dels classificadors base i en la segona s'obté la classificació final ponderant totes les decisions parcials.

Un dels problemes de *boosting* és la possibilitat de sobreentrenar el classificador combinat, per la qual cosa cal disposar d'un conjunt de tests i anar avaluant en cada etapa el resultat obtingut sobre aquest, aturant el procés quan l'error en el conjunt de tests comença a augmentar.

2.2. Combinació seqüencial de classificadors base diferents

En aquest cas, l'objectiu és construir un classificador que combina classificadors base molt diferents, amb l'objectiu d'incrementar la diversitat de prediccions i intentar aprofitar tot el coneixement explícit que es tingui sobre el problema a resoldre o les dades disponibles. Per exemple, si s'utilitza un arbre de decisió com a classificador, es poden construir uns quants classificadors que funcionin com una etapa prèvia, de manera que alimentin l'arbre de decisió amb informació extreta de les dades o altres decisions parcials.

Es tracta, llavors, d'un procés seqüencial, atès que es generen unes quantes decisions parcials que posteriorment són utilitzades per a prendre la decisió


final. En funció de la informació que rep el classificador combinat dels classificadors parcials, es distingeixen dos mètodes, anomenats *stacking* i *cascading*.

Aquestes tècniques són adequades quan la naturalesa del problema a resoldre també presenta una estructura seqüencial. Per exemple, en el diagnòstic no invasiu de tumors cerebrals mitjançant l'ús d'espectroscòpia de ressonància magnètica (Minguillón *et al.*, 2002), en lloc d'intentar predir el tipus de tumor detectat directament (la qual cosa és molt complicat perquè hi ha molts tipus de tumors diferents i de diferent grau de malignitat), l'habitual és establir una seqüència de decisions parcials intentant atacar el problema des d'una primera decisió molt senzilla (per exemple, establir simplement si es tracta d'un tumor o no), seguida d'una segona decisió que determina si es tracta d'un tumor benigne o maligne, seguida d'una tercera que en determina el grau de malignitat. És a dir, en cada pas s'utilitza la decisió presa anteriorment, començant per una primera decisió senzilla que es va refinant en una seqüència de decisions cada vegada més específiques.

Lectura complementària

J. Minguillón, A. R. Tate, C. Arús, J. R. Griffiths (2002). «Classifier Combination for In vivo Magnetic Resonance Spectra of Brain Tumours». A: F. Roli, J. Kittler (eds). Multiple Classifier Systems. MCS 2002. Lecture Notes in Computer Science, vol. 2364. Springer, Berlín, Heidelberg.
https://doi.org/10.1007/3-540-45428-4_28

Figura 3. Diagrama general d'un classificador combinat basat en *cascading* i *stacking*



En general, es pot pensar en la combinació seqüencial com una manera d'abordar el problema, intentant resoldre primer els casos més senzills amb un classificador també senzill, deixant la resta a una seqüència de classificadors cada vegada més complexos i específics.

2.2.1. Stacking

La idea bàsica de *stacking* és construir diferents classificadors base, de manera que cadascun d'ells generi una decisió parcial per a cada element d'entrada del conjunt d'entrenament. Llavors es construeix un nou classificador usant com a dades d'entrada totes les prediccions parcials, en lloc de les dades originals d'entrada. Aquest segon classificador sol ser un arbre de decisió, una xarxa neuronal senzilla o una regressió logística (en el cas que el nombre de classes sigui dos).

Encara que no és habitual, aquesta estructura pot repetir-se en diferents nivells, combinant decisions d'altres classificadors combinats, d'aquí la idea d'apilament o *stacking*. El problema de sempre és la tendència a crear un classificador combinat massa específic per al conjunt d'entrenament que no generalitzi bé davant noves dades.

2.2.2. *Cascading*

El cas de *cascading* és semblant al de *stacking* però utilitzant no solament les prediccions parcials dels classificadors base, sinó també les dades originals i fins i tot altres dades que s'hagin pogut generar durant la presa de decisions. La idea bàsica és alimentar el classificador combinat amb decisions parcials, així com els motius que han portat a prendre aquestes decisions.

Per exemple, quan un arbre de decisió ha assignat una classe a un element del conjunt d'entrada, aquesta classe és el resultat d'una sèrie de decisions internes que porten a una fulla, la qual té una profunditat en l'arbre, representa una regió que conté un percentatge de les dades d'entrada i es coneix l'error comès en assignar aquesta classe com a representant de totes les dades d'entrada contingudes a la regió que representa aquesta fulla. O per exemple, si un dels classificadors base és un algorisme de *clustering*, es pot emprar com a informació addicional la classe o clúster assignat a un element del conjunt d'entrada, juntament amb cadascuna de les distàncies a cadascun dels centroides dels clústers, com a mesura de la força que té aquesta decisió.

2.3. Resum

L'ús de classificadors combinats permet, en moltes ocasions, millorar la capacitat predictiva d'un model, i també és possible la inclusió de coneixement relatiu a la naturalesa del problema a resoldre, especialment amb els classificadors que operen seqüencialment. La seva construcció és senzilla, sovint s'utilitzen els mateixos algorismes i tècniques (reemplaçament amb mostreig, sistemes de votació per majoria simple, etc.), sent el cas de *boosting* el més complex, encara que hi ha diferents algorismes que l'implementen.

No obstant això, els classificadors combinats també presenten una sèrie de problemes, alguns ja esmentats al llarg d'aquest mòdul didàctic. El primer punt que cal tenir en compte és el cost computacional que pot tenir el classificador combinat, tant pel que fa a la seva creació (especialment) com a la seva execució. No obstant això, és possible aprofitar l'estructura paral·lela dels classificadors combinats en cas de disposar d'infraestructura tecnològica que permeti la paral·lelització de processos, de manera que cada classificador base s'executa en un node en paral·lel (alhora) a tots els altres classificadors base, reduint així el temps d'execució necessari.

Un aspecte que cal tenir en compte és que no per augmentar el nombre de classificadors base involucrats s'aconseguirà sempre una millora de la precisió. És molt més important la diversitat dels classificadors base que el seu nombre. Com la diversitat depèn del conjunt d'entrenament utilitzat per a cada classificador base, és important que el conjunt d'entrenament original sigui prou gran i divers i que el procés de mostreig asseguri un bon grau d'aleatorietat, generant conjunts d'entrenament parcials també diversos.

D'altra banda, la interpretabilitat dels resultats és molt més complicada, ja que exigeix la interpretació de centenars o milers de classificadors base parcials i la seva posterior combinació. No obstant això, és possible mesurar la importància relativa de cada variable en el conjunt mitjançant diferents tècniques (per exemple, comptant quantes vegades apareix cada variable en cada classificador base amb el seu pes en el classificador combinat), la qual cosa pot proporcionar cert coneixement sobre aquest tema.

3. Algorismes i mètodes

En aquest apartat veurem alguns dels principals algorismes de combinació de models, encara que una revisió exhaustiva queda fora de l'abast d'aquest text.

3.1. Random Forest

Random Forest (Breiman, 2001) és un algorisme *ensembler* de tipus *bagging*, que s'utilitza principalment per a tasques de classificació i regressió.

Aquest model combina múltiples arbres de decisió independents i s'utilitza un mostreig tant dels elements del conjunt original d'entrenament com de les seves variables. El classificador combinat es coneix com a Random Forest, atès que es tracta precisament d'un conjunt (o «bosc») d'arbres que han estat creats mitjançant un procés aleatori (pel que fa al conjunt d'entrenament utilitzat per a cadascun d'ells).

La pràctica habitual consisteix a generar versions diferents del conjunt d'entrenament usant mostreig amb reemplaçament, tal com defineix el mètode de *bagging*. Llavors, durant el procés de construcció de cada arbre de decisió, se selecciona aleatòriament un subconjunt de les variables del conjunt de dades, donant opcions a variables que normalment quedarien eclipsades per unes altres que tinguessin més rellevància. Aquest procediment permet mesurar la importància relativa de cada variable, estimant l'error comès pel classificador combinat quan s'altera aquesta variable, permutant aleatòriament els seus valors en el conjunt de tests. Aquest error es mesura per a cadascun dels classificadors parcials, fent una mitjana de l'error comès en tots ells per a cadascuna de les variables. El percentatge d'error es compara amb l'estimat amb el conjunt de tests sense aquesta permutació aleatòria, de manera que és possible mesurar l'impacte d'aquesta variable, atès que, si l'error augmenta quan es permuta una variable, això vol dir que la variable és rellevant per al problema que s'està resolent.

El procés per a l'entrenament d'un model Random Forest es detalla en l'algorisme 1.

El conjunt de dades d'entrada D consta de n mostres i m característiques: $D = \{(d_1, c_1), (d_2, c_2), \dots, (d_n, c_n)\}$, on d_i és el vector de característiques de la mostra i i c_i és l'etiqueta corresponent. Els paràmetres que rep l'algorisme inclouen el nombre d'arbres al bosc (T), el nombre de característiques a considerar en buscar la millor divisió a cada node de l'arbre (normalment $m' \leq \sqrt{m}$ o $m' \leq \log_2 m$), que es denota com a m' , i el nombre de mostres que cal considerar

Lectura complementària

L. Breiman (2001).
«Random forests». *Machine learning*, vol. 45(1), p. 5-32

per a entrenar cada arbre (seleccionades aleatòriament amb reemplaçament), indicat com a n' , que és habitualment n .

Algorisme 1 Pseudocodi de l'algorisme Random Forest

Require: Training dataset $D = \{(d_1, c_1), (d_2, c_2), \dots, (d_n, c_n)\}$

Require: Number of trees T , number of features to consider m' , number of samples to consider n'

for $t = 1$ to T **do**

 Randomly select n' samples with replacement to form D_t

 Randomly select m' features from the available m features

 Build a decision tree using D_t and the selected features

 Repeat until the tree is fully developed

end for

return Set of T trained decision trees

Com es pot apreciar en el detall de l'algorisme, el procés que se segueix per a entrenar el model és el següent:

- 1) Per a $t = 1$ fins a T :
 - a) Seleccionar aleatòriament n' mostres del conjunt d'entrenament amb reemplaçament per a formar un conjunt de dades D_t .
 - b) Seleccionar aleatòriament m' característiques de les m característiques disponibles.
 - c) Construir un arbre de decisió utilitzant el conjunt de dades D_t i les característiques seleccionades al pas anterior. Cada divisió es tria buscant la característica i el llindar que maximitzen el guany d'informació (o reducció d'impuresa) en els nodes resultants.
 - d) Repetir els passos anteriors fins que l'arbre estigui completament desenvolupat (s'hagi aconseguit una profunditat màxima o s'hagi complert un altre criteri de detenció).
- 2) El conjunt final d'arbres de decisió forma el bosc aleatori.

Entre els principals avantatges o punts forts de l'algorisme Random Forest, podem destacar l'augment de precisió en els resultats, atès que generalment produeix models més precisos que un sol arbre de decisió. També és notable destacar la reducció del sobreajust (*overfitting*) que se sol produir en aquest model a causa de l'ús de múltiples arbres en subconjunts aleatoris de dades i característiques. Un altre punt important és que aquest model és capaç de proporcionar mesures d'importància de característiques, la qual cosa pot ajudar a entendre quines característiques són més rellevants per a la tasca. Finalment, però no per això menys rellevant, cal destacar que és possible la construcció d'arbres en paral·lel, fet que accelera el procés d'entrenament.

Així mateix, continua aportant alguns dels principals avantatges dels arbres de decisió, com són la robustesa enfront de dades sorolloses i valors atípics,

i la possibilitat de treballar amb característiques numèriques o categòriques sense necessitat d'un preprocessament exhaustiu de les dades.

Per contra, també hem d'esmentar que el consum de recursos d'aquest model és notablement superior a altres, ja que s'han de construir i entrenar múltiples arbres de decisió. Per aquest mateix motiu, el temps de predicció pot ser més llarg a causa de la combinació de les prediccions dels múltiples arbres.

Encara que hem comentat que aquest model és capaç de proporcionar mesures d'importància de característiques, és cert que la interpretació d'un model Random Forest pot ser més costosa que la interpretació d'un sol arbre de decisió, ja que s'han d'inspeccionar tots els models construïts.

3.2. AdaBoost

AdaBoost (*Adaptive Boosting*) va ser proposat per Freund i Schapire (1996) i consisteix a crear diversos predictors senzills en seqüència, de tal manera que cada predictor intenta corregir els errors que ha comès el predictor anterior. És a dir, el segon predictor intentar ajustar correctament els errors del primer predictor, mentre que el tercer fa la mateixa tasca sobre els errors comesos pel segon predictor, i així successivament.

El model AdaBoost és un clar exemple de *boosting*, i segueix l'esquema mostrat a la figura 2.

El procés per a l'entrenament d'un model AdaBoost es detalla en l'algorisme 2.

Algorisme 2 Pseudocodi de l'algorisme AdaBoost

Require: Training dataset $D = \{(d_1, c_1), (d_2, c_2), \dots, (d_n, c_n)\}$

Require: Number of weak learners T

Initialize sample weights: $w_1 = \frac{1}{N}, w_2 = \frac{1}{N}, \dots, w_N = \frac{1}{N}$

for $t = 1$ to T **do**

Train a weak learner $f_t(d)$ using weights $w_1, w_2, \dots, w_n$

Calculate weighted error: $err_t = \sum_{i=1}^n w_i \cdot \mathbb{I}(f_t(d_i) \neq c_i)$

Calculate importance coefficient: $\alpha_t = \frac{1}{2} \ln \left(\frac{1 - err_t}{err_t} \right)$

Update sample weights: $w_i = w_i \cdot \exp(-\alpha_t \cdot c_i \cdot f_t(d_i))$

Normalize sample weights: $w_1, w_2, \dots, w_n = \frac{w_1}{\sum_{i=1}^n w_i}, \frac{w_2}{\sum_{i=1}^n w_i}, \dots, \frac{w_n}{\sum_{i=1}^n w_i}$

end for

Construct weighted combined model: $F(d) = \sum_{t=1}^T \alpha_t f_t(d)$

return Combined model $F(d)$

El conjunt de dades etiquetades d'entrada D consta de n mostres i m característiques: $D = \{(d_1, c_1), (d_2, c_2), \dots, (d_n, c_n)\}$, on d_i és el vector de característiques de la mostra i i c_i és l'etiqueta corresponent (podem suposar que $c_i \in \{-1, +1\}$). Els paràmetres que rep l'algorisme es limiten al nombre de models febles (ge-

Lectura complementària

Yoav Freund, Robert E. Schapire (1996). «Experiments with a new boosting algorithm». In Proc. of the 13th Int. Conf. on Machine Learning, vol. 96, p. 148-156

neralment arbres de decisió) que s'utilitzaran en l'assemblatge, i que denoten com T en el pseudocodi anterior.

Com es pot apreciar en el detall de l'algorisme, el procés que se segueix per a entrenar el model és el següent:

- 1) Inicialitzar els pesos de les mostres: $w_1 = \frac{1}{n}, w_2 = \frac{1}{n}, \dots, w_n = \frac{1}{n}$.
- 2) Per a $t = 1$ fins a T :
 - a) Entrenar un model feble $f_t(d)$ en el conjunt de dades D ponderat pels pesos $w_1, w_2, \dots, w_n$.
 - b) Calcular l'error ponderat del model $f_t(d)$: $err_t = \sum_{i=1}^n w_i \cdot \mathbb{K}(f_t(d_i) \neq c_i)$, on $\mathbb{K}(\text{condició})$ és la funció indicadora que retorna 1 si la condició és veritable i 0 en cas contrari.
 - c) Calcular el coeficient d'importància del model $f_t(d)$: $\alpha_t = \frac{1}{2} \ln \left(\frac{1-err_t}{err_t} \right)$.
 - d) Actualitzar els pesos de les mostres: $w_i = w_i \cdot \exp(-\alpha_t \cdot y_i \cdot f_t(d_i))$ per a normalitzar les mostres correctament.
 - e) Normalitzar els pesos de les mostres: $w_1, w_2, \dots, w_n = \frac{w_1}{\sum_{i=1}^n w_i}, \frac{w_2}{\sum_{i=1}^n w_i}, \dots, \frac{w_n}{\sum_{i=1}^n w_i}$.
- 3) Construir el model combinat ponderat: $F(d) = \sum_{t=1}^T \alpha_t f_t(d)$.

Entre els principals avantatges d'aquest model trobem alguns que ja hem descrit al subapartat anterior i que són compartits amb el model Random Forest, com, per exemple, la millora del rendiment respecte dels arbres de decisió simples, el maneig de característiques numèriques o categòriques, i la informació relativa a la importància de característiques o atributs, que és important i pot ajudar a la interpretació del model.

A més, aquest model aporta altres característiques rellevants, com l'ús d'un nombre de paràmetres molt reduït, la qual cosa facilita la tasca d'ajust d'hiperparàmetres. Addicionalment, aquest model es pot emprar amb diversos algorismes base (*weak learners*) per a adaptar-se millor a diferents tipus de dades i problemes.

Entre els seus principals inconvenients, podem destacar la sensibilitat del model a les dades amb soroll i amb valors atípics (*outliers*) i al desequilibri de classes, la qual cosa pot portar a una classificació esbiaixada. Finalment, cal destacar també que el procés d'ajustar els pesos i entrenar múltiples models pot ser computacionalment costós, sobretot amb un gran nombre de models base.

3.3. Gradient Boosting

El model Gradient Boosting va ser proposat per Friedman (2001) i consisteix a crear diversos predictors en seqüència, específicament models additius, mit-

Lectura complementària

J. Friedman (2001). «Greedy Function Approximation: A Gradient Boosting Machine», a *The Annals of Statistics*, vol. 29(5), p. 1189-1232.

jançant la combinació de diversos models base més simples. El primer predictor usa la mitjana de la variable $a_{.,j}$ per a predir, després el segon predictor explica els errors del primer predictor, el tercer predictor explica els errors del segon predictor i així successivament.

El procés per a l'entrenament d'un model Gradient Boosting es detalla en l'algorisme 3.

Algorisme 3 Pseudocodi de l'algorisme Gradient Boosting

Require: Training dataset $D = \{(d_1, c_1), (d_2, c_2), \dots, (d_n, c_n)\}$

Require: Number of base learners T

Require: Learning rate η

Initialize predictions: $F_0(d) = 0$

for $t = 1$ to T **do**

 Calculate residuals: $r_{ti} = c_i - F_{t-1}(d_i)$ for $i = 1, 2, \dots, n$

 Train a base learner $h_t(d)$ on the residuals r_{ti}

 Find the coefficient α_t by optimizing a loss function, e.g., minimizing squared error: $\alpha_t = \arg \min_{\alpha} \sum_{i=1}^n (\alpha h_t(d_i) - r_{ti})^2$.

 Update predictions: $F_t(d) = F_{t-1}(d) + \eta \alpha_t h_t(d)$

end for

return Combined model $F(d) = \sum_{t=1}^T \eta \alpha_t h_t(d)$

El conjunt de dades etiquetades d'entrada D consta de n mostres i m característiques: $D = \{(d_1, c_1), (d_2, c_2), \dots, (d_n, c_n)\}$, on d_i és el vector de característiques de la mostra i i c_i és l'etiqueta corresponent. Els paràmetres que rep l'algorisme inclouen el nombre de models base que s'utilitzaran en l'assemblatge (T) i una col·lecció de funcions base (en general, arbres de decisió febles) que componen l'assemblatge ($\{h_t(d)\}$). La sortida és un model combinat $F(d)$ que és la suma ponderada dels models base $h_t(d)$: $F(d) = \sum_{t=1}^T \alpha_t h_t(d)$.

Com es pot apreciar en el detall de l'algorisme, el procés que se segueix per a entrenar el model és el següent:

- 1) Inicialitzar les prediccions: $F_0(d) = 0$.
- 2) Per a $t = 1$ fins a T :
 - a) Calcular els residus: $r_{ti} = c_i - F_{t-1}(d_i)$ per a $i = 1, 2, \dots, n$.
 - b) Ajustar un model base $h_t(d)$ als residus r_{ti} .
 - c) Calcular el coeficient d'aprenentatge α_t mitjançant una tècnica de cerca de línia, com a mínims quadrats o descens de gradient, minimitzant una funció de pèrdua entre les prediccions $F_{t-1}(d)$ i els residus r_{ti} .
 - d) Actualitzar el model combinat: $F_t(d) = F_{t-1}(d) + \alpha_t h_t(d)$.
- 3) Construir el model combinat final: $F(d) = \sum_{t=1}^T \alpha_t h_t(d)$.

Entre els principals avantatges o punts forts d'aquest model trobem alguns que ja hem descrit als subapartats anteriors, i que són compartits amb els models

Random Forest i AdaBoost. Entre aquests, cal destacar l'augment de precisió respecte dels models simples, la possibilitat de manejar característiques numèriques i categòriques sense necessitat d'un preprocessament exhaustiu, i la possibilitat d'obtenir informació relativa a la importància de les característiques o atributs, la qual cosa pot ajudar en la interpretació del model.

Per contra, algunes de les seves febleses són: el temps d'entrenament, atès que l'entrenament de múltiples models base pot ser computacionalment costós, especialment en conjunts de dades grans i amb models base complexos. També certa sensibilitat a valors atípics i al soroll de les dades, i la necessària configuració dels hiperparàmetres, com el nombre de models base i la taxa d'aprenentatge, per aconseguir un bon rendiment.

Resum

En aquest mòdul didàctic ens hem centrat en la combinació de classificadors, també coneguts com a models *ensembler*. Aquests models es basen en la composició en sèrie o paral·lel de diferents models més simples que permeten generar una resposta conjunta per a un determinat problema.

A la primera part del text hem revisat els esquemes conceptuals, que bàsicament inclouen la combinació paral·lela de classificadors base similars, i la combinació seqüencial de classificadors base diferents.

A la segona part del mòdul hem enumerat alguns dels principals models *ensembler*, com poden ser Random Forest, AdaBoost i Gradient Boosting.

Glossari

ensemble *m* Model construït combinant altres models, ja sigui de manera seqüencial (en sèrie) o en paral·lel.

processament en paral·lel *m* Quan diferents models es creen alhora (per exemple, usant petites variacions del conjunt de dades d'entrada) i els resultats són combinats per a obtenir un resultat (per exemple, mitjançant una votació per majoria simple).

processament en sèrie *m* Quan el resultat d'un model s'utilitza com a entrada del model següent.

sobreajust *m* El sobreajust es produeix quan l'algorisme emprat per a crear un model captura en excés la naturalesa intrínseca del conjunt de dades usat en el procés de creació, impossibilitant que el model generalitzi bé per a dades mai observades amb anterioritat, creant un biaix.

en overfitting

Bibliografia

Cichosz, P. (2015). *Data mining algorithms. Explained using R*. Wiley.

Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 2nd Edition*. O'Reilly Media, Inc.

Gironés Roig, J., Casas Roma, J., Minguillón Alfonso, J. i Caihuelas Quiles, R. (2017). *Minería de datos: Modelos y algoritmos*. Barcelona: Editorial UOC.