

Ús de bases de dades NoSQL

PRA1

Instruccions

Per poder realitzar la pràctica, cal utilitzar la màquina virtual proporcionada que es troba a l'àrea de recursos i consultar el manual d'usuari proporcionat.

També teniu a la vostra disposició dos vídeos, un d'ús general de la màquina virtual i un altre amb suggeriments per treballar amb la base de dades de Cassandra. Encara que estigueu familiaritzats amb l'ús de màquines virtuals o aquestes bases de dades, us recomanem que els veieu, ja que podeu trobar algun suggeriment o idea nova que us faciliti el desenvolupament de les activitats:

- Consells sobre l'ús de la màquina virtual: <https://vimeo.com/599367789>
- Consells sobre l'ús de Cassandra: <https://vimeo.com/599364323>

Per aquesta pràctica no es farà servir cap de les bases de dades preinstal·lades a la màquina virtual. A cada exercici trobareu les instruccions detallades per carregar la base de dades necessària per poder resoldre'l.

Exercici 1: Cassandra (30%)

Descàrrega i càrrega de dades a la base de dades

Per la resolució de la pràctica es faciliten uns arxius csv, on cada arxiu és un agregat. Tingueu en compte que pot ser que no sigui necessari carregar tots els arxius en la base de dades per resoldre totes les consultes. **Es valorarà la resolució de les consultes usant el mínim nombre d'agregats (arxius csv).**


Descàrrega dels arxius

Un cop tingueu la màquina virtual en execució, seguiu els següents passos:

Obriu la carpeta Cassandra disponible a l'escriptori.



Feu clic amb el botó dret del ratolí en un espai buit de la carpeta i després a “Abrir en un terminal”.



Copieu (al document CTRL + C) i enganxeu a la finestra del terminal (CTRL + MAJÚSCULES + V) les 4 ordres següents. Si en copiar i enganxar s'afegeixen salts de línia, si us plau elimineu-los, ja que l'ordre és una sola línia.

```
wget
https://raw.githubusercontent.com/jconesac/cassandra_dataset/main/bikes.csv
```

```
wget
https://raw.githubusercontent.com/jconesac/cassandra_dataset/main/users.csv
```

```
wget
https://raw.githubusercontent.com/jconesac/cassandra_dataset/main/viajes.csv
```


```
wget
```

```
https://raw.githubusercontent.com/jconesac/cassandra_dataset/main/TESTING_AGGREGATE.csv
```

Espereu que acabi l'execució. Si al final executeu la següent comanda


```
ls -alF *.csv
```

haurieu de veure el següent resultat:




Ja podeu tancar la finestra del terminal. Les dades ja estaran en el directori.


A continuació, feu doble clic en la icona “Start Cassandra”. S'obrirà una finestra de terminal. **No la tanqueu, ja que aturariau el procés de Cassandra.** Podeu minimitzar-la.




Aquesta és la finestra del terminal. Al principi de l'execució pot donar un error segons el qual no es tenen permisos per escriure en l'arxiu de log. L'error es pot ignorar, la base de dades s'executarà normalment. Com hem esmentat anteriorment, no tanqueu aquesta finestra de terminal per mantenir el procés en execució.



Després feu doble clic en la icona CQLSH per situar-vos en el terminal de Cassandra. És possible que el terminal es tanqui sol passats uns segons . Si això passa és perquè el servei de Cassandra encara està arrencant i per tant CQLSH no ha pogut connectar-s'hi. Simplement haureu d'intentar-ho passats uns segons (pot ser que algun minut) i us apareixerà la línia de comandes en la finestra que s'obre.



Ara ja esteu situats a la interfície de comandes de Cassandra.



Càrrega de dades

Primer crearem un keyspace anomenat CRIMES amb la següent comanda:

```
CREATE KEYSPACE BIKES WITH REPLICATION = { 'class':
'SimpleStrategy', 'replication_factor': 1};
```

Aquest és el resultat (la comanda no retorna cap missatge):

```
cqlsh> CREATE KEYSPACE BIKES WITH REPLICATION = { 'class':
'SimpleStrategy', 'replication_factor': 1};
cqlsh>
```


Indiquem que volem fer servir o situar-nos en el keyspace creat tot executant:

```
USE BIKES;
```

Que modificarà el *command prompt* a:

```
cqlsh:bikeys>
```


Aquest hauria de ser el resultat:



Una cop en el keyspace ja podem carregar les dades. **Recordeu que cada vegada que torneu a iniciar el servei de Cassandra i connectar-vos a la base de dades, haureu de situar-vos en el keyspace BIKES novament.**

Primer, a tall d'exemple, i per resoldre el primer exercici, hem de crear una família de columnes (taula en Cassandra) i ho farem per l'agregat TESTING_AGGREGATE.csv. Les comandes són les següents:

Pas opcional: Per si existís la taula (o si voleu recrear-la, per començar l'exercici de nou), podeu executar la següent comanda per tal d'eliminar-la. Si creeu la base de dades per primera vegada, o sabeu que la taula no existeix, no és necessari.

```
DROP TABLE IF EXISTS TESTING_AGGREGATE;
```

Creem la taula amb la comanda:

```
CREATE TABLE TESTING_AGGREGATE
(
    COLUMNA1 TEXT,
    COLUMNA2 TEXT,
    COLUMNA3 TEXT,
    COLUMNA4 TEXT,
    PRIMARY KEY (COLUMNA1, COLUMNA2, COLUMNA3)
);
```

Un cop tinguem la taula creada, carreguem les dades amb la comanda:

```
COPY TESTING_AGGREGATE (COLUMNA1, COLUMNA2, COLUMNA3, COLUMNA4) FROM
'/home/student/Descargas/data/TESTING_AGGREGATE.csv'
WITH DELIMITER=', ' AND HEADER=TRUE;
```

Comprovem que les dades s'han carregat correctament tot executant la consulta:

```
SELECT *
FROM TESTING_AGGREGATE;
```

La consulta retorna en modo texto (no captura de pantalla):

```
cqlsh:bikes> SELECT * FROM TESTING_AGGREGATE;
```


columna1	columna2	columna3	columna4
clave1_1	clave2_1	clave3_1	valor1
clave1_2	clave2_2	clave3_2	valor2

```
(2 rows)
cqlsh:bikes>
```

Recordeu que l'ús de l'asterisc a la clàusula select (SELECT *) no és una bona pràctica en entorns de producció.

El format text (tal com veieu a dalt) és el recomanat quan adjunteu els resultats de les vostres respostes als exercicis de Cassandra. El tipus de lletra Courier alinea millor els resultats, ja que totes les lletres i símbols tenen el mateix ample. Si la consulta no cap en l'ample del document, podeu reduir la grandària de la lletra perquè càpiga. Si us plau, **adjunteu els resultats d'aquest apartat en mode text, no amb captures de pantalla.**

I a la captura de pantalla, que s'adjunta a manera de tutorial, podeu veure tota la seqüència de comandes executades al terminal.



```

student@NoSQLDB: ~/Descargas/data
Archivo  Editar  Ver  Buscar  Terminal  Ayuda
cqlsh> CREATE KEYSPACE BIKES WITH REPLICATION ={'class': 'SimpleStrategy','replication factor': 1};
cqlsh> use bikes;
cqlsh:bikes> DROP TABLE IF EXISTS TESTING_AGGREGATE;
cqlsh:bikes> CREATE TABLE TESTING_AGGREGATE
... (
... COLUMNNA1 TEXT,
... COLUMNNA2 TEXT,
... COLUMNNA3 TEXT,
... COLUMNNA4 TEXT,
... PRIMARY KEY (COLUMNNA1,COLUMNNA2,COLUMNNA3)
... );
cqlsh:bikes> COPY TESTING_AGGREGATE (COLUMNNA1, COLUMNNA2, COLUMNNA3, COLUMNNA4) FROM
... '/home/student/Descargas/data/TESTING_AGGREGATE.csv'
... WITH DELIMITER=',' AND HEADER=TRUE;
Using 1 child processes

Starting copy of bikes.testing_aggregate with columns [columnna1, columnna2, columnna3, columnna4].
Processed: 2 rows; Rate: 3 rows/s; Avg. rate: 5 rows/s
2 rows imported from 1 files in 0.420 seconds (0 skipped).
cqlsh:bikes> SELECT *
... FROM TESTING_AGGREGATE;

columnna1 | columnna2 | columnna3 | columnna4
-----
clave1_1 | clave2_1 | clave3_1 | valor1
clave1_2 | clave2_2 | clave3_2 | valor2

(2 rows)
cqlsh:bikes>
cqlsh:bikes>

```

1.1 Exercici, modificació de dades (5%)

Executar la següent comanda:

```
INSERT INTO TESTING_AGGREGATE (COLUMNNA1, COLUMNNA2, COLUMNNA3,
COLUMNNA4) VALUES ('clave1_2', 'clave2_2', 'clave3_2', 'valorNuevo');
```

Després d'executar la comanda anterior, torneu a executar la consulta per veure totes les dades de la taula i enganxeu a continuació els resultats, de la mateixa forma que s'ha fet en l'exemple.

A continuació, executeu la següent comanda:

```
UPDATE TESTING_AGGREGATE
SET COLUMNNA4 = 'valor3'
WHERE COLUMNNA1 = 'clave1_3' AND COLUMNNA2 = 'clave2_3' AND COLUMNNA3
= 'clave3_3';
```

Després d'executar la comanda anterior, torneu a executar la consulta per veure totes les dades de la taula i enganxar a continuació els resultats, igual que s'ha fet en l'exemple.

Finalment, explica què ha passat en cada comanda de modificació de dades (insert, update) que s'ha executat en els passos anteriors. Contesta les següents preguntes: Per què ha passat això? Quines diferències hi ha entre aquest comportament i el d'una base de dades relacional o tradicional? Aquest és l'únic apartat que puntua de la pregunta, els anteriors són guiats i no puntuen.

Base de dades per a consultes

Per la resta de consultes de l'exercici, haureu de carregar les dades dels agregats que s'han descarregat anteriorment. Els agregats contenen dades sintètiques per a una aplicació de gestió de bicicletes elèctriques compartides, en el context de la mobilitat urbana. En particular, es proporcionen tres fitxers: un que conté informació sobre les bicicletes, un altre que conté informació sobre els usuaris del sistema i un altre que conté informació sobre els darrers viatges realitzats pels usuaris. Les agregacions i els camps dels documents són prou descriptius per entendre'n el significat. Per veure el seu contingut gràficament podeu usar el software LibreOffice, que està instal·lat en la mateixa màquina virtual. Simplement haureu de fer doble clic en l'arxiu de dades de la mateixa carpeta i podreu veure'l com es mostra a continuació.

Part de la pràctica es basa en l'anàlisi, interpretació i comprensió d'aquests fitxers. En cas de tenir dubtes sobre la seva semàntica, us animem a comentar-ho de forma col·laborativa als fòrums de l'assignatura. Aquesta base de dades és semblant a la que utilitzareu a l'exercici de MongoDB.

Error conegut en la creació d'índexs

Durant la resolució de les consultes pot ser que hagueu de crear un índex. És possible que, si executeu la consulta immediatament després de la creació de l'índex, la base de dades retorni l'error:

```
ReadFailure: Error from server: code=1300 [Replica(s) failed to
execute read] message="Operation failed - received 0 responses and 1
failures" info={'failures': 1, 'received_responses': 0,
'required_responses': 1, 'consistency': 'ONE'}
```

Això es deu al fet que, a Cassandra, els índexs es creen de manera asíncrona, per la qual cosa pot ser que encara s'estigui creant l'índex en fer la consulta. Solament haureu d'esperar una estona (sol ser menys d'un o dos minuts), tornar a executar la consulta i s'executarà correctament sense errors. Si l'error persisteix, pot ser que hagueu d'assignar més recursos a la màquina virtual (més CPU i memòria). Tingueu en compte que la màquina ve configurada per defecte amb molts pocs recursos.

Carregant les dades

A continuació farem una primera càrrega dels fitxers proporcionats. Començarem carregant les dades de les bicicletes mitjançant les tres sentències següents:

```
DROP TABLE IF EXISTS BIKES;
```

```
CREATE TABLE BIKES
```

```
(
    ID TEXT,
    BRAND TEXT,
    BATTERY_CHARGE DECIMAL,
    STATUS TEXT,
    HELMETS INT,
    EXTRA_FEATURES LIST<text>,
    DAMAGES LIST<text>,
    IS_CLEAN BOOLEAN,
    RIDES INT,
    KMS DECIMAL,
    LOCATION_TYPE TEXT,
    LOCATION_COORDINATES LIST<decimal>,
    PRIMARY KEY (ID)
);
```

```
COPY BIKES (ID, BRAND, BATTERY_CHARGE, STATUS, HELMETS,
EXTRA_FEATURES, DAMAGES, IS_CLEAN, RIDES, KMS, LOCATION_TYPE,
LOCATION_COORDINATES) FROM
'/home/student/Descargas/data/bikes.csv'
WITH DELIMITER=';' AND HEADER=TRUE;
```

Per comprovar que les dades carregades són correctes podeu executar les següents sentències i comprovar que els resultats són els mateixos que apareixen aquí:

```
cqlsh:bikes> SELECT COUNT(*) FROM BIKES;
```

```
count
-----
2000
```

```
(1 rows)
```

Warnings :

Aggregation query used without partition key

```
cqlsh:bikes> SELECT SUM(RIDES), SUM(KMS) FROM BIKES;
```

```
system.sum(rides) | system.sum(kms)
-----+-----
39822 | 119973.399503084133622
```

```
(1 rows)
```

Warnings :

Aggregation query used without partition key

Un cop carregades les dades de les bicicletes, continuarem carregant les dades dels usuaris:

```
DROP TABLE IF EXISTS USERS;
```

```
CREATE TABLE USERS (  
    ID TEXT,  
    EMAIL TEXT,  
    AGE INT,  
    DAYS_USED INT,  
    NRIDES INT,  
    CREDITS DECIMAL,  
    FIRST_NAME TEXT,  
    LAST_NAME TEXT,  
    BDATE TIMESTAMP,  
    FIRST_USE TIMESTAMP,  
    LAST_USE TIMESTAMP,  
    PRIMARY KEY (ID));
```

```
COPY USERS (ID, EMAIL, AGE, DAYS_USED, NRIDES, CREDITS, FIRST_NAME,  
LAST_NAME, BDATE, FIRST_USE, LAST_USE) FROM  
'/home/student/Descargas/data/users.csv'  
WITH DELIMITER=', ' AND HEADER=TRUE AND NULL='null';
```

Fixeu-vos que en aquest cas, hem afegit la clàusula `NULL='null'` a les opcions per assegurar-nos que s'insereixen les files que tinguin valors nuls en algun dels seus camps. Per comprovar que les dades inserides són correctes podeu executar les sentències següents i comprovar els resultats obtinguts:

```
cqlsh:bikes> SELECT COUNT(*) FROM USERS;
```

```
count  
-----  
60000  
  
(1 rows)
```

Warnings :

Aggregation query used without partition key

```
cqlsh:bikes> SELECT SUM(DAYS_USED), AVG(NRIDES), SUM(CREDITS) FROM  
USERS;
```

```
system.sum(days_used) | system.avg(nrides) | system.sum(credits)
-----+-----+-----
10971634 | 9 | 769642.75
```

(1 rows)

Warnings :

Aggregation query used without partition key

Un cop arribats fins aquí carregarem un nou agregat amb les dades dels darrers viatges realitzats per cada usuari, mitjançant les sentències següents:

```
DROP TABLE IF EXISTS TRIPS;
CREATE TABLE TRIPS (
    ID_USER TEXT,
    EMAIL TEXT,
    CREDITS DECIMAL,
    FROM_STATION INT,
    TO_STATION INT,
    BIKE TEXT,
    DATE TIMESTAMP,
    KILOMETERS DECIMAL,
    PRIMARY KEY (ID_USER));
```

```
COPY TRIPS (ID_USER, EMAIL, CREDITS, FROM_STATION, TO_STATION,
BIKE, DATE, KILOMETERS) FROM
'/home/student/Descargas/data/viajes.csv'
WITH DELIMITER=', ' AND HEADER=TRUE AND NULL='null';
```

Un cop carregats els viatges executarem una consulta per garantir que s'han afegit els 124.954 registres que hi havia al fitxer.

```
cqlsh:bikes> SELECT COUNT(*) FROM TRIPS;
```

```
count
-----
43049
```

(1 rows)

Warnings :

Aggregation query used without partition key

Vaja, sembla que alguna cosa ha anat malament; Només s'han carregat 43.049 registres, quan calia carregar-ne més de 100.000. De moment no feu res, solucionarem aquest problema a la primera consulta d'aquesta activitat.

Consultes a Cassandra

Amb les dades que heu descarregat en l'apartat anterior, es requereix realitzar les consultes detallades i adjuntar el seu resultat en mode text (**no captures de pantalla**).

Pot ser que algunes consultes retornin error i no es puguin executar directament. De cara a escollir les dades i resoldre les consultes pareu atenció a:

- Crear les claus de partició adequades.
- Crear les claus primàries adequades.
- És possible que s'hagi de crear índexs. En la majoria dels casos pot ser millor crear un índex que crear una nova taula i carregar un agregat sencer.
- Es poden resoldre diverses consultes amb un mateix agregat.

Important: abans de fer cap càrrega de dades addicional per resoldre qualsevol consulta, es recomana mirar quins són els requisits de les consultes següents per minimitzar el nombre d'agregats a carregar a la base de dades. Com menys agregats es carreguin per resoldre totes les consultes de l'exercici millor. Per obtenir la màxima puntuació cal fer les consultes correctament juntament amb una càrrega de dades òptima.

Es valorarà tot el procediment realitzat per executar les consultes i obtenir la informació que es demana en l'enunciat. En qualsevol cas, **sempre heu d'adjuntar les consultes que us donin error i totes les sentències CQL, comandes o accions que utilitzeu per tal de realitzar la consulta (incloent les sentències utilitzades per carregar dades)**. Si hi ha més d'una opció, també es tindrà en compte que l'opció triada sigui la que tingui el millor rendiment.

Restricció: No es pot utilitzar la clàusula **ALLOW FILTERING** a cap de les consultes a causa de l'impacte negatiu en el rendiment del clúster i perquè serà retirada a les properes versions de Cassandra.

Els criteris d'avaluació per avaluar aquest exercici són els següents:

No assolit (D/C-)	Mínimament assolit (C+)	Assolit (B)	Assolit de manera excel·lent (A)
La consulta no és correcta.	La consulta és correcta, però no retorna les dades correctes doncs s'han carregat incorrectament.	La consulta retorna les dades esperades, però s'han carregat més dades o agregats dels necessaris.	La consulta retorna les dades esperades i la càrrega de dades és la menor possible.

1.2 Consulta 1 (10%)

Tal com hem vist, hi ha hagut algun problema en la càrrega de dades del fitxer de viatges en bicicleta. La taula TRIPS hauria de tenir 124.954 registres, però només en té 43.049. Explica per què la inserció s'ha realitzat de forma errònia, fes una càrrega de dades que permeti carregar els registres de forma correcta i posa un exemple d'un registre que no s'hagi carregat la primera ocasió i explica'n el perquè.

1.3 Consulta 2 (25%)

Ens demanen crear una consulta per veure si hi ha diferències en el nombre de viatges i quilòmetres realitzats per les bicicletes de les marques BH i Orbea abans que es facin malbé (estat = 'out'). La consulta ha de tornar el nombre de viatges i el nombre de quilòmetres de les bicicletes espatllades agrupats pel nom de la seva marca.

1.4 Consulta 3 (10%)

Suposa que diferents ciutats han contractat la nostra empresa per gestionar les seves bicicletes. En conseqüència, s'espera una quantitat de dades molt més gran i, per poder-les gestionar eficientment, es proposa crear un sistema que permeti repartir la càrrega de les dades de les bicicletes en 10 nodes de forma distribuïda. Analitza si l'agregat que has creat a la consulta anterior seria eficient en aquest nou entorn. En cas contrari, proposa un nou agregat que es comporti de forma més eficient. Justifica la teva resposta.

1.5 Consulta 4 (25%)

La nostra empresa vol repintar les bicicletes que tinguin ratllades (damages = scratches). Com que de moment no ha comprat pintura per a totes, començarà pintant les bicicletes de la marca Orbea que estiguin disponibles (status = free). Per fer-ho, ens demanen crear una consulta, que puguin executar cada dia, per identificar les matrícules de les bicicletes de la marca Orbea que estiguin lliures.

1.6 Consulta 5 (25%)

Per entendre millor els patrons de viatge dels usuaris, ens demanen una consulta que permeti identificar el nombre de viatges de tots els usuaris per a cada parell d'estacions d'origen i destí. En particular, la consulta haurà de permetre escollir un parell d'estacions d'origen i destí i mostrar el nombre de viatges realitzats entre aquestes estacions, la mitjana de quilòmetres dels viatges les estacions i la suma de crèdit consumit.

Per demostrar el funcionament de la consulta, us animem fer servir l'estació de origen 40 i l'estació de destí 60.

Exercici 2: Neo4j (35%)

Context: les dades en què es basa aquest exercici corresponen a la saga cinematogràfica de la Guerra de les Galàxies (*Star Wars*). Per tal de completar l'exercici, no és necessari conèixer les seves pel·lícules, donat que l'objectiu és estudiar un conjunt de dades amb múltiples relacions i poder extreure certa informació a partir d'elles. Donat que no s'han revisat totes les dades en la seva totalitat, és possible que no es corresponguin completament a la saga, o bé que hi hagi algun error o ommissió respecte al contingut de les pel·lícules. En qualsevol cas, és sobre aquest joc de dades, que introduïrem a Neo4j, que es desenvoluparan les respostes.

Per a la realització de l'exercici s'ha de fer servir la versió de Neo4j ja instal·lada a la màquina virtual del curs. Si us plau, ignoreu la base de dades Twitter Neo4j i recordeu que l'usuari/contrasenya per accedir a Neo4j és: neo4j / uoc.

La proposta de solució a tots els apartats ha de proporcionar les consultes Cypher en format text. En relació als resultats obtinguts per les consultes:

- S'adjuntarà un mode text sempre que sigui possible (tal com hem comentat en els exercicis de Cassandra i es veurà en els de MongoDB).
- De no ser possible fer-ho en mode text (per exemple, en el cas que el resultat retorni les dades en format de graf), es podrà presentar el resultat mitjançant una captura de pantalla no textual.

2.1 Càrrega de dades (no puntua)

A continuació es presenten les instruccions per crear un nou graf a Neo4j. Prèviament s'eliminarà tota la informació del graf carregat per defecte. L'apartat no puntua, però és fonamental per una execució correcta de la resta de l'exercici.

TASCA PRÈVIA: Eliminació de tots els nodes, relacions, índexs i restriccions de la base de dades per defecte.

Es recomana executar les sentències mitjançant la versió gràfica de Neo4j. S'hi pot accedir indicant la següent URL al navegador web, després d'haver arrencat la base de dades: `localhost:7474`. L'usuari i contrasenya és: neo4j / uoc.

La versió de Neo4j utilitzada (*community edition*) permet només una base de dades activa. Per això, es recomana utilitzar la base de dades "neo4j" per realitzar l'activitat. Per situar-nos en aquesta base de dades podem executar la següent comanda (fixeu-vos que no hi ha punt i coma final):

```
:USE neo4j
```

Un cop a la base de dades, serà convenient esborrar les dades que hi puguin haver.

- La següent comanda esborra tots els nodes i les seves relacions:

```
MATCH (n) DETACH DELETE n;
```

- La següent comanda presenta tots els índexs i restriccions que encara romanen al gestor de grafs, **i que haureu d'eliminar**:

```
SHOW indexes;
```

NOTA: En cas que algú tingui una versió anterior de Neo4j (o la versió community), les sentències SHOW indexes i SHOW constraints poden no funcionar. En aquests casos s'utilitza CALL db.indexes() i CALL db.constraints().

- Les comandes següents presenten exemples d'eliminació particular de cadascun dels índexs i restriccions. **Adapteu-los, modificant els identificadors corresponents**, per eliminar tots els índexs i restriccions de la sortida de la comanda anterior:

```
DROP INDEX index_f7700477;
```

```
DROP INDEX index_343aff4e;
```


```
DROP CONSTRAINT constraint_59c89b17;
```

CREACIÓ DELS NOUS NODES I LES SEVES RELACIONS

Introducció: una de les maneres més habituals d'obtenir dades és importar-les des d'altres sistemes. Aquestes arribaran en un format determinat com ara CSV, JSON o XML. En el nostre cas, farem servir servir un script de Cypher que carregarà cadascun dels fitxers CSV corresponents a les entitats i relacions existents, amb l'objectiu de crear tots els registres. Aquest codi fa ús de les funcions de la llibreria APOC (Awesome Procedures on Cypher), ja instal·lada en la versió de Neo4j de la màquina virtual.

Copia el contingut del fitxer [GitHub](https://raw.githubusercontent.com/planetacomputer/starwars-full/refs/heads/main/CreateDB3.5.cypher) <https://raw.githubusercontent.com/planetacomputer/starwars-full/refs/heads/main/CreateDB3.5.cypher> i enganxa'l a la mateixa interfície de comandes web que hem indicat anteriorment. És important que la connexió a Internet de la màquina sigui la correcta, donat que el servidor de Neo4j de la màquina virtual acabarà carregant, en última instància, els fitxers CSV amb les dades que, tal com es pot observar al codi Cypher, es troben també al repositori de

GitHub. Després d'executar l'script de Cypher, el nombre total de nodes a la base de dades hauria de ser 528, i el de relacions 877.




Tal com s'ha assenyalat, aquest script està adaptat a la versió Neo4j de la MV del curs (3.5.35 community) que, al seu torn, té instal·lada la llibreria APOC. És possible que en una altra versió més actualitzada mostri algun tipus d'incompatibilitat que obligui a dur a terme alguna mena de modificació, sobretot amb la creació de les CONSTRAINTS. **És per això que l'script s'ha de fer servir a la màquina virtual indicada.**

2.2 Context de les dades (no puntua)

Context: les dades pertanyen tant a detalls sobre la sèrie de les pel·lícules (títol, directors, productors) com als personatges (character) que apareixen en elles. En concret, sobre els nodes corresponents a aquesta darrera etiqueta, veiem la seva relació amb el planeta al qual pertanyen, a quina espècie pertanyen, i l'organització de la qual puguin ser líders.

Estudiar el model de dades en graf obtingut: (CALL db.schema.visualization()) des de la interfície web disponible a l'adreça <http://localhost:7474/>



Breu descripció dels nodes i d'algunes de les relacions existents:

- Film PRODUCED_BY Person → persona (real) que va produir (o coproduir, si n'hi ha més d'una) la pel·lícula.
- Film DIRECTED_BY Person → persona (real) que va dirigir la pel·lícula.
- Planet APPEARS_IN Film → planeta que apareix a la pel·lícula.
- Organization APPEARS_IN Film → organització que apareix a la pel·lícula. Per organització entenem un grup, facció o entitat formal amb estructura, lideratge i un propòsit específic.
- Character LEADER_OF Organization → personatge que lidera una organització.
- Character IS_OF_SPECIE Specie → personatge que pertany a una determinada espècie.
- Character IS_HOMEWORLD Planet → personatge que prové d'un determinat planeta.
- Specie IS_HOMEWORLD Planet → espècie que prové d'un determinat planeta.
- Specie BELONGS_TO Classification → cada espècie pertany a un tipus més genèric, anomenat classificació i que pot englobar d'altres espècies.
- Specie BELONGS_TO Affiliation → a la saga, una espècie sencera pot donar suport a un govern o causa.
- Organization BELONGS_TO Affiliation → les organitzacions tenen una relació de pertinença amb els governs que lluiten per una causa.

2.3 Consultes

Es proposa respondre les següents consultes un cop carregades les dades, fent servir Cypher i la interfície web de Neo4j.

Per tal que una proposta de solució pugui ser considerada vàlida s'han de proporcionar:

- Les **consultes Cypher** plantejades i els **resultats** obtinguts, en format taula, presentats ambdós **en format text (no seran vàlides, en aquest cas, captures de pantalla)**.
- Les consultes **han d'estar justificades**, tot exposant els aspectes claus del disseny que permeten satisfer els requisits de la pregunta.

Consulta 1 (10%)

Mostra per pantalla el recompte de naus que apareixen a la pel·lícula 'A New Hope', de manera que, en la primera columna, aparegui el nombre de naus i, en la segona, una llista amb els noms d'aquestes naus.

Consulta 2 (10%)

Mostra per pantalla el planeta del qual procedeixen el nombre més gran de personatges de la nostra base de dades indicant, en la primera columna, el nom del planeta, en la segona la quantitat de personatges nascuts allà i, finalment, en la tercera columna, la llista amb els seus noms.

Consulta 3 (18%)

A la següent consulta volem obtenir els noms de les espècies els personatges de les quals provenen de més d'un planeta. A la primera columna es mostrarà el nom de l'espècie que compleix aquest requisit, a la segona, el nombre de planetes total del qual prové el conjunt dels seus individus i, a la tercera, el llistat d'aquests planetes. Han d'aparèixer en primer lloc les espècies el conjunt d'individus de les quals pertanyin a més planetes.

Consulta 4 (20%)

Volem obtenir els personatges que van pilotar alguna nau que apareix a una pel·lícula el títol de la qual contingui, sigui en majúscules o sigui minúscules, la paraula *Hope*. Per cada resultat s'ha de mostrar el títol de la pel·lícula, el nom del personatge i el nom de la nau. Els resultats estaran ordenats primer pel títol de la pel·lícula, a continuació pel nom del personatge i finalment pel nom de la nau.

Consulta 5 (20%)

Ens sol·liciten el llistat dels personatges de l'espècie 'Human' que han pilotat més d'una nau del tipus 'Patrol craft'. Per a això, en la primera columna ha d'aparèixer el nom del personatge, en la segona el nombre de naus diferents d'aquesta classe que ha pilotat, en la tercera la llista amb els noms d'aquestes naus.

Consulta 6 (22%)

Volem llistar una classificació dels personatges de Star Wars que han acabat pilotant determinades naus espacials. En concret, es pretén catalogar els personatges de la facció 'Pilot Rebel', que hagin pilotat almenys una nau el nom de la qual contingui *X-wing*, o bé com a 'Pilot Imperial', en cas d'haver pilotat alguna nau el nom de la qual inclogui *TIE*.

La consulta ha de mostrar, en la primera columna el nom del personatge, en la segona la seva categoria de pilot (segons les dues denominacions indicades anteriorment), en la


tercera el nombre total de naus que ha pilotat i, finalment, la llista amb els noms d'aquestes naus. El resultat final ha d'excloure els personatges que no entrin en cap d'aquestes dues categories, i ordenar-se de major a menor segons el nombre total de naus (sigui el que sigui el nom de la nau) pilotades pel personatge.

Exercici 3: MongoDB(35%)


Per crear la base de dades necessària per realitzar tots els exercicis de MongoDB, haureu de seguir les instruccions detallades a l'apartat MongoDB disponible al manual “Ús de màquina virtual”. No confongueu amb l'apartat MongoDB replicaset, aquest apartat no serà necessari per a aquesta pràctica.

Càrrega de dades


Ens situem a la carpeta de MongoDB fent doble clic sobre la icona MongoDB, **no feu servir la carpeta MongoDB ReplicaSet**.




Iniciem el servei de la base de dades de MongoDB fent doble clic sobre la icona Start MongoDB.



Fem doble clic sobre la icona de la mateixa carpeta “Start MongoDB” que obrirà una altra finestra de terminal. **No la tanqueu, ja que aturarieu el procés de MongoDB.** Podeu minimitzar-la.



Novament a la carpeta MongoDB, fem clic amb el botó dret en un espai en blanc, i en *Abrir en una terminal*.




Copiem i executem la següent ordre (en una terminal s'enganxa amb CTRL + MAJÚSCULES + V o botó dret > enganxar). La comanda és d'una sola línia, elimineu qualsevol salt de línia que es pugui haver afegit en copiar i enganxar.

```
git clone
https://github.com/uoc-bbdd-no-tradicionales/mongodb-sample-dataset.
git && cd mongodb-sample-dataset && ./script.sh
```

Aquesta comanda esborra la base de dades si existeix, i carrega totes les dades a partir dels fitxers descarregats. Utilitzeu-la només per la càrrega inicial o si voleu restablir la base de dades.

El resultat d'aquesta comanda serà:



Un cop acabada la càrrega de la base de dades, al mateix terminal podem executar l'ordre:

```
mongo
```

I una vegada a la interfície d'ordres de mongoDB podem executar:

```
use bikes_app
```


Que ens situarà a la base de dades de bikes_app. Per comprovar que tot ha anat bé podem executar:

```
show collections
```

Que ens ha de retornar:

```
> show collections
bikes
users
>
```

O com es veu a la següent captura de pantalla:



També podeu fer doble clic a la icona amb nom “Mongo CLI” que ens proporciona la *shell* des de la qual podem accedir a MongoDB. Recordeu que abans de fer doble clic a “Mongo CLI” s’ha d’haver iniciat el servei fent clic a la icona “Start MongoDB”.

Si atureu la màquina virtual i la torneu a arrancar, haureu de repetir els passos indicats al manual per iniciar el servei MongoDB i els passos per connectar-vos a la base de dades (incloent-hi la comanda `use sample_analytics`). **No repetiu el pas de càrrega de dades (l'ordre que comença amb la instrucció `git clone https://github.com/`) tret que vulgueu esborrar i carregar tota la base de dades de nou. Tingueu present que aquesta comanda esborra la base de dades (si existeix) i la torna a crear a partir dels fitxers de dades.**

Ja estem a la base de dades acabada de carregar, i ja podem fer les consultes.

En tot moment podeu comprovar si esteu a la base de dades correcta escrivint la comanda `db` que indica a quina base de dades s’està treballant actualment. Per exemple:

```
> db
```

Retorna:

```
bikes_app
>
```

Per tant estem a la base de dades correcta. Si l'ordre retorna una altra base de dades com ara:

```
> db
test
>
```

Indica que esteu a la base de dades de test, per tant no trobareu les col·leccions carregades a la base de dades `bikes_app`. **Tingueu en compte que MongoDB és *case sensitive* (sensible a majúscules i minúscules) en totes les comandes que s'executen, incloent els noms dels atributs quan s'especifiquen a les consultes.** Per tant, la base de dades amb la "B" en majúscules `Bikes_app` (incorrecta) no és la mateixa que `bikes_app` (correcta). Si teclejeu per error `use Bikes_app` en comptes de `use bikes_app`, us haureu situat en una base de dades buida anomenada `Bikes_app`.

Finalment, recordeu que després de reiniciar no cal repetir els passos per carregar la base de dades, perquè les dades ja es guarden a la màquina virtual. Només caldrà repetir els passos per iniciar el servei i connectar-vos al terminal.

Consultes

Com sabeu, MongoDB és *schemaless* de manera que l'estructura dels documents que hi ha a les col·leccions pot ser diferent. Per veure quina és l'estructura dels documents de cada col·lecció, haureu d'anar seleccionant-ne els documents de cada col·lecció. La base de dades proporcionada és una base de dades fictícia d'anàlisi de dades i de comptes financers. Les col·leccions i els camps dels documents són prou descriptius per entendre'n el significat.

Us recomanem que mireu bé què hi ha als documents de cada col·lecció revisant-ne alguns. Cal entendre quina informació hi ha emmagatzemada en una base de dades *schemaless*, ja que la base de dades no proporciona aquesta informació, i l'heu d'entendre i mantenir vosaltres mateixos. En cas de tenir dubtes sobre la seva semàntica, us animem a comentar-ho de forma col·laborativa als fòrums de l'assignatura.

Consulta d'exemple

Mostra un usuari de la col·lecció `users` en un format JSON que en faciliti la llegibilitat.

SOLUCIÓ D'EXEMPLE:

Executem:

```
db.users.find({_id: "16943224Q"}).pretty()
```

Que retorna:

```
{
  "_id" : "16943224Q",
  "name" : {
    "first" : "Jose Angel",
    "last" : "Vargas Cabrera"
  },
  "email" : "joseangelvargascabrera@me.com",
  "age" : 17,
  "birthDate" : ISODate("2008-01-23T00:00:00Z"),
  "firstUse" : ISODate("2025-01-26T17:04:56Z"),
  "daysUsed" : 291,
  "lastUse" : ISODate("2025-01-26T17:04:56Z"),
  "rides" : [ ],
  "nRides" : 0,
  "credits" : 0.98
}
```

Si us plau, adjunteu les respostes en mode text com es fa en aquest exemple, no en captures de pantalla. Si no s'indica el contrari, les consultes d'aquest exercici retornen una quantitat de dades que cap perfectament a la pràctica com a text i s'ha d'adjuntar sencera. Si els resultats no caben en pantalla, s'indicarà a l'enunciat i podreu segmentar la sortida a la vostra resposta.

Per aquelles consultes de modificació de dades, cal adjuntar la consulta que modifica les dades, el que retorna, i una altra consulta que mostri que les dades han quedat correctament modificades.

Consulta 1 (10%)

Per a una campanya de revisió d'hivern es busca un tipus de bicicleta molt específic: bicicletes de la marca "Orbea" o "BH" i que, a més, incloguin les funcionalitats "absBrakes" i "lamps" (poden tenir més funcionalitats, però han d'incloure aquestes dues). Cal mostrar la seva matrícula, marca i les seves característiques i ordenar els resultats per la matrícula en ordre ascendent.

Per a aquesta consulta, mostreu el nombre de documents obtinguts i un exemple dels 5 primers.

Consulta 2 (10%)

Recuperar totes les bicicletes que tinguin almenys dos danys reportats i que, a més a més, tinguin un casc o menys. Mostrar només la matrícula (és a dir, el `_id`), la llista de danys i el nombre de cascots disponibles. Ordenar els resultats en ordre descendent pel nombre de danys, de cascots disponibles i `_id` (en aquest ordre).

Per a aquesta consulta, adjunteu el nombre de documents obtinguts al realitzar la consulta i un exemple dels 5 primers.

SUGGERIMENT: S'adjunta un enllaç a aquest [article](#), on s'expliquen diferents mètodes per filtrar un array que contingui un nombre més gran a X d'elements.

Consulta 3 (20%)

L'equip de màrqueting està preparant la segmentació d'usuaris per a la propera temporada i necessiten entendre la distribució d'edat dels nostres usuaris. Per això sol·liciten un informe que agrupi els usuaris pel seu any de naixement, és a dir, necessiten obtenir un recompte de quants usuaris han nascut cada any. S'haurà de mostrar els anys de naixement i el nombre total d'usuaris nascuts per cada any, ordenats per any ascendent. Limitar el nombre de resultats a cinc.

Consulta 4 (20%)

L'equip d'operacions vol entendre millor els patrons d'ús. Sol·liciten un informe que mostri la distància mitjana dels viatges recents, segmentat per grup d'edat, amb l'objectiu d'optimitzar la logística de les bicicletes. Calculeu la distància mitjana dels viatges dels usuaris, segmentant-los per grups d'edat. Els grups han de ser: [16-25], [26-35], [36-45], [46-55] i [56-65].

SUGGERIMENT: per a la resolució d'aquesta consulta cal utilitzar, entre d'altres, l'etapa d'agregació [\\$bucket](#). Es recomana llegir la documentació proporcionada.

Consulta 5 (20%)

Es vol crear un índex d'antiguitat, `Index`, per a les bicicletes que ens ajudi a identificar les més usades. Aquest índex es calcula a partir de la fórmula següent: $(kms * 0.4) + (rides * 0.6)$. Calculeu aquest índex per a totes les bicicletes de la marca "Vandor" que no estiguin netes. Mostrar la matrícula, kms, rides, i el `Index` calculat, ordenat de major a menor antiguitat, és a dir, en ordre descendent i mostrant només els 5 primers resultats.

SUGGERIMENT: per la resolució d'aquesta consulta cal utilitzar, entre d'altres operadors i etapes, els operadors [aritmètics](#). Es recomana llegir la documentació proporcionada.

Consulta 6 (20%)

El departament de manteniment ha detectat que l'accessori "lamps" està donant problemes elèctrics i ha decidit retirar físicament aquest accessori de totes les bicicletes. Com a conseqüència, hem d'actualitzar la base de dades. Per tant, cal eliminar la funcionalitat "lamps" de l'array de funcionalitats extra de totes les bicicletes que la tinguin instal·lada.

En aquest cas cal adjuntar la consulta que modifica les dades, el que retorna i una altra consulta que mostri que les dades han quedat correctament modificades, és a dir, que no hi ha resultats si es busquen bicicletes amb "lamps".

Criteris de valoració

A cada exercici es valorarà la validesa de la solució i la claredat de l'argumentació. Cada exercici té indicat a l'enunciat el seu pes en la valoració final.

Format i data de lliurament

Heu d'enviar la PRA1 a "Continguts > Lliurament de l'activitat PRA1", disponible a l'aula. El format del fitxer que conté la vostra solució pot ser .pdf, .odt, .doc i .docx. Per d'altres opcions, si us plau, contacteu prèviament amb el vostre professor col·laborador. El nom del fitxer ha de contenir el codi de l'assignatura, el vostre cognom i el vostre nom, així com el número d'activitat (PRA1). Per exemple codiassig_cognom1_nom_pra1.docx.

La data límit per lliurar la PRA1 és el **18/01/2026**.

Propietat intel·lectual

En presentar una pràctica o PAC que faci ús de recursos aliens, s'ha de presentar juntament amb ella un document en què es detallin tots ells, especificant el nom de cada recurs, el seu autor, el lloc on es va obtenir i el seu estatus legal: si l'obra està protegida pel copyright o s'acull a alguna altra llicència d'ús (Creative Commons, llicència GNU, GPL, etc.). L'estudiant haurà d'assegurar-se que la llicència que sigui no n'impedeixi específicament l'ús en el marc de la pràctica o PAC. En cas de no trobar la informació corresponent, haureu d'assumir que l'obra està protegida pel copyright.

Caldrà, a més, adjuntar els fitxers originals quan les obres utilitzades siguin digitals, i el seu codi font, si escau.