
Models generatius

PID_00290590

Jordi de la Torre Gallart

Temps mínim de dedicació recomanat: 6 hores



Universitat
Oberta
de Catalunya

Jordi de la Torre Gallart

L'encàrrec i la creació d'aquest recurs d'aprenentatge UOC han estat coordinats pel professor: Jordi Casas Roma

Com citar aquest recurs d'aprenentatge amb l'estil Harvard:

De la Torre Gallart, J. (2024). *Models generatius*. [Recurs d'aprenentatge textual]. 1a. ed. Barcelona: Fundació Universitat Oberta de Catalunya (FUOC).

Primera edició: febrer 2024

© aquesta edició, Fundació Universitat Oberta de Catalunya (FUOC)

Av. Tibidabo, 39-43, 08035 Barcelona

Autoria: Jordi de la Torre Gallart

Producció: FUOC

Tots els drets reservats

Cap part d'aquesta publicació, incloent-hi el disseny general i la coberta, no pot ser copiada, reproduïda, emmagatzemada o transmesa de cap manera ni per cap mitjà, tant si és elèctric com mecànic, òptic, de gravació, de fotocòpia o per altres mètodes, sense l'autorització prèvia per escrit del titular dels drets.

Índex

Introducció	7
Objectius	8
1. Una introducció als models generatius	9
2. Models probabilístics	11
2.1. Modelització probabilística	11
2.1.1. Dificultats	11
2.1.2. Representació	12
2.1.3. Inferència	12
2.2. Revisió de conceptes de probabilitat	12
2.2.1. Elements	12
2.2.2. Probabilitat condicional	13
2.2.3. Regla de la cadena	13
2.2.4. Independència	13
2.3. Variables aleatòries	13
2.4. Funcions de distribució acumulativa	14
2.5. Funcions de massa de probabilitat	14
2.5.1. Funcions de densitat de probabilitat	15
2.5.2. Esperança	15
2.5.3. Variància	16
2.5.4. Algunes variables aleatòries comunes	17
2.5.5. Dues variables aleatòries	18
2.5.6. Teorema de Bayes	20
2.5.7. Independència	21
2.5.8. Esperança i covariància	21
3. Models generatius basats en xarxes antagòniques o adversàries (GANs)	23
3.1. El concepte de xarxes antagòniques	24
3.2. Avantatges i inconvenients de les GAN	25
3.3. Arquitectures derivades	26
3.3.1. GAN semisupervisada (SGAN)	26
3.3.2. Conditional GAN (CGAN)	26
3.3.3. Xarxa antagònica generativa convolucional profunda (DCGAN)	27
3.3.4. Progressive GAN (PROGAN)	27
3.3.5. Self-attention GAN (SAGAN)	27
3.3.6. BigGAN	29
3.3.7. StyleGAN	29

3.4.	f-GAN, una generalització de les GANs.....	31
3.4.1.	Introducció	31
3.4.2.	Estimació de models probabilístics	31
3.4.3.	GANs com a models probabilístics.....	32
3.4.4.	Distància entre distribucions de probabilitat	32
3.4.5.	Conclusió	35
3.4.6.	Funcions d'optimització millorades	35
3.5.	Una aplicació de les GAN: augment de dades	38
3.6.	Conclusions.....	39
4.	Autocodificadors	40
4.1.	Introducció a l'estructura general dels autocodificadors.....	40
4.2.	Definició formal	41
4.3.	Entrenament.....	41
4.4.	Autocodificadors regularitzats.....	41
4.4.1.	Autocodificadors poc densos (SAE)	42
4.4.2.	Autocodificadors d'atenuació de soroll (DAE)	42
4.4.3.	Autocodificador contractiu	43
4.5.	Aplicacions típiques.....	43
5.	Models generatius basats en autocodificadors	
	variacionals (VAEs)	45
5.1.	Models probabilístics	46
5.2.	Optimització de models probabilístics	46
5.3.	Inferència variacional (VI)	47
5.3.1.	Variables observables vs. ocultes.....	47
5.3.2.	Formalització matemàtica	47
5.3.3.	Límit inferior d'evidència (ELBO).....	48
5.3.4.	ELBO com a mitjà d'optimitzar q_ϕ	49
5.4.	El codificador com a forma d'aproximar el posterior	50
5.5.	Optimització de l'ELBO mitjançant gradient estocàstic	51
5.6.	Càlcul de q_ϕ	53
5.7.	Posteriors gaussians	53
5.8.	Posterior gaussiana amb matriu de covariància general	54
5.9.	Desafiaments de l'arquitectura	55
5.10.	Posteriors no gaussians.....	56
5.11.	Propostes d'extensió de l'autocodificador variacional original	56
5.12.	Conclusions.....	58
6.	Models generatius basats en difusió	60
6.1.	Formulació matemàtica	60
6.2.	Models probabilístics d'eliminació del soroll produït per difusió	62
6.2.1.	Procés directe de difusió	62
6.2.2.	Procés de difusió invers o de reconstrucció	63
6.2.3.	Funció de pèrdua	64

6.2.4.	Procés de mostreig i entrenament	67
6.2.5.	Implementació	67
6.2.6.	Parametrització de β_t i Σ_θ	68
6.2.7.	Connexió amb els VAEs	68
6.2.8.	Resum	69
6.3.	Generació basada en puntuació mitjançant l'ús d'equacions diferencials.....	69
6.3.1.	Recordatori d'equacions diferencials.....	69
6.3.2.	El procés de difusió directa com una SDE.....	70
6.3.3.	El procés de difusió invers mitjançant SDEs	70
6.3.4.	Funció de puntuació.....	71
6.4.	Conclusions.....	72
Resum		74
Glossari		75

Introducció

En aquest mòdul s'introdueixen els models generatius basats en arquitectures d'aprenentatge profund. La finalitat d'aquests models és la generació de noves dades que s'assemblen a les d'entrenament. Veurem diferents maneres d'aproximar el problema, totes elles basades en aprenentatge profund, entre les quals es troben les xarxes de generació adversàries, els autocodificadors variacionals (i arquitectures derivades) i els models basats en els mecanismes de difusió.

L'objectiu d'aquest mòdul és presentar els coneixements de base necessaris per introduir-se en l'àmbit dels models generatius i estar en condicions d'aprofundir en aquests aspectes mitjançant la consulta de la bibliografia especialitzada. Aquest camp de coneixement està en profunda evolució, per això és clau no entendre els coneixements aquí presentats com un tractat conclús, sinó com una porta des de la qual accedir a un camp de coneixement que va molt més enllà d'aquest mòdul.

Objectius

Els objectius que es pretén aconseguir en aquest mòdul es poden resumir en els punts següents:

- 1.** Definir una nova classe de models predictius, denominats generatius.
- 2.** Presentar algunes de les propostes existents per abordar el problema de generació de dades.
- 3.** Introduir els fonaments teòrics de les tres propostes més reeixides fins al moment per abordar el problema; a saber, les xarxes de generació antagòniques adversàries, autocodificadors variacionals i els models basats en mecanismes de difusió.

1. Una introducció als models generatius

En els mòduls anteriors hem estudiat diverses arquitectures de xarxes neuronals que permeten modelitzar funcions complexes per a l'avaluació de variables, totes elles amb finalitats de classificació o de regressió. Aquests models queden recollits sota la classe dels denominats **models discriminatius**.

En aquest mòdul didàctic introduïrem una classe diferent de models: els **models generatius**. A diferència dels primers, la seva finalitat no consisteix en la discriminació de les dades d'entrada, sinó en la generació d'instàncies de dades equivalents.

Formalment, donat un conjunt de dades $\mathbf{X}$ i unes etiquetes associades a aquests $\mathbf{y}$, l'objectiu dels models discriminatius seria predir funcions del tipus $P(\mathbf{y}|\mathbf{X})$, mentre que el dels generatius seria capturar $P(\mathbf{X},\mathbf{y})$ o simplement $p(\mathbf{x})$ de manera que sigui possible generar $\mathbf{x} \in \mathbf{X}$ o fins i tot parells $\mathbf{x},\mathbf{y} \in \mathbf{X}$.

L'objectiu dels models generatius és, per tant, la generació de dades similars (idealment pertanyents) a la població de la qual deriva la mostra de dades que conforma el conjunt d'entrenament.

La tasca que s'ha d'abordar és significativament més complexa que la que resolten els models discriminatius. Per exemple, un model generatiu d'imatges ha de ser capaç de capturar les correlacions existents entre els diferents elements que apareixen a la imatge, de manera que mostri de manera conjunta aquells que és més probable que apareguin junts. Una manera d'aconseguir això és capturant els seus elements constitutius. Això requereix, idealment, ser capaç d'identificar l'existència d'aquests elements, així com la seva modelització independent. Les distribucions associades solen ser complexes, en contrast amb les regularitats estadístiques que cal distingir per establir una classificació típica d'un model discriminatiu.

Aquesta diferenciació que hem establert també la podríem analitzar des d'una altra perspectiva, a saber, el tipus de dades que calen per resoldre aquests problemes. Els models discriminatius històricament s'han resolt utilitzant un enfocament *supervisat*, és a dir, les dades estan formades per un conjunt d'instàncies i un conjunt d'etiquetes que han estat prèviament identificades per humans experts. En els models generatius no cal l'existència d'etiquetes, perquè l'objectiu d'aquests és la inferència de propietats internes a partir, únicament, de l'observació del conjunt d'entrenament. L'objectiu posterior és la generació de noves mostres que copii les propietats definitòries de la pobla-

ció a la qual representen. El tipus d'aprenentatge requerit en aquesta mena de models és *no supervisat*.

El desafiament conceptual existent consisteix a capturar la distribució de probabilitat de la població representada per les dades d'entrada (Dades d'entrenament $\sim P_{dades}(x)$), en un model que permeti generar noves instàncies que emulin el comportament observat (Mostres generades $\sim P_{model}(z)$).

No únicament ens interessa assolir aquest objectiu, sinó també fer-ho d'una manera similar a com ho fem els éssers intel·ligents, això és, comprimint la informació en entitats abstractes útils. Una possible manera d'abordar el problema és definir el que denominem *variables latents*, de menor dimensió representativa que la real, i buscar un model algorítmic que permeti trobar la funció capaç de reduir les dimensions, maximitzant la retenció d'informació útil. Si el model resultant permet comprimir la informació en un conjunt de variables reduït, es pot esperar que aquestes variables continguin la informació essencial i distintiva de les dades font, i aquesta informació es pot utilitzar per controlar la generació de dades sobre la base del valor desitjat de les variables latents. Aquesta diferenciació en variables definitòries pot ser utilitzada, per exemple, per a l'ajust i l'eliminació de biaixos en el conjunt de dades original, augmentant artificialment aquelles variables separades menys representades. El coneixement d'aquestes variables també pot ser útil per a la identificació de valors estranys, és a dir, *outliers*. Depenent de l'objectiu que persegueixi el nostre model, ens servirà per identificar-les i separar-les (per exemple, en sistemes de control de qualitat de producte), o bé per incorporar-les com a situacions excepcionals al nostre model i millorar-ne així la capacitat predictiva (per exemple, situacions excepcionals trobades en sistemes de conducció assistida).

Com hem descrit, els models generatius són, en essència, més complexos que els discriminatius i tenen un àmbit d'aplicabilitat molt extens. En els pròxims apartats introduïrem diverses maneres d'abordar aquest desafiament predictiu. Estudiarem els autocodificadors, les xarxes generatives adversàries i els models basats en difusió, tots ells per a la generació d'imatge. Els models generatius de text s'estudien en el mòdul dedicat als transformadors.

2. Models probabilístics

En aquesta introducció explicarem els conceptes bàsics de probabilitat (Koller i Friedman, 2009) que són claus per comprendre la naturalesa probabilística de la majoria dels models generatius existents, especialment els autocodificadors variacionals.

2.1. Modelització probabilística

Quan tractem de predir esdeveniments del món real utilitzant les matemàtiques, solem fer servir operacions entre variables que en el seu conjunt defineixen el que denominem models matemàtics. A vegades pot interessar relacionar variables probabilístiques, això és, variables que no tenen un valor numèric definit, sinó que el seu valor està sotmès a la incertesa. En aquests casos, es poden modelitzar les seves relacions mitjançant distribucions de probabilitat.

2.1.1. Dificultats

La modelització probabilística té una sèrie de dificultats que intentarem presentar a través d'un exemple:

Suposem que disposem d'un model probabilístic paramètric per fer la classificació de correus d'*spam*. Aquest model podria tenir la forma $p_\theta(y, x_1, \dots, x_n)$, on y és una variable binària que pot prendre els valors *spam* o *no spam* i $x_1, x_2, \dots, x_n$ les variables dependents que suposarem, a l'efecte de simplificació, totes binàries. Si volguéssim classificar un nou correu ens fixaríem en el valor de la funció $p(y = 1 | x_1, \dots, x_n)$, això és, la funció que respon a la pregunta de quina és la probabilitat que y sigui *spam* condicionat al fet que $x_1, \dots, x_n$ tinguin un valor determinat.

Si ens preguntem sobre el domini de la funció que acabem de definir ens adonarem que és immens. Si haguéssim d'expressar en forma de taula tots els valors que pot prendre la funció, necessitaríem un total de 2^{n+1} entrades. Si n fos igual a la mida del vocabulari ens adonaríem que seria clarament intractable, tant des del punt de vista computacional com estadístic. Els mètodes probabilístics solen tenir relacions entre variables que escalen de manera exponencial. Una manera de convertir-los en tractables és mitjançant la simplificació sobre la base de la realització de suposicions.

2.1.2. Representació

La representació no és un problema trivial. Ja hem vist en l'exemple del problema de l'*spam*, de manera general, que per a un missatge que pot contenir n paraules diferents, hem d'especificar en el cas més general i sense suposicions, $\mathcal{O}(2^n)$ paràmetres.

2.1.3. Inferència

Suposem que hem estat capaços de trobar la distribució conjunta de probabilitat de les variables que l'integren, $p(x_1, x_2, \dots, x_n)$. A continuació enumerem les preguntes típiques que estariem interessats a respondre.

- *Inferència marginal*: avaluació de la probabilitat que una variable x_1 prengui un valor independentment de la resta. $p(x_1) = \sum_{x_2} \sum_{x_3} \cdots \sum_{x_n} p(x_1, x_2, \dots, x_n)$
- *Inferència Maximum a posteriori (MAP)*: dona com a resultat quina és la configuració de variables més probable $\operatorname{argmax}_{x_1, \dots, x_n} p(x_1, \dots, x_n)$.

En general, la inferència sobre la distribució de probabilitat sol requerir operacions de complexitat NP-hard. La dificultat d'aquestes operacions està relacionada també amb l'estructura del graf que descriu la probabilitat, això és, en el fons amb les característiques de la funció de probabilitat.

2.2. Revisió de conceptes de probabilitat

2.2.1. Elements

A continuació fem la definició d'alguns elements bàsics necessaris per a la formalització de la probabilitat.

- **Espai de la mostra Ω** : és el conjunt de tots els resultats possibles d'un experiment aleatori. Cada succés $\omega \in \Omega$ es pot veure com una descripció completa d'un estat en el món real al final de l'experiment.
- **Conjunt d'esdeveniments (o espai d'esdeveniments)**: un conjunt els elements del qual $A \in F$ (anomenats esdeveniments) són un subconjunt de Ω (i.e. $(A \subseteq \Omega \text{ és un subconjunt dels possibles resultats d'un experiment})$).
- **Mesura de probabilitat**: una funció $P : F \rightarrow \mathbb{R}$ amb les propietats següents:
 - $P(A) \geq 0$, per a tot $A \in F$

Nota

Aquest subapartat està adaptat de Maleki i Do (2000).

- Si $A_1, A_2, \dots$ són esdeveniments disjunts (això és, $A_i \cap A_j = \emptyset$ quan $i \neq j$), llavors $P(\cup_i A_i) = \sum_i P(A_i)$
- $P(\Omega) = 1$

A aquestes tres propietats se les denomina **axiomes de probabilitat**.

2.2.2. Probabilitat condicional

Sigui B un succés amb probabilitat diferent de zero. Es defineix la probabilitat condicionada d'un esdeveniment A havent succeït B com:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \quad (1)$$

En altres paraules, $P(A|B)$ és la probabilitat que succeeixi A després d'haver observat que ha succeït l'esdeveniment B .

2.2.3. Regla de la cadena

Sigui $S_1, \dots, S_k$ una sèrie d'esdeveniments on $P(S_i) > 0$. La regla de la cadena diu que:

$$P(S_1 \cap S_2 \cap \dots \cap S_k) = P(S_1)P(S_2|S_1)P(S_3|S_2 \cap S_1) \dots P(S_k|S_1 \cap S_2 \cap \dots \cap S_{k-1}) \quad (2)$$

En el cas de $k = 2$, llavors la regla de la cadena coincideix amb l'equació 1.

2.2.4. Independència

Es diu que dos esdeveniments són independents si $P(A \cap B) = P(A)P(B)$, o bé equivalentment quan $P(A|B) = P(A)$. Intuïtivament, A i B són independents quan conèixer B no afecta la probabilitat d' A .

2.3. Variables aleatòries

Una variable aleatòria X és una funció $X : \Omega \rightarrow E$, on E és un espai mesurable. Habitualment, es representa amb majúscules les variables aleatòries, i amb minúscules els valors que pot prendre. Així, $X = x$ significa que assignem el valor $x \in E$ a la variable aleatòria X . Per a variables reals representem com $P(a \leq X \leq b) := P(\{\omega : a \leq X(\omega) \leq b\})$.

Si volem indicar que la variable A pren el valor 1, ho podem fer de la manera següent $\mathbf{1}\{A\}$. Un altre exemple seria:

$$\mathbf{1}\{X > 3\} = \begin{cases} 1 & \text{si } x > 3 \\ 0 & \text{si } x \leq 3 \end{cases} \quad (3)$$

2.4. Funcions de distribució acumulativa

Definim una distribució acumulativa de probabilitat (CDF) com a una funció $F_X(x) : \mathbb{R} \rightarrow [0,1]$ que mesura la probabilitat com $F_X(x) = P(X \leq x)$.

Propietats:

- $0 \leq F_X(x) \leq 1$
- $\lim_{x \rightarrow -\infty} F_X(x) = 0$
- $\lim_{x \rightarrow +\infty} F_X(x) = 1$
- $x \leq y \Rightarrow F_X(x) \leq F_X(y)$

2.5. Funcions de massa de probabilitat

En el cas en el qual el nombre de possibles valors que pot prendre una variable aleatòria X sigui finit, una forma més senzilla de representar la probabilitat és especificar directament el seu valor per a cada valor que pugui prendre. La funció de massa de probabilitat (PMF) és una funció $p_X : \mathbb{R} \rightarrow [0,1]$ per a la qual $p_X(x) = P(X = x)$. Per al cas d'una variable aleatòria discreta, utilitzem la notació $Val(X)$ per referir-nos al conjunt de tots els possibles valors que X pot tenir. Per exemple, en el cas que $X(\omega)$ fos una variable aleatòria referida al nombre de cares que poden sortir en tirar 10 vegades seguides una moneda a l'aire, llavors $Val(X) = \{0,1,2,\dots,10\}$.

Propietats:

- $0 \leq p_X(x) \leq 1$
- $\sum_{x \in Val(X)} p_X(x) = 1$
- $\sum_{x \in A} p_X(x) = P(X \in A)$

2.5.1. Funcions de densitat de probabilitat

Per a algunes variables aleatòries contínues, la funció distributiva acumulativa és diferenciable en tot el seu domini. En aquests casos, es pot definir la funció de densitat de probabilitat (PDF) com la derivada de la CDF, a saber:

$$f_X(x) = \frac{dF_X(x)}{dx}$$

Cal puntualitzar que la PDF d'una variable aleatòria contínua no sempre existeix (per exemple, en aquells casos on no és diferenciable en tots els seus punts).

D'acord amb les propietats de derivació, per a un petit δx , $P(x \leq X \leq x + \delta x) \approx f_X(x)\delta x$.

Tant els CDFs com les PDFs (quan existeixen) es poden fer servir per calcular probabilitats. És important fer notar que $f_X(x) \neq P(X = x)$.

Propietats:

- $f_X(x) \geq 0$
- $\int_{-\infty}^{+\infty} f_X(x) dx = 1$
- $\int_{x \in A} f_X(x) dx = P(X \in A)$

2.5.2. Esperança

Suposem que X és una variable aleatòria discreta amb una PMF $p_X(x)$ i $g : \mathbb{R} \rightarrow \mathbb{R}$ una funció arbitrària. En aquest cas, $g(X)$ pot ser considerada també una variable aleatòria. Definim l'esperança o valor esperat de $g(X)$ com

$$\mathbb{E}[g(X)] = \sum_{x \in \text{Val}(X)} g(x)(p_X(x))$$

Si X és una variable aleatòria contínua amb una PDF $f_X(x)$, llavors el valor esperat de $g(X)$ es defineix com

$$\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x)f_X(x) dx$$

Intuïtivament, l'esperança de $g(X)$ pot ser vista com una mitjana ponderada dels valors de $g(x)$ sobre tots els valors d' x , on els pesos venen donats per $p_X(x)$ o $f_X(x)$. Com a cas particular, cal observar que $\mathbb{E}[X]$ s'obté quan $g(x) = x$; aquest valor és conegut també com la mitjana de la variable X .

Propietats:

- $\mathbb{E}[a] = a$ per a qualsevol constant $a \in \mathbb{R}$
- $\mathbb{E}[af(X)] = a\mathbb{E}[f(X)]$ per a qualsevol constant $a \in \mathbb{R}$
- (Linealitat de l'esperança) $\mathbb{E}[f(X) + g(X)] = \mathbb{E}[f(X)] + \mathbb{E}[g(X)]$
- Per a una variable discreta aleatòria X , $\mathbb{E}[\mathbf{1}\{X = k\}] = P(X = k)$

2.5.3. Variància

La variància d'una variable aleatòria X és una mesura de com de concentrada es troba la variable X al voltant de la seva mitjana. Formalment, la variància es defineix com $\text{Var}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2]$

Utilitzant la propietat de l'esperança definida al subapartat anterior, podem derivar definicions alternatives.

$$\begin{aligned}\mathbb{E}[(X - \mathbb{E}[X])^2] &= \\&= \mathbb{E}[X^2 - 2\mathbb{E}[X]X + \mathbb{E}[X]^2] = \\&= \mathbb{E}[X^2] - 2\mathbb{E}[X]\mathbb{E}[X] + \mathbb{E}[X]^2 = \\&= \mathbb{E}[X^2] - \mathbb{E}[X]^2\end{aligned}$$

Propietats:

- $\text{Var}[a] = 0$ per a qualsevol constant $a \in \mathbb{R}$
- $\text{Var}[af(X)] = a^2 \text{Var}[f(X)]$ per a qualsevol constant $a \in \mathbb{R}$

2.5.4. Algunes variables aleatòries comunes

Variables aleatòries discretes

- $X \sim \text{Bernoulli}(p)$ on $(0 \leq p \leq 1)$: per exemple, el resultat de tirar una moneda a l'aire per a la qual la probabilitat de sortir cara és p .

$$p(\mathbf{x}) = \begin{cases} p & \text{si } x = 1 \\ 1 - p & \text{si } x = 0 \end{cases}$$

- $X \sim \text{Binomial}(n, p)$ on $(0 \leq p \leq 1)$: per exemple, la probabilitat d'obtenir x cares en n tirades de moneda independents, on p és la probabilitat que surti cara en una tirada.

$$p(\mathbf{x}) = \binom{n}{x} \cdot p^x (1-p)^{n-x}$$

- $X \sim \text{Geomètrica}(p)$ on $(0 \leq p \leq 1)$: per exemple, la probabilitat d'haver de realitzar x tirades independents per obtenir la primera cara, on p és la probabilitat que surti cara en una tirada.

$$p(\mathbf{x}) = p(1-p)^{(x-1)}$$

- $X \sim \text{Poisson}(\lambda)$ on $(\lambda > 0)$: distribució de probabilitat sobre els enters positius per modelitzar la freqüència d'esdeveniments estranys.

$$p(\mathbf{x}) = e^{-\lambda} \frac{\lambda^x}{x!}$$

Variables aleatòries contínues

- $X \sim \text{Uniforme}(a, b)$ on $(a < b)$: densitat de probabilitat igual per a qualsevol valor situat entre a i b .

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{si } a \leq x \leq b \\ 0 & \text{altres} \end{cases}$$

- $X \sim \text{Exponencial}(\lambda)$ on $(\lambda > 0)$: densitat de probabilitat de decaïment sobre els reals no negatius.

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{si } x \geq 0 \\ 0 & \text{altres} \end{cases}$$

- $X \sim \text{Normal}(\mu, \sigma^2)$ coneguda com a distribució gaussiana.

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

2.5.5. Dues variables aleatòries

Fins ara hem considerat esdeveniments amb una única variable aleatòria. No obstant això, és habitual trobar-se amb experiments on hi ha més d'una variable. Per exemple, en l'experiment de llançar una moneda a l'aire podem considerar, d'una banda, el nombre total de cares que ha sortit i, de l'altra, el nombre màxim de cares consecutives que ha sortit, que serien dues variables aleatòries.

Distribucions conjunta i marginal

Suposem que tenim dues variables aleatòries X i Y . Una manera de tractar amb aquestes variables és fer-ho per separat. Si ho fem d'aquesta manera únicament necessitaríem $F_X(x)$ i $F_Y(y)$. Però si volem saber sobre la interacció simultània de les dues variables en un experiment aleatori, llavors necessitem una estructura més complicada anomenada distribució acumulativa de X i Y , definida com:

$$F_{XY}(x, y) = P(X \leq x, Y \leq y)$$

Coneixent la distribució acumulativa de X i Y es pot conèixer la probabilitat de qualsevol esdeveniment que inclogui X i Y .

La CDF conjunta $F_{XY}(x, y)$ i les distribucions acumulatives $F_X(x)$ i $F_Y(y)$ estan relacionades de la manera següent:

$$F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x, y)$$

$$F_Y(y) = \lim_{x \rightarrow \infty} F_{XY}(x, y)$$

A $F_X(x)$ i $F_Y(y)$ se'ls denomina distribucions acumulatives marginals.

Propietats:

- $0 \leq F_{XY}(x,y) \leq 1$
- $\lim_{x,y \rightarrow \infty} F_{XY}(x,y) = 1$
- $\lim_{x,y \rightarrow -\infty} F_{XY}(x,y) = 0$
- $F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x,y)$

Funcions de massa de probabilitat conjunta i marginal

Siguin X i Y variables aleatòries discretes. Llavors la funció conjunta de massa de probabilitat $p_{XY} : \text{Val}(X) \times \text{Val}(Y) \rightarrow [0,1]$ es defineix com:

$$p_{XY}(x,y) = P(X = x, Y = y)$$

Aquí, $0 \leq p_{XY}(x,y) \leq 1$ per a tot x,y i $\sum_{x \in \text{Val}(X)} \sum_{y \in \text{Val}(Y)} p_{XY}(x,y) = 1$

Podem relacionar també $p_X(x)$ amb $p_{XY}(x,y)$ de la manera següent:

$$p_X(x) = \sum_y p_{XY}(x,y)$$

Ens referim a $p_X(x)$ com la funció de massa probabilística marginal. El procés d'anul·lar l'efecte d'una de les variables es denomina marginalització.

Funcions de densitat de probabilitat conjunta i marginal

Siguin X i Y dues funcions contínues aleatòries amb distribució conjunta de probabilitat F_{XY} . En cas que $F_{XY}(x,y)$ sigui diferenciable en tot el seu domini podem definir la funció de densitat de probabilitat conjunta com:

$$f_{XY}(x,y) = \frac{\partial^2 F_{XY}(x,y)}{\partial x \partial y}$$

Com en el cas unidimensional, $f_{XY}(x,y) \neq P(X = x, Y = y)$, però

$$\int \int_{(x,y) \in A} f_{XY}(x,y) dx dy = P((X,Y) \in A)$$

on $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f_{XY}(x,y) = 1$

Anàlogament al cas discret, definim

$$f_X(x) = \int_{-\infty}^{+\infty} f_{XY}(x,y) dy$$

com la funció de densitat de probabilitat marginal (o densitat marginal) de X . De manera anàloga amb $f_Y(y)$.

Distribucions condicionals

L'objectiu de les distribucions condicionals de probabilitat és la integració de la influència que exerceix de la informació de successos relacionats en la probabilitat d'un esdeveniment. Suposant que $P_X(x) \neq 0$, llavors

$$p_{Y|X}(y|x) = \frac{p_{XY}(x,y)}{p_X(x)}$$

En el cas continu i per analogia amb el cas discret, suposant que $f_X(x) \neq 0$,

$$f_{Y|X}(y|x) = \frac{f_{XY}(x,y)}{f_X(x)}$$

2.5.6. Teorema de Bayes

El teorema de Bayes es pot representar amb l'equació 4.

$$P_{Y|X}(y|x) = \frac{P_{XY}(x,y)}{P_X(x)} = \frac{P_{XY}(x|y)P_Y(y)}{\sum_{y' \in \text{Val}(Y)} P_{X|Y}(x|y')P_Y(y')} \quad (4)$$

A partir d'aquesta equació es deriva una terminologia que convé conèixer:

- **Prior**, $P_Y(y)$: probabilitat que succeeixi y abans de conèixer x .
- **Posterior**, $P_{Y|X}(y|x)$, probabilitat que succeeixi y coneixent que ha succeït x .
- **Evidence**, $P_X(x)$ probabilitat de l'esdeveniment contra el qual volem condicionar.
- **Likelihood**, $P_{XY}(x|y)$

En el cas que X i Y siguin variables contínues:

$$f_{Y|X}(y|x) = \frac{f_{XY}(x,y)}{f_X(x)} = \frac{f_{XY}(x|y)f_Y(y)}{\int_{-\infty}^{+\infty} f_{X|Y}(x|y')f_Y(y') dy'} \quad (5)$$

2.5.7. Independència

Dues variables aleatòries X i Y són independents si $F_{XY}(x,y) = F_X(x) \cdot F_Y(y)$. Equivalentment:

- Per a variables aleatòries discretes, $p_{XY}(x,y) = p_X(x) \cdot p_Y(y)$ per a tot $x \in \text{Val}(X)$ i $y \in \text{Val}(Y)$.
- Per a variables aleatòries discretes, $p_{Y|X}(y|x) = p_Y(y)$ sempre que $p_X(x) \neq 0$ per a tot $y \in \text{Val}(Y)$.
- Per a variables aleatòries contínues, $f_{XY}(x,y) = f_X(x)f_Y(y)$ per a tot $x,y \in \mathbb{R}$.
- Per a variables aleatòries contínues, $f_{Y|X}(y|x) = f_Y(y)$ sempre que $f_X(x) \neq 0$ per a tot $y \in \mathbb{R}$.

2.5.8. Esperança i covariància

Suposem que tenim dues variables aleatòries X,Y i $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ és una funció d'aquestes variables. Llavors, el valor esperat de g es defineix com:

$$\mathbb{E}[g(X,Y)] = \sum_{x \in \text{Val}(X)} \sum_{y \in \text{Val}(Y)} g(x,y) p_{XY}(x,y)$$

Per al cas de variables contínues, l'expressió seria la següent:

$$\mathbb{E}[g(X,Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x,y) f_{XY}(x,y) dx dy$$

Es defineix la covariància com:

$$\text{Cov}[X,Y] = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

Propietats:

- Linealitat de l'esperança: $\mathbb{E}[f(X,Y) + g(X,Y)] = \mathbb{E}[f(X,Y)] + \mathbb{E}[g(X,Y)]$
- $\text{Var}[X + Y] = \text{Var}[X] + \text{Var}[Y] + 2\text{Cov}[X,Y]$

- Si X i Y són independents, llavors $Cov[X, Y] = 0$
- Si X i Y són independents, llavors $\mathbb{E}[f(X)g(Y)] = \mathbb{E}[f(X)]\mathbb{E}[g(Y)]$

Aquestes equacions són fàcilment generalitzables per al cas de variables múltiples. A la bibliografia es poden trobar referències on consultar les equacions per a aquests casos.

3. Models generatius basats en xarxes antagoniques o adversàries (GANs)

Les xarxes antagoniques generatives o xarxes adversàries generatives (GANs) [Creswell i altres (2018), Goodfellow i altres (2020), Cohen i Giryès (2022)] són un mètode per a l'optimització competitiva entre dues xarxes neuronals, una crida generadora i una altra de discriminadora, amb l'objectiu d'aconseguir generar noves instàncies idealment indistingibles a les pertanyents a la distribució de probabilitat de la qual deriven les dades d'entrenament.

El fonament teòric general del qual deriven en permet la utilització per a la generació de qualsevol mena de dades, havent-se demostrat efectiva en camps diversos com són la visió per computador [Dziugaite i altres (2015), Karras i altres (2017), Ledig i altres (2017)], la segmentació semàntica [Luc i altres (2016), Isola i altres (2017), Wang i altres (2018), Hoffman i altres (2018)], la síntesi de sèries temporals (Hartmann i altres (2018)), l'edició d'imatge [Shaham i altres (2019), Lample i altres (2017), Abdal i altres (2021), Xia i altres (2022)], el processament del llenguatge natural [Fedus i altres (2018), Jetchev i altres (2016), Guo i altres (2018)], la generació d'imatge a partir de text [Ramesh i altres (2021), Radford i altres (2021), Patashnik i altres (2021)] entre altres.


Per a qualsevol conjunt de dades, podem hipotetitzar que és possible definir una distribució de probabilitat p_{data} representativa de la població representada per la mostra formada pel conjunt de dades. Si això fos possible, per a qualsevol valor de $\mathbf{x}$ serà possible establir un valor $P_{data}(\mathbf{x})$ que determini la probabilitat que $\mathbf{x}$ pertanyi a la població. Si existís una funció d'aquest tipus, seria una funció discriminativa que donada una instància permetria conèixer la probabilitat de pertinença a la població. Els models generatius modelitzen la distribució de probabilitat esmentada però no proporcionen un valor de probabilitat, sinó que generen instàncies noves que pertanyen a distribucions de probabilitat pròximes a la que pretenen que s'assembli. Les GANs defineixen un esquema d'aprenentatge que facilita la codificació dels atributs definitoris de la distribució de probabilitat en una xarxa neuronal, de manera que la xarxa incorpori la informació essencial que li permet generar instàncies pertanyents a distribucions de probabilitat pròximes a la del conjunt de dades que pretén representar.

Al subapartat següent es presenta l'esquema bàsic de l'arquitectura GAN i el seu aspecte distintiu, la naturalesa de la funció objectiu utilitzada per a la seva optimització. Posteriorment, es presenten les arquitectures i funcions d'objectiu derivades, així com les seves aplicacions.

3.1. El concepte de xarxes antagòniques

L'arquitectura GAN està formada per dues xarxes neuronals constituents: una denominada discriminadora (D) i una altra generadora G . La xarxa G s'encarrega de generar noves instàncies del mateix domini que el del conjunt de dades d'origen. La xarxa D s'encarrega de discriminar si les dades d'entrada són reals, això és, pertanyents al conjunt de dades d'entrada, o bé són fictícies, això és, generades artificialment. Totes dues xarxes s'entrenen conjuntament, de manera que G maximitzi les seves possibilitats de no ser detectada per D i D , de manera que faci cada vegada més sofisticats els seus mètodes de detecció de les dades generades artificialment per G . Aquestes dues xarxes adversàries competeixen en un joc de suma zero en el qual s'hipotetitza que eventualment arriben a un equilibri de Nash (Moghadam i altres, 2021).

Figura 1. Diagrama representatiu del procés d'entrenament de les xarxes adversàries generatives (GANs)



A la figura 1 es mostra un diagrama representatiu del procés d'optimització de les GAN. Un vector $\mathbf{z}$ és un mostreig d'una distribució de probabilitat aleatòria p_z , $\mathbf{z} \sim p_z$ i alimentat com a entrada a G . El propòsit de l'optimització és aconseguir que $G(\mathbf{z}) \sim p_g$ acabi sent una estimació de la distribució de probabilitat P_{data} . Les GANs s'optimitzen mitjançant la funció min-max d'un joc de suma zero, expressat per l'equació 6.

$$\min_G \max_D \mathbb{E}_{x \sim p_r} \log[D(\mathbf{x})] + \mathbb{E}_{z \sim p_z} \log[1 - D(G(\mathbf{z}))] \quad (6)$$

Equivalentment, siguin p_θ , D_ω les xarxes neuronals generadora i discriminadora d'una GAN, sent θ els paràmetres de G i ω els de D . Totes dues xarxes s'optimitzen en conjunt amb la funció objectiu definida per l'equació 7.

$$\min_\theta \max_\omega \mathbb{E}_{x \sim Q} \log[D_\omega(x)] + \mathbb{E}_{x \sim p_\theta} \log[1 - D_\omega(x)] \quad (7)$$

Durant el procés d'optimització, la xarxa D rebrà com a entrada de manera aleatòria dades pertanyents al conjunt de dades i uns altres procedents de la xarxa G . Se n'optimitzarà el funcionament perquè la seva discriminació sigui efectiva (equació 8).

$$\nabla_{\theta_D} \frac{1}{m} \sum_{i=1}^m [\log D(\mathbf{x}^{(i)}) + \log(1 - D(G(\mathbf{z}^{(i)})))] \quad (8)$$

Al mateix temps, quan D rebí una entrada procedent de G , aquest s'optimitza-
rà per millorar les seves prediccions i fer cada vegada més difícil el paper de D .
Això únicament es pot aconseguir millorant la qualitat de les dades generades
i fent-les més semblants al conjunt de dades original (equació 9).

$$\nabla_{\theta_G} \frac{1}{m} \sum_{i=1}^m \log(1 - D(G(\mathbf{z}^{(i)}))) \quad (9)$$

S'estableix així una competició entre totes dues xarxes (d'aquí el nom d'ad-
versàries), de manera que idealment en el progrés d'aquest procés ambdues
milloren el seu funcionament al punt que idealment el generador acaba pro-
duint dades cada vegada més semblants a les del conjunt de dades original.

3.2. Avantatges i inconvenients de les GAN

Des de la seva introducció el 2014, les GANs han despertat un gran interès
sobretot en el camp de la generació d'imatge. Això és pel fet que presenten una
sèrie d'avantatges sobre l'altre paradigma dominant fins al moment pel que
fa a models generatius, els VAEs (Kingma i Welling, 2013). Aquests avantatges
són els següents:

- **Imatges més nítides:** les GANs produeixen imatges més nítides que altres
models generatius disponibles fins al moment. Els models de difusió que
veurem més endavant són una excepció posterior en aquest aspecte.
- **Mida configurable:** la mida de la variable aleatòria no està restringida, i es
pot enriquir en cas que calgués.
- **Generador versàtil:** el paradigma de disseny basat en GANs suporta dife-
rents tipus de funcions generadores, a diferència d'altres models generatius
que poden tenir restriccions a causa de la seva arquitectura. Els VAEs, per
exemple, obliguen a utilitzar una funció gaussiana en la primera capa del
generador.

L'arquitectura també té els seus desavantatges, entre els quals hi ha els se-
güents:

- **Col·lapse de mode:** durant l'entrenament sincronitzat de generador i discriminador, el generador pot tenir tendència a reproduir únicament un mode específic que és capaç de burlar el discriminador. Malgrat que aquest patró pot estar minimitzant la funció objectiu, ho fa sense cobrir tot el domini del conjunt de dades.
- **Esvaïment de gradients:** a vegades el discriminador s'optimitza massa ràpid en la seva funció. En aquests casos, els gradients que propaga poden ser massa baixos per assegurar l'optimització del generador.
- **Inestabilitat:** sovint durant l'entrenament els paràmetres de totes dues xarxes fluctuen sense trobar un punt d'equilibri. En aquestes circumstàncies el generador té dificultats a trobar un punt que generi imatges d'alta qualitat.

3.3. Arquitectures derivades

En aquest subapartat es presenten aquelles arquitectures derivades de l'original que milloren el seu rendiment en algun dels desavantatges esmentats.

3.3.1. GAN semisupervisada (SGAN)

SGAN (Odena, 2016) inclou una variació en el discriminador que li permet aprofitar els avantatges de comptar amb dades supervisades. Consisteix a afegir un capçal addicional per a la predicció de la classe de pertinença. En aquells casos reals que es coneix aquesta classe, s'utilitza el capçal softmax de predicció per optimitzar el discriminador. En aquells casos que no es coneix, s'utilitza l'optimització via classificació binària típica de la GAN convencional. Els resultats demostren que aquest tipus d'entrenament millora les capacitats de SGAN respecte a la GAN original.

3.3.2. Conditional GAN (CGAN)

CGAN (Mirza i Osindero, 2014) modifica el mètode original introduint una entrada addicional tant en el generador com en el discriminador. Aquesta entrada addicional serveix com a condicionant per a totes dues funcions. Aquesta nova informació y es fusiona en el generador amb el mostreig de la variable aleatòria z per posteriorment generar les noves instàncies. El mateix passa al discriminador, on y s'integra amb les dades x a analitzar. La nova funció d'optimització queda com indica l'equació 10.

$$\min_G \max_D \mathbb{E}_{x \sim p_r} \log[D(\mathbf{x}|\mathbf{y})] + \mathbb{E}_{\mathbf{z} \sim p_z} \log[1 - D(G(\mathbf{z}|\mathbf{y}))] \quad (10)$$

3.3.3. Xarxa antagònica generativa convolucional profunda (DCGAN)

Les xarxes antagòniques generatives convolucionals profundes (DCGAN) van ser introduïdes per primera vegada a Radford i altres (2015) com a mètode per a la generació d'imatges. Utilitzen convolucions al discriminador i convolucions transposades (Dumoulin i Visin, 2016) al generador. A més de millores en la resolució de les imatges generades, aconsegueixen millores en l'estabilitat de l'entrenament que en el seu estudi atribueixen a la introducció de les següents modificacions:

- Substitució de totes les capes de *pooling* de les dues xarxes. Al discriminador s'utilitzen nuclis amb *stride* més gran que 1, i al generador convolucions transposades per augmentar la mida de la imatge.
- Ús de la normalització per lots a les dues xarxes.
- Al discriminador es canvia la funció d'activació de ReLU a LeakyReLU (Mas i altres, 2013). Al generador s'utilitzen ReLU en totes les capes excepte a l'última, on es fa servir la funció d'activació tangent hiperbòlica (*tanh*).

3.3.4. Progressive GAN (PROGAN)

A Karras i altres (2017) s'introdueix un mètode progressiu d'entrenament i augment de la resolució de les imatges generades que dona molt bons resultats. Moltes de les arquitectures GAN més reeixides fan servir aquest mètode. En el treball citat es comença entrenant una xarxa generativa de 4x4 per anar afegint capes al generador i discriminador segons va avançant l'entrenament fins a aconseguir resolucions de sortida de 1024x1024. A mesura que es van afegint capes, totes les capes anteriors continuen estant sotmeses als canvis inherents a l'optimització de les xarxes.

3.3.5. Self-attention GAN (SAGAN)

Moltes de les implementacions existents fins al moment fallen en la captura de patrons geomètrics i estructurals de llarg abast. S'hipotetitza que la causa d'això es deu a la naturalesa convolucional de les arquitectures generatives. A causa d'aquesta, les dependències són de curt abast i requereixen el pas a través de diverses capes per ser resoltes. Hi ha diverses solucions que es poden aplicar per solucionar aquest aspecte. La primera seria augmentar la mida de les convolucions amb l'augment associat dels requisits computacionals. Una altra seria l'increment de la profunditat de les xarxes. Una tercera possibilitat, que és la proposta per SAGAN (Zhang i altres, 2019), és la utilització de mecanismes d'autoatenció en alguna de les capes de la xarxa convolucional.

Els atributs de sortida $\mathbf{x} \in \mathbb{R}^{C \times N}$ d'una capa de la xarxa neuronal es transformen en dos espais $\mathbf{f}(\mathbf{x}) = \mathbf{W}_f \mathbf{x}$ i $\mathbf{g}(\mathbf{x}) = \mathbf{W}_g \mathbf{x}$ per posteriorment calcular l'atenció com indica l'equació 11.

$$\beta_{j,i} = \frac{\exp(s_{i,j})}{\sum_{i=1}^N \exp(s_{i,j})} \quad \text{on} \quad s_{i,j} = \mathbf{f}(\mathbf{x}_i)^T \mathbf{g}(\mathbf{x}_j) \quad (11)$$

$\beta_{j,i}$ indica l'atenció que està prestant a la regió i quan està generant la j . C és el nombre de canals i N el nombre d'atributs de l'anterior capa. La sortida de la capa d'atenció $\mathbf{o} = (\mathbf{o}_1, \mathbf{o}_2, \dots, \mathbf{o}_N) \in \mathbb{R}^{C \times N}$ es pot expressar com indica l'equació 12.

$$\mathbf{o}_j = \mathbf{v} \left(\sum_{i=1}^N \beta_{j,i} \mathbf{h}(\mathbf{x}_i) \right), \quad \mathbf{h}(\mathbf{x}_i) = \mathbf{W}_h \mathbf{x}_i, \quad \mathbf{v}(\mathbf{x}_i) = \mathbf{W}_v \mathbf{x}_i \quad (12)$$

On $\mathbf{W}_g \in \mathbb{R}^{\bar{C} \times C}$, $\mathbf{W}_f \in \mathbb{R}^{\bar{C} \times C}$, $\mathbf{W}_h \in \mathbb{R}^{\bar{C} \times C}$ i $\mathbf{W}_v \in \mathbb{R}^{C \times \bar{C}}$ són matrius optimitzades en temps d'entrenament, implementades com a convolucions 1x1. A l'article es fixa $\bar{C} = C/8$ per ser més eficient de cara a la computació i, segons s'indica, no afectar significativament els resultats.

El valor d'autoatenció considerat s'escala i se suma al valor de l'atribut d'entrada, $\mathbf{y}_i = \gamma \mathbf{o}_i + \mathbf{x}_i$, sent γ un paràmetre optimitzable que s'inicialitza a zero. Això té la seva lògica, ja que a l'inici de l'entrenament es pot esperar resoldre les dependències locals perquè, una vegada avançada l'optimització, s'afini resolent les dependències de major abast. Aquest mecanisme d'atenció s'aplica tant al generador com al discriminador. Tots dos són optimitzats minimitzant una versió modificada de la funció d'optimització original, que pren la forma de l'equació 13. Aquesta equació és la versió de màxim-marge (Hinge Loss) típica per a l'optimització de SVMs (Crammer i Singer, 2001).

$$\begin{aligned} L_D &= -\mathbb{E}_{(x,y) \sim P_{data}} [\min(0, -1 + D(x,y))] - \mathbb{E}_{z \sim p_z, y \sim P_{data}} [\min(0, -1 - D(G(z), y))] \\ L_G &= -\mathbb{E}_{z \sim p_z, y \sim P_{data}} G(G(z), y) \end{aligned} \quad (13)$$

Juntament amb la seva proposta presenten també una metodologia d'entrenament per estabilitzar l'inherentment inestable procés d'optimització de les GANs.

3.3.6. BigGAN

BigGAN (Brock i altres, 2018) és un tipus de GAN dissenyada per a la generació, mitjançant escalat, d'imatges d'alta resolució. Inclou una sèrie de canvis incrementals respecte a les xarxes anteriorment esmentades, així com algunes innovacions.

Entre les millores incrementals de rellevància trobem les següents:

- 1) Proposta d'arquitectura basada en SAGAN utilitzant normalització espectral (Miyato i altres, 2018) tant per a D com per a G i utilitzant TTUR (Heusel i altres, 2017).
- 2) Igual que SAGAN, utilitza la funció de pèrdua Hinge com a objectiu d'optimització.
- 3) Utilitza normalització per lots condicionada a la classe (CBN) (De Vries i altres, 2017) (mitjançant projecció lineal) per proveir d'informació de la classe a G .
- 4) Utilitza un discriminador per projecció (Miyato i Koyama, 2018) per incorporar la informació de la classe.

Quant a les innovacions, cal ressaltar:

- 1) Increment de la mida dels lots.
- 2) Increment de la mida de capa.
- 3) Addició de connexions directes entre la variable latent z i les capes intermèdies de la xarxa.
- 4) Ús d'una variant de regularització ortogonal (Brock i altres, 2016).

BigGAN aconsegueix una millora substancial de la qualitat de les imatges generades per a mides de 128x128, 256x256 i 512x512, augmentant el nombre de paràmetres (x4) i incrementant la mida del batch d'entrenament (x8) respecte a SAGAN. A més de les modificacions indicades, introdueixen alguns canvis sobre les variables latents durant el procés d'inferència, consistents a truncar els valors fora d'un rang determinat.

3.3.7. StyleGAN

StyleGAN (Karras i altres, 2019) proposa una nova arquitectura per al generador, mantenint el mateix disseny per al discriminador. A la figura 2 es mostra un esquema de l'arquitectura proposada per a la xarxa generadora.


Two Time-scale Update Rule (TTUR)

És una regla d'actualització dels pesos de les GANs utilitzant descens de gradient, consistent en l'ús de taxes d'aprenentatge diferents en generador i discriminador. Se sap que el discriminador és capaç de convergir a un mínim local quan el generador roman estable. De cara a assegurar la convergència, la idea és utilitzar taxes d'aprenentatge més baixes en el generador que en el discriminador. D'aquesta manera assegurem la convergència de totes dues xarxes a un punt d'equilibri de Nash.

Conditional Batch Normalization (CBN)

És una variant de la normalització batch condicionada a la classe. Donat un mapa d'atributs amb C canals, on γ_c i β_c representen els paràmetres de normalització de cada canal i per als quals la regla d'actualització ve representada per $\hat{\beta}_c = \beta_c + \Delta\beta_c$ i $\hat{\gamma}_c = \gamma_c + \Delta\gamma_c$, llavors $\Delta\beta = MLP_1(\mathbf{e}_q)$ i $\Delta\gamma = MLP_2(\mathbf{e}_q)$. Per al cas de BigGAN MLP és una transformació lineal i $\mathbf{e}_q$ la classe.

Figura 2. Diagrama de l'arquitectura StyleGAN



Font: <https://github.com/christianversloot/machine-learning-articles/>

StyleGAN té tres components característics:

- 1) Creixement progressiu de la mida de la imatge generada a l'estil de PRO-GAN (blocs en groc) ($4 \times 4 \rightarrow 8 \times 8 \rightarrow 16 \times 16 \rightarrow 32 \times 32 \rightarrow 64 \times 64 \rightarrow 128 \times 128 \rightarrow 256 \times 256 \rightarrow 512 \times 512 \rightarrow 1024 \times 1024$)
- 2) En els blocs d'Upsample utilitza mostreig bilineal en comptes de la còpia del valor dels veïns pròxims.
- 3) Substitució del vector d'entrada $z \sim P_z$ per una matriu d'entrada constant de $4 \times 4 \times 512$, i s'introdueix una xarxa de soroll gaussià, que alimenta independentment cadascuna de les capes intermèdies.
- 4) Introducció de la denominada *xarxa de mapatge del soroll*, que, al pas per diverses capes completament connectades, transforma una entrada aleatòria en una representació interna dels estils. La sortida d'aquesta xarxa actua com a entrada en els blocs AdaIN de cada capa, fixant els paràmetres de biaix i escalat del bloc amb la finalitat d'actuar com a estils adaptatius.
- 5) AdaIN. Normalització adaptativa de les instàncies: introduïda inicialment a Huang i Belongie (2017). StyleGAN la utilitza tant com a capa de normalització com per establir l'estil a través dels paràmetres d'escalat i biaix que són derivats de les representacions internes apreses per la xarxa de mapatge de soroll.

3.4. f-GAN, una generalització de les GANs

Als subapartats previs, hem presentat les GANs com una eina per generar dades, que s'optimitza per produir resultats que s'assemblin a les dades d'entrenament. S'ha explicat com aquest procés es duu a terme a través de l'optimització d'un model parametrizable en forma de xarxa neuronal, mesurant la diferència entre la distribució del model i la real durant el procés d'entrenament.

En aquest subapartat, explorarem com diferents maneres de mesurar aquesta distància poden donar lloc a diferents funcions objectiu i, per tant, a diferents xarxes resultants. Aquest concepte s'ha formalitzat a l'article de Nowozin i altres (2016), que proporciona una generalització del concepte de distància en GANs per a diferents maneres de mesurar la distància entre distribucions de probabilitat.

3.4.1. Introducció

Un model probabilístic és una representació formal que descriu un esdeveniment o fenomen en termes d'una distribució de probabilitat, en lloc de proporcionar una resposta única com ho fan els models deterministes. Aquests models s'utilitzen per modelar processos estocàstics, on els resultats no estan determinats per endavant i poden variar amb el temps o en funció de les condicions.

Quan els principis que regeixen un fenomen són desconeguts o és massa complex descriure'ls de manera computacionalment eficient, una forma d'aproximar la solució és modelar la seva distribució de probabilitat a partir de mostres recopilades de l'entorn. D'aquesta manera, es poden fer prediccions i prendre decisions basades en una comprensió probabilística del fenomen en qüestió.

3.4.2. Estimació de models probabilístics

Suposant que hi ha una distribució de probabilitat real Q , es pot utilitzar un model paramètric P per aproximar Q . Per avaluar la validesa del nostre model, hem de tenir un mitjà d'avaluar les diferències entre totes dues distribucions. Sabem que totes dues variables són estocàstiques, això és, no estan definides per un únic valor comparable, sinó que són distribucions (funcions). Hem de disposar, per tant, d'una mesura que ens permeti comparar funcions. Una manera de fer això és realitzar una abstracció del concepte de distància per generalitzar-lo, no únicament per mesurar distàncies entre punts, sinó també per identificar distàncies entre distribucions de probabilitat. Per facilitar el procés, pot ser necessari fer algun tipus de suposició sobre P , com que el

seu mostreig sigui manejable, de cara a assegurar que les mostres del model siguin comparables amb les mostres reals; que P tingui un gradient manejable respecte al mostreig de cara a poder utilitzar tècniques d'optimització i, finalment, que tingui una funció de probabilitat manejable de manera que pugui calcular-se la probabilitat punt a punt.

3.4.3. GANs com a models probabilístics

Com ja sabem, les GANs fan servir una combinació de dues xarxes neuronals per crear un model generatiu amb l'objectiu d'aprendre a imitar una distribució real. El generador, com el seu nom indica, genera una mostra model a partir d'un vector aleatori mitjançant l'ús d'una transformació determinista. El discriminador rep mostres pertanyents a la distribució real triades a l'atzar i del model de generació i s'entrena per diferenciar-les. Totes dues xarxes estan entrenades de manera adversària, una per generar imatges el més pròximes possible a la distribució real, i l'altra per detectar les mostres procedents del generador. Encara que les GANs no proporcionen un valor de probabilitat de la imatge generada, és d'esperar que aquest valor, encara que no sigui conegut, existeixi.

3.4.4. Distància entre distribucions de probabilitat

Hi ha diferents enfocaments per definir la distància entre les distribucions de probabilitat. Podem diferenciar principalment entre tres enfocaments diferents:

- 1) Mètriques de probabilitat integral.
- 2) Regles per a puntuació.
- 3) f-divergències.

Mètriques de probabilitat integral

Abordat per primera vegada a la publicació de Sriperumbudur i altres (2010), el punt clau d'aquest mètode és que totes dues distribucions apareixen en forma d'expectativa, la qual cosa permet aproximar-se a aquest valor mitjançant mostreig. La distància de Wasserstein es deriva d'aquests mètodes, i després es va fer servir amb èxit com una distància a Wasserstein-GAN (Arjovsky i altres, 2017).

Regles per a puntuació

A Gneiting i Raftery (2007) es va proposar l'enfocament d'utilitzar una puntuació per avaluar l'adequació d'una distribució a una altra. El punt és l'optimització de la puntuació. La puntuació màxima s'aconsegueix quan totes dues distribucions són iguals.

f-divergències

Abordat per primera vegada a Ali i Silvey (1966), les distribucions P i Q es requereixen en forma de funció de densitat. Les f-divergències són una generalització de la divergència Kullback-Leiber (Kullback i Leibler, 1951). L'expectativa de la distribució Q es multiplica per una funció convexa de la relació de versemblança entre P i Q . En general, no s'aplica directament perquè normalment no es disposa de la distribució de les dades de manera explícita.

A Nguyen i altres (2010), Reid i altres (2011) i a Goodfellow i altres (2020) es van desenvolupar mètodes per utilitzar f-divergències en problemes on P té forma de distribució i Q té forma d'expectativa, i també on totes dues distribucions tenen forma d'expectativa. Això va permetre l'ús d'aquestes mètriques en problemes on només es troben disponibles mostres de totes dues distribucions.

Des d'un punt de vista matemàtic, podem definir la f-divergència, denotada com $D_f(P \parallel Q)$, com la distància entre dues distribucions de probabilitat P i Q que es pot calcular mitjançant l'equació 14.

$$D_f(Q \parallel P) = \int_{\mathcal{X}} p(\mathbf{x}) f\left(\frac{q(\mathbf{x})}{p(\mathbf{x})}\right) d\mathbf{x} \quad (14)$$

on f és una funció convexa, denominada funció generador (res a veure amb el generador de les GANs), que compleix la propietat $f(1) = 0$, això és, que en aquells punts on les dues funcions són iguals la distància és zero.

La distància sempre és més gran que 0 i és únicament igual a zero quan les dues distribucions coincideixen en tot el domini $\mathcal{X}$.

Estimació de les f-divergències mitjançant mostreig

A Nguyen i altres (2010) es deriva un mètode variacional general per estimar les f-divergències a partir del mostreig de les distribucions P i Q .

Taula 1. f-divergències i generador associat. Formes diferents de mesurar la distància entre dues distribucions de probabilitat P i Q

Nom	$D_f(P \parallel Q)$	Generador $f(u)$
Total variation	$\frac{1}{2} \int p(\mathbf{x}) - q(\mathbf{x}) d\mathbf{x}$	$\frac{1}{2} u - 1 $
Kullback-Leibler	$\int p(\mathbf{x}) \log \frac{p(\mathbf{x})}{q(\mathbf{x})} d\mathbf{x}$	$u \log u$
Reverse Kullback-Leibler	$\int q(\mathbf{x}) \log \frac{q(\mathbf{x})}{p(\mathbf{x})} d\mathbf{x}$	$-\log u$
Pearson χ^2	$\int \frac{(q(\mathbf{x}) - p(\mathbf{x}))^2}{p(\mathbf{x})} d\mathbf{x}$	$(u - 1)^2$
Neyman χ^2	$\int \frac{(p(\mathbf{x}) - q(\mathbf{x}))^2}{q(\mathbf{x})} d\mathbf{x}$	$\frac{(1-u)^2}{u}$
Squared Hellinger	$\int (\sqrt{p(\mathbf{x})} - \sqrt{q(\mathbf{x})})^2 d\mathbf{x}$	$(\sqrt{u} - 1)^2$
Jeffrey	$\int (p(\mathbf{x}) - q(\mathbf{x})) \log \left(\frac{p(\mathbf{x})}{q(\mathbf{x})} \right) d\mathbf{x}$	$(u - 1) \log u$
Jensen-Shannon	$\frac{1}{2} \int p(\mathbf{x}) \log \frac{2p(\mathbf{x})}{p(\mathbf{x}) + q(\mathbf{x})} + q(\mathbf{x}) \log \frac{2q(\mathbf{x})}{p(\mathbf{x}) + q(\mathbf{x})} d\mathbf{x}$	$-(u + 1) \log \frac{1+u}{2} + u \log u$
Jensen-Shannon weighted	$\int p(\mathbf{x}) \pi \log \frac{p(\mathbf{x})}{\pi p(\mathbf{x}) + (1-\pi)q(\mathbf{x})} + (1 - \pi)q(\mathbf{x}) \log \frac{q(\mathbf{x})}{\pi p(\mathbf{x}) + (1-\pi)q(\mathbf{x})} d\mathbf{x}$	$\pi u \log u + (1 - \pi + \pi u) \log(1 - \pi + \pi u)$
GAN	$\int p(\mathbf{x}) \log \frac{2p(\mathbf{x})}{p(\mathbf{x}) + q(\mathbf{x})} + q(\mathbf{x}) \log \frac{2q(\mathbf{x})}{p(\mathbf{x}) + q(\mathbf{x})} d\mathbf{x} - \log 4$	$u \log u - (u + 1) \log(u + 1)$
α -divergence	$\frac{1}{\alpha(\alpha-1)} \int \left(p(\mathbf{x}) \left[\left(\frac{q(\mathbf{x})}{p(\mathbf{x})} \right)^\alpha - 1 \right] - \alpha(q(\mathbf{x}) - p(\mathbf{x})) \right) d\mathbf{x}$	$\frac{1}{\alpha(\alpha-1)} (u^\alpha - 1 - \alpha(u - 1))$

De l'anàlisi de funcions convexes sabem que tota funció convexa f té un conjugat de Fenchel f^* que compleix que $f(u) = \sup_{t \in \text{dom}_{f^*}} \{tu - f^*(t)\}$, això és, que qualsevol funció convexa pot ser representada com un conjunt de màxims puntuals de funcions lineals, on $f^*(t)$ és el punt d'intercepció amb l'eix de y per a cada punt t .

$$\begin{aligned}
 D_f(Q \parallel P) &= \int_{\mathcal{X}} p(\mathbf{x}) f\left(\frac{q(\mathbf{x})}{p(\mathbf{x})}\right) d\mathbf{x} \geq \\
 &\geq \sup_{T \in \mathcal{T}} \left(\int q(\mathbf{x}) T(\mathbf{x}) d\mathbf{x} - \int p(\mathbf{x}) f^*(T(\mathbf{x})) d\mathbf{x} \right) = \\
 &= \sup_{T \in \mathcal{T}} \left(\mathbb{E}_{\mathbf{x} \sim Q}[T(\mathbf{x})] - \mathbb{E}_{\mathbf{x} \sim P}[f^*(T(\mathbf{x}))] \right) \quad (15)
 \end{aligned}$$

Les expressions poden ser convertides a expectatives i utilitzades en un algorisme de mostreig. Un punt que cal tenir en compte és que per a algunes divergències, f^* únicament està definit per a un domini restringit. En aquests casos, abans d'utilitzar la funció objectiu, ha de ser mapada al domini on està definida.

Funció variacional associada al discriminador

A l'article introductori de les GANs (Goodfellow i altres, 2020) es demostra que l'optimització proposada per a la funció de pèrdua (eq. 7) és equivalent a minimitzar la divergència de Jensen-Shanon.

Comparant l'expressió de l'equació 15 amb la funció objectiu de GAN veiem que $T(x) = \log(D_\omega(x))$. Confirmem doncs que la GAN original minimitza la divergència Jensen-Shanon, un cas particular de la f-GAN.

3.4.5. Conclusió

En aquest subapartat s'ha generalitzat el concepte de mesura de la distància entre distribucions de probabilitat, utilitzat en la funció de pèrdua de les GAN, per poder-lo utilitzar en un context més general amb qualsevol f-divergència per a la mesura de la distància entre la distribució de probabilitat del model i l'original. En aquest context més general, s'ha demostrat que la GAN original és un cas particular d'optimització que utilitza la f-divergència de Jensen-Shanon per a la mesura de la distància entre distribucions. Qualsevol de les mesures alternatives presentades dona lloc a optimitzacions equivalents, malgrat ser diferents, des d'un punt de vista representatiu.

3.4.6. Funcions d'optimització millorades

A l'anterior subapartat hem introduït el concepte de f-divergència per generalitzar el concepte de distància entre distribucions i hem nomenat altres mètodes alternatius com les mètriques de probabilitat integral. En aquest subapartat presentarem les opcions d'optimització que en la pràctica han demostrat ser més efectives per millorar els problemes relacionats amb l'optimització min-max original, això és, el col·lapse de mode i l'esvaïment de gradients. Els objectius presentats, a part de remeiar aquests aspectes, també milloren la qualitat de les imatges generades.

Wasserstein GAN (WGAN)

WGAN (Arjovsky i altres, 2017) resol el problema de l'esvaïment de gradients i col·lapse de mode reemplaçant l'optimització de la f-divergència de Jensen-Shanon mitjançant l'ús de la mètrica de probabilitat integral EM [Earth mover distance (Hitchcock, 1941)], també anomenada distància de Wasserstein. L'equació 16 mostra l'equació que la defineix.

$$W(p_r, p_g) = \inf_{\gamma \in \Pi(p_r, p_g)} \mathbb{E}_{(x,y) \sim \gamma} [|x - y|] \quad (16)$$

on $\Pi(p_r, p_g)$ representa el conjunt de totes les distribucions conjuntes $\gamma(x,y)$ que els seus marginals són p_r i p_g . La distància EM representa el mínim cost necessari per transportar la «massa» de p_r a p_g per aconseguir fer-les iguals.

Les f-divergències com KL i JS mostren problemes d'inestabilitat quan p_r i p_g estan molt allunyades l'una de l'altra. EM és estable també en aquests casos, a més de ser contínua, fet que facilita la derivació de gradients útils per dur a terme l'optimització. Un inconvenient és que l'ínfim de l'equació 16 és intractable. Per aquesta raó els autors de WGAN estimen el cost d'EM amb l'equació 17.

$$W(p_r, p_g) \approx \max_{w \in \mathcal{W}} \mathbb{E}_{\mathbf{x} \sim p_r} [f_w(\mathbf{x})] - \mathbb{E}_{\mathbf{z} \sim p_g} [f_w(G(\mathbf{z}))] \quad (17)$$

on $f_{w \in \mathcal{W}}$ és una família de funcions paramètriques que són K-Lipschitz per a algun $K(\|f\|_L \leq K)$.

Els autors proposen trobar la millor funció f_w que maximitza l'equació 17 propagant el gradient $\mathbb{E}_{\mathbf{z} \sim p_g} [f_w(G(\mathbf{z}))]$, on g_θ és el generador g amb paràmetres θ . f_w pot ser representada per D però condicionada a ser K-Lipschitz. w en f_w representa els paràmetres de D i l'objectiu de D és maximitzar 17, que aproxima la distància EM. Quan D és òptim, 17 s'aproxima a la distància EM real i G s'optimitza per minimitzar l'equació 18.

$$-\min_G \mathbb{E}_{\mathbf{z} \sim p_g} [f_w(G(\mathbf{z}))] \quad (18)$$

WGAN sol tenir uns gradients més suaus i mesurables en tot el domini que altres f-divergències i aprèn millor fins i tot quan no està produint encara bones imatges.

GAN autosupervisada (SSGAN)

SSGAN (Chen i altres, 2019) utilitza un sistema similar a la CGAN (Mirza i Osindero, 2014), però sense la necessitat de comptar amb etiquetatge explícit. A més, introdueix un nou element en la funció de pèrdua, l'objectiu del qual és preveure el valor d'una classe que es deriva directament de la naturalesa de la imatge analitzada. Concretament, els autors prediuen la rotació de la imatge de quatre possibles valors. Aquest valor és conegut i calculable sense necessitat d'etiquetar les imatges i es demostra útil per millorar les capacitats predictives del discriminador, així com per aprendre representacions útils per a la generació. La nova funció de pèrdua té la forma indicada en l'equació 19.

$$\begin{aligned} L_G &= -V(G, D) - \alpha \mathbb{E}_{\mathbf{x} \sim p_G} \mathbb{E}_{r \sim \mathbb{R}} [\log Q_D(R = r \mid \mathbf{x}')] \\ L_D &= -V(G, D) - \beta \mathbb{E}_{\mathbf{x} \sim p_{data}} \mathbb{E}_{r \sim \mathbb{R}} [\log Q_D(R = r \mid \mathbf{x}')] \end{aligned} \quad (19)$$

k-Lipschitz

Definició: Sigui $A \subseteq \mathbb{R}$, $A \neq \emptyset$ i $k \in \mathbb{R}, k > 0$ diem que una funció $g : A \rightarrow \mathbb{R}$ és k-Lipschitz si $\forall x, y \in A |g(x) - g(y)| \leq k|x - y|$. Intuitivament, és una condició més forta que la continuïtat i limita el grau de variació permès de g a un màxim fixat per la diferència entre els dos valors x, y considerats multiplicats per la constant k .

on $V(G,D)$ és l'objectiu general de la GAN original (equació 6), P_{data} i P_G són les distribucions real i del generador respectivament, $r \in \mathbb{R}$ és la rotació seleccionada entre els angles permesos ($R = \{0,90,180,270\}$). Una imatge girada r graus es denota com $\mathbf{x}'$ i $Q(R | \mathbf{x}')$ és la distribució predita sobre els angles de rotació de la mostra. Aquesta funció de pèrdua força a aprendre representacions internes de la rotació de forma supervisada, hipotetitzant que aquestes representacions seran útils també per a la generalització de les capacitats generatives de la GAN. SSGAN obté resultats comparables als de CGAN sense la necessitat d'etiquetatge extern.

Normalització espectral (SNGAN)

A SNGAN (Miyato i altres, 2018) es proposa l'ús de normalització dels paràmetres com a mitjà d'estabilització de l'entrenament del discriminador. És una tècnica que és computacionalment eficient i que pot ser aplicada de manera senzilla. Sabem que si D és una funció k -Lipshitz, és a dir, intuïtivament, que és una funció contínua sense variacions abruptes, això pot servir per estabilitzar l'entrenament de les GAN. SNGAN controla el valor de la constant de Lipschitz limitant la norma espectral de cada capa, normalitzant la matriu de pesos de cada capa W per satisfer la restricció $\sigma(W) = 1$ (això és, que el major valor singular de la matriu de pesos sigui 1). Això s'aconsegueix simplement normalitzant cada capa mitjançant l'equació 20.

$$\bar{W}_{SN}(W) = \frac{W}{\sigma(W)} \quad (20)$$

on W representa la matriu de pesos de cada capa. A l'article citat es demostra que aquesta operació fa que la constant de Lipschitz al discriminador quedi limitada a un màxim d'1, fet que en facilita l'optimització.

SNGAN aconsegueix millores importants dels resultats comparat amb les tècniques prèvies d'estabilització de l'entrenament publicades, entre les quals s'inclouen la retallada del valor dels pesos (Arjovsky i altres, 2017), la penalització de gradients (Wu i altres, 2019), (Mescheder i altres, 2018), normalització batch (Ioffe i Szegedy, 2015), normalització de pesos (Salimans i Kingma, 2016), normalització de capes (Lei Ba i altres, 2016) i regularització ortonormal (Brock i altres, 2016).

SphereGAN

SphereGAN (Park i Kwon, 2020) és una GAN que utilitza mètrica de probabilitat integral (IPM) que fa servir una hiperesfera per lligar la IPM a la funció

objectiu i d'aquesta forma millorar l'estabilitat de l'entrenament. La funció objectiu utilitzada és la indicada a l'equació 21.

$$\min_G \max_D \sum_r \mathbb{E}_x[d_s^r(\mathbf{N}, D(\mathbf{x}))] - \sum_r \mathbb{E}_z[d_s^r(\mathbf{N}, D(G(\mathbf{z})))] \quad (21)$$

per a $r = 1, \dots, R$ on d_s^r mesura la distància amb moment r entre cada mostra i el pol nord de la hiperesfera, $\mathbf{N}$. El subíndex s indica que d_s^r està definit en $\mathbb{S}^n$.

Aquesta proposta millora les anteriors funcions objectiu basades en la distància Wasserstein gràcies a la definició dels IPM en la hiperesfera. Això li permet prescindir de moltes de les restriccions que han de ser imposades a D per assegurar un entrenament estable en les anteriors propostes, com les restriccions sobre la naturalesa Lipschitz de les funcions requerides per la distància Wasserstein.

El funcionament de SphereGAN es podria descriure de la manera següent: la xarxa G genera dades a partir d'un vector aleatori z . Imatges reals i altres procedents de G s'alimenten a la xarxa discriminadora D que, a diferència de les propostes anteriors, dona com a resultat un vector de dimensió n . SphereGAN remapeja aquest vector en una hiperesfera de n dimensions utilitzant transformacions geomètriques. Els punts mapats s'utilitzen per calcular els moments geomètrics centrats al pol nord ($\mathbf{N}$) d'aquesta hiperesfera. La xarxa discriminadora intenta maximitzar les diferències de moment entre les imatges reals i les falses, mentre que la generadora intenta aconseguir el contrari.

3.5. Una aplicació de les GAN: augment de dades

L'augment de dades és una tècnica habitual per millorar l'entrenament dels models en aquelles circumstàncies on es disposa de poques dades. Podríem dir que les circumstàncies més habituals que requereixen augment de dades serien les següents:

- **Etiquetatge limitat:** disposar de poques dades etiquetades.
- **Diversitat limitada:** quan el conjunt d'entrenament manca de varietat en les dades.
- **Dades restringides:** alguna de la informació és sensible i no pot utilitzar-se directament.

Els dos primers casos es poden resoldre manualment, posant recursos per etiquetar més dades, però pot suposar un cost elevat. Una alternativa per al

primer cas consisteix a utilitzar GANs per augmentar la quantitat de dades. SGAN, per exemple, permet generar noves dades anotades. El segon cas és més habitual, perquè sol ser habitual disposar de conjunts de dades amb classes desbalancejades pobres en les classes estranyes.

3.6. Conclusions

En aquest apartat hem introduït les GANs com a mètode per a la generació de dades. És un tipus d'arquitectura especialment estudiada en el camp de generació d'imatge. És un tipus d'arquitectura amb molt de potencial que té alguns problemes sobretot relacionats amb l'estabilitat en l'entrenament. En aquest apartat hem estudiat el disseny original, els seus avantatges i inconvenients, així com algunes modificacions destinades a solucionar els problemes de la proposta original. Si bé hem intentat descriure els punts que considerem clau, el camp en qüestió és molt ampli, tant en arquitectures com en aplicacions. Aquest apartat ha de servir com a punt de partida per complementar-lo amb la bibliografia citada, així com amb les futures aportacions.

4. Autocodificadors

Abans de presentar els VAEs, considerem apropiat fer una breu introducció a l'estructura general dels autocodificadors. Aquesta arquitectura precedeix en la història als variacionals i comparteix molts aspectes en comú, encara que les seves aplicacions no s'enfoquin en la generació de dades, com succeeix amb els VAEs.

4.1. Introducció a l'estructura general dels autocodificadors

Els autocodificadors (Ackley i altres, 1985), (Hinton i Zemel, 1993), (Micheleluci, 2022) són un tipus de xarxa neuronal especialitzada en la representació d'un espai dimensional d'origen en un altre de més petit. L'objectiu d'aquesta transformació és la representació de la informació observada en un vector de menor dimensió que el representi amb la major fidelitat possible. Es pretén que aquesta compressió serveixi per codificar en la xarxa una representació significativa dels veritables factors explicatius dels senyals observats. A la representació vectorial reduïda se'l denomina espai latent.

Els autocodificadors (figura 3) són una proposta d'arquitectura per dur a terme aquest procés. Aquests consisteixen en dues parts diferenciades: un codificador que transforma el vector de dades inicial en una representació interna i un decodificador que a partir d'aquesta última intenta reconstruir l'original. Tots dos elements són xarxes neuronals la funció de les quals és modelitzar la distribució de probabilitat de les dades d'origen. L'arquitectura s'optimitza de manera global. El coll d'ampolla existent en la zona de l'espai latent és el que, idealment, obliga l'arquitectura a comprimir en representacions més senzilles la informació rellevant a partir de la qual es reconstruirà l'original.

Figura 3. Esquema general d'un autocodificador



4.2. Definició formal

Sigui $\mathcal{X}$ l'espai de les dades d'entrada i $\mathcal{Z}$ el de la representació codificada, tots dos espais euclidians, això és, $\mathcal{X} = \mathbb{R}^m$, $\mathcal{Z} = \mathbb{R}^n$, on habitualment $m > n$.

Definim dues funcions paramètriques denominades codificador $E_\phi : \mathcal{X} \rightarrow \mathcal{Z}$, parametritzada per ϕ i descodificador $D_\theta : \mathcal{Z} \rightarrow \mathcal{X}$, parametritzada per θ .

Per a qualsevol $x \in \mathcal{X}$, denotem com $z = E_\phi(x)$ a la variable latent $z \in \mathcal{Z}$ derivada d'aplicar la funció E_ϕ a x i a $x' = D_\theta(z)$ com la reproducció de x mitjançant descodificació de z . Habitualment les funcions paramètriques E_ϕ i D_θ són xarxes neuronals.

4.3. Entrenament

Per optimitzar l'arquitectura s'ha de definir un objecte matemàtic a optimitzar. Per a això definim inicialment la funció distància d com $d : \mathcal{X} \times \mathcal{X} \rightarrow [0, \infty]$, tal que $d(x, x')$ és una funció distància que mesura la diferència entre tots dos vectors.

Definida d , definirem la funció d'optimització que minimitza la distància sobre tot el conjunt de dades. Això es pot fer minimitzant el valor esperat de la distància sobre tot el conjunt de dades d'origen:

$$L(\theta, \phi) = \arg \min_{\theta, \phi} \mathbb{E}_{x \sim \mu_{ref}} [d(x, D_\theta(E_\phi(x)))]$$

Per a aquells casos en què disposem únicament d'un conjunt de dades finit representatiu de $\mathcal{X}$, $x_1, \dots, x_N \in \mathcal{X}$, llavors $\mu_{ref} = \frac{1}{N} \sum_{i=1}^N \delta_{x_i}$.

Si es defineix d com $d(x, x') = \|x - x'\|^2$, llavors el problema es converteix en una optimització de mínims quadrats.

4.4. Autocodificadors regularitzats

L'objectiu últim de l'autocodificador és aconseguir una representació comprimida del vector d'entrada, idealment formada pels seus factors constitutius. Això es pretén aconseguir optimitzant un objectiu matemàtic, encara que no sempre l'optimització del segon condueix al primer. Pel fet que l'optimització es realitza mitjançant l'ús d'una mostra finita de la població total, això és, amb un conjunt d'entrenament finit, en determinades circumstàncies pot donar-se el cas que a la funció paramètrica li sigui més senzilla la memorització del

conjunt de dades que l'aprenentatge de representacions senzilles. En aquests casos, diem que l'autocodificador aprèn la funció identitat. Aquest cas no és desitjable, perquè s'allunya de l'objectiu que pretenem assolir.

Una manera d'evitar això és dotar la funció d'optimització de mecanismes de regularització que evitin la memorització. Depenent de com es realitzi aquesta regularització, distingim entre diferents subclasses d'autocodificadors, entre els quals es troben els autocodificadors poc densos, els d'atenuació de soroll i els contractius.

4.4.1. Autocodificadors poc densos (SAE)

Els autocodificadors poc densos introdueixen una restricció en la codificació, de manera que aquesta sigui poc densa, en el sentit que únicament es permeti que uns pocs dels elements de la representació latent estiguin actius. Hi ha dues formes bàsiques d'aconseguir aquest objectiu: la primera és fixar a zero totes les activacions excepte les k majors, on k és un valor predefinit. A aquesta mena d'autocodificador se'l denomina autocodificador poc dens k (Makhzani i Frey, 2013); la segona consisteix a afegir a la funció de pèrdua original una funció de regularització, això és, $\min_{\theta, \phi} L(\theta, \phi) + \lambda L_{\text{sarsity}}(\theta, \phi)$, on $\lambda > 0$ fixa quanta baixa densitat volem aplicar (Ng i altres, 2011). Per a un autocodificador de K capes, una proposta per a la funció de pèrdua de regularització seria la següent:

$$L_{\text{sarsity}}(\theta, \phi) = \mathbb{E}_{x \sim \mu_x} \left[\sum_{k \in 1:K} \omega_k \|h_k\| \right]$$

on h_k representa el valor del vector de la funció d'activació de la capa k i $\|\cdot\|$ normalment representa la norma L1 o la norma L2, donant lloc respectivament a l'autocodificador poc dens L1 o L2.

4.4.2. Autocodificadors d'atenuació de soroll (DAE)

Els autocodificadors d'atenuació de soroll (Vincent i altres, 2010) introdueixen la regularització modificant la funció de reconstrucció. Durant l'entrenament, l'entrada es distorsiona i s'intenta recuperar la informació original.

El procés de distorsió es fa mitjançant una funció $T: \mathcal{X} \rightarrow \mathcal{X}$ que, a partir d'un senyal d'entrada $x \in \mathcal{X}$, la transforma en una versió distorsionada $T(x)$. El valor de T se selecciona aleatòriament amb una distribució de probabilitat μ_T .

La funció d'optimització per al cas del DAE és:

$$\min_{\theta, \phi} L(\theta, \phi) = \mathbb{E}_{x \sim \mu_X, T \sim \mu_T} [d(x, (D_\theta \circ E_\phi \circ T)(x))]$$

Funcions típiques utilitzades per a l'addició de soroll inclouen el soroll isotròpic gaussià, soroll mitjançant emmascarament aleatori de part de l'entrada o fixar a valors aleatoris part dels elements de l'entrada.

4.4.3. Autocodificador contractiu

Un autocodificador contractiu (Rifai i altres, 2011) afegeix una pèrdua de regularització a la pèrdua estàndard de l'autocodificador:

$$\min_{\theta, \phi} L(\theta, \phi) + \lambda L_{contractive}(\theta, \phi)$$

on λ regula la importància de la regularització contractiva, que es defineix com la norma de Frobenius (Van Loan i Golub, 1996) esperada del jacobià de les activacions del codificador respecte a l'entrada:

$$L_{contractive}(\theta, \phi) = \mathbb{E}_{x \sim \mu_{ref}} \|\nabla_x E_\phi(x)\|_F^2$$

Sabem que $\|E_\phi(x + \delta x) - E_\phi(x)\|_2 \leq \|\nabla_x E_\phi(x)\|_F \|\delta x\|_2$ per a qualsevol entrada $x \in \mathcal{X}$ i petita variació δx sobre ella. Per tant, si $\|\nabla_x E_\phi(x)\|_F^2$ és petit, significa que valors al voltant de l'entrada s'assignen també a valors situats en un entorn pròxim de la seva representació latent. Aquesta és una propietat desitjada, ja que significa que una petita variació de l'entrada condueix a una petita variació, tal vegada fins i tot zero, del seu valor latent. Això fa, per exemple, que dues imatges puguin veure's iguals fins i tot si no són exactament iguals.

El DAE pot entendre's com un límit infinitesimal de CAE: en el límit del soroll d'entrada gaussià, els DAE fan que la funció de reconstrucció resisteixi les pertorbacions d'entrada, mentre que el CAE fa que les característiques extretes resisteixin pertorbacions d'entrada infinitesimals.

4.5. Aplicacions típiques

Les aplicacions típiques dels autocodificadors descrits en aquest subapartat inclouen les següents:

- **Compressió:** utilització d'un autocodificador per representar el senyal d'entrada amb una altra de dimensió menor. A efectes comparatius, quan un


autocodificador fa servir una funció lineal com a codificador i descodificador, MSE com a funció de pèrdua i les dades d'entrada es normalitzen d'acord amb $\hat{x}_{i,j} = \frac{1}{\sqrt{M}} \left(x_{i,j} - \frac{1}{M} \sum_{k=1}^M x_{k,j} \right)$, llavors és equivalent a un PCA (Plaut, 2018).

- Classificació mitjançant l'ús d'atributs latents: els atributs de l'espai latent poden ser utilitzats per classificar imatges, per exemple, utilitzant k-NN per dur a terme la separació (supervisada o no supervisada) (Pulgar i altres, 2018).
- Detecció d'anomalies: s'entrena un autocodificador en un conjunt de dades que conté un conjunt representatiu de les imatges/dades que es volen reconèixer com a vàlides per després calcular l'error de reconstrucció de les imatges/dades anòmales i comparar-lo amb els errors de les imatges/dades correctes. Si tots dos conjunts d'imatges/dades són prou diferents, l'error de reconstrucció de les instàncies anòmales serà superior al de les correctes. Fixant el llindar en el punt correcte serà possible detectar aquelles que siguin anòmales, perquè el seu error de reconstrucció hauria de ser més alt (Chen i altres, 2017), (Zhou i Paffenroth, 2017), (Pang i altres, 2021).
- Atenuació de soroll en imatges: l'autocodificador s'utilitza per corregir errors en la imatge d'entrada (Vincent i altres, 2008), (Gondara, 2016).

5. Models generatius basats en autocodificadors variacionals (VAEs)

Els VAEs (figura 4) són una tipologia de models gràfics probabilístics basats en xarxes neuronals. Presenten una estructura similar a la dels autocodificadors introduïts a l'apartat anterior. Permeten realitzar inferència eficient en la presència de variables latents contínues (i/o discretes), amb distribucions intractables del posterior i utilitzant conjunts de dades de gran mida.

Figura 4. Diagrama representatiu de l'arquitectura VAE



Els VAEs són capaços de generar noves dades similars a les de la distribució d'origen. Això s'aconsegueix mitjançant la codificació, en forma de variables latents, de les característiques definidores de la distribució de probabilitat representada per la mostra poblacional del conjunt de dades original. A partir del model après, són capaços de generar noves instàncies que aproximem a aquesta distribució.

Una xarxa codificadora (també anomenada xarxa de reconeixement) transforma la distribució d'origen a un espai latent estocàstic representat per una distribució més senzilla (per exemple, una distribució normal). A partir de la distribució latent es generen les dades de reconstrucció mitjançant l'ús d'una xarxa descodificadora (o xarxa de generació).

Al final de l'entrenament, si aquest ha estat efectiu, serà possible generar noves instàncies mitjançant el descodificador, transformant les mostres de l'espai ocult a l'espai d'expressió. El codificador actua com un model de reconeixement, mentre que el descodificador actua com un de generació. El model de reconeixement proporciona al generador una aproximació del posterior sobre

l'espai latent, que és utilitzat per optimitzar els paràmetres de totes dues xarxes mitjançant estimació per màxima versemblança. Segons la regla de Bayes, el model de reconeixement aproxima a la inversa del model generatiu.

5.1. Models probabilístics

Els models probabilístics són una representació matemàtica de fenòmens afectes d'incertesa. Aquests queden definits mitjançant distribucions de probabilitat. Suposant que $p^*(\mathbf{x})$ representi la distribució de probabilitat original, podem intentar aproximar-la mitjançant un model paramètric $p_\theta(\mathbf{x})$ tal que $p_\theta(\mathbf{x}) \approx p^*(\mathbf{x})$. És d'interès que $p_\theta(\mathbf{x})$ sigui capaç d'adaptar-se a les característiques de les dades d'origen, així com d'incorporar informació que coneguem *a priori*, com per exemple, el coneixement procedent de distribucions de probabilitat condicionades.

A vegades pot succeir que no interressi modelitzar $p_\theta(\mathbf{x})$, sinó que n'hi hagi prou amb modelitzar $p_\theta(\mathbf{y}|\mathbf{x})$ amb l'objectiu d'aconseguir $p_\theta(\mathbf{y}|\mathbf{x}) \approx p^*(\mathbf{y}|\mathbf{x})$. Per simplificar la notació, en aquest apartat ens referirem a la modelització incondicional, encara que el que s'explica aquí també aplica a la condicional.

Els models gràfics probabilístics (PGM) permeten representar la distribució conjunta de probabilitat ateses les interconnexions causals existents entre les diferents variables.

$$p_\theta(x_1, \dots, x_M) = \prod_{j=1}^M p_\theta(x_j | Pa(x_j))$$

on $Pa(x_j)$ representa els nodes pares de x_j . Per als nodes sense pares, la probabilitat referida serà incondicionada.

$p_\theta(x_j | Pa(x_j))$ pot ser definida de diferents maneres, a saber, com una taula de valors, com un model lineal o també com una xarxa neuronal. En aquest últim cas, $p_\theta(x | Pa(\mathbf{x})) = p_\theta(\mathbf{x}|\eta)$, on $\eta = \text{XarxaNeuronal}(Pa(\mathbf{x}))$. Aquests últims són models paramètrics molt versàtils que permeten modelitzar funcions complexes i són una molt bona eina per modelitzar distribucions optimitzables matemàticament.

5.2. Optimització de models probabilístics

Sigui un conjunt de dades $\mathcal{D} = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}\} \equiv \{\mathbf{x}^{(i)}\}_{i=1}^N = \mathbf{x}^{(1:N)}$, on $\mathbf{x}^{(i)}$ són mostres, independents i idènticament distribuïdes (i.i.d), pertanyents a una distribució subjacent. El model paramètric que aproxima la distribució con-

junta de probabilitat serà de la forma $p_{\theta}(\mathcal{D}) = \prod_{\mathbf{x} \in \mathcal{D}} p_{\theta}(\mathbf{x})$, que en la seva versió logarítmica s'expressa com $\log p_{\theta}(\mathcal{D}) = \sum_{\mathbf{x} \in \mathcal{D}} \log p_{\theta}(\mathbf{x})$. La forma típica de calcular θ és optimitzar aquesta funció, això és, l'estimació per màxima versemblança (MLE) de les instàncies pertanyents al conjunt de dades $\mathcal{D}$. El mètode MLE equival a la minimització de la divergència de Kullback-Leibler entre la distribució de les dades i la del model (Broniatowski, 2014). Disposant de la funció d'optimització MLE, ja és possible calcular els paràmetres θ de la xarxa neuronal utilitzant els mètodes d'entrenament convencionals, per exemple, el descens de gradient estocàstic.

5.3. Inferència variacional (VI)

5.3.1. Variables observables vs. ocultes

Considerem una *variable observable* quan forma part d'aquelles de les quals disposem del seu valor en els punts que formen part del conjunt de dades. Una *variable oculta o latent* és aquella de la qual no tenim informació directa a través del conjunt d'entrenament conegut. Aquesta formalització permet connectar la informació percebuda a través de variables observades amb les abstraccions pròpies dels models interpretatius, que serien les variables ocultes o latents que volem calcular. Així, per exemple, en un conjunt de dades format per imatges, les variables observables serien els píxels dels quals disposem d'informació, mentre que les ocultes d'interès podrien ser les abstraccions en forma de models del món que fem els éssers intel·ligents, per exemple, els diferents tipus d'objectes presents a la imatge.

5.3.2. Formalització matemàtica

Suposem que partim d'una distribució de probabilitat representada per un conjunt de dades $\mathcal{D}$, amb $\mathbf{x} \in \mathcal{D}$, de la qual volem inferir una sèrie de propietats ocultes (per exemple, abstraccions), representades per un conjunt de variables, originalment desconegudes, que anomenarem $\mathbf{z}$. Sigui $p(\mathbf{x}, \mathbf{z})$ la distribució conjunta de les variables observables i ocultes.

En aquests casos, ens interessa realitzar la inferència sobre les variables desconegudes, això és, calcular $p(\mathbf{z}|\mathbf{x})$. Sabem que aquest valor es pot representar com:

$$p(\mathbf{z}|\mathbf{x}) = \frac{p(\mathbf{x}, \mathbf{z})}{p(\mathbf{x})} = \frac{p(\mathbf{x}|\mathbf{z})p(\mathbf{z})}{p(\mathbf{x})}$$

Calcular $p(\mathbf{z}|\mathbf{x})$ a partir de la igualtat bayesiana pot tenir la seva dificultat, perquè habitualment alguna de les variables acostuma a resultar intratable computacionalment.

La inferència variacional tracta de resoldre el problema mitjançant una aproximació, això és, restringint l'espai de cerca a una família de funcions senzilles, predefinida d'origen, que anomenarem família de funcions variacional $q_\phi(\mathbf{z}|\mathbf{x})$. És comú, encara que no requisit, que la família triada sigui la de funcions gaussianes.

A partir d'aquí, el problema original es converteix en un d'optimització, consistent a trobar els paràmetres ϕ òptims restringits a la família de funcions $q_\phi(\mathbf{z}|\mathbf{x})$ que minimitzen la distància existent entre les distribucions $p(\mathbf{z}|\mathbf{x})$ i $q_\phi(\mathbf{z}|\mathbf{x})$. Habitualment, la funció de mesura de distància entre distribucions triada és la divergència de Kullback-Leibler:

$$D_{KL}(q_\phi(\mathbf{z}|\mathbf{x})||p(\mathbf{z}|\mathbf{x})) = \mathbb{E}_{\mathbf{z} \sim q} \left[\log \frac{q_\phi(\mathbf{z}|\mathbf{x})}{p(\mathbf{z}|\mathbf{x})} \right] = \sum_{\mathbf{x} \in \mathcal{X}} q_\phi(\mathbf{z}|\mathbf{x}) \log \left(\frac{q_\phi(\mathbf{z}|\mathbf{x})}{p(\mathbf{z}|\mathbf{x})} \right)$$

En aquest cas, l'objectiu de la inferència variacional és trobar:

$$\hat{\theta} = \arg \min_{\phi} D_{KL}(q_\phi(\mathbf{z}|\mathbf{x})||p(\mathbf{z}|\mathbf{x}))$$

Hi ha molts algorismes diferents per abordar aquest problema, cadascun amb els seus avantatges i inconvenients que depenen de la naturalesa de $p(\mathbf{x}, \mathbf{z})$ i de la família subrogada de q .

La inferència variacional defineix una estratègia genèrica per abordar el problema, però no un algorisme concret per aconseguir-ho.

5.3.3. Límit inferior d'evidència (ELBO)

Arribats a aquest punt, definirem una variable nova partint de $p(\mathbf{x})$, que ens serà d'utilitat per facilitar posteriorment l'estratègia d'optimització.

Per a això ens servirem d'una propietat de les funcions convexes, denominada *desigualtat de Jensen*, que diu això: sigui f una funció convexa en el domini $\mathcal{X}$, llavors $\mathbb{E}[f(x)] \leq f(\mathbb{E}[x]), \forall x \in \mathcal{X}$. A l'efecte del nostre cas concret, si prenem f com la funció logarítmica, tenim que $\mathbb{E}[\log(x)] \leq \log(\mathbb{E}[x])$ per a tot el domini de la funció.

Utilitzant aquesta propietat, simplifiquem l'expressió de $\log p(\mathbf{x})$, creant un límit inferior:

$$\begin{aligned}
\log p(\mathbf{x}) &= \log \int p(\mathbf{x}, \mathbf{z}) d\mathbf{z} = \\
&= \log \int p(\mathbf{x}, \mathbf{z}) \frac{q_\phi(\mathbf{z}|\mathbf{x})}{q_\phi(\mathbf{z}|\mathbf{x})} d\mathbf{z} = \\
&= \log \mathbb{E}_{\mathbf{z} \sim q} \frac{p(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z}|\mathbf{x})} d\mathbf{z} \geq \\
&\geq \mathbb{E}_{\mathbf{z} \sim q} \log \frac{p(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z}|\mathbf{x})} d\mathbf{z} = \\
&= \mathbb{E}_{\mathbf{z} \sim q} \log p(\mathbf{x}, \mathbf{z}) - \mathbb{E}_{\mathbf{z} \sim q} \log q_\phi(\mathbf{z}|\mathbf{x}) \\
&= ELBO = \mathcal{L}_{\theta, \phi}(\mathbf{x})
\end{aligned}$$

A aquest límit inferior l'anomenem *límit inferior d'evidència*, *ELBO* en anglès o $\mathcal{L}_{\theta, \phi}(\mathbf{x})$ en la seva expressió matemàtica en aquest text.

L'ELBO també es pot expressar de manera alternativa com:

$$\begin{aligned}
\mathcal{L}_{\theta, \phi}(\mathbf{x}) &= \mathbb{E}_{\mathbf{z} \sim q} \log p(\mathbf{x}, \mathbf{z}) - \underbrace{\mathbb{E}_{\mathbf{z} \sim q} \log q_\phi(\mathbf{z}|\mathbf{x})}_{\text{Entropia de } q} \\
&= \underbrace{\mathbb{E}_{\mathbf{z} \sim q} \log p(\mathbf{x}|\mathbf{z})}_{\text{- Pèrdua de reconstrucció}} - \underbrace{D_{KL}(q_\phi(\mathbf{z}|\mathbf{x})||p(\mathbf{z}|\mathbf{x}))}_{\text{KL entre } q \text{ i el prior}}
\end{aligned}$$

5.3.4. ELBO com a mitjà d'optimitzar q_ϕ

A continuació demostrarem que $D_{KL}(q_\phi(\mathbf{z}|\mathbf{x})||p(\mathbf{z}|\mathbf{x})) = \log p(\mathbf{x}) - \mathcal{L}_{\theta, \phi}(\mathbf{x})$, això és, que maximitzant l'ELBO estem minimitzant també la distància entre les distribucions $p(\mathbf{z}|\mathbf{x})$ i $q_\phi(\mathbf{z}|\mathbf{x})$ i, per tant, aconseguint l'objectiu buscat d'aproximar $p(\mathbf{z}|\mathbf{x})$ amb la funció més senzilla $q_\phi(\mathbf{z}|\mathbf{x})$.

Demostració:

$$\begin{aligned}
D_{KL}(q_\phi(\mathbf{z}|\mathbf{x})||p(\mathbf{z}|\mathbf{x})) &= \mathbb{E}_{\mathbf{z} \sim q} \left[\log \frac{q_\phi(\mathbf{z}|\mathbf{x})}{p(\mathbf{z}|\mathbf{x})} \right] = \\
&= \mathbb{E}_{\mathbf{z} \sim q} \left[\log q_\phi(\mathbf{z}|\mathbf{x}) \right] - \mathbb{E}_{\mathbf{z} \sim q} \left[\log p(\mathbf{z}|\mathbf{x}) \right] = \\
&= \mathbb{E}_{\mathbf{z} \sim q} \left[\log q_\phi(\mathbf{z}|\mathbf{x}) \right] - \mathbb{E}_{\mathbf{z} \sim q} \left[\log \frac{p(\mathbf{x}, \mathbf{z})}{p(\mathbf{x})} \right] = \\
&= \mathbb{E}_{\mathbf{z} \sim q} \left[\log q_\phi(\mathbf{z}|\mathbf{x}) \right] - \mathbb{E}_{\mathbf{z} \sim q} \left[\log p(\mathbf{x}, \mathbf{z}) \right] + \mathbb{E}_{\mathbf{z} \sim q} \left[\log p(\mathbf{x}) \right] = \\
&= \log p(\mathbf{x}) - \left(\mathbb{E}_{\mathbf{z} \sim q} [\log p(\mathbf{x}, \mathbf{z})] - \mathbb{E}_{\mathbf{z} \sim q} [\log q_\phi(\mathbf{z}|\mathbf{x})] \right) = \\
&= \log p(\mathbf{x}) - \mathcal{L}_{\theta, \phi}(\mathbf{x})
\end{aligned}$$

Sabem que l'ELBO és un límit inferior de l'evidència, això és:

$$\mathcal{L}_{\theta, \phi}(\mathbf{x}) = \log p_\theta(\mathbf{x}) - D_{KL}(q_\phi(\mathbf{z}|\mathbf{x})||p(\mathbf{z}|\mathbf{x})) \leq \log p_\theta(\mathbf{x})$$

A partir d'aquesta equació podem entendre que maximitzant l'ELBO respecte als paràmetres ϕ i θ s'aconsegueixen dos objectius: d'una banda, maximitzar la probabilitat marginal $p_\theta(\mathbf{x})$ (el nostre model generatiu es torna millor) i, de l'altra, minimitzar la divergència KL de l'aproximació $q_\phi(\mathbf{z}|\mathbf{x})$ sobre el posterior exacte $p_\theta(\mathbf{z}|\mathbf{x})$ (l'aproximació $q_\phi(\mathbf{z}|\mathbf{x})$ millora).

5.4. El codificador com a forma d'aproximar el posterior

El nostre objectiu és aproximar el posterior, això és:

$$q_\phi(\mathbf{z}|\mathbf{x}) \approx p_\theta(\mathbf{z}|\mathbf{x})$$

El model d'inferència pot ser un model del tipus:

$$q_\phi(\mathbf{z}|\mathbf{x}) = q_\phi(\mathbf{z}_1, \dots, \mathbf{z}_M|\mathbf{x}) = \prod_{j=1}^M q_\phi(\mathbf{z}_j|Pa(\mathbf{z}_j), \mathbf{x})$$

on $Pa(\mathbf{z}_j)$ és el conjunt de nodes precedents a la variable $\mathbf{z}_j$. La distribució $q_\phi(\mathbf{z}|\mathbf{x})$ pot ser igualment modelada com una xarxa neuronal profunda. De cara a trobar els paràmetres òptims de la xarxa neuronal, necessitem definir una funció objectiu tractable.

Utilitzant la inferència variacional definida al subapartat anterior, restringint l'espai de cerca a la família de funcions gaussianes, la funció que cal optimitzar tindria la forma següent:

$$(\boldsymbol{\mu}, \log \boldsymbol{\sigma}) = \text{XarxaNeuralCodificador}_\phi(\mathbf{x})$$

$$q_\phi(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}))$$

Això és, la xarxa neuronal serviria per calcular, per a cadascun dels components de $\mathbf{z}$, la mitjana μ i desviació estàndard σ d'una distribució normal que determinarien q_ϕ , sent ϕ realment els paràmetres que defineixen $\boldsymbol{\mu}$ i $\boldsymbol{\sigma}$.

En els mètodes tradicionals d'inferència variacional, els paràmetres s'optimitzen de manera separada per a cada punt de dades. En el cas de l'autocodificador variacional, els paràmetres se suposen comuns a tot el conjunt de dades. Aquesta aproximació al problema es denomina *inferència variacional amortitzada* (Gershman i Goodman, 2014) i permet l'eliminació del bucle d'optimització per punt de dades. Amb aquesta suposició, implícitament s'està suposant que l'expressivitat de la xarxa neuronal és suficient per codificar la dependència respecte a $\mathbf{x}$. Això permet aprofitar l'eficiència del descens de gradient estocàstic.

5.5. Optimització de l'ELBO mitjançant gradient estocàstic

Per poder utilitzar l'ELBO com a funció objectiu, cal derivar els gradients respecte a θ i ϕ . Donat un conjunt i.i.d. de dades $\mathcal{D}$ l'ELBO es pot representar com:

$$\mathcal{L}_{\theta,\phi}(\mathcal{D}) = \sum_{\mathbf{x} \in \mathcal{D}} \mathcal{L}_{\theta,\phi}(\mathbf{x})$$

Normalment, aquest objectiu acostuma a ser intractable, encara que sol ser possible, tal com veurem a continuació, obtenir bons estimadors no esbiaixats que permetin dur a terme SGD.

El gradient respecte a θ sol ser fàcil d'obtenir:

$$\begin{aligned} \nabla_{\theta} \mathcal{L}_{\theta,\phi}(\mathbf{x}) &= \nabla_{\theta} \mathbb{E}_q[\log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x})] \\ &= \mathbb{E}_q[\nabla_{\theta}(\log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x}))] \\ &= \mathbb{E}_q[\nabla_{\theta}(\log p_{\theta}(\mathbf{x}, \mathbf{z}))] \\ &\simeq \nabla_{\theta} \log p_{\theta}(\mathbf{x}, \mathbf{z}) \end{aligned}$$

L'última línia correspon amb l'estimador de l'esperança simple de Monte Carlo (Metropolis i Ulam, 1949).

No és tan senzill per al cas de ∇_{ϕ} , perquè tal com veurem en la derivació presentada a continuació, $\mathbb{E}_q$ depèn de ϕ .

$$\begin{aligned} \nabla_{\phi} \mathcal{L}_{\theta,\phi}(\mathbf{x}) &= \nabla_{\phi} \mathbb{E}_q[\log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x})] \\ &\neq \mathbb{E}_q \nabla_{\phi}[\log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x})] \end{aligned}$$

Per aconseguir simplificar l'esperança, és necessari desfer la dependència de ϕ . Això és possible fer-ho realitzant un canvi de variable que deslligui el mostreig de ϕ , això és, convertir $\mathbf{z} \sim q_{\phi}(\mathbf{z}|\mathbf{x})$ en $\epsilon \sim p(\epsilon)$ i expressar $\mathbf{z}$ com $\mathbf{z} = \mathbf{g}(\epsilon, \phi, \mathbf{x})$.

Realitzant aquest canvi de variable, l'esperança pot ser expressada com segueix:

$$\begin{aligned} \mathbb{E}_{\mathbf{z} \sim q_{\phi}(\mathbf{z}|\mathbf{x})}[f(\mathbf{z})] &= \mathbb{E}_{\epsilon \sim p(\epsilon)}[f(\mathbf{z})] \\ f(\mathbf{z}) &= \log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x}) \\ \mathbf{z} &= \mathbf{g}(\phi, \mathbf{x}, \epsilon) \end{aligned}$$

A partir d'aquest canvi de variable, ja és possible derivar l'estimador de Monte Carlo:

$$\begin{aligned}\nabla_{\phi} \mathbb{E}_{\mathbf{z} \sim q_{\phi}(\mathbf{z}|\mathbf{x})} [f(\mathbf{z})] &= \nabla_{\phi} \mathbb{E}_{\epsilon \sim p(\epsilon)} [f(\mathbf{z})] \\ &= \mathbb{E}_{\epsilon \sim p(\epsilon)} \nabla_{\phi} [f(\mathbf{z})] \\ &\simeq \nabla_{\phi} [f(\mathbf{z})]\end{aligned}$$

Aquesta reparametrizació $\mathbf{z} = \mathbf{g}(\phi, \mathbf{x}, \epsilon)$ també permet expressar l'ELBO com segueix:

$$\begin{aligned}\mathcal{L}_{\theta, \phi}(\mathbf{x}) &= \mathbb{E}_{\mathbf{z} \sim q_{\phi}(\mathbf{z}|\mathbf{x})} [\log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x})] \\ &= \mathbb{E}_{\epsilon \sim p_{\epsilon}} [\log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x})]\end{aligned}$$

A partir d'aquesta expressió podem derivar un estimador simple de Monte Carlo $\tilde{\mathcal{L}}_{\theta, \phi}(\mathbf{x})$ de l'ELBO d'un punt utilitzant una única mostra de soroll ϵ de $p(\epsilon)$:

$$\begin{aligned}\epsilon &\sim p(\epsilon) \\ \mathbf{z} &= \mathbf{g}(\phi, \mathbf{x}, \epsilon) \\ \tilde{\mathcal{L}}_{\theta, \phi}(\mathbf{x}) &= \log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x})\end{aligned}$$

Aquest estimador pot ser fàcilment calculat mitjançant llibreries de còmput amb diferenciació automàtica, de manera que sigui senzill calcular les derivades respecte als paràmetres θ i ϕ . El valor de $\nabla_{\phi} \tilde{\mathcal{L}}_{\theta, \phi}(\mathbf{x})$ es pot utilitzar per optimitzar l'ELBO mitjançant descens de gradient (Kingma i Welling, 2013). L'algorisme 1 descriu l'operativa d'optimització.

Algorisme 1 Optimització estocàstica de l'ELBO. A aquest procediment d'optimització se'l denomina AEVB, i.e. *autocodificació bayesiana variacional*

Entrada: $\mathcal{D}$, conjunt de dades d'entrenament

Paràmetres: $q_{\phi}(\mathbf{z}|\mathbf{x})$, model d'inferència

Paràmetres: $p_{\theta}(\mathbf{x}, \mathbf{z})$, model generatiu

- 1) $(\theta, \phi) \leftarrow$ Inicialització
 - 2) **mentrestant** SGD no convergeixi **fer**
 - 3) $\mathcal{M} \sim \mathcal{D}$ (seleccionar minibatch)
 - 4) $\epsilon \sim p(\epsilon)$ (soroll aleatori diferent per a cada mostra de $\mathcal{M}$)
 - 5 Calcular $\tilde{\mathcal{L}}_{\theta, \phi}(\mathcal{M}, \epsilon)$ i els seus gradients $\nabla_{\theta, \phi} \tilde{\mathcal{L}}_{\theta, \phi}(\mathcal{M}, \epsilon)$
 - 6) Actualitzar θ i ϕ fent servir l'optimitzador SGD
 - 7) **fi**
-

El gradient utilitzat és un estimador no esbiaixat del gradient de l'ELBO. La mitjana del mostreig sobre $\epsilon \sim p(\epsilon)$ equival al gradient de l'ELBO sobre el punt considerat.

5.6. Càlcul de q_ϕ

Per obtenir l'estimador de l'ELBO cal calcular la densitat $q_\phi(\mathbf{z}|\mathbf{x})$. El càlcul d'aquest valor és senzill si es tria una transformació adequada $\mathbf{g}$. La densitat $p(\epsilon)$ és coneguda, perquè correspon amb la densitat de la distribució triada per endavant.

Si $\mathbf{g}(\cdot)$ és una funció invertible, llavors les funcions de densitat de probabilitat de ϵ i $\mathbf{z}$ estan relacionades per la següent expressió¹:

$$\log q_\phi(\mathbf{z}|\mathbf{x}) = \log p(\epsilon) - \log d_\phi(\mathbf{x}, \epsilon)$$

on:

$$\log d_\phi(\mathbf{x}, \epsilon) = \log \left| \det \left(\frac{\partial \mathbf{z}}{\partial \epsilon} \right) \right|$$

sent

$$\frac{\partial \mathbf{z}}{\partial \epsilon} = \frac{\partial(z_1, \dots, z_k)}{\partial(\epsilon_1, \dots, \epsilon_k)} = \begin{pmatrix} \frac{\partial z_1}{\partial \epsilon_1} & \cdots & \frac{\partial z_1}{\partial \epsilon_k} \\ \vdots & \ddots & \vdots \\ \frac{\partial z_k}{\partial \epsilon_1} & \cdots & \frac{\partial z_k}{\partial \epsilon_k} \end{pmatrix}$$

5.7. Posteriors gaussians

És comú triar un codificador gaussià $q_\phi(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2))$:

$$(\boldsymbol{\mu}, \log \boldsymbol{\sigma}) = \text{XarxaNeuralCodificador}_\phi(\mathbf{x})$$

$$q_\phi(\mathbf{z}|\mathbf{x}) = \prod_i q_\phi(z_i|\mathbf{x}) = \prod_i \mathcal{N}(z_i; \mu_i, \sigma_i^2)$$

Que després de reparametritzar queda com:

$$\epsilon \sim \mathcal{N}(0, \mathbf{I})$$

$$(\boldsymbol{\mu}, \log \boldsymbol{\sigma}) = \text{XarxaNeuralCodificador}(\mathbf{x})$$

$$\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \epsilon$$

⁽¹⁾Per a la prova, consulteu l'apartat 1.6.10 a Soch i altres (2020)

on $\odot$ representa el producte element a element. La transformació jacobiana de ϵ a $\mathbf{z}$ és:

$$\frac{\partial \mathbf{z}}{\partial \epsilon} = \text{diag}(\sigma)$$

El logaritme del determinant del jacobià, seguint les equacions de l'apartat anterior per al cas gaussià, es pot expressar com:

$$\log d_{\phi}(\mathbf{x}, \epsilon) = \log \left| \det \left(\frac{\partial \mathbf{z}}{\partial \epsilon} \right) \right| = \sum_i \log \sigma_i$$

i la densitat del posterior és:

$$\log q_{\phi}(\mathbf{z}|\mathbf{x}) = \sum_i \log \mathcal{N}(\epsilon_i; 0, 1) - \log \sigma_i$$

quan $\mathbf{z} = g(\epsilon, \phi, \mathbf{x})$.

5.8. Posterior gaussià amb matriu de covariància general

El posterior gaussià factoritzat pot ser estès al cas gaussià amb covariància completa:

$$q_{\phi}(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$$

La reparametrització vindria donada per:

$$\epsilon \sim \mathcal{N}(0, \mathbf{I})$$

$$\mathbf{z} = \boldsymbol{\mu} + \mathbf{L}\epsilon$$

on $\mathbf{L}$ és la matriu triangular superior (o inferior) amb valors no nuls en la diagonal resultant de realitzar la descomposició de Cholesky, això és, $\boldsymbol{\Sigma} = \mathbf{L}\mathbf{L}^T$. Es proposa aquest canvi de variable ja que d'aquesta forma el càlcul del jacobià és trivial: $\frac{\partial \mathbf{z}}{\partial \epsilon} = \mathbf{L}$, resulta ser el producte dels elements de la diagonal:

$$\log d_{\phi}(\mathbf{x}, \epsilon) = \log \left| \det \left(\frac{\partial \mathbf{z}}{\partial \epsilon} \right) \right| = \sum_i \log L_{ii}$$

I la densitat logarítmica del posterior es pot representar com:

$$\log q_{\phi}(\mathbf{z}|\mathbf{x}) = \log p(\epsilon) - \sum_i \log |L_{ii}|$$

Calculem ara la variància de $\mathbf{z}$ per demostrar que es correspon amb la resultant de la descomposició de Cholesky:

$$\begin{aligned}\Sigma(\mathbf{z}) &= \mathbb{E}[(\mathbf{z} - \mathbb{E}[\mathbf{z}])(\mathbf{z} - \mathbb{E}[\mathbf{z}])^T] \\ &= \mathbb{E}[\mathbf{L}\epsilon(\mathbf{L}\epsilon)^T] = \mathbf{L}\mathbb{E}[\epsilon\epsilon^T]\mathbf{L}^T = \mathbf{L}\mathbf{L}^T\end{aligned}$$

Es fa notar que $\mathbb{E}[\epsilon\epsilon^T] = \mathbf{I}$ ja que $\epsilon \sim \mathcal{N}(0, \mathbf{I})$.

Una manera de calcular els paràmetres de la funció q_{ϕ} seria utilitzar una xarxa neuronal per predir μ , Σ . El problema d'aquesta aproximació és que per calcular $\mathbf{L}$ a través de la descomposició de Cholesky, incorreríem en un cost computacional $\mathcal{O}(n^3)$ per calcular $\mathbf{L}$. Una forma alternativa més econòmica computacionalment és calcular directament $\mathbf{L}$, per exemple, de la següent manera:

$$(\mu, \log \sigma, \mathbf{L}') \leftarrow \text{XarxaNeuronalCodificador}_{\phi}(\mathbf{x})$$

$$\mathbf{L} \leftarrow \mathbf{L}_{mask} \cdot \mathbf{L}' + \text{diag}(\sigma)$$

La xarxa neuronal prediu μ , $\log \sigma$ i una matriu $\mathbf{L}'$. D'aquesta última únicament es consideren els elements de sota la diagonal. Això es fa aplicant una màscara $\mathbf{L}_{mask}$ per descartar els no necessaris. Aquest principi de derivació s'utilitza en la variació de VAE denominada *flux autoregressiu invers* (Kingma i altres, 2016).

5.9. Desafiaments de l'arquitectura

Un dels problemes típics en utilitzar l'optimització estocàstica dels autocodificadors variacionals és que durant el procés d'entrenament la xarxa quedi atrapada en una zona d'equilibri no òptim que dificulti el progrés, donant com a resultat xarxes deficientes. Diferents solucions s'han plantejat per a aquest problema, que queden fora de l'abast d'un apartat introductori als VAEs. Per a qui tingui interès a aprofundir sobre aquest aspecte, pot consultar, per exemple, Bowman i altres (2015), Larsen i altres (2016), Kingma i altres (2016).

Les característiques definitòries del mètode dels VAEs fan que busquem una aproximació $q_{\phi}(\mathbf{z}|\mathbf{x})$ a $p_{\theta}(\mathbf{z}|\mathbf{x})$. Quan no és possible aconseguir una bona apro-

ximació, ja sigui perquè la funció $q_\phi(\mathbf{z}|\mathbf{x})$ no sigui prou expressiva per aproximar $p_\theta(\mathbf{z}|\mathbf{x})$, o bé per problemes en l'optimització, ens trobem amb la generació d'imatges borroses típiques d'aquesta mena d'arquitectures.

5.10. Posteriors no gaussians

Una manera de millorar el rendiment dels autocodificadors variacionals és a través de la millora de la flexibilitat del model d'inferència $q_\phi(\mathbf{z}|\mathbf{x})$. Millorar la capacitat expressiva de la funció té una incidència directa en l'ajust del límit inferior d'evidència a la probabilitat marginal. Qualsevol modificació del model d'inferència ha de complir dues premisses: (1) que sigui computacionalment eficient de calcular i diferenciar, i (2) computacionalment eficient de mostrejar, perquè totes dues operacions han de ser realitzades per a cada punt del minibatch, per a cada iteració d'optimització. També és desitjable que l'algorisme sigui paral·lelitzable per als elements de $\mathbf{z}$, perquè això permet treballar amb dimensions altes del vector de variables latents.

5.11. Propostes d'extensió de l'autocodificador variacional original

En aquest subapartat enumerem algunes de les arquitectures derivades de l'autocodificador variacional original (Kingma i Welling, 2013) que estenen les seves característiques.

Entre elles podem trobar les que segueixen:

- Structured VAE (Salimans, 2016), Auxiliary Deep VAE (Maaløe i altres, 2016), Conditional VAE (Sohn i altres, 2015): aquests tipus de VAE permeten condicionar l'aprenentatge dels espais latents i la generació a diferents tipus de variables auxiliars.
- Wasserstein Autoencoders (WAE-MMD) (Tolstikhin i altres, 2017), Sliced-Wasserstein VAE (SWAE) (Kolouri i altres, 2018): VAEs que mesuren la distància entre distribucions mitjançant la distància Wasserstein en comptes de la divergència Kullback-Leibler.
- β -VAE (Higgins i altres, 2016), (Burgess i altres, 2018), (Chen i altres, 2018b): introdueix una constant β que s'utilitza durant el procés d'entrenament per modificar el pes de la divergència de Kullback-Leibler en la funció objectiu. Això incideix en la capacitat de separació de les característiques representades per les variables latents.
- Importance Weighted Autoencoders (IWAE) (Burda i altres, 2015), MIWAE (Rainforth i altres, 2018): utilitzen una estimació més precisa de l'ELBO basada en el càlcul de diversos valors de ϵ per mostra. Això permet obtenir un ELBO més ajustat a $p(\mathbf{z}|\mathbf{x})$.

- Deep Feature Consistent VAE (DFCVAE) (Hou i altres, 2017): afegix a la funció de pèrdua d'una VAE convencional la suma dels MSEs obtinguts de comparar les activacions de la imatge original i la imatge reconstruïda al pas d'una CNN preentrenada. L'objectiu és reduir l'aparença borrosa de les imatges predites pel VAE.
- MS-SSIM-VAE (Snell i altres, 2017) utilitza funcions de pèrdua basades en l'ús de mètriques de similitud perceptiva (combinació de luminància, contrast i estructura).
- Categorical VAE (Jang i altres, 2016): proposa una implementació amb l'ús de variables latents categòriques mitjançant una aproximació diferenciable a la seva distribució de probabilitat.
- Joint-VAE (Dupont, 2018): proposa l'ús combinat de variables latents contínues i discretes.
- Info-VAE (Zhao i altres, 2017): proposa una funció d'optimització alternativa per abordar el problema típic dels VAEs quan el generador obvia part de la informació apresada per al codificador, generant imatges subòptimes. Per a això introdueix un terme l'objectiu del qual és maximitzar la informació mútua entre l'espai latent i l'espai de generació.
- LogCosh-VAE (Chen i altres, 2018a): proposa l'ús d'una funció de pèrdua alternativa basada en el logaritme del cosinus hiperbòlic per millorar la qualitat visual de les imatges reconstruïdes.
- DIP-VAE (Kumar i altres, 2017) Proposta alternativa per a la separació de les variables latents del VAE per a dades no etiquetades.
- Vector Quantized Variational Autoencoder (VQ-VAE) (Van Den Oord i altres, 2017): utilitza també un espai latent discret. Utilitza un «llibre de codis» per emmagatzemar els valors permessos per al vector de l'espai latent. Els vectors presents en el llibre de codis són apresos mitjançant descens de gradient.
- Normalizing Flows (Rezende i Mohamed, 2015), (Kobyzev i altres, 2020) es construeix una distribució flexible del posterior a través d'un procediment iteratiu. Es comença amb una variable aleatòria amb una distribució relativament simple amb una coneguda (i computacionalment econòmica) funció de densitat de probabilitat, per després derivar per iteració una cadena de transformacions invertibles parametritzades, de manera que l'última iteració tingui una distribució més flexible. Aquesta operativa no escala bé per a espais dimensionals grans.
- Inverse Autoregressive Flow (IAF) (Kingma i altres, 2016). Igual que els fluxos de normalització, es comença amb una distribució de probabilitat tractable (per exemple, amb una gaussiana amb covariància diagonal), seguit

d'una sèrie de transformacions invertibles no lineals de $\mathbf{z}$. S'espera que la iteració final tingui una distribució flexible.

A Subramanian (2020) podeu trobar implementacions d'alguns d'aquests autocodificadors variacionals.

5.12. Conclusions

Els models probabilístics són un pilar fonamental en el camp de la intel·ligència artificial moderna. Els models probabilístics amb variables latents permeten associar variables observables amb altres d'ocultes. Aquests poden utilitzar-se per descobrir abstraccions, en forma de variables latents, que serveixin per interpretar les regularitats estadístiques observades en les dades. Les distribucions de probabilitat derivades de relacionar aquestes variables amb les observables poden ser utilitzades a manera de funció objectiu per al disseny de models predictius de les dades procedents d'aquestes distribucions. El problema habitual en aquests casos és que les relacions entre distribucions solen implicar càlculs intractables des d'un punt de vista computacional. La inferència variacional (VI) permet convertir aquests problemes intractables en altres de tractables mitjançant optimització. La distribució de probabilitat que relaciona variables ocultes amb observables, això és, el posterior $p(\text{oculta}|\text{dades})$, s'aproxima amb una distribució de probabilitat més senzilla (per exemple, gaussiana), i s'optimitza perquè la distància entre aquesta i el posterior real sigui el més petita possible. Això es fa introduint uns nous models paramètrics denominats variacionals. Les xarxes neuronals, gràcies a la seva alta flexibilitat i expressivitat, són un candidat perfecte per a la seva optimització en aquestes circumstàncies.

La inferència variacional en els VAEs realitza l'optimització típicament a través d'un límit inferior de l'evidència (ELBO) mitjançant optimització per descens de gradient estocàstic. El VAE resulta ser una combinació d'un model profund de variables latents contínues i un model d'inferència associat. El model d'inferència, denominat codificador o model de reconeixement, aproxima la distribució del posterior. Tant el model generatiu com el d'inferència són models probabilístics basats en xarxes neuronals. Els paràmetres de tots dos models són optimitzats de manera conjunta realitzant descens de gradient sobre el límit inferior d'evidència (ELBO). L'ELBO és un límit inferior sobre la probabilitat marginal de les dades, també anomenat límit inferior variacional. Els gradients estocàstics necessaris per a l'optimització són obtinguts mitjançant una reparametrització.

Modificacions posteriors s'han realitzat sobre el model inicial tant per augmentar l'expressivitat del model generatiu com per fer més flexible el model d'inferència del posterior. Les primeres estan destinades a augmentar la variabilitat de les dades generades perquè incloguin tota la diversitat ja codificada en les variables latents apreses pel model; les segones estan destinades

a augmentar la flexibilitat del model d'inferència per fer que el límit inferior d'evidència més pròxim a la probabilitat marginal de les dades i , per tant, augmentar la representativitat de variables latents. Un altre tipus de propostes estan destinades a limitar la correlació entre els elements del vector de variables latents o fins i tot a utilitzar una combinació de variables latents discretes i contínues.


Els VAEs es mantenen com una arquitectura de referència per a la derivació de models d'inferència de variables latents associades a conjunts de variables observades contínues i discretes, i per a la síntesi de noves instàncies pertanyents a distribucions de probabilitat pròximes a l'original.

6. Models generatius basats en difusió

Els models generatius basats en difusió, proposats per primera vegada a Sohl-Dickstein i altres (2015), són un marc de disseny que permet generar noves imatges mitjançant la reversió de processos anàlegs als oposats en la termodinàmica de no equilibri. Si en un got d'aigua introduïm un líquid miscible d'un color diferent, observarem un procés físic de difusió en el qual els dos líquids es van barrejant progressivament fins a finalment formar una mescla homogènia. Els models basats en difusió modelitzen la reversió d'aquest procés.

Els models de difusió es poden aplicar a senyals de diferent naturalesa, entre altres, a senyals d'àudio i imatge. Per al cas d'imatge, el procés s'inicia duent a terme un procés de corrupció progressiva dels píxels que la componen mitjançant l'aplicació de soroll aleatori, a manera de procés de difusió natural. Una xarxa neuronal és entrenada per a la reversió de cadascun dels esmentats passos de corrupció. Perquè el procés de reconstrucció resulti reversible cal realitzar la corrupció de forma molt progressiva. És habitual que el nombre de passos necessaris sigui de l'ordre del miler. Si l'entrenament d'aquesta xarxa és reeixit serà possible generar una imatge a partir de soroll aleatori encadenant un nombre de passos similar a l'utilitzat per a la desconstrucció d'imatges en temps d'entrenament.

Figura 5. Representació de la generació d'imatge típica d'un model generatiu basat en mecanismes de difusió.



6.1. Formulació matemàtica

Els models de difusió són models generatius, això és, són utilitzats per generar noves dades. El mecanisme de funcionament consisteix en dues etapes: una primera on es procedeix a la corrupció incremental de les dades d'entrada mitjançant l'addició de soroll gaussià, i una segona on s'aprèn a revertir


cadascun dels estadis de corrupció aplicats prèviament. Després de l'entrenament, les xarxes de reconstrucció entrenades són capaces de generar noves dades a partir de soroll gaussià mitjançant l'aplicació successiva del procés de reconstrucció prèviament entrenat.

Una cadena de Markov és un procés estocàstic en el qual la probabilitat que succeeixi un esdeveniment depèn únicament de l'estat precedent, és a dir, tota la informació necessària per predir l'estat següent està continguda en l'estat actual, i és, per tant, independent de tots els anteriors.

Un model de difusió pot ser modelitzat com una cadena de Markov, on els nodes representen els successius estadis de la reconstrucció de les dades des del seu estadi original fins al final, representatiu de les dades reconstruïdes.


Per revertir el procés hem de ser capaços de modelitzar $q(\mathbf{x}_t|\mathbf{x}_{t-1})$. La figura 6 representa el procés al qual se sotmet cada imatge durant l'entrenament. La cadena de Markov del procés de difusió directa realitza una desconstrucció gradual de les dades, afegint soroll de manera gradual, per obtenir una aproximació al posterior $q(\mathbf{x}_{1:T}|\mathbf{x}_0)$, on $\mathbf{x}_1, \dots, \mathbf{x}_T$, són variables latents de les mateixes dimensions que $\mathbf{x}_0$. Al final del procés s'acaba transformant la imatge original en soroll gaussià.

Figura 6. Representació de la cadena de Markov representativa del procés de desconstrucció d'una imatge



La xarxa generativa utilitza la informació generada com a mitjà d'optimització del model de reconstrucció del procés invers. La funció generativa correspon a la distribució de probabilitat $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$. La cadena de Markov representativa del procés de reconstrucció es mostra a la figura 7.

Figura 7. Representació de la cadena de Markov representativa del procés de reconstrucció d'una imatge



Els models basats en difusió són capaços de generar imatges d'alta qualitat sense requerir entrenament adversari típic de les GANs. Les dificultats de l'optimització de les xarxes GAN ja han estat tractades a l'apartat corresponent. Els

models de difusió presenten beneficis d'escalabilitat i paral·lelització respecte a altres tipus de models generatius com l'esmentat.

6.2. Models probabilístics d'eliminació del soroll produït per difusió

Els models de difusió són models de variables latents de la forma $p_\theta(\mathbf{x}_0) = \int p_\theta(\mathbf{x}_0, \dots, \mathbf{x}_T) d\mathbf{x}_1 \dots d\mathbf{x}_T$, on $\mathbf{x}_1 \dots \mathbf{x}_T$ són variables latents de les mateixes dimensions que les dades $\mathbf{x}_0 \sim q(\mathbf{x}_0)$.

6.2.1. Procés directe de difusió

Donat un punt de mostreig $\mathbf{x}_0 \sim q(\mathbf{x})$, definim el procés directe de difusió com aquell en el qual afegim soroll gaussià a la mostra original en T passos successius, produint una seqüència de mostres $\mathbf{x}_1, \dots, \mathbf{x}_T$. La mida del canvi es controla mitjançant el paràmetre $\{\beta_t \in (0, 1)\}_{t=1}^T$.

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I})$$

$$q(\mathbf{x}_1, \dots, \mathbf{x}_T | \mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1})$$

La mostra $\mathbf{x}_0$ perd gradualment els seus atributs distingibles. Amb $T \rightarrow \infty$, $\mathbf{x}_T$ tendeix a una distribució isotròpica gaussiana, per exemple, $\mathcal{N}(\mathbf{0}, \mathbf{I})$.

Una propietat interessant que a continuació demostrarem és que per a qualsevol t és possible obtenir en un únic pas la mostra $\mathbf{x}_t$:

Sigui $\alpha_t = 1 - \beta_t$ i $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ llavors,

$$\begin{aligned} \mathbf{x}_t &= \sqrt{\alpha_t} \mathbf{x}_{t-1} + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}_{t-1}; & \boldsymbol{\epsilon}_i &\sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \\ &= \sqrt{\alpha_t \alpha_{t-1}} \mathbf{x}_{t-2} + \sqrt{1 - \alpha_t \alpha_{t-1}} \bar{\boldsymbol{\epsilon}}_{t-2}; & \bar{\boldsymbol{\epsilon}}_{t-2} &\sim \mathcal{N}(\mathbf{0}, \sqrt{1 - \alpha_t \alpha_{t-1}}) \\ &= \dots \\ &= \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon} \end{aligned}$$

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})$$

En general, a mesura que s'avança en el procés de corrupció, és possible realitzar passos d'actualització més grans, per la qual cosa $\beta_1 < \beta_2 < \dots < \beta_T$ i, per tant, $\bar{\alpha}_1 > \bar{\alpha}_2 > \dots > \bar{\alpha}_T$.

Fins ara hem vist com derivar $q(\mathbf{x}_t, \mathbf{x}_0)$. Per a derivar $q(\mathbf{x}_t)$ sabem que $q(\mathbf{x}_t) = \int q(\mathbf{x}_0, \mathbf{x}_t) d\mathbf{x}_0 = \int q(\mathbf{x}_t | \mathbf{x}_0) q(\mathbf{x}_0) d\mathbf{x}_0$, llavors podem mostrejar $\mathbf{x}_t \sim q(\mathbf{x}_t)$ en dos passos: primer mostreiant $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ de les dades d'entrada i després mostreiant $\mathbf{x}_t \sim q(\mathbf{x}_t | \mathbf{x}_0)$, això és, mostreig ancestral.

Suma de dues gaussianes

La suma de dues distribucions gaussianes $\mathcal{N}(0, \sigma_1^2 I)$ i $\mathcal{N}(0, \sigma_2^2 I)$ és $\mathcal{N}(0, (\sigma_1^2 + \sigma_2^2) I)$

A continuació derivarem l'expressió de $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$. Combinant l'aplicació de la regla de Bayes i l'expressió de la funció gaussiana tenim:

$$\begin{aligned} q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) &= q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0) \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_0)}{q(\mathbf{x}_t | \mathbf{x}_0)} \\ &\propto \exp \left(-\frac{1}{2} \left(\frac{(\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_{t-1})^2}{\beta_t} + \frac{(\mathbf{x}_{t-1} - \sqrt{\alpha_{t-1}} \mathbf{x}_0)^2}{1 - \alpha_{t-1}} - \frac{(\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_0)^2}{1 - \alpha_t} \right) \right) \\ &= \exp \left(-\frac{1}{2} \left(\frac{\mathbf{x}_t^2 - 2\sqrt{\alpha_t} \mathbf{x}_t \mathbf{x}_{t-1} + \alpha_t \mathbf{x}_{t-1}^2}{\beta_t} + \frac{\mathbf{x}_{t-1}^2 - 2\sqrt{\alpha_{t-1}} \mathbf{x}_0 \mathbf{x}_{t-1} + \alpha_{t-1} \mathbf{x}_0^2}{1 - \alpha_{t-1}} - \frac{(\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_0)^2}{1 - \alpha_t} \right) \right) \\ &= \exp \left(-\frac{1}{2} \left(\left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \alpha_{t-1}} \right) \mathbf{x}_{t-1}^2 - \left(\frac{2\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{2\sqrt{\alpha_{t-1}}}{1 - \alpha_{t-1}} \mathbf{x}_0 \right) \mathbf{x}_{t-1} + C(\mathbf{x}_t, \mathbf{x}_0) \right) \right) \end{aligned}$$

Expressant els termes en funció d'una distribució estàndard gaussiana tenim que:

$$\begin{aligned} \tilde{\beta}_t &= 1 / \left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \alpha_{t-1}} \right) = 1 / \left(\frac{\alpha_t - \alpha_{t-1} + \beta_t}{\beta_t (1 - \alpha_{t-1})} \right) = \frac{1 - \alpha_{t-1}}{1 - \alpha_t} \cdot \beta_t \\ \tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) &= \left(\frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\alpha_{t-1}}}{1 - \alpha_{t-1}} \mathbf{x}_0 \right) / \left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \alpha_{t-1}} \right) \\ &= \left(\frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\alpha_{t-1}}}{1 - \alpha_{t-1}} \mathbf{x}_0 \right) \frac{1 - \alpha_{t-1}}{1 - \alpha_t} \cdot \beta_t \\ &= \frac{\sqrt{\alpha_t} (1 - \alpha_{t-1})}{1 - \alpha_t} \mathbf{x}_t + \frac{\sqrt{\alpha_{t-1}} \beta_t}{1 - \alpha_t} \mathbf{x}_0 \end{aligned}$$

Sabem que $\mathbf{x}_0 = \frac{1}{\sqrt{\alpha_t}} (\mathbf{x}_t - \sqrt{1 - \alpha_t} \epsilon_t)$, introduint aquesta expressió en la de $\tilde{\mu}_t$ obtenim:

$$\begin{aligned} \tilde{\mu}_t(\mathbf{x}_t, \epsilon_t) &= \frac{\sqrt{\alpha_t} (1 - \alpha_{t-1})}{1 - \alpha_t} \mathbf{x}_t + \frac{\sqrt{\alpha_{t-1}} \beta_t}{1 - \alpha_t} \frac{1}{\sqrt{\alpha_t}} (\mathbf{x}_t - \sqrt{1 - \alpha_t} \epsilon_t) \\ &= \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \epsilon_t \right) \end{aligned}$$

A pesar que $q(\mathbf{x}_{t-1} | \mathbf{x}_t)$ és intractable, es demostra que $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$ és tractable, $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\mu}(\mathbf{x}_t, \mathbf{x}_0), \tilde{\beta}_t \mathbf{I})$.

6.2.2. Procés de difusió invers o de reconstrucció

Si fos possible revertir el procés descrit al subapartat anterior i obtenir mostres de la distribució $q(\mathbf{x}_{t-1} | \mathbf{x}_t)$ llavors seria possible reconstruir una mostra real a partir d'una entrada de soroll gaussià, $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.

Una manera de fer-ho és estimar $q(\mathbf{x}_{t-1} | \mathbf{x}_t)$ mitjançant l'ús d'un model paramètric p_θ que approximi aquestes probabilitats condicionals. Per a β_t prou petit,

$q(\mathbf{x}_{t-1}|\mathbf{x}_t)$ es pot aproximar a una distribució normal. Es decideix aproximar $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$ mitjançant un model paramètric p_θ com una distribució gaussiana i parametritzar la seva mitjana i la seva variància:

$$\begin{aligned} p(\mathbf{x}_T) &= \mathcal{N}(\mathbf{x}_T; \mathbf{0}, \mathbf{I}) \\ p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) &= \mathcal{N}(\mathbf{x}_{t-1}; \mu_\theta(\mathbf{x}_t, t), \Sigma_\theta(\mathbf{x}_t, t)) \\ \Sigma_\theta(\mathbf{x}_t, t) &= \sigma_t \mathbf{I} \end{aligned}$$

$\mu_\theta(\mathbf{x}_t, t)$ se sol parametritzar com una xarxa neuronal (comunament utilitzant l'arquitectura U-Net o bé l'autocodificador atenuador de soroll).

Si apliquem l'equació d'inversió per a tots els passos (trajectòria) podem anar de $\mathbf{x}_T$ fins a la distribució de les dades:

$$p_\theta(\mathbf{x}_0, \dots, \mathbf{x}_T) = p_\theta(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$$

6.2.3. Funció de pèrdua

Per poder trobar els paràmetres òptims del model d'inversió, hem de buscar una manera de connectar el procés de difusió directa (representat per la distribució q) amb el procés invers (distribució p_θ). Una funció objectiu podria ser la següent:

$$-\log p(\mathbf{x}_0) \leq -\log p(\mathbf{x}_0) + D_{KL}(q(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0) || p_\theta(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0))$$

En el cas ideal que $q(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0)$ i $p_\theta(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0)$ fossin iguals, la desigualtat es convertiria en igualtat.

Manipulant l'expressió anterior:

$$\begin{aligned} -\log p(\mathbf{x}_0) &\leq -\log p(\mathbf{x}_0) + D_{KL}(q(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0) || p_\theta(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0)) \\ &= -\log p(\mathbf{x}_0) + \mathbb{E}_{\mathbf{x}_1, \dots, \mathbf{x}_T \sim q(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0)} \left[\log \frac{q(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0)}{p_\theta(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0)} \right] \\ &= -\log p(\mathbf{x}_0) + \mathbb{E}_q \left[\log \frac{q(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0)}{p_\theta(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0)} + \log p_\theta(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0) \right] \\ &= \mathbb{E}_q \left[\log \frac{q(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0)}{p_\theta(\mathbf{x}_1, \dots, \mathbf{x}_T|\mathbf{x}_0)} \right] = L_{VLB} \\ L_{VLB} &\geq -\mathbb{E}_{q(\mathbf{x}_0)} \log p_\theta(\mathbf{x}_0) \end{aligned}$$

Es pot arribar al mateix resultat partint de la desigualtat de Jensen:

$$\begin{aligned}
 L_{CE} &= -\mathbb{E}_{q(\mathbf{x}_0)} \log p_\theta(\mathbf{x}_0) \\
 &= -\mathbb{E}_{q(\mathbf{x}_0)} \log \left(\int p_\theta(\mathbf{x}_0, \dots, \mathbf{x}_T) d\mathbf{x}_1 \dots d\mathbf{x}_T \right) \\
 &= -\mathbb{E}_{q(\mathbf{x}_0)} \log \left(\int q(\mathbf{x}_1, \dots, \mathbf{x}_T | \mathbf{x}_0) \frac{p_\theta(\mathbf{x}_0, \dots, \mathbf{x}_T)}{q(\mathbf{x}_1, \dots, \mathbf{x}_T | \mathbf{x}_0)} d\mathbf{x}_1 \dots d\mathbf{x}_T \right) \\
 &= \mathbb{E}_{q(\mathbf{x}_0)} \log \left(\mathbb{E}_{q(\mathbf{x}_1, \dots, \mathbf{x}_T | \mathbf{x}_0)} \frac{p_\theta(\mathbf{x}_0, \dots, \mathbf{x}_T)}{q(\mathbf{x}_1, \dots, \mathbf{x}_T | \mathbf{x}_0)} \right) \\
 &\leq -\mathbb{E}_{q(\mathbf{x}_0, \dots, \mathbf{x}_T)} \log \left(\frac{p_\theta(\mathbf{x}_0, \dots, \mathbf{x}_T)}{q(\mathbf{x}_1, \dots, \mathbf{x}_T | \mathbf{x}_0)} \right) \\
 &= \mathbb{E}_{q(\mathbf{x}_0, \dots, \mathbf{x}_T)} \log \left(\frac{q(\mathbf{x}_1, \dots, \mathbf{x}_T | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0, \dots, \mathbf{x}_T)} \right) = L_{VLB}
 \end{aligned}$$

Per convertir cada terme de l'equació perquè sigui analíticament computable, l'objectiu es pot reescriure com una combinació de diversos termes de divergència KL i entropia [apèndix B de Sohl-Dickstein i altres (2015)] arribant a la següent expressió:

$$\begin{aligned}
 L_{VLB} &= \mathbb{E}_{q(\mathbf{x}_0, \dots, \mathbf{x}_T)} \left[\log \frac{q(\mathbf{x}_1, \dots, \mathbf{x}_T | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0, \dots, \mathbf{x}_T)} \right] \\
 &= \mathbb{E}_q \left[\log \frac{\prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1})}{p_\theta(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} \right] \\
 &= \mathbb{E}_q \left[-\log p_\theta(\mathbf{x}_T) + \sum_{t=1}^T \log \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1})}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} \right] \\
 &= \mathbb{E}_q \left[-\log p_\theta(\mathbf{x}_T) + \sum_{t=2}^T \log \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1})}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)} \right] \\
 &= \mathbb{E}_q \left[-\log p_\theta(\mathbf{x}_T) + \sum_{t=2}^T \log \left(\frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} \cdot \frac{q(\mathbf{x}_t | \mathbf{x}_0)}{q(\mathbf{x}_{t-1} | \mathbf{x}_0)} \right) + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)} \right] \\
 &= \mathbb{E}_q \left[-\log p_\theta(\mathbf{x}_T) + \sum_{t=2}^T \log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} + \sum_{t=2}^T \log \frac{q(\mathbf{x}_t | \mathbf{x}_0)}{q(\mathbf{x}_{t-1} | \mathbf{x}_0)} + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)} \right] \\
 &= \mathbb{E}_q \left[-\log p_\theta(\mathbf{x}_T) + \sum_{t=2}^T \log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} + \log \frac{q(\mathbf{x}_T | \mathbf{x}_0)}{q(\mathbf{x}_1 | \mathbf{x}_0)} + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)} \right] \\
 &= \mathbb{E}_q \left[\log \frac{q(\mathbf{x}_T | \mathbf{x}_0)}{p_\theta(\mathbf{x}_T)} + \sum_{t=2}^T \log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} - \log p_\theta(\mathbf{x}_0 | \mathbf{x}_1) \right] \\
 &= \mathbb{E}_q \left[\underbrace{D_{KL}(q(\mathbf{x}_T | \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_T))}_{L_T} + \sum_{t=2}^T \underbrace{D_{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t))}_{L_{t-1}} - \underbrace{\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1)}_{L_0} \right]
 \end{aligned}$$

on $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$ és la versió tractable de la distribució del posterior.

Etiquetant cada component de l'ELBO separatament tenim:

$$L_{VLB} = L_T + L_{T-1} + \dots + L_0$$

on

$$L_T = D_{KL}(q(\mathbf{x}_T | \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_T))$$

$$L_t = D_{KL}(q(\mathbf{x}_t | \mathbf{x}_{t+1}, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_t | \mathbf{x}_{t+1})) \text{ per a } 1 \leq t \leq T-1$$

$$L_0 = -\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1)$$

Analitzem cadascun dels termes:

- 1) $\mathbb{E}_{q(\mathbf{x}_1|\mathbf{x}_0)}[\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)]$ Pot ser interpretat com un terme de reconstrucció similar a l'ELBO d'un autocodificador variacional. A Ho i altres (2020) modelitzen L_0 utilitzant un descodificador discret separat derivat de $\mathcal{N}(\mathbf{x}_0; \mu_\theta(\mathbf{x}_1, 1), \Sigma_\theta(\mathbf{x}_1, 1))$
- 2) $D_{KL}(q(\mathbf{x}_T|\mathbf{x}_0) \parallel p_\theta(\mathbf{x}_T))$ mostra com de prop es troba $\mathbf{x}_T$ de la funció gaussiana estàndard. El terme no té paràmetres entrenables i, per tant, és ignorat durant l'entrenament.
- 3) $D_{KL}(q(\mathbf{x}_t|\mathbf{x}_{t+1}, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_t|\mathbf{x}_{t+1}))$ para $1 \leq t \leq T-1$, calcula la diferència entre cadascun dels passos inversos $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ i els aproximats $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$

Tots els termes de L_{VLB} (excepte L_0) estableixen comparacions entre distribucions gaussianes i, per tant, poden ser calculades de manera exacta. A través de l'ELBO, maximitzar la probabilitat es redueix a aprendre els passos d'eliminació del soroll L_t .

Com que tant $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$ com $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ són distribucions normals, la divergència de Kullback-Leibler es pot expressar de manera analítica com:

$$L_{t-1} = D_{KL}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)) = \mathbb{E}_q \left[\frac{1}{2\sigma_t^2} \|\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) - \mu_\theta(\mathbf{x}_t, t)\|^2 \right] + C$$

Sabem que $\mathbf{x}_t = \sqrt{\alpha_t}\mathbf{x}_0 + \sqrt{1-\alpha_t}\epsilon$ i que $\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{1}{\sqrt{1-\beta_t}}\left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\alpha_t}}\epsilon\right)$, llavors es pot representar la funció paramètrica $\mu_\theta(\mathbf{x}_t, t)$ com un model paramètric de predicció del soroll $\epsilon_\theta(\mathbf{x}_t, t)$:

$$\mu_\theta(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}}\left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\alpha_t}}\epsilon_\theta(\mathbf{x}_t, t)\right)$$

La funció de pèrdua quedaria representada de la manera següent:

$$\begin{aligned} L_{t-1} &= \mathbb{E}_{\mathbf{x}_0 \sim q(\mathbf{x}_0), \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\lambda_t \|\epsilon - \epsilon_\theta(\mathbf{x}_t, t)\|^2 \right] + C \\ \lambda_t &= \frac{\beta_t^2}{2\sigma_t^2(1-\beta_t)(1-\alpha_t)} \\ \mathbf{x}_t &= \sqrt{\alpha_t}\mathbf{x}_0 + \sqrt{1-\alpha_t}\epsilon \end{aligned}$$

El valor de λ_t és un pes que pondera la importància en funció del temps. Aquest valor sol ser bastant gran per a valors de t petits. A Ho i altres (2020) observen que establint $\lambda_t = 1$ millora la qualitat del mostreig. Alineat amb aquesta decisió, es fa servir la funció de pèrdua següent:

$$L_{\text{simple}} = \mathbb{E}_{\mathbf{x}_0 \sim q(\mathbf{x}_0), \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), l \sim \mathcal{U}(1, T)} \left[\|\epsilon - \epsilon_\theta(\mathbf{x}_t, t)\|^2 \right]$$

Altres estratègies avançades de ponderació de λ_t poden consultar-se a Choi i altres (2022).

6.2.4. Procés de mostreig i entrenament

Els algorismes 2 i 3 presentats a continuació descriuen el procés d'entrenament i de mostreig, respectivament, presentat en aquest subapartat.

Algorisme 2 Difusió: Algorisme d'entrenament

- 1) **repetir**
 - 2) $\mathbf{x}_0 \sim q(\mathbf{x}_0)$
 - 3) $t \sim \text{Uniform}(\{1, \dots, T\})$
 - 4) $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
 - 5) Descens de gradient amb $\nabla_{\theta} \|\epsilon_t - \epsilon_{\theta}(\sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \alpha_t} \epsilon, t)\|^2$
 - 6) **finis a convergència**
-

Algorisme 3 Difusió: Algorisme de mostreig

- 1) $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
 - 2) **per a** $t = T, \dots, 1$ **fer**
 - 3) $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ si $t > 1$ sinó $\mathbf{z} = \mathbf{0}$
 - 4) $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$
 - 5) **fper**
 - 6) **retorna** $\mathbf{x}_0$
-

6.2.5. Implementació

Els models basats en mecanismes de difusió presentats fins al moment per representar $\epsilon_{\theta}(\mathbf{x}_t, t)$ varien lleugerament depenent de la publicació, però solen coincidir en la utilització d'arquitectures basades en U-Net (Ronneberger i altres, 2015) amb blocs Wide ResNet (Zagoruyko i Komodakis, 2016) i etapes d'autoatenció. La representació de t se sol fer o bé mitjançant els *embeddings* posicionals típics dels transformadors (Vaswani i altres, 2017), o bé mitjançant atributs de Fourier aleatoris (Rahimi i Recht, 2007). No hi ha cap raó que impedeixi que futures arquitectures utilitzin altres propostes diferents.

6.2.6. Parametrització de β_t i Σ_θ

Hem vist que β_t i σ_t^2 controlen la variància del procés de difusió directe i invers, respectivament. És habitual utilitzar un sistema de distribució lineal per a β_t i fixar $\Sigma_\theta = \sigma_t^2 = \beta_t$.

Per exemple, a Ho i altres (2020), les variàncies β_t es fixen de manera que siguin una seqüència de constants creixents des de $\beta_1 = 10^{-4}$ fins a $\beta_T = 0.02$. Són relativament petites comparades amb el rang normalitzat dels valors admissibles per als píxels, que en aquest treball està en l'interval $[-1, 1]$. En aquest treball, la variància del procés invers no és un valor paramètric sinó una constant $\Sigma_\theta(\mathbf{x}_t, t) = \sigma_t \mathbf{I}$, on σ_t és β_t o bé $\tilde{\beta}_t = \frac{1-\bar{\alpha}_t}{1-\bar{\alpha}_1} \beta_t$. En aquest article les mostres generades són d'alta qualitat però encara no aconsegueixen valors competitius pel que fa a versemblança.

A Nichol i Dhariwal (2021) es proposen diverses tècniques per aconseguir millors resultats pel que fa a versemblança. Una d'aquestes millores consisteix a canviar l'evolució lineal de β_t per una de tipus cosinus. L'objectiu del canvi no és tant la funció triada en si, sinó el fet d'aconseguir un canvi petit en els dos extrems 1 i T i un canvi lineal en els valors intermedis. Per a $\Sigma_\theta(\mathbf{x}_t, t)$ proposen interpolat entre els valors β_t i $\tilde{\beta}_t$ mitjançant la funció $\Sigma_\theta(\mathbf{x}_t, t) = \exp(\mathbf{v} \log \beta_t + (1 - \mathbf{v}) \log \tilde{\beta}_t)$. Per a integrar $\Sigma_\theta(\mathbf{x}_t, t)$ en la funció de pèrdua, modifiquen la funció original per $L_{\text{hibrida}} = L_{\text{simple}} + \lambda L_{\text{VLB}}$, amb $\lambda = 0.001$, utilitzant λL_{VLB} per aprendre la variància però no la mitjana, pel fet que comproven experimentalment que λL_{VLB} és difícil d'optimitzar perquè té gradients molt variables. Donades aquestes circumstàncies, per facilitar el procés d'aprenentatge proposen l'ús d'una mitjana mòbil ponderada.

A Kingma i altres (2021) s'utilitza un nou tipus de parametrització utilitzant la raó de senyal a soroll (SNR) i es mostra com optimitzar la reversió minimitzant un objectiu variacional.

Mitjançant la minimització d'un objectiu variacional, altres treballs entrenen σ_t^2 al mateix temps que s'optimitza el model de difusió (Nichol i Dhariwal, 2021) i uns altres després (Bao i altres, 2022).

6.2.7. Connexió amb els VAEs

Els models de difusió poden ser considerats com una forma particular de VAEs jeràrquics. Les diferències essencials resideixen en el fet que el codificador està prefixat, les dimensions de l'espai latent són les mateixes que les de les dades originals, el model d'eliminació de soroll és el mateix per a tots els passos i que el model és entrenat amb alguna modificació dels pesos que formen el límit variacional.

6.2.8. Resum

En aquest subapartat hem introduït els models probabilístics d'eliminació del soroll per difusió. El model s'entrena prenent mostres d'un procés de difusió directa a través de l'entrenament d'un model de reversió capaç de predir el soroll. Els punts claus del disseny resideixen en l'arquitectura de xarxa triada, la ponderació dels objectius d'optimització i l'elecció dels paràmetres de difusió que controlen el procés (com la distribució del soroll de generació). A Karras i altres (2022) es pot trobar un compendi de les decisions de disseny rellevants a l'hora de dissenyar un model de difusió.

6.3. Generació basada en puntuació mitjançant l'ús d'equacions diferencials

6.3.1. Recordatori d'equacions diferencials

Les equacions diferencials ordinàries (ODE) tenen la forma següent:

$$\frac{d\mathbf{x}}{dt} = \mathbf{f}(\mathbf{x}, t)$$

La solució analítica d'aquesta mena d'equacions té la forma:

$$\mathbf{x}(t) = \mathbf{x}(0) + \int_0^t \mathbf{f}(\mathbf{x}, \tau) d\tau$$

La solució numèrica es pot aconseguir iterativament mitjançant:

$$\mathbf{x}(t + \Delta t) \approx \mathbf{x}(t) + \mathbf{f}(\mathbf{x}(t), t) \Delta t$$

D'altra banda, les equacions diferencials estocàstiques (SDE) prenen la forma següent:

$$\frac{d\mathbf{x}}{dt} = \mathbf{f}(\mathbf{x}, t) + \sigma(\mathbf{x}, t) \omega_t$$

on a $\mathbf{f}(\mathbf{x}, t)$ se'l denomina coeficient de deriva i a $\sigma(\mathbf{x}, t)$, coeficient de difusió.

La solució numèrica en aquest cas pren la forma següent:

$$\mathbf{x}(t + \Delta t) \approx \mathbf{x}(t) + \mathbf{f}(\mathbf{x}(t), t) \Delta t + \sigma(\mathbf{x}(t), t) \sqrt{\Delta t} \mathcal{N}(\mathbf{0}, \mathbf{I})$$

6.3.2. El procés de difusió directa com una SDE

Considerem de nou el procés de difusió directa definit al subapartat anterior:

$$q(\mathbf{x}_t, \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I})$$

Si considerem passos infinitesimals podem expressar a $\mathbf{x}_t$ com:

$$\begin{aligned} \mathbf{x}_t &= \sqrt{1 - \beta_t} \mathbf{x}_{t-1} + \sqrt{\beta_t} \mathcal{N}(\mathbf{0}, \mathbf{I}) \\ &= \sqrt{1 - \beta(t) \Delta t} \mathbf{x}_{t-1} + \sqrt{\beta(t) \Delta t} \mathcal{N}(\mathbf{0}, \mathbf{I}) \\ \text{on } \beta_t &= \beta(t) \Delta t \end{aligned}$$

Aplicant l'expansió de Taylor obtenim:

$$\mathbf{x}_t \approx \mathbf{x}_{t-1} - \frac{\beta(t) \Delta t}{2} \mathbf{x}_{t-1} + \sqrt{\beta(t) \Delta t} \mathcal{N}(\mathbf{0}, \mathbf{I})$$

De la qual, portant-la al límit, podem derivar l'equació diferencial estocàstica (SDE), que descriu la difusió en el límit infinitesimal:

$$d\mathbf{x}_t = -\frac{1}{2} \beta(t) \mathbf{x}_t dt + \sqrt{\beta(t)} d\omega_t$$

Atesa la nomenclatura d'equacions diferencials, el terme $-\frac{1}{2} \beta(t) \mathbf{x}_t dt$ es correspondria amb el terme de deriva, i el terme $\sqrt{\beta(t)} d\omega_t$ amb el terme de difusió, que és el que injecta el soroll.

Una equació més general per al SDE utilitzada en models generatius de difusió seria la següent:

$$d\mathbf{x}_t = f(t) \mathbf{x}_t dt + g(t) d\omega_t$$

6.3.3. El procés de difusió invers mitjançant SDEs

Vist el procés directe, com es duu a terme el procés invers? L'equació per dur a terme el procés invers generatiu de difusió, introduïda a Anderson (1982) i proposada per al procés de generació d'imatges a Song i altres (2020), és la següent:

$$d\mathbf{x}_t = \left[-\frac{1}{2} \beta(t) \mathbf{x}_t - \beta(t) \nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t) \right] dt + \sqrt{\beta(t)} d\bar{\omega}_t$$

on $\nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t)$ és la funció de puntuació, $\sqrt{\beta(t)}d\bar{\omega}_t$ el terme de difusió i $-\frac{1}{2}\beta(t)\mathbf{x}_t - \beta(t)\nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t)$ representa el terme de deriva.

6.3.4. Funció de puntuació

Un aspecte important és definir la manera de determinar la funció de puntuació. Una estratègia podria consistir a intentar modelitzar aquesta funció mitjançant una regressió:

$$\min_{\theta} \mathbb{E}_{t \sim \mathcal{U}(0,T)} \mathbb{E}_{\mathbf{x}_t \sim q_t(\mathbf{x}_t)} \|s_{\theta}(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t)\|_2^2$$

on t és el pas temporal de difusió, $\mathbf{x}_t$ les dades difoses, s_{θ} la xarxa neuronal que pretendria modelitzar la funció de puntuació i $\nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t)$ la puntuació marginal de les dades difoses (Vincent, 2011). El problema és que $\nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t)$ resulta intractable.

En comptes d'utilitzar el marginal, es pot realitzar la difusió de punts individuals aprofitant que $q_t(\mathbf{x}_t|\mathbf{x}_0)$ és tractable. D'aquesta manera podem expressar la funció objectiu de la següent manera:

$$\min_{\theta} \mathbb{E}_{t \sim \mathcal{U}(0,T)} \mathbb{E}_{\mathbf{x}_0 \sim q_0(\mathbf{x}_0)} \mathbb{E}_{\mathbf{x}_t \sim q_t(\mathbf{x}_t)|\mathbf{x}_0} \|s_{\theta}(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t|\mathbf{x}_0)\|_2^2$$

Després d'aplicar les esperances resulta que $s_{\theta}(\mathbf{x}_t, t) \approx \nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t)$, que és precisament la funció que pretenem aproximar.

Per a la SDE que preserva la variància sabem que:

$$d\mathbf{x}_t = -\frac{1}{2}\beta(t)\mathbf{x}_t dt + \sqrt{\beta(t)}d\omega_t$$

$$q_t(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \gamma_t\mathbf{x}_0, \sigma_t^2\mathbf{I})$$

$$\gamma_t = e^{-\frac{1}{2} \int_0^t \beta(s)ds}$$

$$\sigma_t^2 = 1 - e^{-\int_0^t \beta(s)ds}$$

A manera de detalls d'implementació, el mostreig es pot reexpressar de la manera següent:

$$\text{Mostreig:} \quad \mathbf{x}_t = \gamma_t\mathbf{x}_0 + \sigma_t\epsilon \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

$$\text{Puntuació:} \quad \nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t|\mathbf{x}_0) = \nabla_{\mathbf{x}_t} \frac{(\mathbf{x}_t - \gamma_t\mathbf{x}_0)^2}{2\sigma_t^2} = -\frac{\epsilon}{\sigma_t}$$

$$\text{Xarxa neuronal model:} \quad s_{\theta}(\mathbf{x}_t, t) := \frac{\epsilon_{\theta}(\mathbf{x}_t, t)}{\sigma_t}$$

Amb la qual cosa la funció d'optimització es pot expressar de la manera següent:

$$\min_{\theta} \mathbb{E}_{t \sim \mathcal{U}(0, T)} \mathbb{E}_{\mathbf{x}_0 \sim q_0(\mathbf{x}_0)} \mathbb{E}_{\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \frac{1}{\sigma_t^2} \|\epsilon - \epsilon_{\theta}(\mathbf{x}_t, t)\|_2^2$$

On la xarxa neuronal alternativa a optimitzar per a predicció del soroll és $\epsilon_{\theta}(\mathbf{x}_t, t)$.

Una modificació addicional que es pot implementar és introduir una variable $\lambda(t)$ que permeti modificar el pes dels diferents constituents de la funció de pèrdua; això és, de les diferents parts del procés de difusió:

$$\min_{\theta} \mathbb{E}_{t \sim \mathcal{U}(0, T)} \mathbb{E}_{\mathbf{x}_0 \sim q_0(\mathbf{x}_0)} \mathbb{E}_{\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \frac{\lambda(t)}{\sigma_t^2} \|\epsilon - \epsilon_{\theta}(\mathbf{x}_t, t)\|_2^2$$

Modificant el seu valor és possible optimitzar per a l'obtenció de bons resultats perceptius $\lambda(t) = \sigma_t^2$ o bé per a la maximització de la versemblança $\lambda(t) = \beta(t)$.

Hem presentat aquesta possibilitat, però també és possible fer servir models amb parametritzacions més sofisticades (Karras i altres, 2022).

Finalment, a Song i altres (2021) s'introdueixen una sèrie de modificacions destinades a reduir la variància i millorar l'estabilitat numèrica que es tradueixen en la següent proposta de funció de pèrdua:

$$\min_{\theta} \mathbb{E}_{t \sim r(t)} \mathbb{E}_{\mathbf{x}_0 \sim q_0(\mathbf{x}_0)} \mathbb{E}_{\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \frac{1}{r(t)} \frac{\lambda(t)}{\sigma_t^2} \|\epsilon - \epsilon_{\theta}(\mathbf{x}_t, t)\|_2^2$$

on $r(t)$ és una funció de mostreig de la importància, $r(t) \propto \frac{\lambda(t)}{\sigma_t^2}$. Per a detalls concrets d'implementació consulteu la bibliografia.

6.4. Conclusions

En aquest apartat hem fet una introducció als models de difusió, els quals tenen la capacitat de revertir el procés de difusió directa i recuperar la imatge original que ha estat degradada. Hem explorat dos enfocaments per modelar aquesta reversió: els models probabilístics i els basats en equacions diferencials. No obstant això, és important destacar que el camp dels models de difusió és molt més ampli i complex que el que s'ha presentat en aquest apartat, i abasta molts altres aspectes que no hem pogut cobrir íntegrament. Aquest tema és un dels més rellevants en l'àmbit dels models generatius, i està en constant evolució i expansió. Per poder aprofundir en aquest tema de manera exhaustiva, caldria dedicar-li una assignatura completa, i així i tot seria difícil abastar tots els aspectes i avanços que s'han produït. L'objectiu d'aques-

ta introducció és establir les bases perquè els estudiants interessats puguin endinsar-se en aquest complex espai de coneixement de manera autònoma i continuar explorant les múltiples possibilitats que ofereix l'ús de models de difusió en la generació d'imatges.

Resum

Un model generatiu és un tipus de model d'aprenentatge automàtic que té la capacitat de crear noves dades a partir d'un conjunt de dades d'entrenament. Aquests models són àmpliament utilitzats en diverses aplicacions, com la generació d'imatges, la síntesi de veu i la creació de música. A través de la generació de noves dades, els models generatius poden ser utilitzats per fer tasques com la simulació, la predicció i l'exploració de noves possibilitats. En general, els models generatius estan en constant evolució i expansió, la qual cosa fa que sigui un tema de gran interès en l'àmbit de la intel·ligència artificial i l'aprenentatge automàtic.

En aquest mòdul hem presentat diversos tipus de models generatius, incloent-hi les xarxes de generació adversàries, els autocodificadors variacionals i els models basats en mecanismes de difusió. Els models generatius de text es tracten en un mòdul separat, el de transformadors.

L'objectiu de la bibliografia presentada en aquest mòdul és servir com a punt de partida per a aquells estudiants que desitgin ampliar els seus coneixements en aquest camp, encara que no pretén ser exhaustiva. És important tenir en compte que els coneixements presentats en aquest mòdul estan subjectes a una contínua recerca i evolució, per la qual cosa cal una constant actualització.

L'objectiu ha estat presentar els coneixements fonamentals que serveixen com a base per a entendre els refinaments introduïts en les publicacions més recents.

Glossari

Generative Adversarial Networks (GAN) Terme en anglès per referir-se a les xarxes adversàries generatives.

Variational Autoencoders (VAE) Terme anglès per referir-se als autocodificadors variacionals.

Bibliografia

- Abdal, R.; Zhu, P.; Mitra, N. J.; Wonka, P.** (2021). «Styleflow: Attribute-conditioned exploration of styleGAN-generated images using conditional continuous normalizing flows». *ACM Transactions on Graphics (ToG)*, vol. 40 (núm. 3, pàg. 1–21).
- Ackley, D. H.; Hinton, G. E.; Sejnowski, T. J.** (1985). «A learning algorithm for Boltzmann machines». *Cognitive science*, vol. 9 (núm. 1, pàg. 147–169).
- Ali, S. M.; Silvey, S. D.** (1966). «A general class of coefficients of divergence of one distribution from another». *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 28 (núm. 1, pàg. 131–142).
- Anderson, B. D.** (1982). «Reverse-time diffusion equation models». *Stochastic Processes and their Applications*, vol. 12 (núm. 3, pàg. 313–326).
- Arjovsky, M.; Chintala, S.; Bottou, L.** (2017). «Wasserstein generative adversarial networks». A: «International conference on machine learning» (pàg. 214–223). PMLR.
- Bao, F.; Li, C.; Zhu, J.; Zhang, B.** (2022). «Analytic-DPM: an analytic estimate of the optimal reverse variance in diffusion probabilistic models». *arXiv preprint arXiv:2201.06503*.
- Bowman, S. R.; Vilnis, L.; Vinyals, O.; Dai, A. M.; Jozefowicz, R.; Bengio, S.** (2015). «Generating sentences from a continuous space». *arXiv preprint arXiv:1511.06349*.
- Brock, A.; Donahue, J.; Simonyan, K.** (2018). «Large scale GAN training for high fidelity natural image synthesis». *arXiv preprint arXiv:1809.11096*.
- Brock, A.; Lim, T.; Ritchie, J. M.; Weston, N.** (2016). «Neural photo editing with introspective adversarial networks». *arXiv preprint arXiv:1609.07093*.
- Broniatowski, M.** (2014). «Minimum divergence estimators, maximum likelihood and exponential families». *Statistics & Probability Letters*, vol. 93 (pàg. 27–33).
- Burda, Y.; Grosse, R.; Salakhutdinov, R.** (2015). «Importance weighted autoencoders». *arXiv preprint arXiv:1509.00519*.
- Burgess, C. P.; Higgins, I.; Pal, A.; Matthey, L.; Watters, N.; Desjardins, G.; Lerchner, A.** (2018). «Understanding disentangling in beta-VAE». *arXiv preprint arXiv:1804.03599*.
- Chen, J.; Sathe, S.; Aggarwal, C.; Turaga, D.** (2017). «Outlier detection with auto-encoder ensembles». A: «Proceedings of the 2017 SIAM international conference on data mining» (pàg. 90–98). SIAM.
- Chen, P.; Chen, G.; Zhang, S.** (2018a). «Log hyperbolic cosine loss improves variational auto-encoder».
- Chen, R. T.; Li, X.; Grosse, R. B.; Duvenaud, D. K.** (2018b). «Isolating sources of disentanglement in variational autoencoders». *Advances in neural information processing systems*, vol. 31.
- Chen, T.; Zhai, X.; Ritter, M.; Lucic, M.; Houlsby, N.** (2019). «Self-supervised GANs via auxiliary rotation loss». A: «Proceedings of the IEEE/CVF conference on computer vision and pattern recognition» (pàg. 12.154–12.163).
- Choi, J.; Lee, J.; Shin, C.; Kim, S.; Kim, H.; Yoon, S.** (2022). «Perception Prioritized Training of Diffusion Models». A: «Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition» (pàg. 11.472–11.481).
- Cohen, G.; Giryès, R.** (2022). «Generative Adversarial Networks». *arXiv preprint arXiv:2203.00667*.
- Crammer, K.; Singer, Y.** (2001). «On the algorithmic implementation of multiclass kernel-based vector machines». *Journal of machine learning research*, vol. 2 (núm. Dec, pàg. 265–292).

- Creswell, A.; White, T.; Dumoulin, V.; Arulkumaran, K.; Sengupta, B.; Bharath, A. A.** (2018). «Generative adversarial networks: An overview». *IEEE signal processing magazine*, vol. 35 (núm. 1, pàg. 53–65).
- De Vries, H.; Strub, F.; Mary, J.; Larochelle, H.; Pietquin, O.; Courville, A. C.** (2017). «Modulating early visual processing by language». *Advances in Neural Information Processing Systems*, vol. 30.
- Dumoulin, V.; Visin, F.** (2016). «A guide to convolution arithmetic for deep learning». *arXiv preprint arXiv:1603.07285*.
- Dupont, E.** (2018). «Learning disentangled joint continuous and discrete representations». *Advances in Neural Information Processing Systems*, vol. 31.
- Dziugaite, G. K.; Roy, D. M.; Ghahramani, Z.** (2015). «Training generative neural networks via maximum mean discrepancy optimization». *arXiv preprint arXiv:1505.03906*.
- Fedus, W.; Goodfellow, I.; Dai, A. M.** (2018). «MaskGAN: better text generation via filling in the _». *arXiv preprint arXiv:1801.07736*.
- Gershman, S.; Goodman, N.** (2014). «Amortized inference in probabilistic reasoning». A: «Proceedings of the annual meeting of the cognitive science society», vol. 36.
- Gneiting, T.; Raftery, A. E.** (2007). «Strictly proper scoring rules, prediction, and estimation». *Journal of the American statistical Association*, vol. 102 (núm. 477, pàg. 359–378).
- Gondara, L.** (2016). «Medical image denoising using convolutional denoising autoencoders». A: «2016 IEEE 16th international conference on data mining workshops (ICDMW)» (pàg. 241–246). IEEE.
- Goodfellow, I.; Pouget-Abadie, J.; Mirza, M.; Xu, B.; Warde-Farley, D.; Ozair, S.; Courville, A.; Bengio, Y.** (2020). «Generative adversarial networks». *Communications of the ACM*, vol. 63 (núm. 11, pàg. 139–144).
- Guo, J.; Lu, S.; Cai, H.; Zhang, W.; Yu, Y.; Wang, J.** (2018). «Long text generation via adversarial training with leaked information». A: «Proceedings of the AAAI conference on artificial intelligence», vol. 32.
- Hartmann, K. G.; Schirrmeister, R. T.; Ball, T.** (2018). «EEG-GAN: Generative adversarial networks for electroencephalographic (EEG) brain signals». *arXiv preprint arXiv:1806.01875*.
- Heusel, M.; Ramsauer, H.; Unterthiner, T.; Nessler, B.; Hochreiter, S.** (2017). «GANs trained by a two time-scale update rule converge to a local nash equilibrium». *Advances in neural information processing systems*, vol. 30.
- Higgins, I.; Matthey, L.; Pal, A.; Burgess, C.; Glorot, X.; Botvinick, M.; Mohamed, S.; Lerchner, A.** (2016). «beta-VAE: Learning basic visual concepts with a constrained variational framework».
- Hinton, G. E.; Zemel, R.** (1993). «Autoencoders, minimum description length and Helmholtz free energy». *Advances in neural information processing systems*, vol. 6.
- Hitchcock, F. L.** (1941). «The distribution of a product from several sources to numerous localities». *Journal of mathematics and physics*, vol. 20 (núm. 1-4, pàg. 224–230).
- Ho, J.; Jain, A.; Abbeel, P.** (2020). «Denoising diffusion probabilistic models». *Advances in Neural Information Processing Systems*, vol. 33 (pàg. 6840–6851).
- Hoffman, J.; Tzeng, E.; Park, T.; Zhu, J.-Y.; Isola, P.; Saenko, K.; Efros, A.; Darrell, T.** (2018). «Cycada: Cycle-consistent adversarial domain adaptation». A: «International conference on machine learning» (pàg. 1989–1998). PMLR.
- Hou, X.; Shen, L.; Sun, K.; Qiu, G.** (2017). «Deep feature consistent variational auto-encoder». A: «2017 IEEE winter conference on applications of computer vision (WACV)» (pàg. 1133–1141). IEEE.
- Huang, X.; Belongie, S.** (2017). «Arbitrary style transfer in real-time with adaptive instance normalization». A: «Proceedings of the IEEE international conference on computer vision» (pàg. 1501–1510).
- Ioffe, S.; Szegedy, C.** (2015). «Batch normalization: Accelerating deep network training by reducing internal covariate shift». A: «International conference on machine learning» (pàg. 448–456). PMLR.

- Isola, P.; Zhu, J.-Y.; Zhou, T.; Efros, A. A.** (2017). «Image-to-image translation with conditional adversarial networks». A: «Proceedings of the IEEE conference on computer vision and pattern recognition» (pàg. 1125–1134).
- Jang, E.; Gu, S.; Poole, B.** (2016). «Categorical reparameterization with gumbel-softmax». *arXiv preprint arXiv:1611.01144*.
- Jetchev, N.; Bergmann, U.; Vollgraf, R.** (2016). «Texture synthesis with spatial generative adversarial networks». *arXiv preprint arXiv:1611.08207*.
- Karras, T.; Aila, T.; Laine, S.; Lehtinen, J.** (2017). «Progressive growing of GANs for improved quality, stability, and variation». *arXiv preprint arXiv:1710.10196*.
- Karras, T.; Aittala, M.; Aila, T.; Laine, S.** (2022). «Elucidating the Design Space of Diffusion-Based Generative Models». *arXiv preprint arXiv:2206.00364*.
- Karras, T.; Laine, S.; Aila, T.** (2019). «A style-based generator architecture for generative adversarial networks». A: «Proceedings of the IEEE/CVF conference on computer vision and pattern recognition» (pàg. 4401–4410).
- Kingma, D.; Salimans, T.; Poole, B.; Ho, J.** (2021). «Variational diffusion models». *Advances in neural information processing systems*, vol. 34 (pàg. 21.696–21.707).
- Kingma, D. P.; Salimans, T.; Jozefowicz, R.; Chen, X.; Sutskever, I.; Welling, M.** (2016). «Improved variational inference with inverse autoregressive flow». *Advances in neural information processing systems*, vol. 29.
- Kingma, D. P.; Welling, M.** (2013). «Auto-encoding variational bayes». *arXiv preprint arXiv:1312.6114*.
- Kobyzev, I.; Prince, S. J.; Brubaker, M. A.** (2020). «Normalizing flows: An introduction and review of current methods». *IEEE transactions on pattern analysis and machine intelligence*, vol. 43 (núm. 11, pàg. 3964–3979).
- Koller, D.; Friedman, N.** (2009). *Probabilistic Graphical Models: Principles and Techniques*. Adaptive computation and machine learning. MIT Press. ISBN 9780262013192. <https://books.google.co.in/books?id=7dzpHCHzNQ4C>.
- Kolouri, S.; Pope, P. E.; Martin, C. E.; Rohde, G. K.** (2018). «Sliced-wasserstein auto-encoder: An embarrassingly simple generative model». *arXiv preprint arXiv:1804.01947*.
- Kullback, S.; Leibler, R. A.** (1951). «On information and sufficiency». *The annals of mathematical statistics*, vol. 22 (núm. 1, pàg. 79–86).
- Kumar, A.; Sattigeri, P.; Balakrishnan, A.** (2017). «Variational inference of disentangled latent concepts from unlabeled observations». *arXiv preprint arXiv:1711.00848*.
- Lample, G.; Zeghidour, N.; Usunier, N.; Bordes, A.; Denoyer, L.; Ranzato, M.** (2017). «Fader networks: Manipulating images by sliding attributes». *Advances in neural information processing systems*, vol. 30.
- Larsen, A. B. L.; Sønderby, S. K.; Larochelle, H.; Winther, O.** (2016). «Autoencoding beyond pixels using a learned similarity metric». A: «International conference on machine learning» (pàg. 1558–1566). PMLR.
- Ledig, C.; Theis, L.; Huszár, F.; Caballero, J.; Cunningham, A.; Acosta, A.; Aitken, A.; Tejani, A.; Totz, J.; Wang, Z. i altres** (2017). «Photo-realistic single image super-resolution using a generative adversarial network». A: «Proceedings of the IEEE conference on computer vision and pattern recognition» (pàg. 4681–4690).
- Lei Ba, J.; Kiros, J. R.; Hinton, G. E.** (2016). «Layer normalization». *ArXiv e-prints*, (pàg. arXiv–1607).
- Luc, P.; Couprie, C.; Chintala, S.; Verbeek, J.** (2016). «Semantic segmentation using adversarial networks». *arXiv preprint arXiv:1611.08408*.
- Maaløe, L.; Sønderby, C. K.; Sønderby, S. K.; Winther, O.** (2016). «Auxiliary deep generative models». A: «International conference on machine learning» (pàg. 1445–1453). PMLR.
- Maas, A. L.; Hannun, A. Y.; Ng, A. Y. i altres** (2013). «Rectifier nonlinearities improve neural network acoustic models». A: «Proc. icml», vol. 30 (pàg. 3). Citeseer.
- Makhzani, A.; Frey, B.** (2013). «K-sparse autoencoders». *arXiv preprint arXiv:1312.5663*.
- Maleki, A.; Do, T.** (2000). «Review of probability theory». *CS*, vol. 229 (núm. 2, pàg. 1).

- Mescheder, L.; Geiger, A.; Nowozin, S.** (2018). «Which training methods for GANs do actually converge?» A: «International conference on machine learning» (pàg. 3481–3490). PMLR.
- Metropolis, N.; Ulam, S.** (1949). «The Monte Carlo method». *Journal of the American statistical association*, vol. 44 (núm. 247, pàg. 335–341).
- Michelucci, U.** (2022). «An Introduction to Autoencoders». *arXiv preprint arXiv:2201.03898*.
- Mirza, M.; Osindero, S.** (2014). «Conditional generative adversarial nets». *arXiv preprint arXiv:1411.1784*.
- Miyato, T.; Kataoka, T.; Koyama, M.; Yoshida, Y.** (2018). «Spectral normalization for generative adversarial networks». *arXiv preprint arXiv:1802.05957*.
- Miyato, T.; Koyama, M.** (2018). «cGANs with projection discriminator». *arXiv preprint arXiv:1802.05637*.
- Moghadam, M. M.; Boroomand, B.; Jalali, M.; Zareian, A.; DaeiJavad, A.; Manshaei, M. H.** (2021). «Game of GANs: Game Theoretical Models for Generative Adversarial Networks». *arXiv preprint arXiv:2106.06976*.
- Ng, A. i altres** (2011). «Sparse autoencoder». *CS294A Lecture notes*, vol. 72 (núm. 2011, pàg. 1–19).
- Nguyen, X.; Wainwright, M. J.; Jordan, M. I.** (2010). «Estimating divergence functionals and the likelihood ratio by convex risk minimization». *IEEE Transactions on Information Theory*, vol. 56 (núm. 11, pàg. 5847–5861).
- Nichol, A. Q.; Dhariwal, P.** (2021). «Improved denoising diffusion probabilistic models». A: «International Conference on Machine Learning» (pàg. 8162–8171). PMLR.
- Nowozin, S.; Cseke, B.; Tomioka, R.** (2016). «f-GAN: Training generative neural samplers using variational divergence minimization». *Advances in neural information processing systems*, vol. 29.
- Odena, A.** (2016). «Semi-supervised learning with generative adversarial networks». *arXiv preprint arXiv:1606.01583*.
- Pang, G.; Shen, C.; Cao, L.; Hengel, A. V. D.** (2021). «Deep learning for anomaly detection: A review». *ACM Computing Surveys (CSUR)*, vol. 54 (núm. 2, pàg. 1–38).
- Park, S. W.; Kwon, J.** (2020). «SphereGAN: Sphere generative adversarial network based on geometric moment matching and its applications». *IEEE Transactions on Pattern Analysis and Machine Intelligence*.
- Patashnik, O.; Wu, Z.; Shechtman, E.; Cohen-Or, D.; Lischinski, D.** (2021). «Styleclip: Text-driven manipulation of stylegan imagery». A: «Proceedings of the IEEE/CVF International Conference on Computer Vision» (pàg. 2085–2094).
- Plaut, E.** (2018). «From principal subspaces to principal components with linear autoencoders». *arXiv preprint arXiv:1804.10253*.
- Pulgar, F. J.; Charle, F.; Rivera, A. J.; Del Jesus, M. J.** (2018). «AEkNN: An AutoEncoder kNN-based classifier with built-in dimensionality reduction». *arXiv preprint arXiv:1802.08465*.
- Radford, A.; Kim, J. W.; Hallacy, C.; Ramesh, A.; Goh, G.; Agarwal, S.; Sastry, G.; Askell, A.; Mishkin, P.; Clark, J. i altres** (2021). «Learning transferable visual models from natural language supervision». A: «International Conference on Machine Learning» (pàg. 8748–8763). PMLR.
- Radford, A.; Metz, L.; Chintala, S.** (2015). «Unsupervised representation learning with deep convolutional generative adversarial networks». *arXiv preprint arXiv:1511.06434*.
- Rahimi, A.; Recht, B.** (2007). «Random features for large-scale kernel machines». *Advances in neural information processing systems*, vol. 20.
- Rainforth, T.; Kosiorek, A.; Le, T. A.; Maddison, C.; Igl, M.; Wood, F.; Teh, Y. W.** (2018). «Tighter variational bounds are not necessarily better». A: «International Conference on Machine Learning» (pàg. 4277–4285). PMLR.
- Ramesh, A.; Pavlov, M.; Goh, G.; Gray, S.; Voss, C.; Radford, A.; Chen, M.; Sutskever, I.** (2021). «Zero-shot text-to-image generation». A: «International Conference on Machine Learning» (pàg. 8821–8831). PMLR.

- Reid, M.; Williamson, R. i altres** (2011). «Information, divergence and risk for binary experiments».
- Rezende, D.; Mohamed, S.** (2015). «Variational inference with normalizing flows». A: «International conference on machine learning» (pàg. 1530–1538). PMLR.
- Rifai, S.; Mesnil, G.; Vincent, P.; Muller, X.; Bengio, Y.; Dauphin, Y.; Glorot, X.** (2011). «Higher order contractive auto-encoder». A: «Joint European conference on machine learning and knowledge discovery in databases» (pàg. 645–660). Springer.
- Ronneberger, O.; Fischer, P.; Brox, T.** (2015). «U-net: Convolutional networks for biomedical image segmentation». A: «International Conference on Medical image computing and computer-assisted intervention» (pàg. 234–241). Springer.
- Salimans, T.** (2016). «A structured variational auto-encoder for learning deep hierarchies of sparse features». *arXiv preprint arXiv:1602.08734*.
- Salimans, T.; Kingma, D. P.** (2016). «Weight normalization: A simple reparameterization to accelerate training of deep neural networks». *Advances in neural information processing systems*, vol. 29.
- Shaham, T. R.; Dekel, T.; Michaeli, T.** (2019). «Singan: Learning a generative model from a single natural image». A: «Proceedings of the IEEE/CVF International Conference on Computer Vision» (pàg. 4570–4580).
- Snell, J.; Ridgeway, K.; Liao, R.; Roads, B. D.; Mozer, M. C.; Zemel, R. S.** (2017). «Learning to generate images with perceptual similarity metrics». A: «2017 IEEE International Conference on Image Processing (ICIP)» (pàg. 4277–4281). IEEE.
- Soch, J.; Faulkenberry, T. J.; Petrykowski, K.; Allefeld, C.** (2020). *The Book of Statistical Proofs*. Zenodo. doi: 10.5281/zenodo.4305950. <https://doi.org/10.5281/zenodo.4305950>.
- Sohl-Dickstein, J.; Weiss, E.; Maheswaranathan, N.; Ganguli, S.** (2015). «Deep unsupervised learning using nonequilibrium thermodynamics». A: «International Conference on Machine Learning» (pàg. 2256–2265). PMLR.
- Sohn, K.; Lee, H.; Yan, X.** (2015). «Learning structured output representation using deep conditional generative models». *Advances in neural information processing systems*, vol. 28.
- Song, Y.; Durkan, C.; Murray, I.; Ermon, S.** (2021). «Maximum likelihood training of score-based diffusion models». *Advances in Neural Information Processing Systems*, vol. 34 (pàg. 1415–1428).
- Song, Y.; Sohl-Dickstein, J.; Kingma, D. P.; Kumar, A.; Ermon, S.; Poole, B.** (2020). «Score-based generative modeling through stochastic differential equations». *arXiv preprint arXiv:2011.13456*.
- Sriperumbudur, B. K.; Gretton, A.; Fukumizu, K.; Schölkopf, B.; Lanckriet, G. R.** (2010). «Hilbert space embeddings and metrics on probability measures». *The Journal of Machine Learning Research*, vol. 11 (pàg. 1517–1561).
- Subramanian, A.** (2020). «PyTorch-VAE». <https://github.com/AntixK/PyTorch-VAE>.
- Tolstikhin, I.; Bousquet, O.; Gelly, S.; Schoelkopf, B.** (2017). «Wasserstein auto-encoders». *arXiv preprint arXiv:1711.01558*.
- Van Den Oord, A.; Vinyals, O. i altres** (2017). «Neural discrete representation learning». *Advances in neural information processing systems*, vol. 30.
- Van Loan, C. F.; Golub, G.** (1996). «Matrix computations (Johns Hopkins studies in mathematical sciences)». *Matrix Computations*.
- Vaswani, A.; Shazeer, N.; Parmar, N.; Uszkoreit, J.; Jones, L.; Gomez, A. N.; Kaiser, Ł.; Polosukhin, I.** (2017). «Attention is all you need». *Advances in neural information processing systems*, vol. 30.
- Vincent, P.** (2011). «A connection between score matching and denoising autoencoders». *Neural computation*, vol. 23 (núm. 7, pàg. 1661–1674).
- Vincent, P.; Larochelle, H.; Bengio, Y.; Manzagol, P.-A.** (2008). «Extracting and composing robust features with denoising autoencoders». A: «Proceedings of the 25th international conference on Machine learning» (pàg. 1096–1103).

- Vincent, P.; Larochelle, H.; Lajoie, I.; Bengio, Y.; Manzagol, P.-A.; Bottou, L.** (2010). «Stacked denoising autoencoders: Learning useful representations in a deep network with a local denoising criterion». *Journal of machine learning research*, vol. 11 (núm. 12).
- Wang, T.-C.; Liu, M.-Y.; Zhu, J.-Y.; Tao, A.; Kautz, J.; Catanzaro, B.** (2018). «High-resolution image synthesis and semantic manipulation with conditional GANs». A: «Proceedings of the IEEE conference on computer vision and pattern recognition» (pàg. 8798–8807).
- Wu, H.; Zheng, S.; Zhang, J.; Huang, K.** (2019). «GP-GAN: Towards realistic high-resolution image blending». A: «Proceedings of the 27th ACM international conference on multimedia» (pàg. 2487–2495).
- Xia, W.; Zhang, Y.; Yang, Y.; Xue, J.-H.; Zhou, B.; Yang, M.-H.** (2022). «Gan inversion: A survey». *IEEE Transactions on Pattern Analysis and Machine Intelligence*.
- Zagoruyko, S.; Komodakis, N.** (2016). «Wide residual networks». *arXiv preprint arXiv:1605.07146*.
- Zhang, H.; Goodfellow, I.; Metaxas, D.; Odena, A.** (2019). «Self-attention generative adversarial networks». A: «International conference on machine learning» (pàg. 7354–7363). PMLR.
- Zhao, S.; Song, J.; Ermon, S.** (2017). «Infovae: Information maximizing variational autoencoders». *arXiv preprint arXiv:1706.02262*.
- Zhou, C.; Paffenroth, R. C.** (2017). «Anomaly detection with robust deep autoencoders». A: «Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining» (pàg. 665–674).

