

Pregunta 1

Dins de Google DeepMind:

- Creus necessària la presència de Científics de Dades?
- Quines tasques farien?
- Quins coneixements i habilitats han de tenir?

Per respondre a la primera pregunta primer hauríem de saber què és Google DeepMind. Google DeepMind és una un centre de recerca subsidiari de Alphabet Inc.(l'empresa mare Google). Aquest centre de recerca té la seva especialització en xarxes neuronals. Alguns dels assoliments més destacats serien generar una xarxa neuronal amb aprenentatge per reforç (*reinforcement learning*) que jugant contra si mateixa va arribar a vencer els millors programes que jugaven a escacs, go i shogi¹ o els seus avenços en doblegament de proteïnes el qual va fer que dos investigadors guanyessin un premi Nobe²l .

Tenint en compte aquest context hauríem de saber quin perfil correspon als científics de dades per poder saber si encaixarien en aquest perfil.

Tenint en compte aquest context hauríem de saber quin perfil correspon als científics de dades per poder saber si encaixarien en aquest perfil.

Les definicions de científics de dades són diverses, però totes coincideixen en l'essencial, un científic de dades és una persona que domina tres camps alhora matemàtiques i estadística, ciència computacional i coneixement d'àrea de negocis. Implicant això que tens un perfil el qual pot crear molt valor de les dades, ja que entén el negoci, per tant, pot saber que és l'important en ell, entén de matemàtiques en conseqüència sap com aplicar el mètode científic per arribar a solucions i entén de ciències computacionals perquè sap com poder implementar-les generant un perfil molt interessant, pel fet que pot fer un treball que normalment seria interdisciplinari. També seria interessant que aquest perfil tingués unes habilitats comunicatives elevades per poder fer una part molt important del procés que a vegades es veu invisibilitzada, el reporting, pel fet que per molt bona que sigui la feina del científic de dades si aquesta no es pot entendre perd tot el valor.

Tenint en compte tot això crec que el perfil de científic de dades podria ser molt atractiu per un grup com DeepMind, ja que els coneixements necessaris per desenvolupar aquestes investigacions són per naturalesa interdisciplinària i els científics de dades, donada la definició anterior aquest seria el medi ideal.

Crec que les tasques que farien aquests perfils en un lloc com DeepMind serien els habituals d'un científic de dades, entendre que és el que volem aconseguir trobant les qüestions que voldríem respondre, seguir el mètode científic per provar si les hipòtesis donades poden explicar el nostre pregunta, obtenir les dades necessàries per poder operar i una vegada aconseguides preparar-les perquè siguin vàlides per poder modelitzar amb elles amb tots els mètodes necessaris, per exemple netejant dades errònies o donat format a

¹ <https://arxiv.org/abs/1712.01815>

² <https://www.nobelprize.org/prizes/chemistry/2024/press-release/>

dades sense format. Després començaria el procés d'obtenir resultat amb el mètode seleccionat, ja sigui un model predictiu, un classificador o un algoritme de clustering. Ara hauríem de mirar si el model compleix els requisits que teníem per acabar posant en producció el model, sigui utilitzant les prediccions o valorant la informació obtinguda.

Per fer aquestes tasques es necessiten coneixement específics, com hem dit abans tenim de quatre tipus, en els matemàtics i estadístics els necessitem no només per fer testos estadístics per explorar les nostres dades o valorar els nostres models, si no que amb models tant punters com els que proposa DeepMind potser tocara optimitzar models vaigant al la part matemàtica dels models perse.

Després esta la part de ciències de computació que si no sabem com implementar aquest models teòrics en un llenguatge de programacio com Python o R, o on desar les dades podem necessitar una base de dades ja sigui una estructurada amb sql o una no estructurada amb MongoDB.

També necessitem els coneixement de negoci que en el cas de DeeMind son molt variats ja que tenen molts projectes a moltes branques diferents així que suposo ens podem centrar en una branca en concret per poder entendre en profunditat quines són les necessitat corresponents, però inclus immersant-nos en profunditat en un tema seria complicat poder entendre la totalitat d'alguns dels projectes ja que per exemple el doblegament de proteïnes és un tema molt complex que requereix una especialització molt gran per poder-ho entendre en la seva completitud. Per això necessitem l'últim tipus de coneixement, una gran capacitat de comunicació, ja que l'única manera de poder suplir la manca de coneixement que es normal tenir en un tema tan específic es parlant amb persones que són expertes en la materia per poder entendre quin és el problema, quina és la millor manera d'arribar a la solució i per després ajudar a interpretar els resultats correctament.

En resum crec que els científics de dades poden ser perfils molt potents per llocs com DeepMind i en cas que es puguin integrar dintre d'un equip interdisciplinar poden impulsar la investigació ja que poden fer de nexa entre moltes branques del coneixement fent que tot l'equip pugui rema cap a la mateixa direcció.

Pregunta 2

Per concretar la configuració dels equips científics encarregats de la investigació liderada per Hassabis i Jumper:

- Defineix els perfils involucrats (pots basar-te en l'organigrama de Google DeepMind)
- Quins nivells de competència analítica han de tenir cadascun?
- Quines bones pràctiques han de considerar com treballadors analítics?

Si mirem l'equip de persones que participen a la investigació veiem que els perfils dels participants a la investigació (mirant la formació dels autors citats al paper que sigui publica³ són els següents: tothom es graduat, tots tenen master menys una persona i la majoria tenen doctorat. Si ara mirem les especialitzacions, en grau la majoria són matemàtics o físics, seguits per ingeniers informàtics. En estudis superiors són més comuns les ciències de computació però veiem més perfils com químics, físics i biòlegs.

Clarament cada perfil aporta coses diferents al projecte però sense la col·laboració de tots el projecte no seria possible. Podem suposar que tindrem uns perfils més científics de dades, especialitzats en machine learning que són els que proposen experiments, analitzen les dades, entre altres.

Uns perfils més informàtics que poden ajudar a la infraestructura i la optimització. I per últim uns perfils més biològics, per entendre si les prediccions tenen sentit i donar un sentit biològic a les prediccions del model.

També podem suposar, encara que no surten aquest perfil al paper, tenint en compte el tamany del equip i de la empresa (segons linkedin a Londres tenen més de 1000 treballadors) a l'equip també habra ajudat gent a rols més organitzatius, com PM, o gent de recursos humans, que directament no han participat en la investigació però han ajudat a que l'equip pugui funcionar.

Respecta el nivell de competència analítica els dos primers grups han de ser els que al tinguin millor ja que desenvolupen nous algorismes, avaluaran els models i optimitzar el procés. Això requerirà que tinguin grans coneixements en els camps d'estudi (AI, machine learning, biologia molecular), competències en testos estadístics i disseny experimental. Ja que seran ells els que dissenyen el model i el posaran a prova. Això és un nivell d'anàlisi predictiu, ja que prediran com es doblegarà la proteïna. Però es possible que no tinguin nivells d'anàlisi descriptiu o de diagnòstic, ja que poden no entendre la base biològica sobre la que es recolza.

Els perfils més biològics poden tenir un nivell inferior de competència però aquest no pot ser nul ja que han de comunicar-se amb l'altre grup. Degut a que hauran de ajudar a dissenyar els testos estadístics ja que saben com funcionen les proteïnes. Per tant aquest perfil si que tindrà un nivell d'anàlisi més descriptiu i de diagnòstic ja que si que entenen la base biològica, al ser la seva especialització.

Els rols més organitzatius també han de tindre unes competències moderades, això és degut a que per organitzar les tasques han d'entendre mínimament les necessitats de cada perfil, ajudant a fragmentar el projecte en tasques més petites i entendre els temps de desenvolupament en cada tasca.

En resum tots els rols necessiten uns mínims d'habilitats analítiques per poder col·laborar junts però el grup que hauria de tenir més seria el científic de dades i informàtics per les raons comentades adalt.

Si ara passem a bones pràctiques podem seguir amb aquesta divisió dels perfils més analítics i els menys analítics. Els perfils més analítics o *quants* haurien de seguir les següents bones pràctiques: Entendre un mínim de proteïnes per poder fer models robustos, per comunicarse còmodament amb els altres perfils i entendre les seves necessitats. També dona estimacions realistes de temps i cost de quan tardarien en fer el procés, entenent que s'ha de formar a gent.

³ <https://www.nature.com/articles/s41586-021-03819-2#auth-John-Jumper-Aff1>

Explicar tantes vegades com sigui necessari el procés als usuaris menys analítics per tant de que ho entenguin. I establir vies clares de comunicació entre els perfils que estiguin estructurades per tal de definir correctament com es vol el model.

Per els perfils menys analítics o *non-quants* les bones pràctiques serien les següents: Dedicar temps per formar als perfils més analítics en proteïnes ja que es possible que el seu coneixement base sigui limitat. Preguntar si no entenen com funciona el model i demanar explicacions alternatives per facilitar la comprensió, formarse una mica en anàlisi per poder entendre quan un model podria ser útil i quan no. Entendre els temps i costos de desenvolupament per poder saber quan esperar la seva completació.

Si totes aquestes coses es tenen en compte podem tenir un equip multidisciplinari molt eficient i que retorni solucions analítiques d'alta qualitat.

Pregunta 3

- Descriu el cicle de vida de les dades involucrades en l'estudi de Hassabis i Jumper.
- Com és la piràmide D-I-K-W associada a aquesta iniciativa?
- Descriu tècnicament el funcionament del model predictiu AlphaFold2.

El cicle de les dades teòric es el següent:

- Captura
- Emmagatzematge
- Preprocessat
- Anàlisi
- Visualització
- Publicació

Ara veurem cadascun d'aquest pasos en el cas específic de Hassabis i Jumper.

Captura: Per l'obtenció de dades de proteïnes hi ha repositoris públics amb informació de l'estructura de proteïnes com PDB (Protein Data Bank), si mirem l'apartat de *Data availability* al article publicat podem veure que es la font principal d'on han tret les dades de proteïnes.

Emmagatzematge: Segons el paper van descarregar-se una copia del PDB i això es el que van utilitzar per entrenar els models. Tot va ser pujat despres de procesat la informació a una base de dades que utilitzava tot l'equip anomenada Big Fantastic Database (BFD).

Preprocessat: Si mirem els mètodes del article veiem que per preparar les dades per la lectura del model i tenir-les organitzades utilitzen protocols conegut per aquesta aplicació com jackhmmer i HHBlits. Amb aquest protocols passen a tenir la informació estructurada i llesta per modelar.

Anàlisi: Aquí és on desenvolupa el model, entrenar-lo perquè compleixi els resultats esperats que en aquest cas es que pugui predir i modelar com es doblegaran proteïnes.

Visualització: Veiem con en l'article tenim varies figures que ilustren la bondad del model i també ajuden a entendre que estem fem exactament, aquesta part és molt important degut a la nostra facilitat com a humans a entendre millor la informació en un estat visual.

Publicació: En aquest cas seria la publicació de l'article científic que com podem veure va ser molt exitosa ja que els va fer guanyar el premi Nobel de química, un dels premis més prestigiosos a la ciència.

La piràmide de DIKW en el context de AlphaFold:

Dades: Seqüències de proteïnes crues i dades estructurals.

Informació: Alineacions de seqüències processades, informació estructural i distàncies predites entre residus d'aminoàcids.

Coneixement: Models i prediccions de com es pleguen les proteïnes, utilitzant relacions apreses entre seqüència i estructura, fonamentades en bioquímica i física.

Saviesa: Aplicar aquesta comprensió a problemes del món real, com el disseny de fàrmacs, la investigació de malalties i la biotecnologia, permetent als científics prendre decisions informades basades en les estructures proteiques i la seva funció.

Per entendre com funciona AlphaFold2 primer haurem d'entendre el problema que vol solucionar. Les proteïnes estan formades per cadenes d'aminoàcids que es pleguen en formes 3D intrincades, i aquestes formes determinen la seva funció en els organismes vius. Tradicionalment, la determinació experimental de les estructures 3D de les proteïnes (a través de mètodes com la cristal·lografia de raigs X, l'espectroscòpia de RMN o el crio-EM) és costosa i requereix molt de temps, i no sempre és possible. AlphaFold2 intenta resoldre aquest problema predient aquestes estructures computacionalment, basant-se només en la seqüència d'aminoàcids.

Per tant el que fa AlphaFold2 es prendre una seqüència d'aminoàcids (estructura primària d'una proteïna) i prediu l'estructura tridimensional modelant com es plegaran aquests aminoàcids. El model utilitza tant la informació evolutiva com les tècniques d'aprenentatge profund per fer les seves prediccions.

Aprofundint més podem mirar com funciona el model amb més detalls, primer veurem les dades d'entrada de les quals tenim 3 tipus.

Seqüència d'aminoàcids: El model comença amb la seqüència d'aminoàcids de la proteïna, que serveix d'entrada.

Alineacions de seqüències múltiples (MSA): AlphaFold2 recull seqüències homòlogues (seqüències relacionades de diferents organismes) a través de l'alineació de seqüències múltiples. Això proporciona informació evolutiva, mostrant com els aminoàcids s'han conservat amb el temps en proteïnes similars. Aquestes dades evolutives ajuden a AlphaFold a entendre quines regions de la proteïna són importants per a la seva funció i quines àrees poden variar.

Informació Coevolucional: El model també es basa en la coevolució d'aminoàcids dins d'una proteïna. Els senyals evolutius ajuden a AlphaFold a inferir quins aminoàcids són propensos a interactuar i com estan relacionats espacialment.

També hem de mirar com funciona el model predictiu d'AlphaFold2 que es una xarxa neuronal profunda la qual té dues etapes, l'Evoformer i el d'estructura.

Mòdul Evoformer:

La primera part del model implica l'Evoformer, que és una arquitectura d'aprenentatge profund dissenyada per gestionar les relacions seqüència-estructura.

Representació de parells: L'Evoformer treballa codificant tant la informació de parells (és a dir, les relacions entre els aminoàcids en la seqüència) com la informació per-residus (és a dir, els aminoàcids individuals). Això permet que AlphaFold2 modeli dependències complexes entre aminoàcids distants, que són crucials per a un plegament precís.

Mecanisme d'Atenció: AlphaFold2 utilitza l'atenció per modelar com evolucionen les relacions entre els aminoàcids en diferents posicions de la seqüència. Utilitza un mecanisme d'atenció basat en transformadors similar a models com BERT o GPT en processament del llenguatge natural (NLP), però adaptat per a seqüències biològiques.

Mòdul d'estructura:

Un cop l'Evoformer ha processat la informació evolutiva, la següent part d'AlphaFold2 genera les coordenades 3D de la proteïna.

El model combina les interaccions per parells i les característiques per-residus per predir els arranjaments espacials dels àtoms i com es pleguen en tres dimensions.

AlphaFold2 realitza múltiples iteracions per refinar l'estructura 3D prevista. Ajusta constantment l'estructura prevista per minimitzar l'energia (és a dir, assegurant que els àtoms de la proteïna estiguin en configuracions físicament plausibles).

AlphaFold2 també pot utilitzar informació basada en plantilles, que implica modelatge d'homologia. Si estructures similars (plantilles) estan disponibles al Banc de Dades de Proteïnes (PDB), AlphaFold2 pot incorporar-les a la seva predicció per millorar l'exactitud de l'estructura final.

La sortida final d'AlphaFold2 és un model 3D de l'estructura de la proteïna, on es prediuen les posicions dels àtoms (o residus). Aquesta predicció ve acompanyada d'una puntuació de confiança per a les seves prediccions, conegudes com a pLDDT (predicted Local Distance Difference Test). Aquesta puntuació quantifica la confiança del model en la seva estructura predita en cada residu.

La clau de l'èxit d'AlphaFold2 rau en la seva capacitat d'aprofitar dades evolutives, principalment a través de les MSA. Comparant la seqüència d'una proteïna amb seqüències homòlogues d'altres organismes, AlphaFold2 pot inferir restriccions en l'estructura de la proteïna que no són immediatament òbvies només a partir de la seqüència.

Predicció de l'estructura de proteïnes: AlphaFold2 avança significativament la capacitat de predir estructures proteiques, que una vegada es va considerar un dels "grans reptes" en biologia. Amb moltes aplicacions a moltes branques de la ciència però les més rellevants son:

Descobriments de fàrmacs: Amb estructures proteiques precises, AlphaFold2 pot ajudar a accelerar el descobriment de nous fàrmacs proporcionant informació detallada sobre com les molècules interactuen amb les proteïnes.

Investigació de malalties: Moltes malalties són causades per proteïnes mal plegades o mutacions. AlphaFold2 pot ajudar els investigadors a entendre com mutacions específiques afecten el plegament de proteïnes i condueixen a malalties com l'Alzheimer, el Parkinson o el càncer.

Biotecnologia: La capacitat de dissenyar proteïnes amb funcions específiques (per exemple, enzims per a processos industrials) es fa més factible amb prediccions d'estructura precises.

Pregunta 4 (20% puntuació)

- Google DeepMind compleix amb els criteris per ser considerada com a una Organització Orientada a la Dada?
- Analitza el model de maduresa DELTA de l'organització

Fins ara només ens hem centrat en la investigació però ara volem veure com es comporta l'organització general de Google DeepMind, encara que utilitzarem els resultats vists fins ara com a referència per determinar la capacitat de l'empresa en general veient-ho com un cas en concret dels protocols utilitzats en general.

Degut a que el concepte d'organització orientada a la dada és relativament recent no tenim una definició formal sobre el que vol dir una organització d'aquestes característiques, però hem vist una definició en teoria que en aquest cas ens servirà: Una organització orientada a la dada és aquella que es gestiona sobre la base de fets i dades.

Amb tres característiques necessàries:

Capacitat per identificar, combinar i gestionar múltiples fonts de dades.

Capacitat de construir models d'anàlisi avançada per a predir i optimitzar els seus resultats.

Capacitat de transformar l'organització perquè les dades i els models realment derivin en millors decisions.

Mirant les tres característiques veiem que la primera la compleix, com hem vist abans per l'article utilitzen diferents font de dades les per treure la informació de les proteïnes per tant podem considerar aquesta com certa.

Per la segona crec que també és evident que la compleixen ja que en aquest cas en concret han generat un model que prediu com es doblegaran proteïnes una cosa que fins ara no s'havia fer, i els altres models que tenen també son molt inovadors. També és a considerar que per el model

de proteïnes van rebre el premi Nobel i crec que pot haver-hi poques coses més prestigioses en el camp de l'investigació que aquest assoliment.

La tercera és la més difícil de provar ja que no tenim coneixement de com funciona DeepMind per dins per tant no podem saber com es prenen les decisions, però tenint en compte els perfils de l'empresa i el camp en el que treballen, on la majoria tenen experiència amb les dades i casi tots els perfils són científics, incloent els caps, no és descabellat pensar que aquesta condició també la compleixen. Per tant jo crec que si, podem dir que DeepMind es una organització centrada en les dades.

El model DELTA (data, enterprise, leadership, targets i analysts) te 5 apartats en cada apartat d'aquest pot tenir una puntuació 1 al 5 respecte a la maduresa en aquest apartat. Consideran cadascun per separat podem veure com està l'empresa en aquest camps

Dades:

DeepMind té accés a alguns dels conjunts de dades més extensos i d'alta qualitat per a l'entrenament i el desenvolupament de models d'IA. Això és degut a que es una filial de Google i com a filial de Google, DeepMind compta amb el suport de la infraestructura massiva de dades que Google ha construït al llarg dels anys. Per tant té a l'abast grans quantitats de dades en diversos dominis, ja sigui per a la formació d'agents d'aprenentatge de reforç (com AlphaGo) o per a l'analítica de dades sanitàries (com la col·laboració amb el Servei Nacional de Salut del Regne Unit).

Organització:

L'estructura empresarial de DeepMind està influenciada en gran mesura per l'entorn corporatiu de Google, que està impulsat per dades i invertint en IA i aprenentatge automàtic. DeepMind funciona com una entitat de recerca independent, però també es beneficia de la integració dins de l'estratègia empresarial més àmplia de Google. Les àrees de recerca i desenvolupament de DeepMind, com la salut, la IA general i l'eficiència energètica, s'alineen amb els objectius estratègics d'Alphabet (empresa matriu de Google). Tenir el suport d'una empresa com Google dona uns recursos inigualables. També la cultura de Google valora la innovació i l'experimentació. L'únic problema que pot tenir es que al ser un centre de recerca te objectius diferents a una empresa, DeepMind te uns objectius més acadèmics en canvi Google tindrà uns objectius més empresarials, aquest conflicte d'interessos pot donar problemes en algun moment.

Lideratge:

DeepMind és conegut pel seu fort lideratge sota figures com Demis Hassabis, que té un profund coneixement de la IA, la neurociència i la visió estratègica. El lideratge dins de DeepMind estableix la direcció tant per a avenços tècnics com per a consideracions ètiques en el desenvolupament de la IA. DeepMind ha demostrat el seu compromís amb l'avanç de la IA d'una manera que beneficia a la humanitat, convertint el lideratge en un pilar central de les seves iniciatives d'IA. Però com hem dit abans els líders poden enfrontar-se a la pressió per equilibrar les ambicions acadèmiques amb objectius comercials i empresarials. Sobretot a mesura que DeepMind s'integra a Google, pot haver-hi reptes per preservar la seva cultura de recerca independent, alhora que s'alinea amb els interessos empresarials més amplis de Google.

Objectius:

Els objectius de DeepMind estan lligats a recerca científica revolucionari en múltiples camps. Tots els seus objectius estan relacionats amb investigacions científiques revolucionàries en el camp de AI. Aquest objectius semblen a llarg termini ja que alguns dels problemes a solucionar són absurdament complexos, però tenim resultat els quals semblen indicar que són un equip molt capaç (com AlphaGo, AlphaFold), ja que han sigut revolucions a nivell mundial. L'únic problema que poden tenir és que els resultats a llarg termini son arriscats, ja que poden no donar rendibilitat al haver invertit molt en ells. Tot i això crec que tots els seus objectius estan basats en dades objectives i pensats per persones analítiques per tant no dubto que DeepMind anirà bé.

Persones:

Com hem vist abans el grup que forma DeepMind és altament qualificat on tenim molts perfils analítics. Tenint en compte que treballen principalment en recerca acadèmica seria normal que estiguin en formació continua per estar al dia de les novetats al camp de la AI i l'anàlisi de dades en general. Per tant tindrem un equip altament qualificat que sempre està intentant millorar i aprendre més. Això genera una cultura empresarial molt adient per una empresa analítica.

En conclusió, DeepMind és un exemple d'una organització amb un alt nivell de maduresa en tot el model DELTA, particularment en persones, lideratge i dades. No obstant això, com totes les organitzacions, s'enfronta a reptes, en concret la gestió de la privacitat, les implicacions ètiques i l'alineació de les ambicions de recerca amb les necessitats de l'empresa.

Pregunta 5

Google DeepMind està guanyant un gran pes dins de l'estructura d'Alphabet gràcies al desenvolupament de productes capdavanters com Astra i Gemini.

Posa't a la pell d'un membre de l'equip de visualització de dades

- Quina visualització proposaries per demostrar l'èxit i l'evolució dels productes de Google DeepMind?
- Quins KPIs (key performance indicators) t'ajudaran a aconseguir aquest objectiu?

Abans de decidir com mostrar les nostres dades, estaria bé saber que volem mostrar per tant primer mirarem els KPIs. Els KPIs poden mirar multitud de coses depenent dels objectius de cada empresa però donada la naturalesa de Google i DeepMind proposarem alguns KPIs centrats en el progrés, l'impacte i l'adopció. Separarem aquestes KPIs en diversos grups rellevants.

Científiques

Bondat dels models: Per models predictius podem tenir quina és la seva *accuracy* o altres estadístiques que ens poden indicar com de bé funciona un model.

Nombre de publicacions: Al ser DeepMind una empresa centrada en la investigació científica tenir una estadística de quants paper s'han publicat pot ser molt útil.

Nombre de cites: Una manera de trobar l'impacte d'un paper es mirar la quantitat de cites que ha tingut, ja que es un molt bon indicador de l'interès general dintre de la comunitat científica.

Temps entre publicacions: Saber quan tarden entre publicació i publicació pot ajudar a saber si tot està funcionant correctament o ja algun retard.

Negoci

Creixement de la base d'usuaris: En aplicacions com Gemini podem mirar quant usuaris o organitzacions l'estan utilitzant.

Retenció d'usuaris: Podem mirar quants usuaris continuen utilitzant un servei a través del temps.

Usuaris actius: Quant usuaris actius hi ha en un determinat moment.

Beneficis generats: Quants diners generen de serveis com Astra o Gemini.

Quota de mercat: Quina quota de mercat avarques amb els serveis.

Eficiencia

Eficiencia de còmput: Com d'eficients són els nostres models desplegats (consum elèctric per els nostres models, memoria necessaria, etc)

Per visualitzar totes aquestes mètriques poden tenir diverses pestanyes cada una amb les KPI rellevants per cada sector del negoci, ja que diferents directius poden necessitar diferents dades. Algunes podran mostrar com un valor ha anat canviant respecte el temps, per exemple el nombre d'usuaris actius, on poden mirar quan hi ha un pic perquè succeeix, podria ser que ha hagut una pujada per una oferta temporal o per una nova funció que s'ha introduït. O una baixada degut a que un competidor ha tret una innovació al mercat. També podrien haver altres on només tinguessim un número a temps real i que es pugés filtrar per condicions, per exemple mirar el número de cites d'un article en concret, per mirar l'impacte que ha tingut una investigació. Tot això podria estar publicat per tal que es puguin prendre decisions respecte les dades objectives i entendre que se està fent bé i on es podria millorar.

Pregunta 6

Destaca dues de les intervencions del primer debat.

- Què destacaríeu de cadascuna d'elles?
- Hi ha algun aspecte en el que no coincideixis?

Primer vull destacar l'opinió de David Piñol Navas respecte "Els avenços de la IA poden tenir cap impacte negatiu en l'àmbit de la investigació". Crec que el problema de la caixa negra es un problema greu, vist sobretot en les xarxes neuronals, i encara que tenim iniciatives com la llibreria XAI a python⁴, una llibreria dissenyada per intentar explicar com aprenen les IA, es un

⁴ <https://pypi.org/project/xai/>

problema molt greu. La gravetat del problema ve que no sabem el motiu el pel qual decideix una cosa, per exemple imaginem que tenim una xarxa neuronal que a partir d'una imatge de teixit cel·lular pot detectar si un pacient té o no cancer. Òbviament és un model molt útil i es una eina increïble pel diagnòstic, però al no saber en quina part de la imatge es fixa o quin tipus de textura li fa pensar que el teixit podria ser cancerigen. En cas de saber on està localitzat el càncer i quins indicadors tenim sobre ell ens podria ajudar a trobar millors tractaments, tant preventius com per curar-lo.

També volia aportar un punt que no he vist a ningú comentar en aquest debat i crec que és molt rellevant i és com l'ús pel públic general de certes IAs, com ChatGPT o Gemini, les quals tendeixen a equivocar-se o donar dades errònies pot provocar una desconfiança cap a qualsevol altra eina d'AI per part del públic general⁵, ja que inconscientment pot fer una associació fent que models els quals no tinguin aquesta tasa d'error. Suposem per exemple una IA com la que hem comentat abans, detectora de càncer a través d'imatge de teixits. Que tingui una *accuracy* molt alta i que tingui una tasa de falsos negatius casi nula. Òbviament un model així és molt útil, però si el metge no confia en la prova per una desconfiança general cap a las IA vinguda d'una mala publicitat per altres usos no s'implantara en consulta. Per tant crec que hem d'anar amb compte

⁵ <https://journals.sagepub.com/doi/full/10.1177/00187208211013988>