

Universitat Oberta de Catalunya



REPTE 2 - Com realitzar la neteja i anàlisi de les dades?

Autors:

Albert Lozano Valverde & Alberto Antorán Ponce

emails:

alozanoval@uoc.edu & aantoran@uoc.edu

Barcelona, Gener , 2026

Memòria

1 Recursos

1. Video: Video en Drive
2. Github: Recursos Github

2 Motivació

La construcció de la base de dades es realitza amb la finalitat de desenvolupar un model d'anàlisi de panel (Països i anys) per valorar les millores d'eficiència en països de la OCDE de l'ús de combustibles per al transport en carretera. Es pretén avaluar tant l'eficiència com estimar l'efecte rebot (*rebound effect*) del guany en eficiència energètica per al transport per carretera.

Renunciem a desenvolupar el *Repte 2* amb les dades del *webscraping* realitzat al *Repte 1* donat que amb les dades generades amb aquest no podem desenvolupar els requisits establerts en el *Repte 2*.

3 Origen de les dades

La base de dades inicial es construeix a partir de dades obertes del Banc Mundial (dades incorporades amb el prefixe WB-); dades obertes del *World Economic Forum* (WEFORUM); dades obertes de l'OCDE (Organització per a la Cooperació i el Desenvolupament Econòmic) i dades de subscripció de l'Agència Internacional de l'Energia (AIE). Com que les dades de l'AIE es poden obtenir a partir dels recursos estadístics de la OCDE sota la subscripció adient (no són completament obertes), les dades amb origen AIE i OCDE s'incorporen amb el prefixe "OECD-".

Entenem hi ha dues formes d'obtenir les dades originàries (dues polítiques)

1. Realitzar abans de descarregar **una anàlisi molt detallada dels regressors** o paràmetres que poden ser d'utilitat. → Aquesta actuació simplificaria molt les fases de depuració, selecció i neteja de la base de dades fins determinar la base de dades finals. Identifiquem però les següents problemàtiques:
 - Desconeixement de quins regressors tenen correlacions i quins poden aportar informació a l'objecte d'estudi
 - La tasca de descarregar d'informació limita la diversitat d'anàlisis que es poden realitzar, pel que descarregar un gran volum de dades permet disposar de dades que posteriorment es poden utilitzar per diferents anàlisis, **especialment si la descarrega de dades precisa**

de pagament o alguna altre restricció d'accés tal és el cas de l'Agència Internacional de l'Energia.

2. Realitzar abans de descarregar les dades una anàlisi no profunda de les dades, a fi de disposar d'una gran base de dades en brut amb paràmetres extensius. Aquesta tasca comporta una extensa depuració posterior que comporta un esforç en codificació (realitzat en el nostre cas amb *R*) molt significatiu. L'avantatge és que un cop codificat, les actualitzacions de les dades originals es poden processar automàticament i es disposar de més flexibilitat.

Amb la finalitat que les dades descarregades puguin ser d'utilitat per diferents anàlisis així com degut al desconexament de la potencial causalitat entre variables o l'existència de correlacions excessius entre regressors, s'ha optat per la segona opció: **una selecció de paràmetres "extensiu" en les bases de dades d'origen**. Cal dir i emfatitzar però, que després de realitzar la tasca, l'esforç de codificació és massa elevat i havia estat menystingut en origen, pel que creiem només té sentit aquest esforç si les dades en brut es poden utilitzar en molts estudis diferents. Si no, si es coneixen les dades que poden ser d'utilitat, és més desitjable realitzar un esforç previ en la selecció de variables abans de descarregar-les de les bases de dades d'origen.

```
# ..... DIRECTORIS BASES DE DADES
# .....

BBDD_OECD_reading_directory <- "C:/UOC-Tipologia Dades/DADES/OECD/"
BBDD_OECD_writing_directory <- "C:/UOC-Tipologia
    Dades/DADES/OECD/GENERADOS desde R/"

BBDD_WD_reading_directory<-"C:/UOC-Tipologia Dades/DADES/WORLD BANK/"
BBDD_WD_writing_directory<-"C:/UOC-Tipologia DadesR/DADES/WORLD
    BANK/GENERADOS desde R/"

BBDD_WEF_reading_directory <- "C:/UOC-Tipologia Dades/DADES/WEFORUM/"
BBDD_WEF_writing_directory <- "C:/UOC-Tipologia
    Dades/DADES/WEFORUM/GENERADOS desde R/"

BBDD.FINAL.writing_directory<- "C:/UOC-Tipologia Dades/DADES/GENERADOS
    desde R/"
# *****
# ----- DATABASES CREATED
# *****


# # --- OECD -----

# BBDD_OECD_OIL_Road      --> BBDD_OECD_OIL_Road.csv BBDD from OECD
    with Road oil data consumption
```

```

#
# BBDD_OECD_Road_PI --> BBDD_OECD_Road_PI.csv BBDD from OECD
# with Road PERFORMANCES INDICATORS related with
# freight,
# passengers, infrastructure, Kms etc
#
# BBDD_OECD_Rail --> BBDD_OECD_Rail.csv BBDD from OECD
# with railways data
#
# BBDD_OECD_Vehicles --> BBDD_OECD_Vehicles.csv BBDD from OECD
# with data about passenger cars &
# motorcycles
# registrations
#
# BBDD_OECD_STI_Traffic --> BBDD_OECD_STI_Traffic.csv BBDD from
# OECD data about rail, road and waterway
# goods
# transport and passenger traffic
#
# BBDD_OECD_STI_Registrations --> BBDD_OECD_STI_Registrations.csv BBDD
# from OECD with first registrations of
# brand
# new goods vehicles, passenger cars & road vehicles
#
# BBDD_OECD_Goods_Transport --> BBDD_OECD_Goods_Transport.csv BBDD
# from OECD with Road, Rail, Maritime freight
# and
# containers data
#
# BBDD_OECD_Passenger_Transport --> BBDD_OECD_Passenger_Transport.csv
# BBDD from OECD with road and rail million
#
# passenger-km for buses, passenger carse, rail
#
# BBDD_OECD_Transport_Safety --> BBDD_OECD_Transport_Safety.csv BBDD
# from OECD with data of fatalities & injuries
#
# BBDD_OECD_Transport_Infrastructure -->
# BBDD_OECD_Transport_Infrastructure.csv BDD from OECD with data of
# infrastructure
#
# investment & maintenance in Rails, Roads,
#
# Airports, Ports

```



Així doncs, la base de dades inicial s'ha construït amb la selecció de múltiples paràmetres (variables) que es consideren poden ser d'utilitat (Taula 1).

Posteriorment aquesta base de dades es depurarà per eliminar:

- Anys amb dades incompletes
- Dades que es considerin no necessàries donada la correlació entre variables que introdueix multicolinealitat
- Dades que després d'una valoració més detallada no es consideren d'utilitat per al model

Els fitxers R utilitzats així com els fitxers .csv amb les dades es poden accedir al directori Github - Tipologia_cicle_vida_dades-Practica_2

Les variables han estat renombrades en el fitxer final (Taula 1 per ser més fàcilment treballables des de les comandes R. Així, a títol d'exemple tenim variables com

- "GDP 2015 PPP US\$" $\rightarrow$ *GDP*
- "Automov diesel Total price Households, PPP, US" $\rightarrow$ *Price.Diesel*
- "Railways, goods transported (million ton-km)" $\rightarrow$ *Rail.Freight*
- "Population density (people/sq. km of land area)" $\rightarrow$ *Pop.Density*
- Etc

La variable *Total.Fuel* es correspon amb la suma de tots els combustibles (Diesel, GLP, Benzina). En comptes d'identificar un preu mitjà per a cada

tipologia de combustible, utilitzem com a variable proxy de tots els preus del combustible "*Automov diesel Total price Households, PPP, US*". Aquesta variable al codi R s'ha anomenat *Price.Diesel*

Taula 1: Paràmetres (regressors potencials) amb els que es construeix la base de dades inicials pre-neteja

Variable	Descripció
GDP	PIB a preus de 2015 i en paritats de poder adquisitiu (PPA), milers de milions de dòlars EUA
GDPxCapita	PIB per càpita a preus constants de 2015 i en PPA, dòlars EUA
Perctg.Act.ind.consum	Consum individual efectiu, percentatge del PIB
Perctg.Household.fin-al.consum	Despesa final de consum de les llars, percentatge del PIB
GDP.Growth	Creixement del PIB (percentatge anual)
GDP.Growth.x.Capita	Creixement del PIB per càpita (percentatge anual)
Population	Població total
Perctg.Urban.Pop	Població urbana (percentatge de la població total)
Urban.Pop.Growth	Creixement de la població urbana (percentatge anual)
Pop.Largest.City	Població de la ciutat més gran (percentatge de la població urbana)
Pop.Urban.Agglo	Població en aglomeracions urbanes de més d'1 milió d'habitants (percentatge de la població total)
Pop.Density	Densitat de població (persones per km ² de superfície terrestre)
Total.Fuel	Consum total de combustible per carretera (quilòtones)
Price.Diesel	Preu del dièsel per a automoció (per litre), llars, preu total (USD per unitat en PPA)
Road.Passenger	Transport de passatgers per carretera (passatgers-quilòmetre)
Road.Passenger.Buses	Transport de passatgers per carretera en autobusos i autocars (passatgers-quilòmetre)
Road.Passenger.Cars	Transport de passatgers per carretera en turismes (passatgers-quilòmetre)
Rail.Passenger	Transport ferroviari de passatgers (passatgers-quilòmetre)
Total.Inland.Passenger	Transport interior total de passatgers
Perctg.BUS.Passenger	Percentatge del transport de passatgers en autobús
Perctg.CAR.Passenger	Percentatge del transport de passatgers en automòbil
Perctg.RAIL.Passenger	Percentatge del transport de passatgers en ferrocarril
Total.Inland.Freight	Transport interior total de mercaderies
Water.Freight	Transport de mercaderies per vies navegables interiors (tones-quilòmetre)
Rail.Freight	Transport ferroviari de mercaderies (tones-quilòmetre)
Road.Freight	Transport de mercaderies per carretera (tones-quilòmetre)
Pipelines.Transport	Transport de mercaderies per canonades (tones-quilòmetre)
Total.Inland.Transport	Transport interior total de mercaderies (tones-quilòmetre)
Perctg.ROAD.Freight	Percentatge del transport de mercaderies per carretera
Perctg.RAIL.Freight	Percentatge del transport de mercaderies per ferrocarril
Perctg.WATER.Freight	Percentatge del transport de mercaderies per vies navegables
Perctg.PIPELINES.Freight	Percentatge del transport de mercaderies per canonades
Total.Fuel.GDP	Consum total de combustible en relació amb el PIB

El fitxer final resultant té **dimensió (667,36)**. Les dades disponibles per

països i any són:

Taula 2: Data Span per països

	Estat	n	Any min	Any max
X11	Australia	39.00	1978.00	2016.00
X12	Austria	15.00	1978.00	1992.00
X13	Belgium	22.00	1990.00	2011.00
X14	Canada	4.00	2004.00	2007.00
X15	Czech Republic	26.00	1993.00	2018.00
X16	Denmark	21.00	1996.00	2016.00
X17	Finland	41.00	1978.00	2018.00
X18	France	41.00	1978.00	2018.00
X19	Germany	41.00	1978.00	2018.00
X110	Greece	27.00	1982.00	2008.00
X111	Hungary	27.00	1992.00	2018.00
X112	Italy	41.00	1978.00	2018.00
X113	Japan	41.00	1978.00	2018.00
X114	Netherlands	31.00	1978.00	2008.00
X115	Norway	21.00	1996.00	2018.00
X116	Poland	26.00	1993.00	2018.00
X117	Portugal	24.00	1979.00	2008.00
X118	Spain	41.00	1978.00	2018.00
X119	Sweden	41.00	1978.00	2018.00
X120	Switzerland	26.00	1981.00	2018.00
X121	United Kingdom	41.00	1978.00	2018.00
X122	United States	30.00	1980.00	2017.00

4 Anàlisi de les dades

Amb les dades netes ja disponibles tractem d'obtenir informació per respondre a preguntes que ens podríem formular. Per això es necessari realitzar una tria de regressors donat que a priori 36 semblen excessius i a més segurament molts d'ells estan correlacionats com ara el *GDP agregat*, la *Població*, o el *Transport de mercaderies o passatgers per carretera o ferrocarril*

```
# Seleccionar les columnes 4 a 36
subdata <- BBDD_Road_Energy_Regressors[, 4:36]

# Calcular estadstics bsics per cada variable
stats <- data.frame(
  Min = apply(subdata, 2, min, na.rm = TRUE),
  Max = apply(subdata, 2, max, na.rm = TRUE),
  Mean = apply(subdata, 2, mean, na.rm = TRUE),
  SD = apply(subdata, 2, sd, na.rm = TRUE)
)


# Convertir a LaTeX amb xtable
library(xtable)
print(xtable(stats, caption = "Estadstiques descriptives (col. 4--36)",
  digits = 2), type = "latex")
```

La Base de dades original conté un total de 34 regressors amb els següents estadístics bàsics:

	Min	Max	Mean	SD
GDP	100.56	18983.16	1764.88	2989.91
GDPxCapita	10796.50	68580.02	35578.71	10869.96
Perctg.Act.ind.consum	50.60	80.31	67.44	5.16
Perctg.Household.final.consum	38.39	69.34	56.05	6.37
GDP.Growth	-8.07	7.49	2.31	2.10
GDP.Growth.x.Capita	-8.51	7.60	1.84	2.14
Population	4381336.00	325122128.00	46089311.81	61992241.38
Perctg.Urban.Pop	42.38	97.70	76.03	9.05
Urban.Pop.Growth	-1.60	2.28	0.72	0.60
Pop.Largest.City	5.32	58.61	19.89	10.59
Pop.Urban.Agglo	4.28	64.63	25.11	15.54
Pop.Density	1.87	487.13	146.09	119.71
Total.Fuel	1691.00	516784.00	38999.27	92800.62
Price.Diesel	0.12	3.46	1.02	0.59
Road.Passenger	16416.00	6558301.00	520038.88	1007750.71
Road.Passenger.Buses	4812.00	587765.00	45456.09	74505.41
Road.Passenger.Cars	10500.00	5970536.00	474582.79	936605.18
Rail.Passenger	1413.00	441614.00	45690.08	89517.02
Total.Inland.Passenger	17917.00	6591556.54	565728.95	1024942.46
Perctg.BUS.Passenger	0.03	0.33	0.11	0.05
Perctg.CAR.Passenger	0.44	0.97	0.80	0.09
Perctg.RAIL.Passenger	0.00	0.44	0.09	0.07
Total.Inland.Freight	8699.00	7225946.00	417196.24	1281231.33
Water.Freight	0.00	534398.00	28546.29	102455.37
Rail.Freight	306.00	2709558.00	128144.06	457998.81
Road.Freight	6632.00	3283857.00	216349.38	556817.15
Pipelines.Transport	0.00	904891.00	44156.51	173848.05
Total.Inland.Transport	8699.00	7225946.00	417149.56	1281240.47
Perctg.ROAD.Freight	0.27	0.98	0.68	0.18
Perctg.RAIL.Freight	0.02	0.66	0.22	0.15
Perctg.WATER.Freight	0.00	0.53	0.05	0.10
Perctg.PIPELINES.Freight	0.00	0.29	0.06	0.07
Total.Fuel.GDP	8.84	46.02	17.82	5.64

Taula 3: Estadístiques descriptives (col. 5–8)

El següent pas es realitzar una tria de regressors i una normalització i transformació de dades si s'escau (per exemple les de *Població* i *GDP* dificulten la homogenització de les anàlisis pel que és més important utilitzar *GDPxCapita*). Dades transformades a format logarítmic neperià ajuden a que les dades s'ajustin millor a una distribució normal reduint la heterostaciditat



4.1 Model supervisat

Les dades són susceptibles d'analitzar-se amb diferents models com ara *Panel data*; *Linear Mixed Effect* (amb *Fixed effects* o *Random Effects*), etc. Un anàlisi detallat no és l'objectiu del repte pel que ens limitarem a utilitzar un model supervisat, amb aquest model intentarem mirar si podem predir el consum de combustible total donada certes característiques. Per fer-ho utilitzarem un *RandomForest*. Com hem vist abans el nostre *DataSet* netejat té les variables vistes a taula 1.

No podem utilitzar com a regressors totes les variables seleccionades que poden afectar directament a *Total.Fuel*, tant per raó de dimensionalitat, com de correlació entre variables. Així si utilitzem *Perctg.CAR.Passenger* no es necessari que posen *Perctg.BUS.Passenger* ja que són complementàries (quan sumem tots han de donar 1) i estan correlacionats. Aquestes correlacions es poden veure a la figura 1 on tenim la correlació entre totes les variables finals




Figura 1: Correlació entre variables

Per últim hi haurà variables que no utilitzarem perquè en aquest cas no explicaven la variable objectiu.

Ens hem quedat finalment amb les variables següents:

Total.Fuel, GDP, Population, Price.Diesel, Total.Inland.Transport, Perctg.ROAD.Freight, Perctg.CAR.Passenger, Urban.Pop.Growth, Pop.Density.

A continuació hem partit el *DataSet* en entrenament i test, en el nostre cas tindrem un 80% entrenament i un 20% test.

Un cop entrenat el model amb la partició d'entrenament, comprovem com de

bona és la nostra predicció amb la partició de test.

El model de Random Forest desenvolupat per predir el consum total de combustible (*Total Fuel*) mostra un rendiment molt elevat, tal com indiquen els principals indicadors de qualitat del model: l'error quadràtic mitjà (RMSE), l'error absolut mitjà (MAE) i el coeficient de determinació (R^2).

En primer lloc, el valor de l'RMSE, situat en 4850.19, mesura la magnitud mitjana dels errors de predicció penalitzant especialment els errors grans. Tenint en compte l'escala del consum total de combustible observat en el conjunt de dades, aquest valor pot considerar-se relativament baix, fet que indica que el model és capaç de capturar amb precisió les variacions principals del consum energètic entre països i anys.

D'altra banda, el MAE, amb un valor de 1516.32, reflecteix l'error mitjà absolut en unitats originals de la variable dependent. Aquest resultat suggereix que, de mitjana, les prediccions del model difereixen molt poc dels valors reals, reforçant la idea que el Random Forest ofereix estimacions robustes i estables.

Finalment, el coeficient de determinació R^2 assoleix un valor de 0.9973, cosa que implica que el model explica aproximadament el 99.73% de la variabilitat total del consum de combustible. Aquest resultat posa de manifest l'elevada capacitat explicativa del model i confirma que les variables seleccionades, relacionades amb l'activitat econòmica, l'estructura del transport i les característiques urbanes, són determinants clau del consum energètic.

En conjunt, aquests resultats indiquen que el model de Random Forest no només presenta una excel·lent capacitat predictiva, sinó que també és adequat per analitzar relacions no lineals i interaccions complexes entre variables. Això el converteix en una eina especialment útil per a l'estudi del consum de combustible i per a l'avaluació de possibles escenaris de política energètica i de transport. Això es pot veure molt ben representat en la següent figura 2, on veiem que la majoria de valors estan molt a prop de la recta que implicaria una predicció perfecta.




Figura 2: Valors vs Predicció

4.2 Model no supervisat: PCA i *clustering* amb K-means

En aquest apartat s'ha aplicat una estratègia no supervisada per identificar patrons latents i agrupar observacions segons similituds en variables de mobilitat i energia. El flux de treball s'ha estructurat en dos passos: estandardització de variables i reducció de dimensionalitat amb PCA, i *clustering* amb K-means sobre les dades escalades.

4.2.1 Preparació de les dades i estandardització

A partir del conjunt de dades original es va construir un subconjunt (`cluster_df`) amb variables relacionades amb el repartiment modal de passatgers i mercaderies (`Perctg.*`), així com indicadors demogràfics i energètics (`Pop.Density`, `Perctg.Urban.Pop`, `Urban.Pop.Growth`, `Price.Diesel`, `Total.Fuel.GDP`).

Com que les variables tenen escales molt diferents (per exemple, densitat de població versus percentatges), el *clustering* s'ha de fer sobre dades estandarditzades. Per això es va aplicar:

$$\mathbf{X}_{scaled} = \text{scale}(\mathbf{X}),$$

de manera que cada variable queda centrada (mitjana 0) i normalitzada (desviació estàndard 1). Aquesta transformació evita que variables amb magnitud gran dominin les distàncies euclidianes utilitzades per K-means.

4.2.2 Reducció de dimensionalitat amb PCA

Per facilitar la interpretació i entendre l'estructura global de les dades, s'ha aplicat una Anàlisi de Components Principals (PCA) sobre les dades estandarditzades (`prcomp` amb `center=TRUE` i `scale.=TRUE`). La PCA transforma les variables originals en components ortogonals que expliquen la màxima variància possible.

L'anàlisi dels valors propis i el gràfic de variància explicada (`fviz_eig`) permeten identificar quantes components acumulen una proporció significativa de variància. A més, la representació de les contribucions de les variables a les components (`fviz_pca_var`) ajuda a interpretar quins factors (p.ex. dependència de carretera, pes del ferrocarril, presència d'aigua o *pipelines*, etc.) expliquen millor les diferències entre observacions.

Cal remarcar que en aquest treball la PCA s'ha utilitzat principalment com a eina exploratòria i de visualització; el *clustering* final s'ha fet sobre les dades escalades completes, no només sobre les primeres components.

4.2.3 Selecció del nombre de clústers

Per escollir el nombre òptim de clústers k en K-means, s'ha utilitzat el criteri de la suma de quadrats intra-clúster (*Within-Cluster Sum of Squares*, WSS) mitjançant `fviz_nbclust(..., method="wss")`. Aquest mètode busca el punt on l'augment de k deixa d'aportar una reducció substancial de la variabilitat interna.

El gràfic 3 mostra una caiguda pronunciada fins aproximadament $k = 7$, i a partir d'aquest valor la corba s'aplanava, indicant rendiments decreixents. Per aquest motiu es va seleccionar:

$$k = 7$$

com a compromís raonable entre complexitat i capacitat explicativa.




Figura 3: fviz_nbclust method WSS

4.2.4 Model de *clustering* amb K-means

Un cop fixat $k = 7$, s'ha ajustat el model K-means sobre les dades escalades (`cluster_scaled`) amb inicialització robusta: `set.seed(123)` i `nstart=25`. Això redueix el risc d'obtenir solucions locals depenents de la inicialització.

Posteriorment, s'ha visualitzat la separació dels grups 4, incloent punts i el·lipses normals, per obtenir una representació intuïtiva de la segmentació en l'espai reduït utilitzat per la funció de visualització.




Figura 4: K-means

4.2.5 Caracterització dels clústers (interpretació amb z-scores)

Per interpretar el significat de cada clúster, s'han calculat les mitjanes de cada variable per clúster en l'espai estandarditzat (z-score). Això permet comparar directament entre variables i clústers:

- $z > 0$: el clúster està per sobre de la mitjana global en aquella variable,
- $z < 0$: el clúster està per sota,
- $|z| \geq 1$: diferència notable,
- $|z| \geq 2$: diferència molt marcada.

A partir d'aquest resum, els set clústers identifiquen règims de transport-energia diferenciats:

Clúster 1: *Urban mixed + rail-freight* Presenta una població més urbana que la mitjana ($z \approx +0.48$) i un ús moderadament superior del ferrocarril en mercaderies ($z \approx +0.40$), amb la resta de variables relativament properes a la mitjana. Es pot interpretar com un perfil urbà equilibrat amb una lleugera orientació al *rail freight*.

Clúster 2: *Diesel-expensive pipeline / low-urban* Es caracteritza per un preu del dièsel alt ($z \approx +1.12$) i un pes notable del transport per *pipelines* ($z \approx +1.13$). Alhora, mostra menor urbanització ($z \approx -1.17$) i creixement urbà baix ($z \approx -1.30$). Aquest perfil suggereix entorns menys urbans, amb dependència logística de *pipelines* i costos energètics elevats.

Clúster 3: *Low-density fuel-intensive* Destaca per baixa densitat de població ($z \approx -1.10$), forta dependència del cotxe en passatgers ($z \approx +1.26$) i un component elevat de mercaderies per ferrocarril ($z \approx +1.65$). L'indicador **Total.Fuel.GDP** és extremadament alt ($z \approx +2.41$), indicant una intensitat de consum de combustible elevada respecte al PIB. És un règim clarament intensiu energèticament.

Clúster 4: *Water-freight hub* És el clúster més distintiu: el transport de mercaderies per aigua és molt superior a la mitjana ($z \approx +4.06$), amb densitat poblacional molt alta ($z \approx +2.55$) i creixement urbà positiu ($z \approx +1.29$). Aquest patró és coherent amb països o regions amb forta infraestructura portuària o fluvial i alta concentració demogràfica.

Clúster 5: *Pipeline-heavy / low fuel-intensity* Mostra el valor més alt de mercaderies per *pipelines* ($z \approx +1.94$) i, simultàniament, un **Total.Fuel.GDP** per sota de la mitjana ($z \approx -0.56$). Això apunta a un perfil amb logística basada en *pipelines* i menor intensitat de consum de combustible en relació amb l'activitat econòmica.

Clúster 6: *Road-freight dominant* Es defineix per un predomini del transport de mercaderies per carretera ($z \approx +1.01$) i valors baixos en altres modes (ferrocarril, aigua i *pipelines*). És un règim típic de dependència de la carretera per a mercaderies.

Clúster 7: *Rail-passenger megaccluster* És el clúster amb un ús extrem del ferrocarril en passatgers ($z \approx +3.43$) i un valor molt alt de mercaderies per carretera ($z \approx +1.28$), combinat amb una reduïda dependència del cotxe en passatgers ($z \approx -2.40$) i una densitat poblacional elevada ($z \approx +1.63$). Representa contextos densos on el rail té un paper central en mobilitat de passatgers.

En conjunt, els models no supervisats han permès reduir i interpretar l'estructura latent de les variables mitjançant PCA, i identificar set perfils diferenciats (*regimes*) de transport i energia amb K-means. La segmentació obtinguda és coherent amb diferències estructurals en densitat i urbanització, així com amb l'especialització modal en mercaderies (carretera, aigua o *pipelines*) i en passatgers (cotxe versus ferrocarril). Aquesta caracterització pot facilitar l'anàlisi comparativa i pot servir de base per discutir implicacions en política de transport, planificació urbana i dependència energètica.

4.3 Contrast d'hipòtesi: tendència temporal de `Total.Fuel.GDP` i heterogeneïtat entre països

L'objectiu d'aquesta secció és determinar si l'evolució temporal de `Total.Fuel.GDP` és similar entre països i si la variabilitat es manté estable any a any. Les dades tenen estructura de panell (observacions per `Country` i `Year`) en el període 1978-2015. Donada l'asimetria habitual d'aquesta variable, es va treballar amb la transformació

$$y = \log(\text{Total.Fuel.GDP}),$$

que permet interpretar les pendents com a canvis percentuals anuals aproximats.

Models i hipòtesis. Es generen dos models lineals:

$$\begin{aligned}\mathcal{M}_1 : y &\sim \text{Year} + \text{Country} && \text{(tendència comuna)} \\ \mathcal{M}_2 : y &\sim \text{Year} * \text{Country} && \text{(tendència específica per país)}\end{aligned}$$

El contrast principal és sobre la interacció `Year:Country`:

$$H_0 : \beta_{\text{Year:Country}} = 0 \quad \forall \text{ països} \quad \text{(mateixa pendent temporal en tots els països)}$$

$$H_1 : \exists \text{ algun país amb } \beta_{\text{Year:Country}} \neq 0 \quad \text{(pendents diferents entre països)}.$$

Comprovació de normalitat dels residus (Shapiro–Wilk). Per avaluar l'assumpció de normalitat dels residus del model base $\mathcal{M}_1$, s'aplica el test de Shapiro–Wilk:

$$H_0 : \varepsilon \sim \mathcal{N}(0, \sigma^2) \quad \text{vs.} \quad H_1 : \varepsilon \not\sim \mathcal{N}(0, \sigma^2).$$

El resultat rebutja la normalitat ($W = 0.9653$, $p = 1.864 \times 10^{-11}$). Cal notar que, amb mostres moderades o grans, aquest test és especialment sensible i pot detectar desviacions petites. Per aquest motiu, i per robustesa, es complementa la inferència amb un contrast basat en matrius de covariància per veure si els resultats del test encara que assumim normalitat coincideixen.

Comprovació d'homoscedasticitat entre anys (Levene). Com que l'interès és comparar la variabilitat *any a any* entre països, s'avalua l'homogeneïtat de variàncies entre anys sobre els residus del model base $\mathcal{M}_1$, agrupant per `Year` (tractat com a factor) i utilitzant el test de Levene (centre a la mediana):

$$H_0 : \sigma_{1978}^2 = \sigma_{1979}^2 = \dots = \sigma_{2015}^2 \quad \text{vs.} \quad H_1 : \exists t, t' \text{ amb } \sigma_t^2 \neq \sigma_{t'}^2.$$

El test de Levene no rebutja l'homogeneïtat ($F = 0.7858$, $p = 0.8263$), suggerint que la dispersió residual és comparable al llarg del temps un cop controlats els efectes de país i la tendència agregada.

Contrast d'hipòtesi: igualtat de pendents entre països. Per comprovar si la progressió temporal és comuna o bé difereix per país, es compararan $\mathcal{M}_1$ i $\mathcal{M}_2$ mitjançant un contrast F de models (equivalent a testar simultàniament totes les interaccions **Year:Country**). El resultat és altament significatiu:

$$F(21, 623) = 42.745, \quad p < 2.2 \times 10^{-16},$$

i, per tant, es rebutja H_0 . Això implica que l'efecte del temps sobre $y = \log(\text{Total.Fuel.GDP})$ **depèn del país**; és a dir, les pendents temporals no són homogènies entre països.

Atès que Shapiro–Wilk rebutja normalitat, es realitzarà un contrast addicional utilitzant una matriu de covariància (HC3) per testar conjuntament totes les interaccions **Year:Country** mitjançant **linearHypothesis**. El contrast confirmarà el resultat:

$$F(21, 623) = 42.668, \quad p < 2.2 \times 10^{-16},$$

reforçant la conclusió que existeixen diferències significatives en la tendència temporal entre països fins i tot sense assumir normalitat estricta.

Interpretació dels coeficients d'interacció. Els coeficients **Year:Country** indiquen quant difereix la pendent temporal d'un país respecte al país de referència (nivell base de **Country**). El terme principal **Year** (estimació $\hat{\beta} = -1.306 \times 10^{-2}$, $p < 2.2 \times 10^{-16}$) representa la pendent del país de referència, i les interaccions ajusten aquesta pendent per a la resta de països. La significació de moltes interaccions (per exemple, Bèlgica, França, Alemanya, Hongria, Itàlia, Polònia, Portugal i Espanya, entre d'altres) evidencia que la trajectòria temporal no és uniforme. En particular, alguns països presenten pendents negatives (descens sostingut), mentre que d'altres mostren pendents positives (increment), destacant Portugal amb una interacció positiva elevada (estimació $\approx 3.506 \times 10^{-2}$, $p < 2.2 \times 10^{-16}$), coherent amb una tendència de creixement relativa més marcada.

En resum, tot i que no s'observa evidència d'heteroscedasticitat entre anys (Levene no significatiu), la tendència temporal de **Total.Fuel.GDP** **no és comuna** entre països. Tant el contrast F clàssic com el contrast robust (HC3) indiquen diferències molt significatives en les pendents temporals (**Year:Country**), la qual cosa confirma que hi ha trajectòries diferenciades segons el país. Això es poden veure clarament en el gràfic 5 on podem veure com tenim alguns països que segueixen una trajectòria similar any a any i altres que tenen comportaments molt diferents.




Figura 5: Progressió del Fuel.GPD per país

5 Contribucions

Contribucions	Signatura
Investigació prèvia	Alberto Lozano, Alberto Antorán
Redacció de les propostes	Alberto Lozano, Alberto Antorán
Desenvolupament del codi	Alberto Lozano, Alberto Antorán
Participació del video	Alberto Lozano, Alberto Antorán