

Visualització de dades

Introducció a la preparació de dades

Julià Minguillón
setembre 2024

Índex

1. Què són les dades?
 2. Dades estructurades
 3. Obtenció de dades
 4. Preparació de dades
 5. Eines
 6. Per a saber-ne més
-

Què són les dades?

Què són les dades?

Representació simbòlica d'una entitat que descriu algun aspecte o atribut de la mateixa

Una dada que respon una pregunta és **informació**

Així, **42** no és res més que una dada, però quan respon a la pregunta “Quina temperatura té el pacient?” es converteix en informació

Les dades necessiten context, unitats, precisió, format, etc. per poder ser útils (ser analitzades, visualitzades)

Dades, informació, coneixement, saviesa

Dada: 42


Informació: temperatura del pacient en graus Celsius

Coneixement: febre de 42°C o més pot ser mortal

Saviesa: no hem de deixar que la temperatura del pacient arribi a aquest valor



Usar el coneixement pel bé comú



Quin tipus de dades hi ha?

Simples: descriuen només un element, aspecte, ...

Estructurades: és una combinació de diferents dades simples o estructurades, organitzades (l·listes, matrius, ...)

- Un color RGB és una tripleta de dades (R, G i B)
- Una imatge és una matriu 2D de píxels RGB

Simbòlics: cert/fals (booleans), categories (p.e. dia de la setmana)

Numèrics: sencers, reals, complexes

Text: caràcters, cadenes, ... (línies, paràgrafs, ...)

Metadades: dades sobre les dades

A la pràctica

Dades binàries: valors True / False (de vegades 1 / 0), permeten operacions lògiques (AND, OR, NOT)

Dades numèriques: descriuen quantitats, permeten operacions matemàtiques i comparacions, poden ser sencers o amb decimals

Dades categòriques: descriuen aspectes, no permeten operacions matemàtiques

- **Ordinals:** existeix un ordre, permeten comparacions
- **Nominals:** no existeix un ordre

Data / hora: permeten certes operacions (p.e. dia següent, diferència) i comparacions (abans de / després de)

Problemes típics

Outliers: són valors atípics que no concorden amb la majoria de la resta de dades, poden ser errors puntuals de registre o bé causats per un fenomen inusual

Missing data: dades que no han estat registrades i queden en blanc o bé amb valors del tipus N/A, NA, etc.

Registres duplicats: en alguns casos hi ha un camp que fa d'identificador únic, però apareixen dos o més registres amb el mateix identificador

Errors de format: típics en camps tipus data o altres on hi ha una estructura prefixada que no es respecta

Múltiples categories: cadenes de text diferents usades com si fossin el mateix valor

Exemple: dades d'usuaris

12345678	H	32	Barcelona	1-9-2012	Molt bé
13572468	M	128	Madrid	15/12/2010	Malament
24681357	M		Barcelona	01/08/2020	Regular
14235867	H	22		15/7/2021	Molt bé
14.235.867	H	22	BCN	15/7/2021	Bé

Problemes típics

Outliers

Diferents formats

Duplicats / inconsistències

Valors absents (*missing data*)

Diferents categories equivalents

Garbage In, Garbage Out (GIGO)

GIGO: si les dades que alimenten un procés són dolentes, el resultat també serà dolent

És necessària una **preparació de les dades** per poder analitzar-les i visualitzar-les posteriorment, eliminant tots els problemes típics presents

Objectiu: disposar de les dades necessàries en un format estructurat per facilitar la seva anàlisi i visualització

Dades estructurades

Dades estructurades

Tabulars / matricials: format més senzill per representar dades

- Fila: registre, individu, element, ...
- Columna: atribut / variable

Quasi tot es pot representar en forma tabular amb una o més taules

Grafs: relacions entre elements

- Nodes: elements (taula de nodes)
- Arestes / arcs: relació entre elements (taula de relacions)

Altres: dades geoespacials, imatges, àudio, vídeo, etc.

El concepte de *tidy data*

Tidy data: dades “endreçades” en taules sense problemes

- Cada columna és una variable (atribut, camp)
- Cada fila és una observació (registre, element, individu, ...)
- Cada cel·la té un sol valor (dada)

Això facilita les operacions bàsiques amb les dades

- Filtrat / selecció de files i columnes
- Fusió de dues taules
- Pivatat entre formats *long* i *wide*
- Agregats

Exemples

A

Untidy Data

species	habitat	weight	length	latitude/longitude	date
Alligator mississippiensis	swamp	431 lb	4 ft 2	29.531,-82.184	Sept 15, 2015
Puma concolor	forest	125 lb	2.2m	29.125,-81.682	08/10/2015
Ursus americanus	forest	88 kg	133 cm	N29°7'30"/W81°40'55.2"	07-13-2015

B

Tidy Data

meta-data

data

species_code	date	station_code	weight_kg	length_cm
TSN 551771	2015-09-15	1	196	127
TSN 55247	2015-08-10	2	57	220
TSN 180544	2015-07-13	2	88	133

station_code	habitat	latitude	longitude
1	swamp	29.531	-82.184
2	forest	29.125	-81.682

species_code	class	genus	species
TSN 551771	Reptilia	Alligator	mississippiensis
TSN 55247	Mammalia	Puma	concolor
TSN 180544	Mammalia	Ursus	americanus

wide

id	x	y	z
1	a	c	e
2	b	d	f

long

id	key	val
1	x	a
2	x	b
1	y	c
2	y	d
1	z	e
2	z	f

Dades no estructurades o semi-estructurades

Text: encara que formi part d'una entitat amb certa estructura (llibre, article, ...) el text es considera una dada no estructurada

Normalment, hi ha un procés previ per extreure les dades que després seran usades en forma de taula:

- Comptar freqüències de caràcters, n-grames, paraules
- Ús de certes paraules clau, connectors, gramàtica
- Anàlisi de contingut (estil, noms, personatges, ...)

Analitzar i visualitzar text és un repte molt complex

Exemple d'anàlisi de text

Biografies a Wikipedia/Viquipèdia: mitjançant l'API o els dumps de Wikipedia/Viquipèdia és possible accedir al contingut d'una o més pàgines d'una o més categories (biografies)

<https://www.mediawiki.org/wiki/API:Categorymembers>

Un estudi amb la Wikipedia anglesa va demostrar que les paraules usades a les biografies de dones corresponen més a la família i les relacions (“filla de”, “muller de”, ...) i que tenen més enllaços a biografies d'homes

Referència

<https://link.springer.com/content/pdf/10.1140/epjds/s13688-016-0066-4.pdf>

Obtenció de dades

Dades en obert (*Open Data*)

Definició: dades que poden ser localitzades, accessibles, utilitzades, reutilitzades i redistribuïdes sense “cap” restricció tecnològica o jurídica

Possibles restriccions (a la pràctica):

- Registre per accedir a les dades
- Cost econòmic per accedir a les dades: obert $\neq$ gratis
- Limitacions a la redistribució
- Dificultats en l'ús $\Rightarrow$ format de les dades, necessitat d'eines propietàries, ...

El model de cinc estrelles de *Open Data*

Primer nivell: dades disponibles (en qualsevol format), p.e. en PDF


Segon nivell: disponibles en un format estructurat, p.e. XLSX

Tercer nivell: en un format estructurat obert, p.e. CSV, JSON

Quart nivell: permeten accés via URI, p.e. RDF

Cinquè nivell: inclouen context via *linked data*

Font: <https://5stardata.info/es/>



Fonts de dades en obert

Repositoris genèrics: data World Bank, Kaggle, UCI ML, ...

Fonts oficials: INE, IDESCAT, EUROSTAT, UN SDG, ...

Bases de dades: genòmiques, imatges per satèl·lit, cites bibliogràfiques, ...

Xarxes socials: Twitter (limitat), Wikipedia, Instagram, ...

Sensors: AEMET, dades de la Borsa, imatges CCTV, trànsit marítim, ...

Moltes permeten un **accés estàtic** i algunes també **dinàmic**

Accés estàtic

Són “fotografies” de l'estat d'una col·lecció de dades en un moment donat

Exemple: bolcats de Wikipedia en un dia concret

<https://dumps.wikimedia.org/eswiki/latest/>

Acostumen a ser un o més fitxers en formats CSV, JSON, XML o d'altres més específics de l'àmbit en qüestió

No sempre és possible especificar quins registres volem que apareguin als fitxers disponibles

Accés dinàmic

Les dades són accessibles mitjançant una **API** que respon a una petició (*query*) d'acord amb uns paràmetres.

Els **paràmetres** determinen quines dades es volen recuperar i en quin format

Normalment, hi ha un límit de peticions i/o de resultat obtinguts per petició

El resultat acostuma a ser un fitxer CSV, JSON o XML amb les dades requerides

Exemple de *query*

API de flickr: ens permet accedir a tots els continguts de flickr (imatges, usuaris, grups, etiquetes, ...)

Exemple: recuperar imatges geolocalitzades prop de la Sagrada Família a Barcelona des de 2022

Query: des de

<https://www.flickr.com/services/api/explore/flickr.photos.search>

sol·licitem (omplint els camps del formulari)

https://www.flickr.com/services/rest/?method=flickr.photos.search&api_key=8857a51562ecac8bb8549f540f2ae26f&tags=Sagrada+Familia&min_upload_date=2022%2F01%2F01&has_geo=yes&lat=41.403638&lon=+2.174388&radius=1&format=rest

Resultat (amb una api_key vàlida)

```
<?xml version="1.0" encoding="utf-8" ?>
<rsp stat="ok">
  <photos page="1" pages="2" perpage="100" total="167">
    <photo id="52512618299" owner="369888894@N02" secret="09907659cc" server="65535" farm="66" title="Barcelona - Sagrada Familia" ispublic="1" isfriend="0" isfamily="0" />
    <photo id="52512349821" owner="369888894@N02" secret="7f2bb78def" server="65535" farm="66" title="Barcelona - Sagrada Familia" ispublic="1" isfriend="0" isfamily="0" />
    <photo id="52511874012" owner="369888894@N02" secret="65764255f3" server="65535" farm="66" title="Barcelona - Sagrada Familia" ispublic="1" isfriend="0" isfamily="0" />
    ...
  </photos>
</rsp>
```

Ens diu que hi ha 167 fotos en total i ens retorna 100 a la primera pàgina de resultats (es necessita una segona *query* per a la resta)

Podem usar <https://www.flickr.com/services/api/explore/flickr.photos.getInfo> per obtenir informació de cada foto i accedir a la mateixa via URL a partir del *photo id* retornat per la consulta anterior

Preparació de dades

El concepte de *data wrangling*

Data wrangling: es tracta de preparar les dades obtingudes en “cru” per poder “cuinar-les” després

- Eliminar les dades inservibles
- Seleccionar les necessàries
- Netejar-les
- Trossejar-les
- Barrejar-les
- Enriquir-les

Fase crucial del **cicle de vida** de les dades (preprocessament)

<https://datascience.recursos.uoc.edu/cicle-de-vida-de-les-dades/>

Operacions bàsiques

Filtrat (SELECT): selecció de les files i/o columnes d'acord amb certs criteris

Selecció de files: elements que compleixen una condició, i també

- Eliminar files amb moltes dades absents
- Mostrejar una taula massa gran

Selecció de columnes: atributs que es consideren rellevants per a l'objectiu a aconseguir, i també

- Reducció de la dimensionalitat
- Reendreçar columnes

Operacions bàsiques

Fusió (JOIN): enriqueix una taula amb dades provinents d'una segona, ambdues taules comparteixen un camp clau únic

Exemple: al fitxer de notes (usuari, semestre, assignatura, nota) volem afegir algunes dades del fitxer de perfils (usuari, data de naixement, gènere, ...)

USUARI	SEMESTRE	ASSIGNATURA	NOTA
12345678	2021/2	05.554	NO
12345678	2021/2	05.562	A
24681357	2021/2	05.570	A
...	...	...	...

USUARI	DATA NAIXEMENT	GÈNERE
12345678	23/06/1981	H
24681357	01/12/1977	M
...	...	...

Operacions bàsiques

Pivot: al format **wide** hi ha una columna per a cada valor possible d'una variable (p.e. despesa mensual)

USUARI	GENER	FEBRER	...	DESEMBRE
12345678	125	120		200
13572468	150	220		250
...				

Noves
variables
clau, valor

USUARI	MES	VALOR
12345678	GENER	125
12345678	FEBRER	120
...	...	...
12345678	DESEMBRE	200
13572468	GENER	150
	...	...

El format **long** acostuma a ser el més adient per a moltes operacions amb les dades ⇒ hi ha una fila per a cada valor possible de la columna clau que s'usa com a pivot

Operacions bàsiques

Agregats (GROUP): a partir d'una o més files que satisfan un criteri (formen un grup), aplicar una operació sobre alguna variable

Operacions típiques

- Comptar el nombre ocurrencies / ocurrencies úniques
- Descriptors estadístics: mitjanes, màxims, mínims

Exemple: a partir de les notes d'un estudiant de cada semestre, podem generar un nou conjunt amb la nota mitjana de l'expedient, el nombre de semestres en actiu i el total d'assignatures matriculades i aprovades

Variables *dummy*

Objectiu: convertir una variable categòrica de N valors en N-1 variables binàries (0/1, presència/absència)

Exemple: si tenim una variable que indica el tipus de dispositiu que usa un estudiant amb els 5 valors *ordinador*, *laptop*, *tablet*, *mòbil*, *altre*, podem crear 4 variables *dummy* amb els noms *usa_ordinador*, *usa_laptop*, *usa_tablet*, *usa_mobil*, que tindran valor de 0 si aquest estudiant no usa aquest tipus de dispositiu i 1 si ho fa

No cal codificar els N valors, el valor per defecte absent s'acostuma a assignar a la categoria més popular o al valor de referència

Extracció de característiques

Objectiu: afegir valor al conjunt de dades mitjançant el càlcul de noves variables a partir de les existents

Exemple: a partir del pes i l'alçada es pot calcular l'índex de massa corporal (https://es.wikipedia.org/wiki/Índice_de_masa_corporal)

Exemple: a partir d'una col·lecció d'ítems de resposta d'una enquesta, calcular els factors més importants (mitjançant PCA)

Exemple: a partir dels logs de connexió al campus virtual, calcular el nombre de sessions de cada usuari

S'usen fórmules, mètodes estadístics o de mineria de dades

Descriptors estadístics

Objectiu: obtenir informació sobre la natura de les dades

Moda, Mitjana, Mediana: al voltant de quin valor o valors es distribueixen les dades

Variança, Kurtosis: com de disperses i esbiaixades estan les dades

Box-plot: visualització dels quartils i altres descriptors importants

Histograma: distribució dels valors possibles d'una variable

Correlació: mesura d'associació entre dues variables

Atenció: diferents conjunts de dades poden tenir els mateixos descriptors! <https://datascience.recursos.uoc.edu/drawmydata/>

Eines

Manipulació de PDFs

Tabula: extracció de taules i fitxers PDF

<https://tabula.technology/>

PDFsam Basic: fusió, extracció, rotació, etc., de documents PDF

<https://pdfsam.org/pdfsam-basic/>

XpdfReader: conversió de PDF a altres formats (p.e. text)

<https://www.xpdfreader.com/about.html>

Conversió de formats

DenCode: codificació i descodificació de text, nombres, dates, etc. en diferents formats

<https://decode.com/>

Mr. Data Converter: eina online per a convertir formats

<http://shancarter.github.io/mr-data-converter/>

Web scraping

Scrapy / BeautifulSoup: llibreries en Python per a l'extracció de continguts de pàgines web

<https://scrapy.org/>

<https://pypi.org/project/beautifulsoup4/>

rvest: llibreria en R per a la captura i anàlisi de pàgines HTML

<https://rvest.tidyverse.org/>

instant data: extensió pel navegador per tal de captar dades de pàgines web

<https://webrobots.io/instantdata/>

ParseHub: aplicació per a l'extracció de pàgines HTML

<https://www.parsehub.com/>

Eines de la línia de comandes

Des de la línia de comandes del sistema operatiu és possible realitzar algunes operacions bàsiques

Windows: des del Linux subsystem + Ubuntu (p.e.)


MacOS / GNU/Linux: des del terminal amb bash o zsh

cURL: eina per accedir a enllaços HTTP

iconv: conversió entre formats ISO, UTF, ...

csvkit: manipulació de fitxers CSV

jq: manipulació de fitxers JSON



R + RStudio + CRAN

R: llenguatge de programació orientat a la manipulació, anàlisi i visualització de dades

<https://www.r-project.org/about.html>

RStudio: entorn de desenvolupament en R

<https://posit.co/products/open-source/rstudio/>

CRAN: arxiu de paquets per a R orientats a resoldre problemes específics

<https://cran.r-project.org/web/views/>

Tidyverse

Tidyverse: col·lecció de paquets per a R orientats a la manipulació de dades

<https://www.tidyverse.org/packages/>

dplyr: operacions bàsiques amb taules

tidyr: manteniment de dades “endreçades” (*tidy data*)

ggplot2: generació de gràfics

Python

Python: llenguatge de programació de propòsit general molt usat en ciència de dades

<https://www.python.org/>

dataprep: mòdul per a la preparació de dades en Python

<https://dataprep.ai/>

pandas: llibreria completa per la manipulació, anàlisi i visualització de dades en Python

<https://pandas.pydata.org/>

Altres eines

Tableau Prep: eina visual per a la preparació de dades

<https://www.tableau.com/es-es/trial/tableau-prep>

DataWrangler: eina online per netejar i transformar dades

<http://vis.stanford.edu/wrangler/app/>

OpenRefine: eina avançada per a la manipulació i extracció de dades mitjançant filtres i fixers tipus CSV, JSON, RDF, XML, ...

<https://openrefine.org/>

TAGS: captura de tweets mitjançant Google Sheets

<https://tags.hawksey.info/> => des del canvi de Twitter a X funciona parcialment

Power Query: eina integrada en Excel per manipular dades

<https://learn.microsoft.com/es-es/power-query/power-query-what-is-power-query>

Per saber-ne més

Per saber-ne més

Piràmide DIKW: https://en.wikipedia.org/wiki/DIKW_pyramid

Tipus de dades: https://en.wikipedia.org/wiki/Data_type

Open Data: <https://opendatahandbook.org/guide/es/what-is-open-data/>

Fonts de dades: <https://datacatalog.worldbank.org/>

Cerca de dades: <https://datasetsearch.research.google.com/>

Llista d'APIs disponibles: <https://github.com/public-apis/public-apis>

El llenguatge SQL: <http://sqlfiddle.com/>

Línia de comandes: <https://link.springer.com/book/10.1007/978-1-4842-0121-3>

Descriptors estadístics:

<https://learning.oreilly.com/library/view/statistics-in-a/9781449361129/ch04.html>

EDA: https://en.wikipedia.org/wiki/Exploratory_data_analysis

