
Introducció al *deep learning* aplicat al processament del llenguatge natural

PID_00280551

Joaquim Moré López

Temps mínim de dedicació recomanat: 2 hores



Joaquim Moré López

L'encàrrec i la creació d'aquest recurs d'aprenentatge UOC han estat coordinats pel professor: Jordi Conesa Caralt

Primera edició: febrer 2021

© d'aquesta edició, Fundació Universitat Oberta de Catalunya (FUOC)

Av. Tibidabo, 39-43, 08035 Barcelona

Autoria: Joaquim Moré López

Producció: FUOC



Els textos i imatges publicats en aquesta obra estan subjectes –llevat que s'indiqui el contrari– a una llicència Creative Commons de tipus Reconeixement-Compartir igual (BY-SA) v.3.0. Podeu modificar l'obra, reproduir-la, distribuir-la o comunicar-la públicament sempre que en citeu l'autor i la font (Fundació per a la Universitat Oberta de Catalunya), i sempre que l'obra derivada quedi subjecta a la mateixa llicència que l'obra original. La llicència completa es pot consultar a <http://creativecommons.org/licenses/by-sa/3.0/es/legalcode.ca>

Índex

Introducció	5
1. Aspectes avantatjosos i crítics del <i>deep learning</i> en el PLN	7
1.1. Aspectes avantatjosos	7
1.1.1. Caràcter multipropòsit i interoperabilitat	7
1.1.2. Transferència de dades	8
1.1.3. Accessibilitat	9
1.1.4. Atenció	10
1.2. Aspectes crítics	11
1.2.1. Dependència dels desenvolupadors de programari	12
1.2.2. Transferència de dades amb biaixos	12
1.2.3. Manca de transparència en els resultats	14
1.2.4. Pobre poder explicatiu sobre la naturalesa del llenguatge	14
2. Exemples d'aplicació del <i>deep learning</i> en el PLN	15
2.1. <i>Deep learning</i> en la traducció automàtica	15
2.1.1. Presentació del cas d'ús	15
2.1.2. Arquitectura	15
2.1.3. Codificació	16
2.1.4. Descodificació	16
2.1.5. Resum del procés	16
2.2. <i>Deep learning</i> en la generació de <i>captions</i>	17
2.2.1. Presentació del cas d'ús	17
2.2.2. Interoperabilitat en la generació de <i>captions</i>	17
2.2.3. Accessibilitat en la generació de <i>captions</i>	18
2.2.4. Aprenentatge amb models de diferents fonts	18
2.2.5. <i>Transfer learning</i>	19
2.2.6. Dependència del programari	20
Resum	21
Glossari	22
Bibliografia	23

Introducció

El processament del llenguatge natural (PLN) ha experimentat un salt molt significatiu quan s'han aplicat mètodes de *deep learning*.

El reconeixement d'estructures abstractes que són la carcassa del significat d'una frase és fonamental en el PLN. Les peces de la carcassa són entitats físiques, ja siguin els sons del llenguatge parlat, ja siguin les lletres en el llenguatge escrit. Aquestes entitats físiques s'organitzen en estructures abstractes com les de la sintaxi. En les primeres dècades del PLN el reconeixement de les estructures abstractes es feia aplicant regles gramaticals sobre una seqüència de lletres o sons que conformaven les paraules. Quan es va veure que la implementació de regles gramaticals no podia evitar que el llenguatge s'escapés per les seves esclatxes, es va pensar que les paraules obeïen a un ordre intern que només la prova empírica amb moltes dades podia demostrar. Aquest ordre intern podia ser capturat amb els mateixos algoritmes predefinits de *machine learning* aplicats a altres camps. Per això es va passar a aplicar algoritmes estàndard de *machine learning* que no consideraven l'estructura sintàctica de la frase (mètodes *bag of words*, o BOW). No obstant això, les aplicacions del PLN a casos d'ús reals aviat van demostrar que els mètodes apriorístics, com són l'aplicació de regles gramaticals i d'algoritmes de *machine learning*, no eren suficients per modelar un ens tan complex i líquid com el llenguatge.

Després de constatar la insuficiència dels mètodes apriorístics, en els últims anys s'ha optat per aplicar mètodes de *deep learning* per la seva efectivitat en reconèixer abstraccions directament de les dades en brut, sense aplicar regles apriorístiques. Un cas d'ús conegut del *deep learning* és el reconeixement d'imatges, que suposa identificar entitats abstractes com *home*, *vehicle*, etc., mitjançant el reconeixement d'elements menys abstractes (figures, contorns, angles, etc.), que, al seu torn, requereixen el reconeixement d'unitats amb una abstracció mínima (píxels). A les xarxes neuronals, el reconeixement de conceptes abstractes es realitza descomposant aquesta tasca en diferents capes. Unes capes que formen una jerarquia de conceptes, des dels més simples als més complexos.

Al PLN, el nivell més simple correspon als *tokens* d'un text. Els *tokens* són les paraules, encara que en alguns casos també ho són els fonemes o les lletres que formen la paraula. Si prenem les paraules com a *tokens*, en un nivell superior hi ha les representacions dels seus significats, i en el nivell més alt hi hauria la traducció del text i també la polaritat positiva o negativa d'una opinió. És un model que s'acosta a la nostra intuïció de com el parlant entén un text.

D'altra banda, el comportament de les xarxes neuronals s'acosta a la intuïció que tenim sobre com aprenem i arribem a dominar una llengua. La capaci-

tat adaptativa i autocorrectora de les xarxes neuronals amb cada iteració fa que s'assemblin a estudiants d'una segona llengua. Estudiants que aprenen a adaptar-se a les variacions de context i desxifren el sentit adequat d'una paraula o una frase després d'haver corregit els seus errors d'interpretació passats.

Aquest mòdul està organitzat en dues parts. La primera presenta els avantatges, encara que també els aspectes més crítics, del *deep learning* aplicat al PLN. La segona part està dedicada a exemplificar els continguts de la primera part en dos casos d'ús, concretament la traducció automàtica i la generació automàtica de peus de foto. Aquest bloc segueix el fil argumental de la realització de projectes per part de l'empresa fictícia Sense&Suitability.

1. Aspectes avantatjosos i crítics del *deep learning* en el PLN

En aquest apartat exposarem els aspectes avantatjosos del *deep learning* que expliquen el gran salt que ha experimentat el PLN des del 2013, aproximadament. Després exposarem els aspectes que, a parer nostre, són crítics.

1.1. Aspectes avantatjosos

Ens centrarem en tres aspectes:

- El caràcter multipropòsit i la interoperabilitat dels mètodes de *deep learning*.
- La transferència de dades.
- L'atenció en les dades realment rellevants.

1.1.1. Caràcter multipropòsit i interoperabilitat

Una tasca de PLN pot utilitzar mètodes de *deep learning* que funcionen també per a altres tasques. La clau és trobar els objectius comuns de les tasques des d'un punt de vista més abstracte. La traducció automàtica amb xarxes neuronals ha inspirat la visió d'un d'aquests objectius comuns, que és la transformació d'unes dades d'entrada en unes dades de naturalesa diferent. Els sistemes de traducció automàtica basats en xarxes neuronals apliquen mètodes de *deep learning* per codificar els conceptes expressats en la llengua origen i descodificar-los en la llengua destí. Com assenyalen Vinyals i altres (2015):

For many years, machine translation was also achieved by a series of separate tasks (translating words individually, aligning words, reordering, etc.), but recent work has shown that translation can be done in a much simpler way using Recurrent Neural Networks (RNNs) and still reach state-of-the-art performance. An «encoder» RNN reads the source sentence and transforms it into a rich fixed-length vector representation, which in turn is used as the initial hidden state of a «decoder» RNN that generates the target sentence.

Aquests autors reconeixen que el disseny d'un flux amb unes dades d'entrada llegides per un codificador (*encoder*) i després transformades per un descodificador (*decoder*) ha inspirat el seu sistema de generació automàtica de peus de foto.

La codificació i la descodificació s'apliquen a dos tipus de dades:

- Dades que no es despleguen en una seqüència de temps.
- Dades que es despleguen en una seqüència de temps.

Un exemple d'interoperabilitat amb tots dos tipus de dades és la generació automàtica de peus de foto. A partir d'aquest moment, ens referirem als peus de foto i, per extensió, als textos que descriuen el contingut d'una imatge, com a *captions*, que és el seu terme en anglès.

La generació de *captions* amb mètodes de *deep learning* es produeix amb una xarxa neuronal encarregada de representar la imatge en termes de figures i relacions espacials entre elles. Les dades d'entrada són els píxels, que no es despleguen en una seqüència de temps. La representació de la imatge es codifica en l'última capa i és, al seu torn, l'*input* d'una altra xarxa neuronal encarregada de decodificar-la i traduir-la al llenguatge natural. El traductor transforma unes dades que no es despleguen en el temps (les figures i relacions espacials) en una frase les paraules de la qual sí que s'hi despleguen.

En canvi, els sistemes de traducció automàtica codifiquen i decodifiquen dades que es despleguen en el temps. Codifiquen el text en la llengua origen i el decodifiquen en un text de la llengua destí. Les paraules són les dades que segueixen una seqüència temporal i corresponen, cadascuna d'elles, a unitats de temps.

La visió abstracta de les frases com a seqüències de dades que es despleguen en el temps ha afavorit la transferència de mètodes de *deep learning* independents del domini, com són les RNN, al PLN. Tractarem aquest tema amb més detall a l'apartat 2.

Altres casos en els quals s'aplica el flux d'informació entre un codificador i un decodificador quan es tracten seqüències són els següents:

- reconeixement de la parla
- extracció del tema principal d'un text
- resums automàtics
- *chatbots*
- sistema de preguntes-respostes

1.1.2. Transferència de dades

Amb la transferència de dades el *deep learning* ha aconseguit resultats espectaculars. Un exemple d'això és el projecte The New Rembrandt*, en el qual van treballar desenvolupadors de Microsoft, historiadors de l'art de la Universitat de Delft i de museus holandesos i també analistes del Banc ING. L'objectiu del projecte consistia a pintar un retrat original com si Rembrandt l'hagués pintat gairebé quatre-cents anys després de la seva mort. Per a això, es va transferir el coneixement sobre els trets d'estil i coloració de l'artista així com dades sobre trets facials, d'edat, raça, etc. Aquest és un exemple de transferència de dades per generar una cosa nova a l'estil d'alguna cosa o d'algú.

* <https://bit.ly/30NP66r>

En el PLN hi ha desenvolupadors que donen a conèixer sistemes que amb xarxes RNN escriuen cançons a l'estil de The Beatles* o escriuen contes originals per a nens a partir de les faules d'Isop**. En aquests casos, les dades transferides són la representació numèrica dels textos d'aquests autors, sobre els quals els sistemes aprenen un model d'ús particular del llenguatge i prediuen la paraula que ve a continuació tenint en compte la seqüència generada fins al moment. La generació de textos amb sistemes que aprenen un model d'ús característic és un camp actiu de desenvolupament. Ara bé, el més interessant per al PLN i per a la intel·ligència artificial és la transferència de dades sobre l'ús general d'una llengua. Els models d'ús general són molt importants per al desenvolupament de la intel·ligència artificial, ja que indirectament modelen el sentit comú.

* <https://bit.ly/2SEcVti>
** <https://bit.ly/34J3ajg>

OpenAI

Una notícia publicada a *The Guardian* (<https://bit.ly/3d90MWy>) informava que OpenAI havia decidit no publicitar els progressos del seu sistema GPT2 per no donar pistes sobre com escriure notícies falses.

El sentit comú ha estat l'assignatura pendent de la intel·ligència artificial, per ser difícil de modelar amb regles i constructes formals lògics. A la intel·ligència artificial, l'adagi «el sentit comú és el menys comú dels sentits» és realment cert. Afortunadament, els models d'ús del llenguatge contribueixen a interpretar els textos pel sedàs del sentit comú i l'aplicació de models del llenguatge fets amb *deep learning*, com BERT, ha suposat un avanç espectacular en el desenvolupament del PLN i de la intel·ligència artificial en general. Sobre models BERT parlarem al mòdul «Implementació del *deep learning* aplicat al processament del llenguatge natural». De moment, direm que els models de tipus BERT permeten tenir representacions numèriques de les paraules segons el context en què apareixen. La conseqüència és que els sistemes aborden molt millor reptes difícils per al PLN que ens semblen obvis per sentit comú; per exemple, distingir el sentit de la paraula *brutal* en el context «La sèrie és brutal. Te la recomano», del sentit de la mateixa paraula en el context «S'ha comès un brutal assassinat».

1.1.3. Accessibilitat

Les xarxes neurals funcionen amb procediments purament matemàtics, i aquesta és la clau de la seva transferència a diferents aplicacions i dominis. Sorprenentment, la complexitat matemàtica dels procediments del *deep learning* no és un problema per a molts investigadors i desenvolupadors que pertanyen a dominis diversos i que no tenen la formació matemàtica per entendre i, encara menys, desenvolupar una xarxa neuronal des de zero. La prova d'això és que els lingüistes computacionals que venen de la filologia ara són els primers que executen *scripts* preparats per resoldre un aspecte del PLN amb mètodes de *deep learning*.

La facilitat amb què s'han incorporat lingüistes computacionals al *deep learning*, tot i no tenir una formació prèvia en enginyeria informàtica, es deu en gran part a l'existència de *frameworks* de codi lliure com TensorFlow, Keras, Pytorch, etc. Aquests *frameworks* estan pensats perquè qualsevol que tingui un mínim de coneixement del que fa una xarxa neuronal i tingui una mica

clares les capes on desplegar una tasca pugui muntar una aplicació de *deep learning*. No cal comprendre completament el funcionament dels mòduls ni les matemàtiques en què se sustenten. L'usuari crida els components de la xarxa neuronal, generalment estructurats al voltant d'una capa d'inserció de l'*input*, una capa de codificació i una capa de decodificació, i ajusta les dades al cas d'ús. De la resta s'ocupen els mòduls del *framework*. A més, hi ha un gran nombre de blocs que publiquen *scripts* d'exemple que expliquen com s'utilitzen aquests *frameworks* per a casos d'ús tradicionals en PLN, com el *sentiment analysis*.

És significatiu veure com en blogs com *Medium* diàriament es publiquen breus entrades que expliquen a un públic tècnic, però multidisciplinari, com fer aplicacions d'intel·ligència artificial que són molt atractives. Entrades que es poden llegir en deu minuts expliquen el codi dels ja comentats compositors de cançons i contes a l'estil d'un autor. A més, expliquen el codi de recomanadors de música, resumidors automàtics, un detector de notícies falses, un assistent tipus Alexa de preguntes i respostes, i altres aplicacions espectaculars –tot i que encara força millorables–, com les que escriuen una història inspirada en una imatge*. El codi de moltes d'aquestes aplicacions està disponible a Github. La conseqüència d'això és que el PLN s'està popularitzant i va despertant més interès. Aquests nivells d'interès i popularització contrasten amb el poc interès que suscita el PLN fora de l'acadèmia des dels seus inicis fins al 2014 aproximadament, llevat de la traducció automàtica.

* <https://bit.ly/34zZlao>

Ara bé, de què li serveix l'accessibilitat a un programari que facilita la tasca si les dades necessàries per entrenar els sistemes no són accessibles? Per sort, hi ha corpus extensos sense restriccions d'ús, com la Viquipèdia, i dades que companyies com Google, Facebook i Microsoft han cedit, derivades dels seus projectes de *deep learning*. Quan els desenvolupadors no disposen de suficients dades, llavors transfereixen aquestes dades cedides a la comunitat al seu cas d'ús concret. Recorren a l'anomenat *transfer learning***.

En el segon apartat exemplifiquem el *transfer learning* en la generació de peus de foto. També és un recurs utilitzat en la traducció automàtica quan es disposa de pocs documents per entrenar perquè la llengua destí és una llengua minoritària. Imaginem que volem traduir de l'anglès al gallec. La transferència d'un model de traducció anglès-francès a un sistema de traducció automàtica anglès-gallec causa un significatiu augment de la qualitat de les seves traduccions***.

** <https://bit.ly/2GueQ1b>

*** <https://bit.ly/3nx5Hpe>

1.1.4. Atenció

Quan els procediments de PLN es basen en regles, el sistema sovint s'endinsa en el reconeixement d'estructures complexes que no són la part més important i crucial per comprendre el text. Això sol succeir amb analitzadors sintàctics que dediquen un cost computacional molt gran per resoldre una oració de relatiu molt complexa i després no són capaços d'associar-la al nom al qual complementa, que és, probablement, la paraula en què el receptor posa

més atenció. També ocorre amb la resolució de referències anafòriques. Entre l'antecedent i la referència anafòrica pot haver-hi estructures sintàctiques tan complexes que l'analitzador no «recordi», per dir-ho d'alguna manera, quin sintagma nominal és l'antecedent correcte d'un pronom.

Les relacions de llarga distància han estat també un problema per als procediments de PLN basats en *machine learning*. El mètode *bag of words* suposa no controlar les relacions de distància entre elements, i en mètodes tipus Word2Vec, encara que si ja tenen en compte aquestes relacions posant les paraules en context, la finestra de paraules dels contextos rarament abasta la relació entre un antecedent i una referència anafòrica. En l'àmbit del *deep learning* s'han implementat xarxes LSTM per la seva capacitat de mantenir en memòria els antecedents malgrat la distància entre aquests i les seves referències. No obstant això, com s'explica al mòdul «Implementació del *deep learning* aplicat al processament del llenguatge natural», les xarxes LSTM processen la seqüència de la frase en una sola direcció, generalment d'esquerra a dreta, i hi ha fenòmens com la catàfora en els quals la relació a distància entre antecedent i referent es produeix precisament en la direcció contrària.

En el mateix mòdul explicarem com s'han implementat mètodes de *deep learning* que modelen l'atenció que posem a identificar l'antecedent d'una relació anafòrica. Aquests mètodes són els anomenats *mecanismes d'atenció*. L'important és que aquests mecanismes d'atenció modelen l'atenció que posem en les paraules que ens ajuden a interpretar el significat correcte d'un terme. No us ha passat que entenem una paraula desconeguda sense necessitat de buscar-la al diccionari perquè parem esment en una o més paraules que ens ajuden a entendre-la? De la mateixa manera, les paraules del context ens ajuden a desambiguar el sentit d'una paraula. Per exemple, *assassinat* ens ajuda a desambiguar el sentit de *brutal*.

Amb la codificació d'una frase posant èmfasi en els elements que atreuen més l'atenció, és possible reconèixer similituds entre frases i relacionar-les per ser una la resposta a l'altra o per ser la inferència a una hipòtesi. Amb els mecanismes d'atenció, l'impacte del PLN en el desenvolupament de la intel·ligència artificial ha estat molt potent.

1.2. Aspectes crítics

En aquest subapartat presentarem alguns aspectes crítics que mereixen ser comentats. Són els següents:

- dependència dels desenvolupadors de programari
- transferència de dades amb un biaix cultural, ideològic, etc.
- falta de transparència en els resultats
- pobre poder explicatiu sobre la naturalesa del llenguatge

1.2.1. Dependència dels desenvolupadors de programari

Companyies líders en la millora de procediments i productes basats en *deep learning* com Google ofereixen els seus *frameworks* i mòduls especialitzats en casos d'ús concrets. Es tracta de mòduls *open source*, lliures, sense restriccions en les seves llicències. Ja hem comentat els avantatges d'aquests mòduls perquè permeten ser utilitzats per desenvolupadors que no tenen un coneixement complet de l'aparell matemàtic sobre els quals es basen. Ara bé, és obvi que cal adaptar les dades a les condicions i especificacions d'aquests mòduls.

1.2.2. Transferència de dades amb biaixos


Actualment, en el marc de la intel·ligència artificial, i del *deep learning* en particular, hi ha un debat sobre els biaixos ideològics de les dades d'entrenament. Ens referim a dades d'entrenament precalculades a partir de textos que no són sensibles respecte a les minories, que assumeixen les desigualtats de gènere, etc. Si es transfereixen aquestes dades, els biaixos ideològics i els prejudicis culturals es van perpetuant. Fins i tot els biaixos i prejudicis poden augmentar, ja que la confiança cega en determinats serveis provoca que la gent que no discriminava ara ho faci inconscientment.

Per exemple, hem comprovat si hi ha biaixos en la base de dades d'Open Images*, de Google, amb la qual s'entrenen generadors de *captions*. A les imatges les figures mantenen relacions de posició entre elles que s'etiqueten amb preposicions. Per exemple, a les imatges en les quals una persona està pujada a una moto, la relació entre la persona i la moto s'etiqueta amb ON.

* <https://bit.ly/2Gu4Ftx>

A continuació mostrem la distribució de la relació ON entre les figures.

Figura 1. Distribució de la relació ON entre diferents figures en les imatges d'Open Images



Crida l'atenció que hi hagi, per exemple, moltes més imatges d'homes pujats sobre una bicicleta, una moto o un cavall que no pas dones. Per tant, la transferència de les dades entrenades amb aquestes imatges mantenen la idea preconcebuda que conduir una moto és cosa més d'homes que de dones.

Casos de biaix de gènere els ofereix molt sovint la traducció automàtica. Sobre tot quan es tradueix d'una llengua que no distingeix gènere masculí i femení a una llengua que sí que ho fa*. La traducció amb un pronom en la forma masculina quan no hi ha suficients dades en la llengua origen que ho justifiqui és bastant freqüent.

* <https://bit.ly/3iycMIN>

Un altre problema és la transferència de dades del present per reconèixer el passat. Amb un exemple de generació de *captions* s'entendrà millor. Els generadors de *captions* s'entrenen amb multitud de fotografies, juntament amb les seves *captions*, que reproduïxen la vida quotidiana actual. Si transferim les dades entrenades per a aquests sistemes a una xarxa neuronal que descriu una pintura en la qual apareix sant Jordi matant el drac, és probable que la descripció digui que és un home muntat en una moto amb un gos saltant al seu costat**.

** <https://bit.ly/36lUv2D>

1.2.3. Manca de transparència en els resultats

Els resultats que s'obtenen amb les xarxes neuronals poden ser molt satisfactoris, però sovint és difícil explicar per què s'obtenen. Per exemple, sobre els models BERT, introduïts al subapartat 1.1.2 i que s'expliquen més extensament al mòdul «Implementació del *deep learning* aplicat al processament del llenguatge natural», s'ha creat un camp que alguns han batejat com a *Bertologia**. La Bertologia tracta de desentranyar per què, en determinades tasques, els models BERT funcionen millor que els procediments tradicionals. Altres temes són de caràcter més especulatiu, com preguntar-se si el canvi de valor d'un paràmetre realment afecta la seva eficàcia.

* <https://bit.ly/36OQdqz>

1.2.4. Pobre poder explicatiu sobre la naturalesa del llenguatge

Un aspecte relacionat amb l'anterior és la incapacitat dels sistemes de *deep learning* per aportar llum sobre la naturalesa del llenguatge. Això és una cosa que apunta Noam Chomsky, el gran teòric del llenguatge, en una entrevista amb Lex Fridman.

What deep learning is doing is taking huge numbers of examples and finding some patterns [...] but we have to ask here a certain question: is it engineering or is it science? [...] science in the sense that it's trying to understand something about elements of the world [...] Does it tell you anything about human language? Zero, nothing.

Per a Chomsky, el *deep learning* és una eina d'enginyeria útil, però que és incapaç d'explicar la naturalesa del llenguatge. El motiu és que sempre aprèn de frases gramaticals ben formades. Però es comportaria igual amb dades no gramaticals. En canvi, si fos una ciència capaç d'explicar la naturalesa del llenguatge, també seria capaç d'explicar per què una frase està mal formada.

Enllaç d'interès

L'entrevista entre Noam Chomsky i Lex Fridman es pot veure aquí:
<https://bit.ly/2GJCkz0>

2. Exemples d'aplicació del *deep learning* en el PLN

Per il·lustrar els aspectes explicats a l'apartat anterior, ara parlarem de dues aplicacions del *deep learning* en el PLN. Primer explicarem un traductor automàtic anglès-alemany. Seguidament, la generació automàtica de *captions*.

Tots dos casos tenen en comú la codificació d'una estructura de dades que es descodifica en una altra estructura de dades. En la traducció automàtica, la codificació-descodificació es realitza entre dues estructures de la mateixa naturalesa, que són oracions en una llengua. En la generació de *captions*, hi ha una estructura que es transforma en una altra de naturalesa diferent. L'estructura origen representa el contingut d'una imatge i l'estructura final és l'expressió d'aquest contingut en llenguatge natural.

2.1. *Deep learning* en la traducció automàtica

2.1.1. Presentació del cas d'ús

L'empresa Sense&Suitability accepta l'encàrrec de desenvolupar un prototip de traductor automàtic de frases curtes de l'alemany a l'anglès. L'encàrrec prové dels responsables d'una plataforma que crea bases de dades amb frases curtes en una llengua juntament amb les seves traduccions en altres llengües. L'objectiu de l'encàrrec és demostrar que aquestes bases de dades són útils per crear un traductor automàtic en un període curt de temps aplicant mètodes de *deep learning*.

La creació d'aquest prototip està explicada al *notebook* «Traducció automàtica amb *deep learning*».

2.1.2. Arquitectura

El Peter, que és el coordinador del grup de lingüística computacional de l'empresa, pregunta al Joseph, l'especialista en *deep learning*, si el projecte de fer un traductor automàtic de frases curtes és factible. El Joseph li contesta que quant a prototip sí que ho és. La seva idea consisteix a realitzar aquest prototip amb una arquitectura Seq2Seq (seqüència a seqüència), organitzada en dos mòduls:

- un codificador de la seqüència de paraules en la llengua origen
- un descodificador en una seqüència de paraules en la llengua destí

2.1.3. Codificació

Per a la codificació, el Joseph pensa utilitzar una capa LSTM per capturar dependències a llarga distància. En aquesta capa, les paraules de la frase en la llengua origen es representen com a vectors i segueixen una seqüència temporal. Per tant, la capa posa les paraules en context segons l'ordre en el qual apareixen.

Les llibreries de *deep learning* com Keras requereixen que els vectors de les paraules tinguin la mateixa longitud. El *notebook* mostra com les paraules es representen amb vectors que tenen la mateixa longitud amb el procediment anomenat *padding*.

El LSTM de l'*input* processa la seqüència de manera que genera uns vectors d'estat. Aquests vectors serveixen de context o condicionant perquè el descodificador predigui l'element que cal generar.

2.1.4. Descodificació

Una altra capa LSTM prediu una paraula de la seqüència destí, segons les paraules que les precedeixen. Per a això, té una capa densa de predicció amb la funció d'activació softmax. És important assenyalar que en l'estat inicial agafa els vectors d'estat del codificador, que és com obté informació sobre el que ha de generar. Així, el descodificador aprèn a generar els elements destí, donats uns elements precedents, condicionats per la seqüència d'*input*.


2.1.5. Resum del procés

El Joseph resumeix el procés de la manera següent:

- Codificar l'*input* (seqüència en la llengua origen) en vectors d'estat.
- Començar amb una seqüència destí de mida 1 (símbol d'inici de seqüència).
- Presentar al descodificador els vectors d'estat i la seqüència destí de mida 1.
- Obtenir la següent paraula segons el càlcul softmax en la predicció.
- Concatenar aquesta paraula a la seqüència destí.
- Repetir el procés fins a generar el símbol de final de seqüència o arribar al límit de longitud de paraules.

La figura 2, que il·lustra l'arquitectura d'un traductor anglès-francès, resumeix aquest procés.

Figura 2. Procés Seq2Seq en la traducció automàtica (anglès-francès)



Font: <https://blog.keras.io/a-ten-minute-introduction-to-sequence-to-sequence-learning-in-keras.html>

2.2. Deep learning en la generació de captions

2.2.1. Presentació del cas d'ús

L'empresa Sense&Suitability accepta l'encàrrec de desenvolupar un generador de *captions*, que s'inseriran en el codi HTML de pàgines web preparades per ser consultades per persones invidents. Les descripcions seran el contingut de les etiquetes *Alt*, de manera que els invidents puguin saber el que es representa en una imatge que no poden veure.

2.2.2. Interoperabilitat en la generació de captions


El Peter, el coordinador del grup de lingüística computacional de l'empresa, es reuneix amb el Joseph, l'enginyer informàtic especialista en *machine learning* i *deep learning*. El Peter li demana que faci un estudi dels treballs realitzats sobre generació de *captions* i presenti una proposta metodològica abordable amb els recursos que tenen.

Al cap d'una setmana, el Joseph presenta al Peter aquesta proposta, que es resumeix en la figura 3. S'hi il·lustra la interoperabilitat de dos tipus de xarxes: les xarxes neuronals CNN i les xarxes RNN.

El Joseph explica que la xarxa de tipus CNN s'ocupa de crear la representació del contingut de la imatge de la fotografia. Aquesta representació és l'*input* de la xarxa RNN, especialitzada a generar el text de la descripció com una seqüència de paraules ordenades temporalment. En altres paraules, la xarxa de tipus CNN és el codificador i la xarxa RNN és el descodificador. El codificador llegeix la imatge i crea una representació interna, mentre que el descodificador llegeix aquesta representació interna i genera la descripció textual.

Lectura recomanada

Per entendre per què les xarxes CNN són adequades per representar el contingut de la fotografia, és recomanable llegir el capítol 7 del llibre *Deep Learning. Principios y fundamentos*.

Figura 3. Xarxes CNN i RNN intervenint en el *workflow* de la generació de *captions*

Font: www.packtpub.com y <https://medium.com/swlh/image-captioning-in-python-with-keras-870f976e0f18>

Segons el Joseph, es pot aprofitar la flexibilitat de les estructures per capes. Es pot reutilitzar una xarxa neuronal que classifica imatges traient l'última capa, encarregada de fer la classificació, i transferint la representació del contingut de la imatge a la xarxa neuronal encarregada de generar la descripció.

2.2.3. Accessibilitat en la generació de *captions*

El Peter demana al Joseph que prepari documentació que demostrï la possibilitat de dur a terme un *workflow* com el que es presenta a la figura 3. El Joseph no triga a trobar documentació que conté codi explicatiu de com fer un generador de *captions* amb el *framework* Keras. El Peter troba aquest codi fàcil d'entendre i de provar per a una persona amb uns coneixements mínims de Python i de fonaments de *deep learning*.

Keras ofereix totes les facilitats per implementar xarxes CNN i RNN i integrar-les en un *workflow* com el presentat. A més, és una llibreria preparada per carregar *datasets* molt grans per dur a terme l'entrenament, com les imatges i els *captions* de la base de dades de Flickr*. Aquest *dataset*, de lliure accés i processament, conté vuit mil imatges amb cinc *captions* per a cada imatge. Els cinc *captions* són cinc variants de descripció de la mateixa imatge. Ara bé, la llibreria està preparada per carregar *datasets* més grans, com un *dataset* també de Flickr però amb trenta mil imatges, o MS-COCO amb cent vuitanta mil imatges. Aquests *datasets* també són oberts.

* Podeu veure la referència a aquest *dataset* a <https://bit.ly/36QysqT>.


2.2.4. Aprenentatge amb models de diferents fonts

El Peter li comenta al Joseph que entén que una CNN generi una representació de la imatge i que la representació textual es faci amb una RNN, però no acaba de veure com el sistema pot aprendre a generar *captions* combinant dades de

naturalitat tan diferent com són els trets d'una imatge i les paraules d'una llengua. El Joseph li ho explica amb l'esquema que apareix a la figura 4.

Figura 4. Intervenció d'un model d'imatges amb un model de *captions*

Input 1



Font: <https://bit.ly/36NSJgY>

L'esquema il·lustra un model d'integració anomenat *merge*. El model *merge* combina la codificació de la imatge, feta amb una CNN, amb la codificació del *caption* que s'ha generat fins a un moment t , també anomenat *caption parcial*. La codificació de la descripció parcial es fa amb la RNN. La combinació d'aquestes dues codificacions serveix perquè un descodificador generi la següent paraula i s'obtingui un altre *caption* parcial i així successivament. La figura següent il·lustra aquest procés.

Referència bibliogràfica

M. Tanti; A. Gatt; K. P. Camilleri (2018). *Where to put the image in an image caption generator*. Natural Language Engineering. Cambridge University Press (CUP).

Figura 5. Intervenció d'un model d'imatges amb un model de *captions*

i	Xi		Yi
	Image feature vector	Partial Caption	Target word
1	Image_1	startseq	the
2	Image_1	startseq the	black
3	Image_1	startseq the black	cat
4	Image_1	startseq the black cat	sat
5	Image_1	startseq the black cat sat	on
6	Image_1	startseq the black cat sat on	grass
7	Image_1	startseq the black cat sat on grass	endseq

Font: <https://bit.ly/2sef833>

2.2.5. Transfer learning

El processament de milers d'imatges amb N *captions* per a cadascuna requereix un entorn de computació molt potent. Si abordar la generació de *captions* suposés fer un model d'imatges des de zero, els costos en infraestructura, temps i recursos humans per dur-ho a terme seria molt considerable, fins i tot inabordable per a companyies modestes. Per això és important obtenir el contingut de les imatges amb un model preentrenat. Keras ofereix un model important, el de l'Oxford Visual Geometry Group, conegut com a VGG model, que va guanyar la competició d'ImageNet el 2014.

En l'entrenament, la codificació consisteix a vectoritzar tant les imatges com els seus *captions* i calcular els pesos. En el *notebook* «Generador de *captions*», la codificació d'imatges no es fa de zero, sinó gràcies al *transfer learning*. El sistema es nodreix amb vectors i pesos ja preentrenats en el VGG. Quant a la codificació dels textos, al mòdul «Implementació del *deep learning* aplicat al processament del llenguatge natural» tractarem amb més detall l'aplicació del *transfer learning*.

2.2.6. Dependència del programari

Keras, com altres llibreries especialitzades en *deep learning*, fixa una mida per als vectors. En el cas que ens ocupa, cal que es produeixi un redimensionat adequat a les condicions de la llibreria.

D'altra banda, la llibreria requereix que els *captions* amb els quals s'entrena la xarxa tinguin unes etiquetes que marquin l'inici i el final de seqüència. Quan es tracta de *captions*, les etiquetes es col·loquen al principi i al final.

Resum

En aquest mòdul hem vist una introducció al *deep learning* aplicat al processament del llenguatge natural. Al principi hem destacat que el *deep learning* és capaç de reconèixer estructures molt abstractes a partir de dades amb un nivell d'abstracció menor. Una capacitat que s'acosta a la dels humans, que són capaços de tenir una representació conceptual d'una frase per mitjà d'elements físics com les lletres o els sons. Una altra capacitat similar a la dels humans és la capacitat adaptativa i autocorrectora a l'hora d'aprendre un model del llenguatge.

A continuació hem comentat els aspectes avantatjosos de l'aplicació del *deep learning* al processament del llenguatge natural. En primer lloc, hem considerat com a aspecte avantatjós la interoperabilitat dels sistemes, que, encara que el seu domini concret d'aplicació és diferent, tenen un objectiu central: codificar unes dades d'entrada i descodificar-les en dades de diferent naturalesa. Ho hem exemplificat veient les similituds entre un sistema de traducció automàtica i un sistema de descripció automàtica d'imatges (*caption generator*).

Altres avantatges que hem comentat que tenen un impacte no només en el processament del llenguatge natural sinó també en la intel·ligència artificial són, d'una banda, la facilitat de transferència de dades diferents en un flux d'informació metodològicament estàndard (e. g., RNN) i, d'altra banda, la capacitat d'identificar les dades –en el nostre cas, les paraules– més significatives en les quals se centra la nostra atenció. Un altre avantatge que cal destacar és la creació de paquets de programari dissenyat perquè siguin utilitzats per tècnics de diferents àmbits, sense necessitat de tenir coneixements extensos de l'aparell matemàtic en què es basen.

També s'han plantejat els aspectes crítics, que són la dependència del programari, els perills de transferir dades amb biaix ideològic, etc. A més, hem exposat les objeccions de lingüistes teòrics, com la falta de transparència en els resultats i el pobre poder explicatiu sobre el llenguatge.

Finalment, hem explicat dos exemples d'aplicació del *deep learning* al processament del llenguatge natural. El primer ha estat la creació d'un traductor automàtic. El segon ha estat un *caption generator*. Tots dos han estat explicats seguint el fil argumental de dos projectes desenvolupats per la fictícia empresa Sense&Suitability. El codi d'aquesta implementació està als *notebooks* «Traducció automàtica amb *deep learning*» i «Generador de *captions*».

Glossari

codificador *m* Xarxa neuronal que crea una representació de l'*input* en forma de vector o tensor.

descodificador *m* Xarxa neuronal que pren la representació del codificador per generar un *output*

mecanismes d'atenció *m* Mètode de *deep learning* que determina les paraules que mereixen més atenció a l'hora d'interpretar el significat d'una paraula.

referència anafòrica *f* Referència d'un element del text –com un pronom– a un altre que ha aparegut anteriorment, denominat antecedent. Quan l'element referit apareix després es tracta d'una *catàfora*.

transfer learning *m* Mètode de *machine learning* en el qual un model desenvolupat per a una tasca es reutilitza com a punt de partida per crear un model per a una altra tasca.

Bibliografia

Atienza, Rowen (2017). *LSTM by Example using Tensorflow*
[en línia]. <<https://towardsdatascience.com/lstm-by-example-using-tensorflow-feb0c1968537>>

Brownlee, Jason (2017). *Deep Learning for Natural Language Processing. Develop Deep Learning Models for your Natural Language Problems* [en línia]. Machine Learning Mastery.

Brownlee, Jason (2017). *A Gentle Introduction to Transfer Learning for Deep Learning*
[en línia]. <<https://machinelearningmastery.com/transfer-learning-for-deep-learning/>>

Öktem, Alp (2019). *Transfer Learning Approaches for Machine Translation*
[en línia]. <<https://bit.ly/33JFdJb>>

Vinyals, Oriol; Toshev, Alexander; Bengio, Samy; Erhan, Dumitru (2015). *Show and Tell: A Neural Image Caption Generator*. ICML.

Zhou, Sharon (2018). *Has AI surpassed humans at translation? Not even close!*
[en línia]. <<https://bit.ly/3iEOXIN>>

