

Deep Learning per a l'anàlisi de textos

PRA2

Instruccions

La segona pràctica de l'assignatura, PRA2, de Minería de textos està dissenyada per aplicar el que s'ha après als mòduls de: 'Conceptes bàsics de Deep Learning per aplicar-los al processament del llenguatge', 'Com aplicar aprenentatge profund all processament del llenguatge?' i 'Com detectar i enllaçar entitats anomenades?'

La PRA2 consta de dues parts: 1) traducció automàtica de textos, i 2) detecció i classificació d'entitats. Com a punt de partida, cada estudiant haurà d'escollir dos arxius:

- Un dataset de textos (frases) en dos idiomes, per utilitzar-los a la primera part de la PRA (traducció automàtica de textos). El dataset escollit ha de tenir com a **idioma origen de traducció l'anglès**.
- Un altre dataset anotat amb entitats i que l'usarem per a la segona part de la PRA (detecció i classificació d'entitats).

Per a l'anàlisi de textos, inicialment, es requereix l'aplicació d'algorismes senzills de preparació de dades, per a seguir amb algorismes més sofisticats, orientats a:

- Implementar i aplicar algorismes d'aprenentatge profund per entrenar models de traducció automàtica de textos.
- Implementar i aplicar algorismes per a la detecció i classificació d'entitats anomenades.
- Aplicar algorismes d'*entity linking* per a connectar entitats anomenades a les seves respectives descripcions semàntiques.

La realització d'aquesta pràctica es realitzarà mitjançant la consecució de diferents passos, com es comenta a continuació.

Primer pas: identificació de datasets

Abans d'iniciar el desenvolupament de la PRA2, haureu de triar dos arxius. El primer ha de tenir parells de textos (frase en idioma origen -anglès-, frase en idioma destí, -traducció-). El segon arxiu servirà per a entrenar un model de detecció i classificació d'entitats (NER)

Per a la selecció de conjunts de dades **es recomana considerar els criteris següents:**

- El primer conjunt de dades (traducció automàtica), haurà de tenir **almenys 50.000 parelles de text en idioma origen i destí**; podeu triar la parella d'idiomes que us sembli més interessant, partint de la base que l'idioma origen ha de ser **anglès**. Com més dades sempre és millor, però això és una PRA, no un desenvolupament per a posar a producció, i no tindrem els recursos maquinari per fer experiments amb moltes dades.
- El segon conjunt de dades ha de ser un dataset anotat a nivell d'entitats.

En general per a datasets de traducció automàtica, es poden utilitzar repositoris de dades públics o oberts, i pots prendre com a referència els repositoris següents.

- <https://tatoeba.org/ca/downloads>
- <https://opus.nlpl.eu/>

Per a la part de l'anotació d'entitats anomenades, també hi ha diversos repositoris. Els més comuns estan relacionats amb CONLL03, però n'hi ha d'altres, que han de ser adaptats a les necessitats de l'eina d'entrenament i detecció/classificació, com ara els que podeu trobar a:

- <https://github.com/juand-r/entity-recognition-datasets>

Segon pas: realitzar l'activitat

Per a realitzar la pràctica haureu d'implementar un notebook que faci les següents tasques:

1) **Traducció Automàtica (70%)**. En aquesta part es duran a terme diferents activitats:

1. Traducció automàtica amb *custom embeddings* (45%)

- Triar un dataset i analitzar-ho breument. Es realitzarà el pre-processament i la neteja del seu text i es prepararan les seves dades per a la seva posterior utilització. El notebook haurà de mostrar, per a cada transformació realitzada, un exemple que mostri els canvis realitzats. Algunes de les transformacions que es podran realitzar són la conversió de text a minúscules i l'adequació al format de la tasca. (10%)
- Es definirà el model d'*encoder-decoder* i s'entrenarà el model de traducció. (20%)
- S'experimentarà amb diferents valors de grandària de vectors d'*embedding* per a entendre el seu efecte sobre els resultats que s'obtenen. (15%)

2. Traducció automàtica amb *embeddings preentrenats* (25%)

- Es carregarà els *embeddings* de GloVe i s'entrenarà un altre model de traducció automàtica (10%)
- Anàlisi de resultats i diferència de models entrenats (15%)

2) **Detecció de NERC i NEL (30%)**. En aquesta part, després de triar un dataset, a partir de spacy, entrenarem un model de detecció de NER. Finalment, s'aplicaran algorismes de *linking* per a explorar com els termes detectats per la funció NER s'enllacen amb Wikidata.

- Detecció NER (20%)**: Elecció de dataset, separació en conjunts d'entrenament, test i dev per a l'entrenament de model de detecció i classificació d'entitats (NER). Aplicació de spacy per a l'entrenament d'un model de classificació d'entitats i adaptació de corpus. Finalment, avaluació del model.
- NEL (10%)**: En aquest apartat es desenvoluparà un algorisme que mitjançant la crida a Wikidata, busqui els enllaços d'algunes de les entitats detectades, en el pas anterior.

Fitxers proporcionats

Per a realitzar la PRA2 es proporcionen els següents fitxers:

- Enunciat_PRA2.ipynb**: Enunciat de la PRA2 en format ipynb. Aquí trobareu l'especificació dels exercicis que haureu de realitzar en l'activitat.
- PRA2_Anàlisi de resultats**: Enunciat de les preguntes d'anàlisi plantejades que haureu de resoldre per a cadascuna de les tasques realitzades.
- Exemple-PRA2.html**: Fitxer d'exemple que conté les sortides d'alguns dels exercicis proposats per a un cas sobre el qual s'usa un dataset de traducció anglès-alemany. El seu objectiu és orientar el desenvolupament del treball propi.

Lliurables

El lliurament d'aquesta PRA es realitzarà mitjançant tres documents:

- **Fitxer en format ipynb:** Aquest notebook contindrà el codi de les tasques plantejades. Haurà de seguir el format de l'enunciat proporcionat, on s'especificaran totes les activitats a realitzar per a cadascuna de les tasques.
- **Fitxer en format html:** Aquest document serà la impressió en format html del notebook realitzat.
- **Fitxer d'anàlisi dels resultats:** Aquest document haurà de contenir informació sobre l'activitat realitzada, bàsicament informació sobre el dataset utilitzat i sobre totes les tasques realitzades. Els estudiants hauran de contestar algunes preguntes de reflexió plantejades per a cadascuna de les tasques proposades. Les preguntes a respondre es detallaran en el document d'enunciat proposat.

Criteris de valoració

En aquesta activitat, es valorarà tant la competència implementant solucions que processin textos, com la capacitat de comprensió i anàlisi en l'àmbit del processament de text. Seguint aquest precepte, la nota final de l'activitat es compondrà a partir del 70% de la nota obtinguda en el notebook i el 30% de la nota obtinguda en el document d'anàlisi. Serà obligatori lliurar tots dos documents. Cada exercici té indicat en l'enunciat el seu pes en la valoració final.

Propietat intel·lectual

Al presentar una pràctica que faci ús de recursos aliens, s'ha d'afegir a la pràctica un document en què es detallin tots ells, especificant el nom de cada recurs, l'autor, el lloc on es va obtenir i el seu estatus legal: si l'obra està protegida pel copyright o s'acull a alguna altra llicència d'ús (Creative Commons, llicència GNU, GPL etc.). L'estudiant haurà d'assegurar-se que la llicència que sigui no impedeix específicament el seu ús en el marc de la pràctica. En cas de no trobar la informació corresponent, haurà d'assumir que l'obra està protegida pel copyright.

Serà necessari, a més, adjuntar els fitxers originals quan les obres utilitzades siguin digitals, i el seu codi font, si així correspon.