
Deep learning **per a l'anàlisi de** **sentiments**

PID_00270817

Emília Garcia Casademont

Temps mínim de dedicació recomanat: 2 hores



Universitat
Oberta
de Catalunya

Emília Garcia Casademont

L'encàrrec i la creació d'aquest recurs d'aprenentatge UOC han estat coordinats pel professor: Jordi Conesa Caralt

Primera edició: febrer 2021

© d'aquesta edició, Fundació Universitat Oberta de Catalunya (FUOC)

Av. Tibidabo, 39-43, 08035 Barcelona

Autoria: Emília Garcia Casademont

Producció: FUOC



Els textos i imatges publicats en aquesta obra estan subjectes –llevat que s'indiqui el contrari– a una llicència Creative Commons de tipus Reconeixement-Compartir igual (BY-SA) v.3.0. Podeu modificar l'obra, reproduir-la o comunicar-la públicament sempre que en citeu l'autor i la font (Fundació per a la Universitat Oberta de Catalunya), i sempre que l'obra derivada quedi subjecta a la mateixa llicència que l'obra original. La llicència completa es pot consultar a <http://creativecommons.org/licenses/by-sa/3.0/es/legalcode.ca>

Índex

Introducció	5
1. Deep learning per a l'anàlisi de sentiments	7
1.1. Models	8
1.1.1. Arquitectura	8
1.1.2. Avaluació i conjunts de dades	11
1.2. Impacte del <i>deep learning</i> en l'anàlisi de sentiments	12
1.2.1. Recerca	12
1.2.2. Producció	13
2. Cas d'ús	14
2.1. Presentació	14
2.2. Implementació	15
2.2.1. BiLSTM	15
2.2.2. Model basat en BERT	16
2.3. Avaluació i observacions	17
3. Anàlisi de sentiments en els aspectes	19
3.1. Definicions	19
3.1.1. Detecció d'aspecte	20
3.1.2. Detecció de polaritat	21
3.2. Models	21
3.2.1. Arquitectura	22
3.2.2. Avaluació i conjunts de dades	24
4. Cas d'ús	25
4.1. Presentació	25
4.2. Implementació	25
4.2.1. Detecció d'aspectes	26
4.2.2. Detecció de polaritat de termes	26
4.3. Avaluació i observacions	27
Resum	29
Glossari	30
Bibliografia	31

Introducció

L'anàlisi de sentiments és una de les àrees de recerca del processament del llenguatge natural que desperta més interès en l'àmbit de la recerca. En els primers mòduls del curs ja hem vist mètodes d'anàlisi de sentiments basats en lexicons anotats prèviament, com ara l'aplicació de mètodes de *machine learning*, entrenats a partir de dades de frases etiquetades amb el seu sentiment associat.

En aquest mòdul veurem com els models de *deep learning* han impactat en el camp de l'anàlisi de sentiments. Per a això, plantejarem l'enfocament de l'aplicació de models de *deep learning* a aquesta tasca i n'estudiarem la rellevància, l'impacte i els límits del moment.

L'interès per analitzar els sentiments de les frases no para de créixer, a causa tant de l'impacte de les xarxes socials com de la creixent accessibilitat per fer i llegir comentaris i *reviews* en llocs web dedicats a avaluar diferents tipus de productes o serveis, per exemple Trip Advisor.

L'anàlisi de sentiments es pot dividir en dues categories segons la font de les dades, precisament considerant aquests dos casos: sentiments expressats en xarxes socials i sentiments expressats sobre productes o serveis.

Els tipus d'anàlisis de sentiments també es poden classificar segons la seva granularitat i distingir-ne com a mínim dos punts de vista diferents: l'escala de sentiments i la granularitat del *target* del sentiment.

En l'escala de sentiments, els casos discrets més habituals són de dos sentiments (positiu o negatiu), però també tenen rellevància els models i els conjunts de dades que tracten amb tres o cinc etiquetes, considerant el sentiment *neutre* en el cas de tres, i afegint la gradació de positiu i negatiu en el cas de cinc, és a dir, *molt negatiu*, *negatiu*, *neutre*, *positiu* i *molt positiu*. En algunes situacions també és convenient afegir l'etiqueta *conflicte* per assignar-la, per exemple, al cas d'un comentari que conté tant opinions positives com negatives.

D'altra banda, en l'escala de granularitat del *target* del sentiment o *target* de l'opinió, s'identifiquen almenys els tres nivells següents:

- Sentiment en el document
- Sentiment en la frase
- Sentiment en l'aspecte

Pel que fa al document, s'avaluarà el sentiment d'un paràgraf o document, en la frase s'avaluarà el sentiment de la frase i en l'aspecte s'avaluarà el sentiment dels diferents aspectes que apareixen en la frase.

En els primers mòduls hem vist com extreure *targets* i aspectes d'opinions, però no com enfocar el problema d'extreure sentiments per aspectes sinó que hem tractat el problema de l'anàlisi de sentiment només en l'àmbit de la frase.

En els dos primers apartats d'aquest mòdul estudiarem l'aplicació de models de *deep learning* per a l'anàlisi de sentiments en la frase, i, en els dos últims, per a l'anàlisi de sentiments en l'aspecte. Revisarem els punts clau de les recerques del moment i il·lustrarem l'aplicació d'algunes de les solucions descrites.

1. Deep learning per a l'anàlisi de sentiments

Una vegada vistes les principals arquitectures de xarxes neuronals de *deep learning* que s'apliquen per a les tasques de processament del llenguatge natural (PLN), en aquest mòdul entrarem en el detall de la tasca de l'anàlisi de sentiments. En primer lloc, continuarem estudiant el problema de l'extracció de polaritat d'una opinió; recordem que l'objectiu d'aquesta tasca és extreure la polaritat d'una opinió, identificant-la com una opinió positiva o negativa. D'aquesta tasca també se'n diu **anàlisi de sentiment binari**.

El problema que afrontem és, per tant, una tasca de classificació de frases. La solució a aquest problema es plantejarà com les solucions de *machine learning* vistes en els mòduls anteriors i consistirà de manera general a obtenir:

- Una vectorització de la frase
- Un classificador per a les vectoritzacions

En el mòdul 2 hem vist vectoritzacions TfIdf i vectoritzacions entrenades a partir de corpus de text grans, com ara Word2Vec i GloVe; i les hem aplicat a un classificador lineal per obtenir el model de classificació de sentiments desitjat. Ho hem provat amb els classificadors clàssics SVM, Naive Bayes i Random Forest, que també són els més freqüents en aplicacions de PLN basades en mètodes clàssics de *machine learning*.

En el cas dels models de *deep learning*, la solució consistirà en una arquitectura unificada en una xarxa neuronal, amb diversos *layers* i possibles recombinacions entre aquests, a partir de la qual es resolgui la classificació. L'*input* d'aquesta xarxa consistirà en vectoritzacions de les paraules o *tokens* (*word embeddings*) que podran ser preentrenats o inicialitzats de manera aleatòria amb uns pesos que seran ajustats durant el procés d'entrenament.

La classificació vindrà determinada pels valors de l'última capa. En cas de diverses etiquetes possibles (sentiment granulat), aquesta capa serà una capa lineal amb tantes neurones de sortida com classes possibles, i amb l'ús de la funció d'activació softmax. En el cas de dues etiquetes, com ara en l'anàlisi de sentiment binari, habitualment serà un *layer* de dimensió 1 a la sortida i amb l'aplicació de la funció d'activació sigmoide, identificant els valors pròxims a 0 en una classe i els valors pròxims a 1, en l'altra classe.

Els models de *deep learning* més populars per a l'anàlisi de sentiments consisteixen, habitualment, en models basats en xarxes convolucionals o models basats en xarxes recurrents, especialment LSTM. I com veurem, també hi ha arquitectures que combinen les dues aproximacions.

En la primera secció d'aquest apartat revisarem les arquitectures més populars per a l'anàlisi de sentiments, inclosos alguns dels últims avenços en el camp.

1.1. Models

En aquesta secció revisarem algunes de les generalitats i punts que cal tenir en compte en l'enfocament de la tasca de l'anàlisi de sentiments mitjançant models de *deep learning* supervisats. En el cas de la tasca de l'anàlisi de sentiments binaris o extracció de polaritat, la incidència dels models no supervisats és molt menor ja que habitualment l'obtenció de dades no és un problema, perquè es disposen de diversos llocs web o xarxes socials on es poden obtenir dades d'opinions binàries amb facilitat.

1.1.1. Arquitectura

Repassarem quatre tipus d'arquitectures:


- Xarxes convolucionals
- Xarxes recurrents
- Xarxes híbrides que combinen els dos tipus
- Aplicacions de models BERT

Xarxes convolucionals

El primer treball influent en l'aplicació de xarxes convolucionals a dades textuals va ser el de Kim (2014), que va introduir un tipus de xarxes a les quals de vegades la literatura s'hi refereix amb el nom de TextCNN.

En aquestes xarxes convolucionals l'entrada es presenta com una matriu on cada fila és la vectorització d'un *token* de la frase; per tant, les dimensions de la matriu són $m \times n$ on m es la longitud de la frase i n és la dimensionalitat dels *embeddings* que s'usen. La longitud de la frase correspondrà a una longitud màxima fixa, i si es requereix usar com a entrada una frase de longitud menor, els últims *tokens* s'emplenaran com a *padding*.

Figura 1. Xarxes convolucionals



Font: captura de Kim (2014)

A partir del treball de Kim, en què va aplicar TextCNN al problema de la classificació de frases, s'ha investigat en diversos treballs l'aplicació d'aquests models emprant diferents tipus de filtres i actualitzacions de la xarxa; algunes de les xarxes derivades que s'han definit són:

- **DynamicCNN**: és la xarxa derivada de CNN que ha donat millors resultats; consisteix en uns filtres dinàmics.
- **Static-CNN**: és aquest cas, els *word embeddings* són fixos.
- **Non-static CNN**: en aquest cas, els pesos dels *word embeddings* també varien al llarg de l'entrenament i la xarxa els ajusta al problema que està aprenent a resoldre.
- **CNN multi-canal**: l'entrada es codifica en més d'una matriu d'entrada, com es mostra a la figura 1.

Xarxes recurrents


L'aplicació de les xarxes recurrents a la classificació de textos i, en particular, a l'anàlisi de sentiments ha estat present des del principi dels enfocaments de *deep learning*, atesa la capacitat d'aquestes xarxes per analitzar seqüències. Actualment, aquestes xarxes se solen emprar construint arquitectures bidireccionals i amb el mecanisme d'atenció, presentat en el mòdul anterior.

Arquitectures híbrides

Per superar algunes de les limitacions que impedié millorar en l'anàlisi de sentiments, Zhou (2016) va proposar combinar les arquitectures de xarxes convolucionals i xarxes recurrents de manera que els *outputs* del *layer* convolucional s'empressin com a *input* per a la xarxa recurrent. Aquestes arquitectures CNN-LSTM són molt populars actualment, i combinades amb les adaptacions adequades constitueixen un dels grups d'arquitectures més reeixides. A la fi-

gura 2 es mostra el cas conegut com BiLSTM-2DCNN, ja que consisteix en un *layer* d'LSTM bidireccional i una xarxa convolucional de dues dimensions.

Figura 2. Arquitectures híbrides




Font: captura de Zhou (2016)

Aplicacions de models BERT

L'adaptació més simple de models BERT per servir com a solucions a tasques de classificació de textos consisteix a incorporar una capa lineal que tingui com entrada la sortida que el model BERT calcula per representar tota la frase, és a dir, l'*output* del token [CLS]. A la figura 3 s'il·lustra l'*output* de BERT que s'emprarà com a *input* del *layer* per fer la classificació.

Figura 3. Aplicacions de models BERT



Font: captura de Devlin (2018)

Altres xarxes que han tingut un paper destacat en els models de *deep learning* per a l'anàlisi de sentiments són les xarxes recursives, que requereixen com a entrada una frase analitzada, parcialment o totalment, i apliquen les mateixes regles recursivament en l'arbre d'anàlisi. No obstant això, a causa dels últims avenços en models de llenguatge que no requereixen dades tan etiquetades per ser entrenats, l'interès per aquests models ha disminuït.

1.1.2. Avaluació i conjunts de dades

És habitual, en el món de la recerca, definir tasques de referència (*benchmark*) per comparar models utilitzant un mateix conjunt de dades (un mateix joc de proves) per a la tasca, i també una mateixa mètrica per comparar els resultats obtinguts pel model entrenat. En el cas de l'anàlisi de sentiments, és força freqüent trobar referències a aquests dos conjunts de dades:

- **IMDb:** el conjunt de dades d'IMDb és un conjunt de dades d'anàlisi de sentiment binari, que consta de 50.000 ressenyes de la base de dades de pel·lícules d'internet (IMDb) etiquetades com a positives o negatives. El conjunt només considera les revisions altament polaritzades; una crítica negativa té una puntuació inferior a 4 sobre 10, i una crítica positiva té una puntuació superior a 7 sobre 10.
- **SST:** l'Stanford Sentiment Treebank conté 215.154 frases amb etiquetes de sentiment granulat assignades en diferents parts dels arbres sintàctics d'11.855 opinions de pel·lícules. El conjunt de dades serveix per avaluar models en la classificació de sentiment binari, com en el cas de sentiment granulat en cinc classes.

A la taula 1 es mostren resultats comparats per al conjunt de dades SST en les tasques de l'anàlisi de sentiment binari, on es pot veure l'impacte dels models basats en *transformers*, que són tots els que tenen data de publicació 2018 i 2019. En tots dos casos, quatre dels cinc primers són models basats en models *transformers*.

És important destacar de nou que aquesta comparació es fa amb una tasca, un conjunt de dades i unes mètriques de referència concrets. En el moment de resoldre un problema amb dades reals per a una aplicació des del punt de vista productiu, pot ser perfectament possible que una solució basada en arquitectures més simples aconsegueixi una *accuracy* semblant a la d'un altre model amb una arquitectura més complexa.

A més, els models de *deep learning* basats en *transformers* poden ser costosos d'entrenar, i dependrà de les dades de què disposem per valorar si val la pena o no emprar-los en aplicacions pràctiques, en relació amb la millora de resultats que puguin aportar per al problema que estem tractant.

Diversos estudis han validat que el consens entre persones en l'anàlisi de sentiments d'opinions no és total. És a dir, els models són bons per aprendre d'un conjunt de dades, però l'ús d'aquests models no sempre tindrà la mateixa utilitat per a un problema real.

Taula 1. Resultats per a la tasca d'anàlisi de sentiment binari en el conjunt de dades de Stanford Sentiment Treebank

Exactitud (<i>Accuracy</i>)	Model	Any
96,8	XLNET	2019
96,5	MT-DNN	2019
94,9	BERT	2018
93,2	Block-sparse LSTM	2017
90,7	Single layer bilstm (BERT)	2019
88,1	CNN-multi canal	2014
87,8	CLSTM	2015
87,2	CNN-non-static	2014
86,8	DCNN	2014
84,9	LSTM	2015

1.2. Impacte del *deep learning* en l'anàlisi de sentiments

1.2.1. Recerca

El *deep learning* ha tingut un impacte molt gran en la resolució de tasques de PLN, tant tasques que existien des de fa molts anys, per exemple *POST-tagging* o *Named-Entity Recognition*, o tasques més actuals com ara l'obtenció de resums de textos o sistemes simuladors de diàlegs. El cas de l'anàlisi de sentiments no és diferent i els progressos fets els últims tres anys han estat molt grans.

Transversalment a la millora de resultats en tasques de recerca, trobem el problema de l'aplicabilitat d'un model en contextos reals. Una pregunta molt important és si un model és aplicable a un domini general o solament al domini específic en el qual ha estat entrenat. Aquest és un assumpte recurrent en les aplicacions de PLN. És a dir, les dades d'entrenament delimiten la cobertura del model final en el domini al qual es refereixen les frases a analitzar? Si entrenem un model amb *reviews* sobre restauració i hotels, servirà per fer prediccions en opinions de pel·lícules?

En el cas de l'anàlisi de sentiments, l'aplicació dels models entrenats és força restrictiva, i generalment només estan validats per fer prediccions en frases del mateix domini.

En el tercer apartat parlarem més detalladament dels progressos fets en l'anàlisi de sentiments en aspectes per a dominis específics.

1.2.2. Producció

Des del punt de vista econòmic, és molt valuós conèixer l'opinió de la gent, i els models d'anàlisi de sentiments cada vegada són més emprats per diferents tipus d'empreses i amb varietat d'objectius.

La facilitat d'accés a les dades i les noves tècniques d'emmagatzematge de gran quantitat de dades faciliten avui l'estudi d'opinions i tendències de manera massiva.

Ara mateix, hi ha trillions de zettabytes de dades en línia que potencialment poden ser utilitzats per inferir les tendències, les opinions, els gustos, etc. A més, gràcies al progrés en les tècniques d'emmagatzematge i processament de *big data* i en les tècniques de *deep learning*, cada vegada és més possible extreure dades significatives eliminant el soroll i aportar valor a partir d'aquestes dades als negocis amb informació que cada vegada és més important per al seu bon posicionament en el mercat.

Així i tot, si és necessari obtenir dades més precises, s'han d'aplicar solucions *ad hoc*, que combinen la mineria massiva d'opinions amb bases de coneixements especialitzades.

En el món de les finances els models d'anàlisi de sentiments també són més importants per poder predir els comportaments de la població. I fonts de dades, com ara Twitter, permeten accedir a gran quantitat d'informació útil.

2. Cas d'ús

En aquest apartat revisarem diversos aspectes de l'aplicació de *deep learning* en l'anàlisi de sentiments a partir de l'empresa fictícia S&S.

En aquest cas, el context és la proposta que fa Peter, del Departament de Dades, de provar sort amb models de *deep learning* per millorar els resultats obtinguts fins ara.

Per a això, volen fer proves amb el conjunt de dades extretes de YELP que ja han emprat per entrenar models d'anàlisi de sentiments mitjançant mètodes clàssics de *machine learning*.


YELP

<https://www.kaggle.com/yelp-dataset/yelp-dataset>

2.1. Presentació

Abans de començar, discuteixen si val la pena explorar aquest camí, ja que fins ara els ha servit el que tenen, i tampoc no disposen de conjunts de dades gaire més grans. A més, per a alguns clients, la major explicabilitat dels models clàssics, com ara Random Forest, és un valor afegit. Amb tot, Peter els convenç per provar-ho.

Figura 4. Aprenentatge i decisions d'un model de *deep learning*



Font: captura d'Advanced Research Project Agency

És veritat que la dificultat d'explicar què ha après exactament un model de *deep learning* i com pren les decisions és un problema que, en els models clàssics, és molt menor, com mostra la figura 4. No obstant això, des de la comunitat científica s'estan fent esforços per millorar també l'explicabilitat dels

models de *deep learning*, per exemple, amb eines que ajudin a visualitzar millors quins *features* són rellevants en quines decisions.

2.2. Implementació

Peter proposa aplicar un model derivat de les xarxes neuronals recurrents. A més, atès el recent interès pels models preentrenats i el *fine tuning* per a tasques específiques, també es decideix provar un model basat en BERT.

2.2.1. BiLSTM

La primera prova que fan consisteix en una adaptació d'una xarxa recurrent (RNN), en concret una LSTM, que recordem que és una versió millorada de les RNN per controlar el problema del *vanishing gradient*.

Aquesta adaptació consisteix principalment en dos passos dins de l'arquitectura de la xarxa:

- **Bidireccionalitat (Bi)**: consisteix a forçar la xarxa a aprendre relacions dins de la frase tant en una direcció (d'esquerra a dreta) com en una altra (de dreta a esquerra). Per a això, es defineixen **dues** RNN, una que processa la frase en una direcció i l'altra, en la contrària; i finalment, s'usa com a vector resultant la concatenació de tots dos resultats.
- **Multi-layered**: la segona adaptació consisteix a no considerar només una RNN per a cada direcció, sinó diverses. És a dir, l'últim *hidden state* d'una RNN és passat com a *input* a una altra RNN, i així successivament, fins que el resultat final de cada direcció és pres com l'*output* de l'últim *layer*.

A més, val la pena destacar els punts següents:

- **Word embeddings**: els *word embeddings* de les paraules, per exemple, representacions numèriques que són usades com a *input* de l'RNN, són inicialitzats amb vectors GloVe ja entrenats. Es podria optar tant per afegir els pesos d'aquests vectors com a paràmetres de la xarxa com per deixar-los fixos durant l'entrenament. En aquest cas, la prova es fa deixant-los fixos.
- **Dropout**: per prevenir el sobreajust (*overfitting*) s'usa com a mecanisme de regularització el *dropout*.
- **Classificador lineal**: s'afegeix un últim *layer fully-connected* que té una dimensió d'*output* igual a 1, i s'usa la funció d'activació sigmoide per destriar entre una classe o una altra segons si el valor final és més pròxim a 0 o a 1.

Finalment, en el detall de la implementació és rellevant dir que, atès que estem processant l'*input* en dues direccions, el *padding* de l'entrada pot causar molt soroll. Per evitar-ho, és habitual crear *batches* que ajuntin frases de longituds similars, per minimitzar el nombre de components afegit com *padding* i a més no considerar-los en les computacions, i forçar que la sortida d'aquests elements sigui sempre zero, el que anomenem *padding*.

2.2.2. Model basat en BERT

Quan comencen a treballar amb models basats en BERT, el primer que els sorprèn és la facilitat per adaptar-los a les seves necessitats gràcies a les eines disponibles. Poder inicialitzar un classificador amb tantíssims paràmetres i poder-lo entrenar perquè s'adapti a un petit *dataset* des del seu propi ordinador els sembla realment potent.

Atès que el model és tan gran, conté més de cent milions de paràmetres, congelen la major part dels pesos i entrenen només la part que no és de BERT, i que aprendrà a partir de les representacions de BERT.

Com ja hem vist en el mòdul anterior, aquest model ens proporciona tant representacions vectorials de les paraules (*word embeddings*) com de la frase (la representació corresponent al *token* [CLS]). Per tant, podem considerar-ho com una mena d'*embedding layer*, la sortida del qual ens pot servir com a entrada per a una altra capa.

Decideixen usar les vectoritzacions de BERT per fer dues proves:

- 1) Ús directe del vector que representa [CLS] per classificar, usant-lo com a entrada d'una altra capa lineal.
- 2) Ús dels *word embeddings* resultants com a *input* d'una xarxa RNN, en concret, GRU, *multi-layered* i bidireccional, la sortida final de la qual és usat per a la classificació.

Encara que el nombre de paràmetres a entrenar siguin pocs, el temps de l'entrenament és llarg, ja que les representacions del text tenen que propagar-se pel model de BERT i computar tots els passos que això implica. Aquest és un dels motius per usar una GRU (*gated recurrent unit*) en comptes d'una LSTM per a la xarxa recurrent, ja que les GRU són menys costoses computacionalment, i aconsegueixen obtenir resultats similars.

El primer mètode no els dona resultats gaire diferents als obtinguts fins al moment; en canvi, el segon supera totes les seves proves anteriors.

En tots dos casos, els passos que segueixen per implementar i comparar els models en tots els seus nivells són els següents:

- **Explorar i preprocessar les dades:** entendre i conèixer les dades de què es disposa (format, codificació, estadístiques generals), i preprocessar-les netejant tot el que sigui necessari, com caràcters estranys, etc.
- **Preparar les dades per a l'entrenament:** *tokenitzar* i codificar els textos, dividir el conjunt de dades en validació, test i entrenament, i preparar tot el que sigui necessari segons el marc de treball (*framework*) de *deep learning* que s'estigui utilitzant. En el cas que la codificació vingui donada per *word embeddings* preentrenats, caldrà carregar-los prèviament.
- **Preparar i dissenyar l'entrenament:** seleccionar una funció de pèrdua (criteri per a la *loss function*) i un optimitzador (*optimizer*). A més, per poder fer seguiment de l'entrenament, cal definir les mètriques que es faran servir. En aquest cas, una mètrica per a *accuracy* que es basi en la classificació binària.
- **Crear i instanciar el model:** definir les capes del model i instanciar un model amb hiperparàmetres concrets.
- **Entrenar:** entrenar el model a partir de les dades d'entrenament i validació.
- **Avaluar:** avaluar el model amb les dades de test. Aquest punt pot estar integrat amb l'anterior, en el codi, depenent del marc de treball que s'utilitzi.

2.3. Avaluació i observacions

Es comparen els nous models amb el model emprat abans, i l'últim els millora significativament. En el *notebook* 1 del mòdul se segueix aquest exemple per al primer i últim models explicats.

Taula 2. Comparació de models

	<i>label</i>	<i>precision</i>	<i>recall</i>	<i>F1-score</i>	<i>support</i>
Models clàssics	0	0,98	0,41	0,57	148
	1	0,88	1,00	0,94	670
Model BiLSTM	0	0,87	0,32	0,47	143
	1	0,87	0,99	0,93	674
Model BERT-GRU	0	0,95	0,89	0,92	143
	1	0,98	0,99	0,98	674

Les primeres conclusions que treuen són que s'han de replantejar millorar o ampliar el conjunt de dades més endavant i fer més proves, encara que ja decideixen que volen continuar endavant amb les proves amb models a partir de BERT o altres arquitectures *transformers*.

L'opció d'usar un model més gran, com ara BERT *large*, no la consideraran, encara que, segons ha estudiat Devlin (2018), saben que obtindrien millors resultats, però requereix més poder computacional ja que té un nombre de paràmetres encara més elevat.

D'altra banda, plantejar-se directament preentrenar arquitectures de *transformers* en la seva tasca és molt costós i només és possible en aquest punt amb màquines molt especialitzades i costoses, o amb hores de computació de TPU de Google.

3. Anàlisi de sentiments en els aspectes

La rellevància de l'anàlisi de sentiments en els aspectes és cada vegada més gran en les recerques i aplicacions de PLN.

Els diferents aspectes d'un producte s'identifiquen amb les seves diferents característiques. L'anàlisi de sentiments en l'aspecte ajuda a entendre què s'opina sobre cada producte o servei. Per exemple, en el comentari: *Els cambrers van ser amables i la paella era bona, encara que era una mica escassa*, hi ha diversos aspectes del restaurant en qüestió que s'hi estan comentant: el menjar i, en concret, el gust de la paella, i la ració de la paella; el servei i, en concret, els cambrers; i cada aspecte es comenta amb la seva polaritat.

Per tant, l'anàlisi de l'aspecte ofereix una anàlisi més detallada de l'opinió i brinda una oportunitat immensa per al camp del *business intelligence* per poder obtenir informació sobre com el producte o el servei és rebut entre els consumidors, i prendre decisions a partir d'aquesta informació.

En els apartats 3 i 4 introduïrem l'estudi de l'anàlisi de sentiments basat en aspectes, també anomenat anàlisi de sentiments basada en l'aspecte o anàlisi de sentiments per aspectes, al qual ens referirem en el text com AbSA, de l'anglès *aspect-based sentiment analysis*.

3.1. Definicions

Sovint, la informació més rellevant d'una opinió no és el sentiment global de l'opinió, la definició de la qual pot ser bastant difusa, sinó el sentiment respecte a una entitat, i en concret respecte a algun aspecte de l'entitat.

En el primer apartat vam veure la definició de la tasca d'anàlisi de sentiments granulats com ara la identificació del sentiment d'una frase amb cinc gradacions diferents (molt dolent, dolent, neutre, bo i molt bo).

El nombre d'articles que proposen solucions per millorar els resultats en aquesta tasca ha disminuït els últims dos anys, i ara el millor resultat d'aquesta tasca en el conjunt de dades SST encara no supera el 58 % de *accuracy*.

Aquesta dificultat en la millora dels resultats i el desinterès per aquestes tasques és degut a dos motius principalment: la complexitat del problema i l'obertura de la definició del problema. Considerant més granularitat en el sentiment d'una opinió, l'efecte del domini de l'opinió, és a dir, si és una opinió sobre una pel·lícula, sobre un producte, sobre una experiència, etc., és molt més gran que en el cas del sentiment binari. Encara que ja vam veure que, fins i tot així, el domini afecta i el judici humà d'una opinió no és unànim.

Per poder afrontar aquest problema, ha crescut l'interès en l'estudi de l'AbSA.

S'han definit diverses subtasques en les quals se subdivideix el problema de l'AbSA. En els següents apartats revisarem les principals definicions de subtasques, i diferenciarem les tasques de detecció d'aspectes i les tasques de detecció de polaritat.

3.1.1. Detecció d'aspecte

Hi ha dos subtasques relacionades amb la detecció d'aspectes que s'estudien en el problema de l'AbSA:

- **Detecció de categoria aspectual:** l'objectiu és identificar sobre quin aspecte o aspectes s'està opinant en la frase que es processa. Això simplifica el problema de la detecció d'aspectes vistos en el mòdul 2 de l'assignatura, i el converteix en un problema de classificació multiclasse, de manera que en comptes de trobar candidats a aspectes en una frase, es busca identificar la frase amb algun dels aspectes prèviament determinats. En el cas dels restaurants, el conjunt pot ser: FOOD, AMBIENCE, SERVICE, RESTAURANT, MISCELANIOUS. També podria incloure PRICE o DRINKS, però recordem que això dependrà de les dades etiquetades de què puguem disposar.
- **Detecció de terme de l'aspecte:** en aquest cas, l'objectiu és identificar el terme o els termes de la frase que estan subjectes a una opinió. Depenent de la definició de la tasca, aquesta pot anar al costat de la detecció de la categoria aspectual. Per exemple, en la frase: «Els cambrers van ser amables i la paella era bona encara que era una mica escassa» els cambrers és un terme de l'aspecte (en anglès, *aspect term*), que es pot referir a l'aspecte *SERVICE*.

A més, també trobem la tasca d'extracció del *target* de l'opinió (coneguda com OTE, de l'anglès *opinion target extraction*), en la qual no solament es busca detectar termes, sinó tot tipus d'expressions lingüístiques que siguin objecte d'opinió.

3.1.2. Detecció de polaritat

Paral·lelament al cas de la detecció d'aspectes, en la detecció de polaritat podem diferenciar dues subtasques:

- **Detecció de polaritat en categoria aspectual:** en aquesta tasca es demana calcular una polaritat en relació amb una categoria aspectual.
- **Detecció de polaritat en terme de l'aspecte:** en aquest cas, la polaritat es demana respecte al terme. La tasca també es pot denominar directament anàlisi de sentiments basada en l'aspecte, ja que és la tasca més estesa a l'hora d'afrontar el problema general de l'anàlisi de sentiments per aspectes. La tasca, anomenada en anglès *targeted sentiment classification* o *targeted AbSA* (TABSA) consisteix a trobar el sentiment d'una frase respecte a un aspecte concret, però en aquest cas donat per un terme concret. Llavors l'entrada ha de representar tant la frase com el terme sobre el qual es busca l'aspecte.

Cal destacar que hi ha moltes propostes de models que afronten algunes de les subtasques d'AbSA descrites de manera conjunta amb una única arquitectura.

A més, també s'han definit tasques per detectar les *opinion words*, és a dir, la part de la frase que dona opinió al terme o aspecte, tal com es van denominar en la primera definició de subtasques (Pontiki, 2014).

A la taula 3 s'identifiquen les tasques segons l'*input* extra, més enllà de la mateixa frase, el seu *output* i el nom o sigles amb què es coneixen en la literatura científica:

Taula 3. Resum de tasques

Input extra	Output	Nom
terme	polaritat	<i>Targeted AbSA</i> (TABSA)
	terme	<i>Aspect term extraction</i> (ATE)
	terme	<i>Aspect category detection</i>
	aspecte i polaritat	<i>Aspect category polarity</i> (ACP)
	terme i polaritat	<i>Aspect term polarity</i> (ATP)
	target d'opinió	<i>Opinion target extraction</i> (OTE)

Finalment, també es poden trobar altres subtasques d'AbSA específicament definides en el document i no en la frase. Però en aquest mòdul ens centrem en la frase.

3.2. Models

Des del punt de vista general, el que es busca per resoldre una tasca AbSA és dissenyar arquitectures dirigides a poder trobar representacions de la relació entre el *target* i el context, que siguin dependents de la polaritat. Per a ai-


xò, s'han proposat diverses alternatives i nous mecanismes i combinacions de mecanismes.

3.2.1. Arquitectura

No hi ha unes arquitectures predominants en l'enfocament de les tasques d'AbSA. No obstant això, en les tasques que tinguin el *target* com a *input*, les estratègies més populars en les propostes actuals d'aquest actiu camp de recerca consisteixen a processar paral·lelament el context del *target*, i després recombinar tots dos resultats de l'una o l'altra forma; les figures 5 i 6 mostren exemples d'aquestes arquitectures.


A més, la bidireccionalitat i el mecanisme d'atenció estan presents gairebé en tots els models. I també és força prominent la combinació de l'output de la xarxa amb un model probabilístic del tipus *conditional random field* (CRF).

Figura 5. Arquitectura




Font: captura de Dehong (2017)

Figura 6. Arquitectura



Font: imatge extreta de Zeng (2019)

Figura 7. Arquitectura



Font: captura de Song (2019)

Com mostren aquests exemples, les propostes de solució consisteixen a dissenyar arquitectures que combinin diferents tipus de *layers* per aconseguir obtenir *features* vàlids per representar les característiques de la frase destacant la posició del terme en qüestió, la seva relació amb la resta de la frase i la resta de la frase en si.

Taula 4. Resultats de la tasca TABSA amb el conjunt de dades de SentiHood

F1-score	Model	Any
87,9	BERT	2019
78,5	REN	2018
78,2	LSTM	2018
69,3	LSTM	2016

Taula 5. Resultats de la tasca ATE amb el conjunt de dades de SemEval 2014

F1-score	Model	Any
90,7	BERT	2019
88,1	DE-CNN	2018
87,8	MT-DNN	2017
87,2	RNCRF	2016

3.2.2. Avaluació i conjunts de dades

La comunitat científica diu que l'impediment més gran que hi ha per a les subtasques d'AbSA en opinions és l'obtenció de conjunts de dades etiquetades, ja que es requereix etiquetar manualment. Encara que hi ha treballs recents en què es proposen mètodes que combinen conjunts de dades etiquetades manualment i semiautomàticament, la gran majoria dels treballs que estudien models per resoldre subtasques d'AbSA utilitzen algun *dataset* de referència d'entre els proposats per les conferències de SemEval (2014, 2015 i 2016) (Pontiki, 2014) per a les diferents subtasques corresponents; o el *dataset* SentiHood (Saeidi, 2016), introduït per estudiar una aproximació més general de l'AbSA.

- **SentiHood** (Saeidi, 2016): és un conjunt de dades per a la tasca TABSA l'objectiu del qual és identificar la polaritat cap a un aspecte específic. El conjunt de dades consta de més de cinc mil frases.
- **SemEval**: en els anys 2014, 2015 i 2016 la conferència SemEval ha incorporat propostes de tasques i *dataset* per a AbSA. Especialment per als dominis específics d'ordinadors portàtils i restaurants, que consten de milers de frases anotades manualment.

A les taules 4 i 5 es mostren els millors resultats per a les tasques de AbSA amb el conjunt de dades de SentiHood i per a la tasca ATE amb el conjunt de dades de SemEval 2014.

De nou, els models basats en *transformers* lideren les tasques d'AbSA; així i tot, pel que fa a la tasca, el marge de millora encara és molt més gran comparat amb el de la tasca de l'anàlisi de sentiment binari.

4. Cas d'ús

En aquest apartat presentarem un cas d'ús d'aplicació de solucions per al sentiment per aspectes basant-nos de nou en l'empresa fictícia S&S.

4.1. Presentació

El grup de restaurants Quality&Food, que ja ha obtingut resultats respecte a les opinions dels seus clients gràcies al sistema ofert per l'empresa S&S, voldria saber amb més detall quins aspectes del seu servei valoren positivament o negativament els seus comensals. Demanen a l'empresa S&S si els podrien fer un estudi inicial.

A aquest grup li interessa especialment distingir entre menjar i servei.

Peter i Joseph s'adonen que, com en altres tasques de PLN, abans de l'auge del *deep learning*, el resultat de models d'anàlisi de sentiments per aspectes era molt dependent del coneixement del domini del qual es disposés, és a dir, d'ontologies introduïdes a mà. I que, en canvi, ara hi ha diversos articles que proposen solucions a les diferents tasques de l'anàlisi de sentiments per aspectes mitjançant models de *deep learning*.

Per això, abans de contestar als representants de Quality&Food, decideixen que primer faran unes quantes proves.

Tenint en compte els interessos del grup, decideixen començar fent dues proves: una amb la tasca de **detecció d'aspectes** i una altra amb la tasca de **detecció de polaritat per aspectes**.

4.2. Implementació

Aquesta vegada, Peter proposa per a la tasca de detecció d'aspectes un model que ells coneixen millor, basat en una xarxa recurrent; i per a la detecció de polaritat de termes, usen l'arquitectura de BERT per classificar dues frases, en aquest cas, **frase** i **terme**.

4.2.1. Detecció d'aspectes

Ràpidament veuen que la tasca de detecció d'aspectes no és diferent d'una altra tasca de classificació de frases en diferents classes.


La dificultat de l'obtenció de *datasets*, per exemple, de webs d'opinions, també és més gran, i finalment decideixen partir del *dataset* per a SemE-val 2014 del domini de la restauració (Pontiki, 2014).

Com a solució opten per provar una xarxa com una capa *embedding*, que inicialitzaran amb els pesos d'un model GloVe preentrenat, una altra capa LSTM amb dos *layers* i, finalment, una capa lineal amb dimensió 5 de sortida per identificar les classes.

4.2.2. Detecció de polaritat de termes

L'entrada consisteix en dos *inputs*, la frase i el terme; és per això que decideixen optar per fer una primera prova directament amb l'*embedding* BERT de la frase (l'*embedding* resultant per a [CLS]) i usar-lo com a *input* d'un *layer* lineal, ja que el model BERT està especialment preparat per a l'entrada de dos *inputs* amb la seva codificació per segments. recordem que, de fet, ha estat entrenat en una tasca que té com a *input* dues frases.

Figura 8. Model BERT



Font: captura de Devlin (2018)

Aquesta vegada, a diferència del cas vist en el segon apartat amb l'anàlisi de sentiments, no és tan senzill dissenyar un model que funcioni millor intercalant un *layer* de xarxes recurrents, ja que el doble *input*, frase-terme, complica els efectes. Això els fa entendre millor el perquè de les diferents propostes d'arquitectures complexes que han trobat en diversos articles parlant de les tasques d'AbSA.

Efectivament, s'adonen que les arquitectures de les solucions per a AbSA són molt més complexes que les usades per a la anàlisi de sentiments justament per resoldre aquest problema. També veuen que últimament han aparegut noves propostes a partir dels *embeddings* contextuals de models preentrenats amb arquitectures *transformers* que simplifiquen una mica l'elaboració dels models, i es plantegen usar-les en algun moment, però primer volen provar aquesta arquitectura més simple.

De moment, deixen fora del pla l'ajust dels pesos de BERT per a la tasca, i els deixen fixos, encara que pel que veuen en la literatura això pot ajudar a millorar els resultats del model.

Per a totes dues tasques, els passos que seguiran seran molt semblants als vistos en el segon apartat. I això els permet reaprofitar gran part del codi treballat. Destaquem els canvis que necessiten fer respecte dels passos anteriors:

- Explorar i preprocessar les dades
- Preparar les dades per a l'entrenament
- Preparar i dissenyar l'entrenament: adaptar-ho a cada tasca
- Crear i instanciar el model
- Entrenar
- Avaluar: avaluar el model amb les dades de test

En el *notebook* 2 del mòdul se segueixen parcialment els exemples comentats aquí.

4.3. Avaluació i observacions

En el cas de la detecció d'aspectes no obtenen resultats gaire bons amb la primera prova, i obtenen un 67 % de *accuracy*. Però, pensant-ho bé, finalment adapten la seva solució per distingir tres classes: menjar, servei i altres. I aquí aconsegueixen millorar la *accuracy* fins a un 78 %.

La següent prova que decideixen fer consistirà a millorar els *embeddings*, que deixaran com a paràmetres entrenables primer, i ho provaran amb uns altres *embeddings*, com els de BERT, congelant-los i sense congelar.

Per a la detecció de polaritat en els termes també els costa superar la barrera del 70 % de *accuracy*, encara que finalment entrenen un model que els serveix per filtrar força frases; així doncs, decideixen continuar i aplicar aquest model a les frases de Quality&Food, i després aplicar un model d'anàlisi de sentiments a aquestes frases com a primera prova.

Resum

En aquest mòdul hem revisat les bases de l'aplicació de models de *deep learning* a l'anàlisi de sentiments, destacant el seu desenvolupament al llarg dels últims anys i el seu impacte en la recerca d'aquesta tasca de PLN.

Hem descrit com es fa el seguiment i la comparació de resultats de diferents models, i hem ressaltat les limitacions de l'estat de la qüestió en aquests moments, tant per a l'anàlisi de sentiments com per a l'anàlisi de sentiments per aspectes.

Hem repassat l'aplicació de les principals arquitectures de *deep learning* al problema de l'anàlisi de sentiments, i hem destacat alguns mecanismes més avançats que s'usen per millorar els resultats d'algunes tasques relacionades amb l'anàlisi de sentiments.

Finalment, tant per al cas de l'anàlisi de sentiment com per a la anàlisi de sentiment per aspectes, hem presentat un cas d'ús amb diferents solucions i hem descrit la seva aplicació i la seva avaluació.

Glossari

atenció *f* El mecanisme d'atenció en una xarxa neuronal és un component de l'arquitectura de la xarxa que modela la interdependència entre els *inputs* i els *outputs*. També es pot emprar per modelar la interdependència entre els mateixos *inputs*, i en aquest cas es parla d'autoatenció (*self-attention*).

ATE Sigles que identifiquen la tasca d'*aspect-term extraction*.

input En el cas de les xarxes neuronals, vectors sobre els quals actua el primer *layer* de la xarxa.

layer Sinònim de capa en el context de les xarxes neuronals que és usat de manera habitual.

layer lineal Sinònim de capa *fully-connected* en el context de les xarxes neuronals.

models clàssics de ML *m pl* Models de *machine learning* no basats en xarxes neuronals, per exemple, *support vector machines*.

output En el cas de les xarxes neuronals, vectors resultants de l'actuació de l'últim *layer*.

padding Forma en la qual es completa o trunca un *input* perquè tingui una dimensió concreta. En cas de completar-lo, prèviament s'ha d'haver reservat un nombre (normalment el 0) per identificar components del vector que s'hauran emplenat pel *padding*.

polaritat *f* Nom amb el qual s'identifica el sentiment d'una frase quan s'analitza de manera binària.

target d'una opinió Entitat sobre la qual s'està opinant.

token Part d'un text que es codificarà de manera independent; sovint s'identificarà amb una paraula, però no sempre.

TABSA Sigles que identifiquen la tasca de *targeted aspect based sentiment analysis*.

transformers Tipus de xarxes neuronals que han adquirit molta popularitat els últims dos anys; estan basades en el mecanisme d'autoatenció, entre altres. A partir d'aquestes arquitectures s'han entrenat models de *language*, com ara BERT, que s'han posat a disposició dels investigadors promovent el *transfer of learning*, és a dir, partir d'un model ja entrenat i usar-lo per entrenar un model per a una altra tasca.

Bibliografia

Biqing, Z. i altres (2019). *LCF: A Local Context Focus Mechanism for Aspect-Based Sentiment Classification*. Applied Sciences.

Devlin i altres (2018). *BERT: Pre-training of deep bidirectional transformers for language understanding*. arXiv:1810.04805.

Kalchbrenner, N. i altres (2014). «Convolutional neural network for modelling sentences». A: *Proceedings of the Annual Meeting of the Association for Computational Linguistics*.

Kim, Y. (2014). «Convolutional neural networks for sentence classification». En: *Proceedings of the Annual Meeting of the Association for Computational Linguistics*.

Pontiki, M. i altres (2014). «SemEval-2014 Task 4: Aspect Based Sentiment Analysis». A: *Proceedings of the 8th International Workshop on Semantic Evaluation*. ACL.

Saeidi, M. (2016). *SentiHood: Targeted Aspect Based Sentiment Analysis Dataset for Urban Neighbourhoods*. COLING 2016.

Song, Y. i altres (2019). *Attentional Encoder Network for Targeted Sentiment Classification*.

Zhou, P. i altres (2016). *Text Classification Improved by Integrating Bidirectional LSTM with Two-dimensional Max Pooling*. arXiv::1611.06639.