

Processament i anàlisi d'informació textual

PRA1

Instruccions

La primera pràctica de l'assignatura està dissenyada per a aplicar l'aprenentatge en els primers mòduls de l'assignatura.

A la PRA1 treballarem amb un *dataset* de ressenyes (opinions o *reviews*) i l'analtzarem seguint un conjunt de tasques: des de la preparació i neteja de les dades, fins a l'avaluació de models de classificació de sentiments. Per tant, els objectius d'aquesta activitat són:

- Aplicar tècniques de processament de llenguatge natural per a netejar i preprocessar les dades del dataset triat.
- Implementar algorismes d'aprenentatge automàtic, com ara LDA i classificació supervisada, per a analitzar els textos de les ressenyes.
- Avaluar el rendiment dels models creats, utilitzant les mètriques adequades.

Per a iniciar el desenvolupament de la PRA1, abordarem l'anàlisi de textos aplicant enfocaments clàssics del processament del llenguatge natural i de l'aprenentatge automàtic. A continuació, trobareu informació important per a orientar el seu desenvolupament.

La realització d'aquesta pràctica es realitzarà mitjançant l'elecció d'un dataset de ressenyes; sereu els estudiants els encarregats d'aquesta tasca, la qual es durà terme mitjançant la consecució de diferents passos, com es comenta a continuació.

Primer pas: identificació del dataset

Abans d'iniciar el desenvolupament de la PRA1, haureu de triar un conjunt de dades, de tipus textual, sobre el que aplicareu diferents tècniques de processament i anàlisi de text vistes en l'assignatura.

Per a la selecció del conjunt de dades es recomana considerar els següents criteris:

- El conjunt de dades haurà de tenir almenys 5000 opinions i pot contenir textos en castellà, anglès o català.
- A més del text de les opinions, el dataset haurà de tenir una columna que indiqui el sentiment de cada text (negatiu/positiu, 0/1 o similar), és a dir, ha de ser un dataset etiquetat. Si no trobes un dataset etiquetat amb el sentiment binari, una altra opció és triar un dataset amb una columna que descrigui el 'rating' de l'opinió, i a partir del seu valor, crear una nova columna de sentiment. Per exemple, si tenim els valors 1 a 5 per a rating, podem considerar els valors d'1 i 2, com a sentiment negatiu (0), i els valors 4 i 5 com a positiu (1). Ara com ara, ens centrarem en la classificació binària, per tant, no és necessari considerar els valors de sentiment "neutral" o amb un rating igual a 3.

Per exemple, podeu utilitzar datasets de ressenyes de productes, comentaris en xarxes socials o articles de notícies.

Per a buscar datasets, pots utilitzar qualsevol repositori de dades públiques o obertes, o pots prendre com a referència els següents repositoris:

- [KAGGLE Datasets.](#)
- [Top 10 Sentiment Analysis Datasets.](#)
- [Hugging Face Datasets.](#)

Segon pas: realitzar l'activitat

Per a realitzar la pràctica haureu d'implementar un notebook que faci les següents tasques:

1. **Preparació del dataset (10%).** En aquesta part s'analitzarà breument el dataset, es realitzarà el preprocessament i la neteja del seu text i es prepararan les seves dades per a la seva posterior anàlisi. El notebook haurà de mostrar (amb un *print*), per a cada transformació realitzada, un exemple que mostri els canvis realitzats. Algunes de les transformacions que es podran realitzar són la conversió de text a minúscules, el filtratge de caràcters especials i de tokens no alfabètics, l'eliminació de mencions, hashtags i pàgines web, correccions de paraules mal escrites, eliminació de duplicats, conversió de contraccions (per exemple, en lloc de wouldn't, es canviaria a would not), etc. També mirarem coses com la longitud mitjana dels textos (segmentats) i nombre de duplicats trobats i eliminats.
2. **Obtenció de dades (30%).** En aquesta part analitzarem el text, trobarem el conjunt de termes multi-paraula rellevants del dataset i analitzarem l'objecte i aspectes de les opinions del text utilitzant el model Word2Vec. Per a això començarem calculant els millors bigrames i trigramas de les opinions del dataset i avaluar-los segons diferents mètriques (PMI i Likelihood). Posteriorment, detectarem els n-grames que compleixin un

patró sintàctic d'un sintagma nominal (e.g: adjectiu + nom en singular/plural, nom + nom i nom en singular/plural) i acabarem detectant col·locacions amb un model de detecció de Phrases, per exemple amb el mòdul Phraser de Gensim. Un cop analitzats els termes multi-paraula, crearem un model word2vec amb les opinions lematitzades i l'utilitzarem per a analitzar els targets de les opinions.

3. **Detecció de temes (30%).** En aquesta part ens dedicarem a explorar els temes detectats utilitzant WordNet i durem a terme l'extracció de temes a partir de LDA. Haurem de provar diferents números de temes i seleccionar el millor fent servir una mètrica de coherència com C_v .
4. **Classificació automàtica d'opinions positives i negatives (20%).** L'objectiu d'aquesta part serà crear un classificador que permeti, donat un text, identificar la polaritat de la seva opinió.
5. **Avaluació de models de classificació (10%).** En aquest apartat s'utilitzaran les mètriques d'avaluació vistes a classe per a avaluar el model de classificació creat en l'apartat anterior i per a comparar aquest model amb altres models de classificació.

Tercer pas: analitzar els resultats obtinguts

Aquest pas es farà de manera concurrent amb el segon i el seu objectiu serà analitzar i reflexionar sobre els resultats obtinguts a cadascuna de les tasques realitzades.

Fitxers proporcionats

Per a dur a terme la PRA1 se subministren els següents documents:

- **'Enunciat_PRA1.ipynb':** Enunciat de la PRA1 en format ipynb. Aquí hi trobaràs l'especificació dels exercicis que es demana realitzar.
- **'PRA 1 - Anàlisi de resultats':** Enunciat de les preguntes d'anàlisi plantejades que haureu de resoldre per a cada tasca.
- **'Exemple-PRA1.html':** Fitxer d'exemple que conté unes cel·les de codi bàsiques i les sortides d'alguns dels exercicis proposats per a un cas en què s'analitzen opinions d'Amazon. El seu objectiu és orientar-vos en el desenvolupament de la pràctica.
- **AFINN-111.txt:** Diccionari d'*opinion words* que serà usat per a l'anàlisi de sentiments del dataset.

Lliurables

El lliurament d'aquesta PRA1 consta de tres documents:

- **Fitxer en format ipynb:** Aquest notebook contindrà el codi de les tasques plantejades. Haurà de seguir el format de l'enunciat proporcionat, on s'especifiquen totes les activitats a realitzar per a cadascuna de les tasques.
- **Fitxer en format html:** Aquest document serà la impressió en format html del notebook realitzat.
- **Fitxer d'anàlisi dels resultats:** Aquest document haurà de contenir informació sobre l'activitat realitzada, com ara el dataset utilitzat i l'anàlisi dels resultats obtinguts. Els estudiants hauran de contestar les preguntes de reflexió plantejades en el document 'PRA 1 - Anàlisi de resultats'

Criteris de valoració

En aquesta activitat es valorarà tant la competència implementant solucions que processin textos, com la capacitat de comprensió i anàlisi en l'àmbit del processament de text. Seguint aquest precepte, la nota final de l'activitat es compondrà d'un 70% de la nota obtinguda en el notebook i d'un 30% de la nota obtinguda en el document d'anàlisi. Cada exercici té indicat a l'enunciat el seu pes en la valoració final.

Propietat intel·lectual

Al lliurar una pràctica que faci ús de recursos aliens, s'ha de presentar juntament amb ella un document en què es detallin tots ells, especificant el nom de cada recurs, l'autor, el lloc on es va obtenir i el seu estatus legal: si l'obra està protegida pel copyright o s'acull a alguna altra llicència d'ús (Creative Commons, llicència GNU, GPL, etc.) L'estudiant haurà d'assegurar-se que la llicència que sigui no impedeix específicament el seu ús en el marc de la pràctica o PAC. En cas de no trobar la informació corresponent, haurà d'assumir que l'obra està protegida pel copyright.

Serà necessari, a més, adjuntar els fitxers originals quan les obres utilitzades siguin digitals, i el seu codi font, si així correspon.