

Processament i anàlisi d'informació textual

1. Elecció i preparació del dataset (10%)

A partir de la selecció del dataset i de les tasques realitzades en l'apartat 1 de la pràctica, titulat "Elecció i preparació del dataset", contesta les següents preguntes:

1. Descriu el dataset triat. Indica el seu origen, la quantitat de dades que conté, la tipologia de les mateixes i justifica la seva elecció.
2. Explica els problemes que has trobat a les dades i les activitats de neteja i preprocessament que has realitzat durant l'etapa de "preparació del dataset".

Els criteris per a avaluar aquest exercici són els següents:

Pregunta	No assolit (C-)	Mínimament assolit (C+)	Assolit (B)	Assolit de manera excel·lent (A)
1)	No es respon a la pregunta plantejada o la resposta és incompleta.	El dataset es comenta breument, amb informació parcial sobre el tipus de dades, nombre de registres i distribució de les dades.	El dataset es descriu de manera clara indicant la majoria dels elements requerits encara que no tots. La justificació del perquè de l'ús del dataset és adequada.	El dataset es descriu de manera clara indicant el seu origen, el nombre de registres que conté i la distribució de les seves dades (quant a opinions positives i negatives). El dataset compleix les característiques indicades en l'enunciat. Es presenta una justificació adequada del perquè de l'elecció del dataset triat. La resposta ocupa mitja pàgina o menys.
2.	No es respon a la pregunta plantejada o la resposta és incompleta.	Es comenten breument els problemes trobats en les dades i els algorismes utilitzats per a resoldre'ls.	Es comenten clarament els problemes en les dades, els algorismes utilitzats per a resoldre'ls i es justifica l'ús de la majoria d'aquests.	Es comenten clarament els problemes en les dades, així com els algorismes utilitzats per a resoldre'ls. Per a cadascun d'ells hi ha una justificació clara del seu ús. La resposta ocupa mitja pàgina o menys.

2. Obtenció de dades (30%)

A partir de les tasques realitzades a l'apartat 2 de la pràctica, titulada "Obtenció de dades", contesta les següents preguntes:

1. Comenta les similituds / diferències i compara els n-grames i les col·locacions obtinguts mitjançant els diferents mètodes d'aquest apartat (Exercici 2.1)
2. Analitza els termes obtinguts utilitzant el model Word2Vec, tria els 5 termes (aspectes) més rellevants i comenta els criteris tinguts en compte per a la seva selecció.

Els criteris d'avaluació per a les dues preguntes són els següents:

No assolit (C-)	Mínimament assolit (C+)	Assolit (B)	Assolit de manera excel·lent (A)
La resposta és incorrecta o no està justificada.	La resposta és parcialment incorrecta, però la justificació és correcta, demostra coneixement sobre el tema.	La resposta és correcta i està convenientment justificada.	La resposta és correcta, està correctament justificada mitjançant exemples i és concisa (ocupa mitja pàgina com a molt per cada pregunta).

3. Detecció de temes (30%)

A partir de les tasques realitzades a l'apartat 3 de la pràctica, titulada “Detecció de temes”, respon les següents preguntes:

1. Analitza els resultats obtinguts en la primera part de l'exercici, l'exploració dels temes amb WordNet.
2. Compara els diferents models LDA utilitzats, tria el més adequat de forma justificada. A més de les mètriques calculades, considera la ‘interpretabilitat’ dels resultats que ofereix el millor model, és a dir, és possible assignar una etiqueta o categoria a les paraules destacades que representen a cada tòpic?

Els criteris d'avaluació per a avaluar aquest exercici són els següents:

Pregunta	No assolit (C-)	Mínimament assolit (C+)	Assolit (B)	Assolit de manera excel·lent (A)
1.	No es respon a la pregunta plantejada o la resposta és incompleta.	La resposta és parcialment incorrecta, però la justificació és correcta, demostra coneixement sobre el tema.	La resposta és correcta, tot i que parcialment incompleta. Entenem una resposta completa si en la mateixa s'analitzen els resultats obtinguts en WordNet i es comparen amb els de Word2Vec.	La resposta és correcta, és completa i mostra exemples per a justificar els arguments. Entenem una resposta completa si en la mateixa s'analitzen els resultats obtinguts en WordNet i es comparen amb els de Word2Vec. La resposta ocupa mitja pàgina o menys.
2.	No es respon a la pregunta plantejada o la resposta és incompleta.	La resposta és parcialment incorrecta, però la justificació és correcta, demostra coneixement sobre el tema.	La resposta compara els diferents models LDA utilitzats i proposa el més adequat de forma justificada. La resposta ocupa mitja pàgina o menys.	La resposta compara els diferents models LDA utilitzats, proposa el més adequat i es justifica utilitzant les mètriques de perplexitat i coherència. La resposta ocupa mitja pàgina o menys.

4. Classificació automàtica d'opinions positives i negatives (20%)

A partir de les tasques realitzades a l'apartat 4 de la pràctica, titulat "Classificació automàtica d'opinions positives i negatives", comentar:

1. Si existeix coherència entre les classes (0 i 1) i les paraules més informatives identificades (vegeu el quart pas de l'apartat 4.1)
2. Segons els resultats obtinguts a l'apartat 4.2, *Tercer pas*, identifica els aspectes sobre els quals s'han realitzat valoracions negatives i comenta els resultats.

Els criteris d'avaluació per a aquest exercici són els següents:

Pregunta	No assolit (C-)	Mínimament assolit (C+)	Assolit (B)	Assolit de manera excel·lent (A)
1	No es respon a la pregunta plantejada o la resposta és incompleta.	La resposta és parcialment incorrecta, però la justificació és correcta, demostra coneixement sobre el tema.	La resposta és correcta, tot i que no existeix coherència entre les paraules informatives i les classes.	La resposta és correcta, completa i es justifica prou amb l'ús d'exemples. La resposta ocupa mitja pàgina o menys.
2	No es respon a la pregunta plantejada o la resposta és incompleta.	La resposta és parcialment incorrecta, però la justificació és correcta, demostra coneixement sobre el tema.	La resposta és correcta, tot i que incompleta perquè no s'identifiquen els aspectes pitjor valorats.	La resposta és correcta, completa i es justifica prou amb l'ús d'exemples. La resposta ocupa mitja pàgina o menys.

5. Avaluació (10%)

A partir de les mètriques calculades en els classificadors de l'apartat 5 de la pràctica, titulat “Avaluació: comparació de models i discussió de resultats”, compara i avalua els dos models proposats en funció de les mètriques d'avaluació vistes a l'assignatura (*precision*, *recall* i *f1*) i del temps d'execució. Conclou finalment quin dels dos models triaries per a predir noves ressenyes sobre productes i el perquè.

Els criteris d'avaluació per a avaluar aquest exercici són els següents:

No assolit (C-)	Mínimament assolit (C+)	Assolit (B)	Assolit de manera excel·lent (A)
La resposta és incorrecta.	Els dos algorismes es comparen convenientment utilitzant les mètriques requerides (<i>precision</i> , <i>recall</i> i <i>f1</i>).	Els dos algorismes es comparen detalladament utilitzant les mètriques requerides, destacant les seves diferències i justificant quin model s'utilitzarà i el perquè.	Els dos algorismes es comparen detalladament utilitzant les mètriques requerides, destacant les seves diferències i justificant quin model s'utilitzarà i el perquè. La resposta ocupa mitja pàgina o menys.

Criteris de valoració

Els exercicis tenen un pes de 10%, 30%, 30%, 20% i 10% respectivament. Es valorarà, per a cada apartat, la validesa de la solució i la claredat de l'argumentació d'acord amb la rúbrica facilitada en cada exercici. Molts dels exercicis plantejats no tenen una única resposta, per la qual cosa és important justificar adequadament la resposta proposada. Qualsevol solució no justificada es considerarà incompleta.