

Deep Learning per a l'anàlisi de textos

1. Elecció de Datasets (25%)

A partir de la selecció dels datasets per a la PRA2, que s'usen tant a la secció 1 "Traducció Automàtica (TA)" com a la secció 2 "Detecció de NER i NEL" contesta les següents preguntes:

1. Descriu els datasets escollits. Indica l'origen, la quantitat de dades que contenen, la tipologia d'aquestes i justifica l'elecció.
2. Explica els problemes que has trobat a les dades i les activitats de neteja i preprocessament que has realitzat en preparar les dades per a la pràctica de TA i la de NER.

Els criteris d'avaluació per avaluar aquest exercici són els següents:

Pregunta	No aconseguit (C-)	Mínimament aconseguit (C+)	Assolit (B)	Assolit de manera excel·lent (A)
1	No es respon a la pregunta plantejada o la resposta és incompleta.	Els datasets es comenten breument, amb informació parcial sobre el tipus de dades, el número de registre, la distribució de dades.	Els datasets es descriuen de manera clara indicant la majoria dels elements requerits encara que no tots. La justificació del perquè de l'ús del dataset és adequada	Els datasets es descriuen de forma clara indicant-ne l'origen, el nombre de registres que contenen i informació del seu contingut. Els datasets compleixen les característiques indicades a l'enunciat. Es presenta una justificació adequada del perquè de l'elecció dels datasets d'interès. La resposta ocupa mitja pàgina o menys per a cada dataset escollit.
2	No es respon a la pregunta plantejada o la resposta és incompleta.	Es comenten breument els problemes trobats a les dades i els algorismes utilitzats per resoldre'ls	Es comenten clarament els problemes en les dades, els algorismes utilitzats per resoldre'ls i se'n justifica l'ús de la majoria.	Es comenten clarament els problemes en les dades, així com els algorismes utilitzats per resoldre'ls. Per a cadascun hi ha una justificació clara del seu ús. La resposta ocupa mitja pàgina o menys per a cada dataset.

2. Traducció automàtica (50%)

Per a cadascun dels models de traducció automàtica creats, respon les preguntes següents:

1. Explica com has definit el primer model encoder-decoder i com has triat els paràmetres que s'hi fan servir. A més, explica quins valors dels paràmetres haurien estat més apropiats, depenent de les dades de l'arxiu seleccionat per a TA.
2. En el primer model de TA, descriu quin efecte tenen els diferents valors en el rendiment del model. Com podríem millorar els resultats d'aquesta tasca?
3. Compara els dos models de TA entrenats: Explica quines són les principals diferències entre els dos models entrenats. Quina proporciona millors resultats? Per què?

Els criteris d'avaluació per a les tres preguntes són els següents:

Pregunta	No aconseguit (C-)	Mínimament aconseguit (C+)	Assolit (B)	Assolit de manera excel·lent (A)
1	La resposta és incorrecta o no està justificada.	La resposta és parcialment incorrecta, però la justificació és correcta demostra coneixement sobre el tema.	La resposta és correcta i està convenientment justificada.	La resposta és correcta, està correctament justificada mitjançant exemples i és concisa (ocupa mitja pàgina com a molt).
2	La resposta és incorrecta o no està justificada.	La resposta és parcialment incorrecta, però la justificació és correcta demostra coneixement sobre el tema.	La resposta és correcta i està convenientment justificada, però no es mostren exemples de com afecten els embeddings.	La resposta és correcta, està justificada correctament mitjançant exemples i és concisa. (ocupa mitja pàgina com a molt).

3. Detecció de NER y NEL (25%)

A partir de les tasques realitzades a l'apartat 2 de la pràctica, titulada “Detecció de NER i NEL”, contesta les preguntes següents:

1. Quins resultats s'obtenen en general en la detecció d'entitats? De què depenen, i quin efecte té el corpus utilitzat en la distribució de tipus d'entitats i en la seva avaluació?
2. Quin tipus d'entitats podem enllaçar amb Wikidata? Què ocorre si tenim una entitat amb un nom ambigu? Què podríem fer per intentar trobar l'enllaç correcte donat cada context?

Els criteris d'avaluació per avaluar aquest exercici són els següents:

Pregunta	No aconseguit (C-)	Mínimament aconseguit (C+)	Assolit (B)	Assolit de manera excel·lent (A)
1	No es respon la pregunta plantejada o la resposta és incompleta.	La resposta és parcialment incorrecta, però la justificació és correcta demostra coneixement sobre el tema.	La resposta és correcta, encara que parcialment incompleta. Entenem una resposta completa si es demostra que els conceptes s'han entès i es descriuen clarament.	La resposta és correcta, és completa i mostra exemples per justificar els arguments. Entenem una resposta completa si es demostra que els conceptes s'han entès i es descriuen clarament. La resposta ocupa mitja pàgina o menys.
2	No es respon la pregunta plantejada o la resposta és incompleta.	La resposta és parcialment incorrecta, però la justificació és correcta demostra coneixement sobre el tema.	La resposta no compara exemples d'entitats enllaçades amb DBpedia/Wikidata i no es justifica la pregunta adequadament. La resposta ocupa mitja pàgina o menys.	La resposta compara els exemples d'entitats enllaçades o no amb el DBpedia /Wikidata i es justifica la pregunta adequadament. S'apunta com es podrien millorar els models per trobar l'enllaç correcte a cada context. La resposta ocupa mitja pàgina o menys.



Criteris de valoració

Els exercicis d'aquest apartat tenen un pes de 25%, 50% i 25% respectivament. Es valorarà, per a cada apartat, la validesa de la solució i la claredat de l'argumentació d'acord amb la rúbrica facilitada en cada exercici. Molts dels exercicis plantejats no tenen una única resposta, per la qual cosa és important justificar la resposta proposada adequadament. Qualsevol solució no justificada es considera incompleta.