

Tipologia i cicle de vida de les dades

Pràctica 1

UOC

Com podem capturar les dades de la web?

25% nota final

Data de lliurament

11 de novembre de 2025

Presentació

En aquesta pràctica s'elabora un cas pràctic orientat a aprendre a identificar i extreure dades rellevants per a un projecte analític, fent servir eines específiques de *web scraping*. Per fer aquesta pràctica haureu de treballar en **grups de dues persones**.

De manera orientativa, es poden consultar els següents exemples, tenint en compte que poden les respostes poden no ser les més adequades per a la pràctica que es planteja aquest semestre:

- Exemple: <https://github.com/rafoelhonrado/foodPriceScraper>
- Exemple complex: <https://github.com/tteguayco/Web-scraping>

El lliurament d'aquesta pràctica s'ha de realitzar tal com s'especifica a l'apartat [Format i data de lliurament](#). Haureu de lliurar els següents elements:

- Una memòria en format PDF amb les respostes als apartats.
- Un repositori amb el codi font de la pràctica.
- El dataset obtingut (tant al repositori com a Zenodo).
- Un vídeo explicatiu, en el que ambdós integrants del grup han de comentar els aspectes més rellevants del projecte.

És important tenir en compte les següents consideracions a l'hora de lliurar la pràctica:

- És obligatori i **queda com a responsabilitat de cada estudiant revisar que l'arxiu lliurat és el correcte**. Un arxiu buit o no pertinent es considerarà com no lliurat.
- Perquè el lliurament es consideri com realitzat, s'ha de completar almenys el 25% de tota l'activitat.
- No podrà modificar-se cap element de la pràctica passada la data de lliurament (repositori, arxius de Google Drive, etc.).
- Així mateix, també és responsabilitat de l'estudiant assegurar-se que, en el moment del lliurament de la pràctica, **s'ha donat accés al professor als diferents elements privats que es lliurin** (p. ex., repositori GitHub privat o arxius restringits de Google Drive). El professor indicarà als Anuncis de l'aula el seu nom d'usuari en aquestes plataformes.
- No es poden fer grups amb alumnes de diferents aules.

Competències

En aquesta pràctica es desenvolupen les següents competències del Màster universitari en Ciència de Dades:

- Capacitat d'analitzar un problema en el nivell d'abstracció adequat a cada situació i aplicar les habilitats i coneixements adquirits per resoldre-ho.
- Capacitat per aplicar les tècniques específiques de *web scraping*.

Objectius

Els objectius concrets d'aquesta pràctica són:

- Aprendre a aplicar els coneixements adquirits i la seva capacitat de resolució de problemes en entorns nous o poc coneguts dins de contextos més amplis o multidisciplinaris.
- Saber identificar les dades rellevants que el seu tractament aporta valor a una empresa i la identificació de nous projectes analítics.
- Saber identificar les dades rellevants per dur a terme un projecte analític.
- Capturar dades de diferents fonts de dades (tals com a xarxes socials, web de dades o repositoris).
- Actuar segons els principis ètics i legals relacionats amb la manipulació de dades en funció de l'àmbit d'aplicació.
- Desenvolupar la capacitat de cerca, gestió i ús d'informació i recursos en l'àmbit de la ciència de dades.

Descripció de la pràctica a realitzar

L'objectiu d'aquesta activitat serà la creació d'un *dataset* a partir de les dades contingudes a un lloc web, mitjançant el desenvolupament d'un script propi d'extracció de dades. Han de tenir-se en compte les [consideracions sobre el lloc web triat, el codi i el dataset](#) que s'indiquen més endavant. S'haurà de presentar un document PDF en el qual es resolguin els següents apartats (**màxim 20 pàgines**):

1. **Context.** Explicar en quin context específic s'han recollit les dades i argumentar per què el lloc web seleccionat és una font pertinent i fiable d'aquesta informació. Indicar l'adreça del lloc web.
2. **Títol.** Definir un títol concís i que sigui descriptiu per al dataset.
3. **Descripció del dataset.** Desenvolupar una descripció breu del conjunt de dades que s'ha extret. És necessari que aquesta descripció sigui coherent amb el títol escollit.
4. **Representació gràfica.** Dibuixar un esquema o diagrama que reflecteixi visualment el dataset i el projecte escollit.
5. **Contingut.** Explicar els camps que s'inclouen al dataset i el període de temps a què pertanyen les dades.
6. **Propietari.** Presentar el propietari del conjunt de dades. És necessari incloure cites d'anàlisis anteriors o, en cas de no haver-n'hi, justificar aquesta cerca amb anàlisis similars. Indiqueu quins passos s'han seguit per actuar d'acord amb els principis ètics i legals en el context del projecte escollit.
7. **Inspiració.** Explicar per què pot ser interessant aquest conjunt de dades i quines preguntes s'hi pretenen respondre. És necessari comparar amb les anàlisis anteriors o anàlisis similars presentades a l'apartat 6.
8. **Llicència.** Seleccionar una d'aquestes llicències pel dataset resultant i justificar el motiu de la seva selecció. Exemples de llicències que poden considerar-se:
 - Released Under CC0: Public Domain License.

- Released Under CC BY-NC-SA 4.0 License.
 - Released Under CC BY-SA 4.0 License.
 - Database released under Open Database License, individual contents under Database Contents License.
 - Altres (especificar quina).
9. **Codi.** Codi implementat per a l'obtenció del dataset, preferiblement en Python o, alternativament, en R.
- El codi haurà de situar-se a la carpeta **/source** del repositori.
 - S'han d'indicar les llibreries i versions utilitzades. P. ex., en Python poden obtenir-se mitjançant la comanda

```
pip3 freeze > requirements.txt
```
 - Al document PDF s'han de comentar els aspectes més rellevants sobre com el codi realitza el procés de recol·lecció de dades, quines dificultats presenta el lloc web triat, i com les heu resolt.
10. **Dataset.** Publicar el dataset obtingut en format CSV a Zenodo, incloent-hi una breu descripció del mateix. Obtenir i adjuntar l'enllaç del DOI del dataset (<https://doi.org/>). El dataset també haurà d'incloure's a la carpeta **/dataset** del repositori. Si existeix qualsevol circumstància que impedeixi publicar obertament el dataset real a Zenodo, s'haurà de:
- a. Comentar aquesta circumstància i justificar el motiu.
 - b. Generar un dataset simulat i publicar-lo a Zenodo, obtenint l'enllaç del DOI.
 - c. Comunicar al professor el dataset real de manera privada (p. ex., al repositori privat o a una carpeta de Google Drive privada).
11. **Vídeo.** Realitzar un breu vídeo explicatiu de la pràctica (**màxim 10 minuts**), que haurà de comptar amb la participació dels dos integrants del grup. Al vídeo s'haurà de realitzar una presentació del projecte, destacant els punts més rellevants, tant de les respostes als apartats com del codi utilitzat per a extreure les dades. Indicar l'enllaç del vídeo (<https://drive.google.com/>), que haurà d'estar al Google Drive de la UOC.

Consideracions sobre el lloc web triat, el codi i el dataset

A l'hora de triar un lloc web per a realitzar aquesta pràctica, és important tenir en compte que l'objectiu primordial consisteix a extreure un dataset potencialment "interessant", i que el procés d'extracció de les dades no sigui completament "trivial":

- L'idioma del lloc web triat ha de ser **castellà, anglès o català**.
- El lloc web triat no pot ser un lloc de "pràctiques" (p.ex. <https://books.toscrape.com/>), sinó **un lloc real**.
- El codi generat per a obtenir el dataset ha de realitzar **descobriment d'enllaços i navegació autònoma**. P. ex., no és suficient amb processar el contingut d'una única pàgina web on aparegui tot el dataset a una única taula.
- El codi ha d'implementar mecanismes per a fer **un bon ús del web scraping** (p. ex., evitar saturar al servidor).

- Ha de comprovar-se **quin User-Agent està utilitzant el codi**, encara que s'utilitzi un WebDriver.
- **No es permet l'ús d'APIs com a part principal de la pràctica.** En cas que el lloc web triat ofereixi alguna API per a accedir a les dades, s'haurà de prescindir d'aquesta. Es permet l'ús d'APIs com a part complementària a la pràctica, p. ex., per a realitzar consultes a algun servei addicional per a tractar/completar les dades recollides.
- El codi ha de tenir un **nivell adequat de modularitat i estar degudament comentat**. No es tracta d'introduir un comentari per cada línia de codi, sinó de comentar punts clau que ajudin a seguir i entendre què s'està realitzant.
- Es recomana, tot i que no és obligatori, **utilitzar un entorn virtual** per gestionar les dependències, com ara venv, virtualenv, Poetry o Pipenv.
- **No és necessari realitzar neteja del dataset resultant**, ja que això serà un dels objectius de la Pràctica 2. Si es vol utilitzar el dataset generat per a la Pràctica 2 (no és obligatori utilitzar aquest dataset), seria convenient que inclogués tant dades numèriques com categòriques.

La nota final tindrà en compte les dificultats abordades en la recol·lecció del dataset. Alguns aspectes que incrementen la dificultat són:

- Ús de tecnologies avançades com *Selenium* o *Scrapy*.
- Recol·lecció de dades de llocs web amb contingut dinàmic (p. ex., infinite scroll, mouseover).
- Ús de mètodes avançats per a saltar-se la prevenció de *web scraping*.
- Gestió de contingut audiovisual.
- Gestió d'usuaris i contrasenyes.
- Gestió de codi *JavaScript*.

Recursos

Els següents recursos són d'utilitat per la realització de la pràctica:

- Subirats, L., Calvo, M. (2018). Web Scraping. Editorial UOC.
- Masip, D. El lenguaje Python. Editorial UOC.
- Lawson, R. (2015). Web Scraping with Python. Packt Publishing Ltd. Chapter 2. Scraping the Data.
- Simon Munzert, Christian Rubba, Peter Meißner, Dominic Nyhuis. (2015). Automated Data Collection with R: A Practical Guide to Web Scraping and Text Mining. John Wiley & Sons.
- Tutorial de Github <https://guides.github.com/activities/hello-world>.

Criteris de valoració

Tots els apartats són obligatoris. La ponderació dels apartats és la següent:

Apartat	1	2	3	4	5	6	7	8	9	10	11
Punts	0,25	0,25	0,25	0,5	1	1,5	1,25	0,5	2	2	0,5

Criteris que es tindran en compte per a l'avaluació de la pràctica són:

- Idoneïtat de les respostes (hauran de ser clares i completes).
- **Complexitat** del lloc web triat per a l'extracció. És important tenir en compte que la complexitat serà un factor que s'avaluarà i dependrà tant del lloc triat com de l'anàlisi realitzat a la pràctica.
- Síntesi i claredat, a través de l'ús de comentaris, del codi resultant.
- Presentació adequada de les dades.
- Organització i claredat dels documents de lliurament final.
- Completitud dels documents requerits per al lliurament final.
- Seguiment de recomanacions per al bon ús del *web scraping*.

Format i data de lliurament

En referència al lliurament de la pràctica, es demana:

- a. **La memòria de la pràctica**, que haurà de ser **un únic document PDF**. La primera pàgina haurà de contenir les metadades de la pràctica:
 - Els noms dels integrants del grup.
 - L'enllaç al lloc web elegit.
 - L'enllaç al repositori amb el codi de la pràctica.
 - L'enllaç al dataset publicat a Zenodo.
 - L'enllaç al vídeo de presentació de la pràctica.

A continuació, la memòria ha de contenir les **respostes als 11 apartats** en un **màxim de 20 pàgines**.

Al final del document, ha d'aparèixer la següent taula de contribucions al treball, la qual ha de signar cada integrant del grup amb les seves inicials. Les inicials representen la confirmació per part del grup que l'integrant ha participat a aquest apartat. Tots els integrants han de participar en cada apartat, per la qual cosa, idealment, els apartats haurien d'estar signats per tots els integrants.

Contribucions	Signatura
Investigació prèvia	Integrant 1, Integrant 2
Redacció de les respostes	Integrant 1, Integrant 2

Desenvolupament del codi	Integrant 1, Integrant 2
Participació al vídeo	Integrant 1, Integrant 2

Aquest document es lliurarà, per cadascun dels integrants del grup, a l'**Espai de Lliurament PR1 de l'aula Canvas**.

- b. **Un repositori Git** amb el codi de la pràctica a la branca “main”. El repositori es crearà a GitHub (<https://github.com/>). Haurà de ser un **repositori privat**, per la qual cosa s'haurà de donar accés al professor. El repositori haurà de contenir:
1. **Un document README.md**: Estarà situat a la carpeta arrel i haurà de contenir:
 - Els noms dels integrants del grup.
 - Un apartat on es descriuin els arxius que componen el repositori.
 - Un apartat on es descrigui com utilitzar el codi generat. Haurà d'incloure informació sobre els possibles paràmetres que admeti el script i un o diversos exemples replicables del seu ús.
 - El DOI de Zenodo del dataset generat.
 2. Un arxiu `requirements.txt` (o equivalent) amb les llibreries necessàries per a executar el codi.
 3. **Carpeta /source**: Haurà de contenir el codi Python o R generat per a obtenir les dades.
 4. **Carpeta /dataset**: Haurà de contenir el dataset resultant en format CSV.
- c. **Un vídeo explicatiu**, la durada del qual **no ha de superar els 10 minuts**. L'enllaç del mateix s'ha d'indicar a l'apartat 11 del document PDF.

El lliurament de la pràctica s'ha de realitzar abans de les **23:59 CET del dia 11 de novembre de 2025**. No s'acceptaran lliuraments fora de termini.

- **No podrà modificar-se cap element de la pràctica passada la data de lliurament** (repositori, arxius de Google Drive, etc.).
- Pel que fa a l'ús de programari, llibreries o repositoris de tercers, s'hauran de complir les seves respectives llicències i condicions d'ús.
- La còpia o plagi en la realització de la pràctica comportarà la qualificació de suspens (D). El treball lliurat ha de ser original, citant adequadament les fonts bibliogràfiques utilitzades. Per a més informació i recursos podeu consultar:
 - **Integritat acadèmica i plagi**:
<https://campus.uoc.edu/estudiant/microsites/plagi/ca/index.html>
 - **Com citar correctament i evitar el plagi (Biblioteca UOC)**:
<https://biblioteca.uoc.edu/ca/plana/Com-citar/>

Si s'estima oportú, el professor convocarà als integrants del grup a una entrevista remota (de manera conjunta o individual) mitjançant Google Meet, en referència a la pràctica realitzada, en un dia i hora acordats.

Propietat intel·lectual

Al presentar una pràctica o PAC que faci ús de recursos aliens, s'ha de presentar juntament amb ella un document en què es detallin tots ells, especificant el nom de cada recurs, el seu autor, el lloc on es va obtenir i el seu estatus legal: si l'obra està protegida pel copyright o s'acull a alguna altra llicència d'ús (Creative Commons, llicència GNU, GPL etc.). L'estudiant haurà d'assegurar que la llicència que sigui no impedeix específicament seu ús en el marc de la pràctica o PAC. En cas de no trobar la informació corresponent haurà d'assumir que l'obra està protegida pel copyright.