

Universitat Oberta de Catalunya



PRACTICA 1 - Com podem capturar les dades de la web?

Autors:

Albert Lozano Valverde & Alberto Antorán Ponce

emails:

alozanoval@uoc.edu & aantoran@uoc.edu

Barcelona, Novembre , 2025

Memòria

- Grup: **Alberto Lozano Valverde & Alberto Antorán Ponce**
- Web escollida: platesmania.com/
- Repositori Github amb codi: Repositori alvimn / entrega_{1+cvd}
- Dataset Zenodo: Zenodo-Spain and France car plates repository from www.platesmania.com
- Enllaç Video

1 Context

El projecte s'emmarca en l'àmbit de la mobilitat internacional i la identificació de vehicles a través de les seves matrícules. Les dades s'han recollit del lloc web Platesmania, una plataforma col·laborativa amb **28.042.808 de fotografies de vehicles i les seves matrícules**. Aquesta plataforma permet als usuaris compartir fotografies de vehicles de tot el món, associant-hi informació addicional com el país, la regió, la data, la matrícula i el model del vehicle.

Aquest lloc és una font rellevant i fiable per diverses raons:

1. És una comunitat activa amb milers de contribucions diàries verificades per moderadors.
2. La informació es basa en fotografies reals, fet que redueix el risc d'errors de transcripció.
3. PlatesMania és àmpliament utilitzada per aficionats i **investigadors d'identificació de vehicles i geolocalització visual**.

L'objectiu del projecte és crear un dataset estructurat de matrícules per país i tipus de vehicle, que pugui servir per a estudis sobre mobilitat, disseny de plaques o detecció automàtica de vehicles en imatges.

2 Títol


“Global Vehicle License Plate Dataset from PlatesMania”

3 Descripció

El dataset recull una mostra de dades extretes automàticament de la web PlatesMania. Cada registre correspon a una fotografia d'una matrícula i inclou informació sobre el país, la regió, la marca i model del vehicle, la data de pujada, l'usuari autor de la imatge i l'enllaç original.

L'objectiu és generar un conjunt de dades net i estructurat que pugui ser utilitzat per a tasques d'anàlisi visual o reconeixement automàtic de matrícules (ALPR), així com estudis geogràfics o culturals sobre dissenys de plaques.

4 Representació



5 Contingut

Període de temps de les dades: darreres 100 dades pujades a Platesmania el dia 08/11/2025

- **Country:** País d'origen de les dades
- **Vehicle:** Model del del vehicle

- **Generation:** Generació del model del vehicle
- **Gen. Link (Generation Link):** Link amb llista de totes les fotografies dels vehicles amb del mateix model i generació
- **Main Link:** Link de l'entrada
- **Main image:** Imatge del vehicle
- **Plate Number:** Número de matrícula
- **Plate Image:** Imatge del número de matrícula
- **Description:** Descripció realitzada per l'usuari descriptiu del vehicle amb informació com ara marca del vehicle; Ubicació; Combustible (Gasoil, Benzina...); Automàtica o manual; Potència
- **User name:** Nom de l'usuari que ha fet l'entrada **User Link:** Link al perfil del usuari
- **Upload Time:** Data de pujada de l'entrada
- **Likes:** Numero de likes
- **Comments:** Número de comentaris de la comunitat

6 Propietat

El propietari original de les dades és PlatesMania, una comunitat oberta i pública que permet l'accés lliure a les imatges sota les seves condicions d'ús.

No existeixen anàlisis acadèmiques directes sobre aquest lloc, però sí estudis similars sobre datasets visuals de matrícules com OpenALPR Benchmark o SSIG-SegPlate Dataset, que segueixen una estructura comparable.

Per actuar d'acord amb els principis ètics i legals:

- No s'han descarregat imatges directament, només metadades.
- Es respecten les polítiques de robots.txt del lloc.
- Es citen clarament la font i l'autor de cada dada.
- No s'inclou informació personal ni dades sensibles.

7 Inspiració i utilitat

Aquest dataset pot resultar interessant per a múltiples aplicacions:

- Anàlisi geogràfica: distribució de vehicles i estils de matrícules per país.
- Entrenament de models de visió per computador: reconeixement de textos o classificació d'imatges.
- Estudis culturals o de disseny: comparació de formats i tipografies de plaques entre països.
- A diferència d'altres datasets tancats, ofereix dades actualitzades i crowd-sourced, amb una cobertura global difícil d'obtenir d'altres fonts.

8 Llicència

Proposta: Database released under Open Database License (ODbL), amb continguts individuals sota Database Contents License.

Justificació: Aquesta llicència és adequada per a datasets construïts a partir de fonts obertes. Permet reutilitzar, modificar i redistribuir les dades sempre que se'n citi l'origen i es comparteixi amb la mateixa llicència. D'aquesta manera es garanteix la transparència, la traçabilitat i el respecte als drets dels creadors originals del lloc PlatesMania.

9 Codi

El codi es pot accedir a Codi Github

```
# -*- coding: utf-8 -*-

"""
Script para descargar automaticamente imagenes de matrículas de
Platesmania,
filtradas por pas.
"""

import time
from bs4 import BeautifulSoup
import os
import csv
from seleniumbase import Driver
from seleniumbase import BaseCase
import time

# Rango de paginas a recorrer (cada pagina ~10 imagenes segun el sitio)
st_pg = 1
end_pg = 10

main_dir = "./data/"
BASE = "https://platesmania.com"

driver = Driver(
    browser="chrome",
    uc=True,
    headless2=False,
    incognito=True,
    agent="Mozilla/5.0 (Windows NT 10.0; Win64; x64)...",
    do_not_track=True,
    undetectable=True
)

def click_manage_options_if_exists(driver):
    selector = "button.fc-button.fc-cta-consent.fc-primary-button"
    try:
        if driver.is_element_present(selector):
            print("Found 'Consentir' button, clicking it...")
            driver.click(selector)
            time.sleep(1)
        else:
            print("No cookie options button found.")
    except Exception as e:
        print(f"Could not handle cookie button: {e}")
```

```

def get_countrys():
    """
    Devuelve una lista con todos los paises que dispone la pagina
    """

    url = BASE + "/countries"
    driver.get(url)
    time.sleep(10)
    click_manage_options_if_exists(driver)
    html = driver.page_source
    soup = BeautifulSoup(html, 'html.parser')
    countrys = [a.find_all("a", href=True) for a in
        soup.find_all("span", class_="lead")]
    countrys = [x for x in countrys if x]
    countrys = [x[0]['href'] for x in countrys]
    # Hay muchos paises podremos solo dos para no saturar el servidor
    countrys = ['es', 'fr']
    return countrys

def get_plate_links(country, page):
    """
    Devuelve los enlaces 'nomer...' de una pgina de galera para un pas.
    Retorna lista vaca si no existe el pas o no se encuentra la galera.
    """

    url = BASE + "{}/gallery.php?&start={}".format(country, page)
    driver.get(url)
    time.sleep(5)
    click_manage_options_if_exists(driver)
    html = driver.page_source
    soup = BeautifulSoup(html, 'html.parser')

    # Heuristica sencilla para comprobar que el pas/galera es vlida
    if not soup.find(string=lambda t: "Has buscado:" in t):
        print("No se encontr el pas ")
        return []

    # Acotar el HTML a la columna principal donde est la galera
    main_col = soup.find("div", class_="col-md-9")
    if not main_col:
        print("No se encontr la galera principal")
        return []

    items = main_col.find_all("div", class_="col-sm-6")

    results = []

    for item in items:
        panel = item.find("div", class_="panel")
        if not panel:

```

```

        continue

    # Pais
    country_tag = panel.find("h3", class_="panel-title")
    country_name = country_tag.get_text(strip=True) if country_tag
        else None

    # Imagen principal y link a la entrada
    main_a = panel.find("div", class_="panel-body").find("a",
        href=True)
    main_link = main_a["href"] if main_a else None
    main_img = main_a.find("img")["src"] if main_a and
        main_a.find("img") else None

    # Vehicle name
    vehicle_tag = panel.find("h4", class_="text-center")
    vehicle_name = vehicle_tag.get_text(strip=True) if vehicle_tag
        else None

    # Vehicle generation/details
    gen_tag = panel.find("small").find("a")
    generation = gen_tag.get_text(strip=True) if gen_tag else None
    generation_link = gen_tag["href"] if gen_tag else None

    # License plate image and number
    plate_img = panel.find("div", class_="col-xs-offset-3 col-xs-6
        text-center").find("img")
    plate_number = plate_img["alt"] if plate_img and
        plate_img["alt"] else None
    plate_img_url = plate_img["src"] if plate_img else None

    # Description line (location + details)
    desc_tag = panel.find_all("small")
    description = desc_tag[1].get_text(" ", strip=True) if
        len(desc_tag) > 1 else None

    # User info
    user_tag = panel.find("i", class_="fa-user")
    user_a = user_tag.find_next("a") if user_tag else None
    username = user_a.get_text(strip=True) if user_a else None
    user_link = user_a["href"] if user_a else None

    # Date/time
    date_tag = panel.find("i", class_="fa-clock-o")
    upload_time = date_tag.find_next(string=True).strip() if
        date_tag else None

    # Likes and comments
    likes_tag = panel.find("i", class_="fa-heart")

```



```

        likes = likes_tag.find_next(string=True).strip() if likes_tag
            else "0"
        comments_tag = panel.find("i", class_="fa-comments-o")
        comments = comments_tag.find_next(string=True).strip() if
            comments_tag else "0"

    results.append({
        "country": country_name,
        "vehicle": vehicle_name,
        "generation": generation,
        "generation_link": generation_link,
        "main_link": main_link,
        "main_img": main_img,
        "plate_number": plate_number,
        "plate_img": plate_img_url,
        "description": description,
        "username": username,
        "user_link": user_link,
        "upload_time": upload_time,
        "likes": likes,
        "comments": comments
    })

    return results

try:
    # Carpeta de destino por pas (p.ej. C:\...\data\es)
    countrys = get_countrys()
    for country in countrys:
        dl_folder = os.path.join(main_dir, country)
        os.makedirs(dl_folder, exist_ok=True)

        files = os.listdir(dl_folder)

        # En el sitio, la paginacin suele empezar en 0; aqu se usa
        # st_pg-1 por esa razn.
        for page in range(st_pg - 1, end_pg):
            time.sleep(2) # pequena pausa para no saturar el servidor
            data = get_plate_links(country, page)
            with open(dl_folder + "/mycsvfile.csv", "a", newline="",
                encoding="utf-8") as f:
                w = csv.DictWriter(f, data[0].keys())
                w.writeheader()
                w.writerows(data)

except Exception as e:
    print("Error general: {}".format(e))

```

10 Dataset

Per raons de practicitat, hem limitat el dataset a 2 països, Espanya i França, i a les 100 darreres dades disponibles per país. És accessible als enllaços:

- Dataset Zenodo: Zenodo-Spain and France car plates repository from www.platesmania.com
- Dataset Global Vehicles License Plate - Espanya
- Dataset Global Vehicles License Plate - França

```
def get_countrys():  
    """  
    Devuelve una lista con todos los paises que dispone la pagina  
    """  
    url = BASE + "/countries"  
    driver.get(url)  
    time.sleep(10)  
    click_manage_options_if_exists(driver)  
    html = driver.page_source  
    soup = BeautifulSoup(html, 'html.parser')  
    countrys = [a.find_all("a", href=True) for a in  
                 soup.find_all("span", class_="lead")]  
    countrys = [x for x in countrys if x]  
    countrys = [x[0]['href'] for x in countrys]
```

```
countrys = ['es', 'fr']
```

```
return countrys
```

Country	Vehicle	Generation	Gen. Link	Main Link	Main Img	Plate Number	Plate Img	Description	Username	User Link	Upload Time	Likes	Comments
España	Nissan Juke	1st gen (F15), 2010–2014	/gallery.php?markaavto=72&model=3531&modgen=1813	/es/nomer30160606	https://img03.platesmania.com/251108/m/30160606.jpg	S 0677 BCL	https://img03.platesmania.com/251108/inf/30160606db88ee.png	Mallorca, Illes Balears (Spain) - 2025	ElV ocho	/user95504	2025-11-08 18:54:16	0	0
España	Mitsubishi Pajero	3rd gen 3-door SUV (V60/NM/NP), 1999–2006	/gallery.php?markaavto=70&model=1224&modgen=3151	/es/nomer30160541	https://img03.platesmania.com/251108/m/30160541.jpg	1756 NBZ	https://img03.platesmania.com/251108/inf/30160541c7d741.png	Mallorca, Illes Balears (Spain) - 2025 Former license plate: [PL]GND 1U46 License plate frames	ElV ocho	/user95504	2025-11-08 18:48:44	1	0
España	Alfa Romeo Junior	Compact SUV (966), 2024–	/gallery.php?markaavto=15&model=5965&modgen=21938	/es/nomer30160359	https://img03.platesmania.com/251108/m/30160359.jpg	5234 NFC	https://img03.platesmania.com/251108/inf/301603598de612.png	Mallorca, Illes Balears (Spain) - 2025	ElV ocho	/user95504	2025-11-08 18:34:03	2	0
España	Mercedes-Benz SL-Klasse	4th gen (R129), 1989–2001	/gallery.php?markaavto=66&model=2298&modgen=2118	/es/nomer30160302	https://img03.platesmania.com/251108/m/30160302.jpg	H 7539 BBH	https://img03.platesmania.com/251108/inf/30160302b443f3.png	Mallorca, Illes Balears (Spain) - 2025	ElV ocho	/user95504	2025-11-08 18:29:24	1	0
España	Volvo FH	3rd gen, facelift, 2020–	/gallery.php?markaavto=97&model=1945&modgen=5140	/es/nomer30160296	https://img03.platesmania.com/251108/m/30160296.jpg	8921 MKJ	https://img03.platesmania.com/251108/inf/301602969d9f55.png	November 7th 2025 On the A50, in Heelsum, Gelderland, Netherlands Angles-Morts ConvoiExceptionnel Panalon Pañalón Pañalón					

11 Contribucions

Contribucions	Signatura
Investigació prèvia	Alberto Lozano, Alberto Antorán
Redacció de les propostes	Alberto Lozano, Alberto Antorán
Desenvolupament del codi	Alberto Lozano, Alberto Antorán
Participació del video	Alberto Lozano, Alberto Antorán