

Tipologia i cicle de vida de les dades

PAC1

UOC

Què son les dades i quin el seu cicle de vida?

20% nota final

Data de lliurament

14 d'octubre de 2025

Presentació

En aquesta prova d'avaluació continuada es treballen els conceptes generals del cicle de vida de les dades, i se n'identifiquen i se'n revisen les característiques. També es treballen els conceptes fonamentals del Web Scraping.

Competències

En aquesta PAC es desenvolupen les següents competències del Màster de Data Science:

- Capacitat d'analitzar un problema en el nivell d'abstracció adequat a cada situació i aplicar les habilitats i els coneixements adquirits per abordar-lo i resoldre'l.
- Capacitat per aplicar les tècniques específiques de tractament, emmagatzematge i administració de dades

Objectius

Els objectius concrets d'aquesta prova d'avaluació continuada són:

- Conèixer el cicle de vida de les dades i els principals tipus de dades.
- Aprendre a aplicar els coneixements adquirits i la seva capacitat de resolució de problemes en entorns nous o poc coneguts dins de contextos més amplis o multidisciplinaris.
- Desenvolupar les habilitats d'aprenentatge que permetin continuar estudiant d'una manera que haurà de ser en gran mesura autodirigida o autònoma.
- Desenvolupar la capacitat de cerca, gestió i ús d'informació i recursos en l'àmbit de la ciència de dades.
- Entendre la utilitat, la legalitat i algunes característiques del web scraping.

Enunciat

Exercici 1 [65%]

Després de llegir el recurs “Calvo, M., Pérez, D., Subirats, L. (2019). Introducció al cicle de vida de les dades.” respon les preguntes següents amb les teves pròpies paraules:

1. Enumera les sis fases principals del cicle de vida de les dades. Per a cadascuna, indica el seu objectiu i assenyala una dimensió de qualitat de les dades que es pugui veure compromesa en aquella fase, explicant breument com podria avaluar-se (Màxim 200 paraules).
2. Explica la diferència entre creació i extracció de dades en la fase de captura. Inclou un exemple realista de cada tipus i assenyala un avantatge i un inconvenient de cadascun (Màxim 100 paraules).
3. Ordena les següents etapes de preprocessament segons la seva seqüència lògica habitual i justifica breument l'ordre. Afegeix un exemple concret del que es faria en cada etapa: integració, selecció, reducció, conversió, neteja (Màxim 150 paraules).
4. Explica com publicaries un conjunt de dades obert perquè sigui fàcilment reutilitzable i es preservi en el temps. Inclou tipus de repositori, formats recomanats, metadades mínimes necessàries i freqüència d'actualització (Màxim 150 paraules).
5. Imagina que gestioness un petit conjunt de dades amb els camps següents: ID d'usuari, edat, número de telèfon i data de registre. Classifica cada camp segons el nivell d'accés corresponent. Proposa un control de seguretat concret per a dos d'aquests camps (Màxim 100 paraules).
6. Accedeix a l'inventari interactiu d'emissions de gasos amb efecte d'hivernacle del Ministeri per a la Transició Ecològica i el Repte Demogràfic (Espanya), disponible a:

<https://www.miteco.gob.es/es/calidad-y-evaluacion-ambiental/temas/sistema-espanol-de-inventario-sei-/otra-informacion/inv-gei-ccaa.html>.

Explica quin és l'objectiu de la fase de visualització en el cicle de vida de les dades i analitza si l'exemple mostrat en aquest portal compleix aquesta funció, justificant la resposta (Màxim 150 paraules).

Exercici 2 [35%]

Després de llegir el recurs “Subirats, L., Calvo, M. (2019). Web Scraping”, capítols 1 i 6. Contesta les següents preguntes amb les teves pròpies paraules:

1. Esmenta un exemple real d'un lloc web on seria interessant aplicar web scraping per descarregar informació en format CSV o JSON. Explica breument quins beneficis té guardar les dades en un format interoperable i quins problemes podrien sorgir si no es fa. (Màxim 100 paraules.)
2. Posa un exemple d'un lloc web on, en comptes de text, sigui necessari extreure contingut gràfic o audiovisual. Explica breument quins passos seguiries per fer aquest web scraping i quines tecnologies o llibreries utilitzaries. (Màxim 250 paraules.)
3. Quines serien tres bones pràctiques a l'hora de crear i compartir un conjunt de dades obtingut per web scraping, tenint en compte l'apartat sobre repositoris de dades? (Màxim 100 paraules.)

Recursos d'aprenentatge

Els recursos següents són útils per a la realització de la PAC:

Bàsics

- Calvo, M., Pérez, D., Subirats, L. (2019). Introducció al cicle de vida de les dades. Editorial UOC.
- Subirats, L., Calvo, M. (2019). Web Scraping. Editorial UOC.

Complementaris

- Lawson, R. (2015). Web Scraping with Python. Packt Publishing Ltd Capítol 1. Introduction to Web Scraping.
- Minguillón, J. (2016). Fonaments de data Science. Editorial UOC.

Criteris de valoració

La ponderació dels exercicis és la següent:

- Exercici 1.1: 15%
- Exercici 1.2: 10%
- Exercici 1.3: 10%
- Exercici 1.4: 10%
- Exercici 1.5: 10%
- Exercici 1.6: 10%
- Exercici 2.1: 10%
- Exercici 2.2: 15%
- Exercici 2.3: 10%

S'avaluarà la precisió dels exemples així com pel que fa al nombre de paraules màxim establert per a cada pregunta. La idoneïtat i claredat de les respostes també serà avaluada. No es poden donar exemples que s'esmentin directament en els recursos proporcionats.

Format i data de lliurament

- La solució amb les respostes a les preguntes es lliurarà en un únic document PDF. No s'han de copiar els enunciats de les preguntes i s'ha de respectar la mateixa numeració per a identificar les respostes.
- No oblideu posar el vostre nom i cognoms al document. El nom de l'arxiu ha de contenir el codi de l'assignatura, el vostre cognom i el vostre nom, així com el

nombre d'activitat (PAC1). Per exemple,
M2.951_Cognom1_Cognom2_Nom_PAC1.pdf.

- El document amb la solució s'ha de pujar a l'espai “Lliurament PAC1” de l'aula.
- **L'alumnat és responsable que ha fet el lliurament correctament i ha pujat els fitxers correctes.**
- **L'autoria de la PAC ha de ser individual i pròpia.**
- La còpia o plagi en la realització de la PEC comportarà la qualificació de suspens (D). La PEC s'ha de realitzar de manera individual i el treball lliurat ha de ser original, citant adequadament les fonts bibliogràfiques utilitzades. Per a més informació i recursos podeu consultar:
 - **Integritat acadèmica i plagi:**
<https://campus.uoc.edu/estudiant/microsites/plagi/es/index.html>
 - **Com citar correctament i evitar el plagi (Biblioteca UOC):**
<https://biblioteca.uoc.edu/es/pagina/Como-citar/>
- La data límit de lliurament és el **14 d'octubre de 2025 a les 23h59 CEST**. No s'acceptaran entregues fora de termini.

Propietat intel·lectual

Al presentar una pràctica o PAC que faci ús de recursos aliens, s'ha de presentar juntament amb ella un document en què es detallin tots ells, especificant el nom de cada recurs, el seu autor, el lloc on es va obtenir i el seu estatus legal: si l'obra està protegida pel copyright o s'acull a alguna altra llicència d'ús (Creative Commons, llicència GNU, GPL etc.). L'estudiant haurà d'assegurar que la llicència que sigui no impedeix específicament seu ús en el marc de la pràctica o PAC. En cas de no trobar la informació corresponent haurà d'assumir que l'obra està protegida pel copyright.