

Tipologia i cicle de vida de les dades - PAC1

Exercici 1

Apartat 1

Fase del cicle de vida de les dades: Captura de les dades, l'objectiu és la obtenció de dades.

Dimensió de qualitat que pot ser compromesa: Puntualitat.

Exemple de problema i solució: Descarregar dades de un període de temps concret no representatiu del total, mirar la data de les dades.

Fase: Emmagatzematge, on emmagatzem les dades obtingudes anteriorment,.

Dimensió: Unicitat

Exemple : Emmagatzem dades dues vegades, fer comprovacions de duplicitat.

Fase: Preprocessat, preparació de les dades per el seu ús a l'anàlisi.

Dimensió: Consistència

Exemple: El preprocessat no consistent per totes les entrades, comparar el preprocessat per entrades amb dades similars .

Fase: Anàlisi, generar un model que expliqui com son les dades

Dimensió: Exactitud

Exemple: El model no descriu correctament el món real, separar dades test per comprovar la validesa del model.

Fase: Visualització, generar representacions de les dades per extreure coneixement

Dimensió: Validesa

Exemple: A l'hora de visualitzar les dades veiem que una variable categòrica té més classes que les descrites inicialment, revisar on s'han introduït les classes extra

Fase: Publicació, documentar els resultats obtinguts

Dimensió: Completesa

Exemple: Es publica només un resultat parcial, publicar el resultat total.

Apartat 2

En la creació de dades, les dades son capturades en temps real cada vegada que es generen, per fer-ho podem utilitzar sensors, formularis etc.

Avantatge: dades s'ajusten exactament a les necessitats.

Problema: costos de generar.

Exemple: volem saber el moments de major activitat d'un parking, registrem entrades.

Encanvi la extracció consisteix en obtenir les dades que ja han sigut generades anteriorment, ja sigui per nosaltres o per altres persones.

Avantatge: No es perd temps obtenint les dades.

Problema: Dades desfasades, ja que ha passat temps desde la captura.

Exemple: Programa que llegeixi matricules, obtenir les dades utilitzant repositoris com “platesmania”.

Apartat 3

Per aquest apartat seguirem l'exemple de l'apartat anterior.

Selecció: Filtrar dades per seleccionar només d'interès, sense dades no podem començar.

Filtrem per matricules d'espanya

Neteja: Eliminem totes les dades que no passin els estàndard de qualitat. No dedicarem més esforç en aquestes dades

Eliminar fotos borroses.

Integració: Combinem dades de fonts diferents. Tenim fonts netes que juntem.

Tenim fotos de dos períodes temporals i les juntem.

Conversió: Canviar el format original de les dades a un més pla i comprensible. Ara que tenim totes les dades amb el mateix format les transformem amb els nostres interessos.

El format en el que envia les matricules utilitza majúscules i minúscules, ho canviem tot a majúscules.

Reducció: En quedem només amb les variables que considerem d'interès. Per tant hem de tenir totes les variables com volem.

En les dades tenim la data de la fotografia, no es aporta res per llegir la matricula.

Apartat 4

Per publicar un conjunt de dades obert de manera que sigui fàcilment reutilitzable i es preservi en el temps, s'ha de seguir un procés estructurat.

Cal dipositar les dades en un repositori digital obert (p. ex. Kaggle, Dataverse o repositoris institucionals), que garanteixi la preservació i disponibilitat a llarg termini.

Els formats recomanats són oberts i estàndard, com CSV, JSON o XML, ja que permeten l'accés des de diverses eines.

Les dades han d'anar acompanyades de metadades mínimes que descriguin: títol, autor, data, descripció, origen, format, condicions d'ús i actualització, per facilitar la disseminació i reutilització.

La freqüència d'actualització dependrà del tipus de dades, però hauria de definir-se clarament i aplicar-se de manera periòdica per mantenir la seva vigència.

Apartat 5

ID d'usuari: Dades restringides, és l'identificador inequívoc per usuari.

Edat: Dades públiques, sempre que no permeti identificar l'usuari.

Telèfon: Dades restringides, és una via de comunicació directa amb l'usuari i només ha de ser accessible per les persones autoritzades.

Data de registre: Dades restringides, ja que revela informació temporal associada a l'activitat de l'usuari.

Controls de seguretat:

Per al número de telèfon, aplicar xifratge AES durant l'emmagatzematge.

Per a l'ID d'usuari, utilitzar control d'accés amb autenticació per limitar-ne la consulta només a personal autoritzat.

Apartat 6

L'objectiu de la fase de visualització es aprofitar la capacitat humana de reconèixer patrons tendències i extracció d'informació a partir de models o gràfics. En aquest cas veiem que tenim una publicació a PowerBi que permet fer moltes de les tasques bàsiques que ajuden a millorar la nostra comprensió de les dades.

Per exemple podem filtrar les dades per tenir les dades de contaminació d'un any en concret a la pestanya de "datos generales sobre gases de efecto invernadero en CCAA", També veiem que podem demanar les taules amb subconjunts de dades per poder descarregar.

El que no tenim es un historial dels canvis que fem a la visualització per poder repetir-los en un futur, cosa que és recomanable.

En general crec que compleix la funció de ser una visualització útil ja que podem extreure coneixement d'ella.

Exercici 2

Apartat 1

Una web de ressenyes de llibres per veure si les tendències de lectura van variant inclos poder fer un "sentiment analysis" de les reviews.

Desar les dades en formats interoperables com CSV o JSON facilita la seva reutilització, anàlisi i integració amb altres eines o projectes. Si no s'utilitzen formats oberts, poden sorgir problemes de compatibilitat, pèrdua d'informació o dificultat de processament en altres sistemes, limitant-ne la reutilització i l'intercanvi entre plataformes. Ja que aquest formats són estàndards àmpliament utilitzats.

Apartat 2

Platesmania es una pagina web on la gent puja fotografies de matrícules, imaginem el cas on volguéssim fer un model que pogués llegir matrícules amb molta precisió, aquesta pagina web podria ser un bon repositori per extreure les imatges.

Per fer-ho el primer que hauriem de fer és investigar la pagina web, veiem que quan entrem a una galeria ex "<https://platesmania.com/fr/gallery>" podem anar avançant per les pàgines afegint-li números a la url, per tant tenim la navegació coberta. Si investiguem l'html veiem que dintre de la classe "panel-body" tenim un link amb la fotografia i informació sobre la fotografia com la matrícula.

Una vegada sabem això podem utilitzar python i itinerant per un enter creuem x pàgines de la galeria utilitzant la llibreria "request" per obtenir l'html per cadascuna. Aquest html utilitzant llibreries per parsejar-lo com "beautiful soup" anirem als tags anomenats anteriorment. Després l'imatge la podem descarregar amb request i li podem posar el nom de la matrícula a la imatge així tindrem una carpeta en local amb fotografies de matrícules amb la matrícula al nom de l'imatge.

Apartat 3

Utilitzar repositoris oberts i fiables (com Kaggle, UCI Machine Learning Repository o Github) per garantir la preservació, traçabilitat i accés públic a les dades.

Publicar les dades en formats oberts i interoperables (CSV, JSON, XML) i acompanyar-les de metadades completes: font, data de recollida, descripció del contingut, autor i condicions d'ús.

Assegurar-se que les dades descarregades respecten l'user agreement i si la pagina te un arxiu robots.txt respectar-ho en lo posible per evitar problemes legals.