

Tipologia i cicle de vida de les dades

PAC2

UOC

Universitat Oberta
de Catalunya

Data de lliurament:
02 de desembre de 2025



PAC 2

Presentació

En aquesta prova d'avaluació continuada (PAC) es treballen els conceptes generals d'integració, validació i anàlisi dels diferents tipus de dades.

És important tenir en compte les següents consideracions a l'hora de lliurar la PAC:

- És obligatori i **queda com a responsabilitat de l'estudiant revisar que l'arxiu lliurat al RAC és el correcte**. Un arxiu buit o no pertinent es considerarà com no lliurat.
- Perquè el lliurament es consideri com realitzat, s'ha de completar almenys el 25% de tota l'activitat.

Competències

En aquesta PAC es desenvolupen les següents competències del Màster de Data Science:

- Capacitat d'analitzar un problema amb el nivell d'abstracció adequat a cada situació i aplicar les habilitats i els coneixements adquirits per abordar-lo i resoldre'l.
- Capacitat per aplicar les tècniques específiques de tractament de dades (integració, transformació, neteja i validació) per a la posterior anàlisi.

Objectius

Els objectius concrets d'aquesta prova d'avaluació continuada són:

- Conèixer els efectes de la utilització de dades de qualitat en els processos analítics.
- Conèixer les principals eines de neteja i anàlisi dels diferents tipus de dades.
- Aprendre a aplicar els coneixements adquirits i la seva capacitat de resolució de problemes en entorns nous o poc coneguts dins de contextos més amplis o multidisciplinaris.
- Desenvolupar les habilitats d'aprenentatge que permeten continuar estudiant d'una manera que haurà de ser en gran mesura autodirigida o autònoma.
- Desenvolupar la capacitat de cerca, gestió i ús d'informació i recursos en l'àmbit de la ciència de dades.

Descripció de la PAC a realitzar

Exercici 1

Després de llegir el capítol 1 del recurs “*Introducció a la neteja i anàlisi de les dades*”, respon les preguntes següents amb les teves pròpies paraules.

1. Explica la diferència entre reducció de la dimensionalitat i reducció de la quantitat de dades. Dóna un exemple pràctic de cadascuna. **[Màxim 200 paraules]**
2. Quan faries servir la normalització *min-max*, l'estandardització *z-score* i la transformació de Box-Cox? Normalitzar fa que les dades siguin “normals”?

Exercici 2

Després de llegir els capítols 1.5 i 1.6 del recurs “*Introducció a la neteja i anàlisi de les dades*”, respon amb les teves paraules:

1. Quines implicacions tenen les dades perdudes i què has de considerar en triar una tècnica de tractament? **[Màxim 200 paraules]**
2. Descriu dos mètodes d'imputació i un cas d'ús per a cadascun. **[Màxim 200 paraules]**

Exercici 3

Després de llegir el capítol 2.2 del recurs “*Introducció a la neteja i anàlisi de les dades*”, respon amb les teves paraules:

1. Què és la correlació i com interpretaries Pearson vs. Spearman? Dóna'n un exemple.
2. Diferència entre regressió lineal i logística. Quines mètriques s'haurien d'utilitzar?

Exercici 4

Després de llegir els capítols 2.3 i 2.4 del recurs “*Introducció a la neteja i anàlisi de les dades*” i el recurs complementari “*Data mining: concepts and techniques*”, respon amb les teves paraules:

1. Exposar tres formes de particionar dades per a entrenament/prova i quan convé cadascuna. **[Màxim 200 paraules]**

2. Defineix VP, FP, VN i FN i relaciona aquestes quantitats amb tres mètriques clau. **[Màxim 200 paraules]**

Recursos

Els següents recursos són d'utilitat per a la realització de la PAC:

Bàsics

- Calvo M., Pérez D., Subirats L (2019). Introducció a la neteja i anàlisi de les dades. Editorial UOC.

Complementaris

- Megan Squire (2015). *Clean Data*. Packt Publishing Ltd. Capítols 1 i 2.
- Jiawei Han, Micheline Kamber, Jian Pei (2012). *Data mining: concepts and techniques*. Morgan Kaufmann. Capítol 3.
- Jason W. Osborne (2010). *Data Cleaning Basics: Best Practices in Dealing with Extreme Scores*. Newborn and Infant Nursing Reviews; 10 (1): pp. 1527-3369.

Criteris de valoració

La ponderació dels exercicis és la següent:

Exercici	1.1	1.2	2.1	2.2	3.1	3.2	4.1	4.2
Punts	10%	10%	10%	10%	15%	15%	15%	15%

Es valorarà la idoneïtat de les respostes, que hauran de ser clares i completes. Quan sigui necessari, hauran d'acompanyar-se d'exemples representatius i ben justificats.

Si s'estima oportú, el professor sol·licitarà una entrevista remota mitjançant Google Meet, en referència a l'activitat realitzada, en un dia i hora acordats.

Format i data de lliurament

La solució amb les respostes a les preguntes es lliurarà en un únic document PDF. No s'han de copiar els enunciats de les preguntes i s'ha de respectar la mateixa numeració per a identificar les respostes.

No oblideu posar el vostre nom i cognoms al document. El nom de l'arxiu ha de contenir el codi de l'assignatura, el vostre cognom i el vostre nom, així com el nombre d'activitat (PAC1). Per exemple, M2.851_Cognom1_Cognom2_Nom_PAC2.pdf.

El document amb la solució s'ha de pujar a l'espai "Lliurament PAC2" de l'aula.

L'alumnat és responsable que ha fet el lliurament correctament i ha pujat els fitxers correctes.

L'autoria de la PAC ha de ser individual i pròpia.

La còpia o plagi en la realització de la PEC comportarà la qualificació de suspens (D). La PEC s'ha de realitzar de manera individual i el treball lliurat ha de ser original, citant adequadament les fonts bibliogràfiques utilitzades. Per a més informació i recursos podeu consultar:

- **Integritat acadèmica i plagi:**
<https://campus.uoc.edu/estudiant/microsites/plagi/es/index.html>
- **Com citar correctament i evitar el plagi (Biblioteca UOC):**
<https://biblioteca.uoc.edu/es/pagina/Como-citar/>

La data límit de lliurament és el **23:59 CET del dia 02 de desembre**. No s'acceptaran entregues fora de termini.

Propietat intel·lectual

Al presentar una pràctica o PAC que faci ús de recursos aliens, s'ha de presentar juntament amb ella un document en què es detallin tots ells, especificant el nom de cada recurs, el seu autor, el lloc on es va obtenir i el seu estatus legal: si l'obra està protegida pel copyright o s'acull a alguna altra llicència d'ús (Creative Commons, llicència GNU, GPL etc.). L'estudiant haurà d'assegurar que la llicència que sigui no impedeix específicament seu ús en el marc de la pràctica o PAC. En cas de no trobar la informació corresponent haurà d'assumir que l'obra està protegida pel copyright.