

Tipologia i cicle de vida de les dades - PAC2

Exercici 1

Apartat 1

La reducció de la dimensionalitat consisteix en disminuir el nombre d'atributs o variables d'un conjunt de dades mantenint-ne la màxima informació possible. No elimina registres, sinó característiques. S'utilitza quan hi ha moltes variables redundants o correlacionades que compliquen l'anàlisi i no aporten informació extra. Tècniques usals per assolir aquest objectiu són Anàlisi de Components Principals (ACP) o selecció d'atributs.

Exemple: Dataset de preus de diamants donades certes característiques, entre elles alçada, amplada, altura, color i pes, fent ACP veiem que amb les 4 primeres variables podem explicar el 95% de la variança. En aquest cas podem suposar que es perquè el pes està correlacionat amb les tres primeres variables ja que si sabem el volum i la densitat podem calcular el pes.

La reducció de la quantitat de dades, en canvi, redueix el nombre de dades, mantenint una representació globalment equivalent. L'objectiu és fer l'anàlisi més eficient quan tenim milions de dades. Tècniques usals per assolir aquest objectiu són sampling, clustering o histogrames.

Exemple: Dataset amb 20 milions de transaccions, apliquem sampling estratificat per quedar-nos amb 200.000 registres que mantenint la mateixa distribució estadística i permetin entrenar models amb costos molt menors.

Apartat 2

La normalització *min-max* s'utilitza quan necessites portar les variables al un mateix rang, normalment entre (0,1). Però les dades no tenen perquè ser normals. Ja que aquesta normalització preserva la relació proporcional entre valors originals. Això és útil en models sensibles a l'escala, com *k-NN*, *reds neuronals* o *regressió logística*. Normalment s'utilitzen quan l'atribut té límits naturals (per exemple: percentatges, edats, puntuacions, sensors).

L'estandardització *z-score* s'utilitza quan vols centrar les variables al voltant de mitjana = 0 i desviació = 1. Però les dades poden tenir valors extrems i no vols comprimir tant com el min-max. És la transformació habitual per a mètodes basats en distàncies i models lineals (PCA, regressió, SVM). Això tampoc fa que les dades siguin normals: només les reescala.

La transformació de Box-Cox s'utilitza quan necessites que les dades s'acostin a una distribució normal. Perquè necessites homoscedasticitat (variància constant). Això és necessari si vols aplicar proves paramètriques (t-test, ANOVA) o models que assumeixen

normalitat dels residus. Però aquesta transformació requereix que les dades siguin positives.

Ninguna de les primeres transformacions fa que les dades siguin normals. Ja que normalització min–max o el z-score només canvien l'escala, no la forma de la distribució. Per tant si les dades eren asimètriques, continuaran sent-ho. I si tenien valors extrems, continuaran existint.

L'única transformació de les esmentades que pot fer les dades més “normals” és Box-Cox, perquè modifica la forma de la distribució, no només l'escala

Exercici 2

Apartat 1

Abans d'escollir una tècnica de tractament, és essencial identificar correctament els valors buits ja que poden prendre moltes formes “”, “ ” o NA (not available, en anglès), fins i tot, valors numèrics com 0 o 999. També tenir en compte que els valors buits poden tenir sentit en certs contextos, per exemple, informació clínica i on certa intervenció no es realitzi per a un pacient concret.

A l'hora de triar una tècnica, cal considerar diversos factors. Existeixen solucions simples, com substituir per una constant o per mesures de tendència central (mitjana o mediana), són ràpides però poden distorsionar la variabilitat del conjunt de dades. Per aliviar això podem calcular-les a partir de cadascuna de les classes, ex (separar per gènere). També tenim la imputació basada en mètodes probabilístics com regressions, mètodes bayesians, kNN o algoritmes com missForest. Aquest mètodes poden predir millor els valors perduts. Per exemple kNN permet predir valors en conjunts de dades multidimensionals de dades mixtes (contínues, discretes, ordinals o nominals). Però, és sensible al valor k.

Encara que aquest mètodes es presenten com una alternativa interessant per no perdre informació útil, s'han d'aplicar amb precaució i utilitzant mètodes adequats, per no introduir error i falsejar els resultats.

Apartat 2

Imputació mitjançant mitjana o mediana

Utilitzant aquest mètode substituïm els valors buits per una mesura de tendència central. La mitjana és més adequada quan la variable és numèrica i aproximadament simètrica, mentre que la mediana és més robusta davant valors extrems.

Exemple: Dataset de salut amb l'alçada d'alguns pacients perduda, i sabent que la distribució és simètrica, substituïm la dada buida per la mitjana d'alçada del mateix grup (per exemple, per gènere). Aquesta tècnica és ràpida i manté una estimació raonable del valor real ja que l'alçada no té una alta variabilitat.

Imputació mitjançant un model de regressió

Utilitzant aquest mètode construïm un model predictiu a partir de les altres variables plenes per estimar el valor perdut. La regressió pot ser lineal, logística o models més complexos.

En aquest cas tampoc podem fer un model molt complex perquè el nostre objectiu és netejar les dades no fer un model per predir aquesta variable.

Exemple: Dataset de preus d'habitatges, on el valor de superfície útil en alguns registres és

buit, es pot entrenar una regressió lineal utilitzant variables com el nombre d'habitacions, metres quadrats o any de construcció.

Exercici 3

Apartat 1

La correlació mesura com dues variables es relacionen entre si. Indicant la força i direcció de la relació. Si augmenta una variable quan ho fa l'altra tindrem una correlació positiva, si una puja quan l'altra baixa tindrem correlació negativa, o si no hi ha relació la correlació sera zero. El coeficient de Pearson mesura una relació lineal entre dues variables numèriques. Però assumeix normalitat en la distribució de variables i que es compleixi el criteri d'homoscedasticitat. En canvi el coeficient de Spearman també mesura la correlació entre dues variables però no requereix suposar res sobre la distribució de les dades, només necessita que les variables es puguin mesurar en una escala ordinal

Els dos coeficients indiquen que quan una variable creix, l'altra tendeix a créixer (o disminuir) de manera consistent, Person a sobre ens diu que aquesta relació és lineal, mentre que Spearman no pot assegurar el tipus de relació.

Per exemple suposem que volem estudiar la relació entre l'edat i els ingressos. Veiem que el coeficiente de Pearson és 0,30. D'aquí podem intuir una relació lineal feble, el que indicaria que més edat sol associar-se a més ingressos, però amb molta variació. En canvi si mirem el coeficient de Spearman veiem que és 0,70. Això és perquè tenim una relació monòtona forta, ja que els ingressos solen augmentar amb l'edat, però no de manera proporcional ni lineal.

Apartat 2

Les regressions lineals modelen relacions entre una variable dependent numèrica contínua (per exemple, volum, preu, altura...) i una o múltiples variables independents. Per fer-ho assumeix una relació lineal entre les variables i produeix prediccions en valors reals.

S'utilitza per predir variables numeriques o estimar relacions lineals.

Entre les mètriques habituals per avaluar la validesa d'aquests models existeix R^2 i Adjusted R^2 , que indiquen el percentatge de variabilitat explicada. RMSE (Root Mean Squared Error) o MSE que quantifiquen l'error de predicció. MAE que es error absolut mitjà. o F-statistic i p-valors dels coeficients que comproven la significació estadística.

En canvi les regressions logístiques s'utilitzen quan la variable dependent és dicotòmica. En lloc de predir un valor real, modela la probabilitat d'un resultat, transformant la sortida mitjançant una funció logística perquè sempre estigui entre 0 i 1. S'utilitza per poder classificar o modelar probabilitats d'esdeveniments. En aquest cas algunes de les mètriques més habituals per avaluar la bondad de les prediccions son Accuracy que es percentatge d'encerts (aquesta metrica només útil si les classes estan equilibrades). Precision, Recall i F1-score que indiquen la fracció de casos veritablement positius entre els casos seleccionats com a positius, la fracció de casos veritablement positius entre els casos rellevant i $2(Precision * Recall) / (Precision + Recall)$ respectivament. També tenim AUC-ROC que mesura la capacitat del model per discriminar entre classes.

O la matriu de confusió que mostra en una taula la relació entre veritats positius, falsos positius, veritats negatius i falsos negatius.

Exercici 4

Apartat 1

Primer tenim Holdout (exclusió), consisteix a dividir les dades en dos conjunts, habitualment en un 70% per entrenament i un 30% per prova. És simple i ràpid, adequat quan el conjunt de dades és gran i es vol una estimació ràpida del rendiment. El seu inconvenient és que la precisió depèn molt de com hagi quedat la partició.

Segon tenim Random subsampling (submostreig aleatori), consisteix en repetir diverses vegades el procés holdout i calcula el rendiment mitjà. Redueix la probabilitat d'una mala partició i proporciona una estimació més representativa del conjunt total. És útil quan es disposa de prou capacitat computacional per repetir el procés n vegades i es vol una mesura més robusta l'anterior.

Per últim tenim la validació creuada de tipus k-fold, consisteix en dividir les dades en k subconjunts mútuament exclusius i de mides semblants. Després entrenem el model k vegades, utilitzant k-1 models per entrenar i un per testar. Per calcular la exactitud dividim el nombre total de classificacions correctes entre el nombre total de mostres en el conjunt de dades original. És especialment recomanable amb conjunts de dades petits o quan cal una avaluació precisa.

Apartat 2

Per avaluar la bondat d'un model de classificació definim els veritables positius (VP) com els casos positius que el model classifica correctament com a positius. Els falsos positius (FP) com casos negatius classificats erròniament com a positius. Els veritables negatius (VN) corresponen a negatius classificats correctament, i els falsos negatius (FN) corresponen a casos positius que el model etiqueta com a negatius.

A partir d'aquestes quatre quantitats podem definir tres mètriques.

La exactitud (accuracy) mesura la proporció total de prediccions correctes i es calcula com $(VP + VN) / (VP + FP + VN + FN)$. És útil quan les classes estan equilibrades, però pot ser enganyosa davant de desequilibris importants entre positius i negatius.

La sensibilitat (recall o TPR) quantifica la capacitat del model per detectar casos positius i s'expressa com $VP / (VP + FN)$. És especialment rellevant en contextos on és crític no deixar escapar positius, com el diagnòstic mèdic.

La precisió (precision) mesura quants dels elements classificats com a positius són realment positius i s'obté com $VP / (VP + FP)$. Es fa servir quan el cost dels falsos positius és alt, per exemple en filtres de correu brossa. Aquestes mètriques complementen la visió global que dona l'accuracy.