
Introducció a l'anàlisi de sèries temporals

PID_00270810

Jordi Casas Roma

Temps mínim de dedicació recomanat: 4 hores



Jordi Casas Roma

Llicenciat en Enginyeria Informàtica per la Universitat Autònoma de Barcelona (UAB), màster d'Intel·ligència Artificial Avançada per la Universitat Nacional d'Educació a Distància (UNED) i doctor en Informàtica per la UAB. Des del 2009 és professor dels Estudis d'Informàtica, Multimèdia i Telecomunicació de la Universitat Oberta de Catalunya (UOC) i professor associat de la UAB. És director del màster universitari de Ciència de Dades de la UOC. Les seves activitats docents se centren en la mineria de dades, l'aprenentatge automàtic (*machine learning*) i l'anàlisi de xarxes o grafs (*graph mining*). Des del 2010 pertany al grup de recerca KISON (K-ryptography and Information Security for Open Networks). Els seus interessos de recerca inclouen temes relacionats amb la privacitat, l'aprenentatge automàtic i la mineria de grafs.

Primera edició: febrer 2020

© Jordi Casas Roma

Tots els drets reservats

© d'aquesta edició, FUOC, 2020

Av. Tibidabo, 39-43, 08035 Barcelona

Realització editorial: FUOC

Cap part d'aquesta publicació, incloent-hi el disseny general i la coberta, no pot ser copiada, reproduïda, emmagatzemada o transmesa de cap manera ni per cap mitjà, tant si és elèctric com químic, mecànic, òptic, de gravació, de fotocòpia o per altres mètodes, sense l'autorització prèvia per escrit dels titulars dels drets.

Índex

Introducció	5
Objectius	6
1. Introducció a les sèries temporals	7
1.1. Conceptes preliminars	7
1.1.1. Dades transversals	7
1.1.2. Sèries temporals	8
1.1.3. Dades de panell	9
1.2. Definició i exemples	10
1.3. Objectius i tasques analítiques	12
2. Components d'una sèrie temporal	13
2.1. Tendència general	13
2.2. Variacions estacionals	14
2.3. Variacions cícliques	15
2.4. Variacions aleatòries o irregulars	15
2.5. Descomposició d'una sèrie temporal	16
3. Estacionarietat en sèries temporals	17
3.1. Definició d'estacionarietat	17
3.2. Test de Dickey-Fuller augmentat	18
3.3. Convertir una sèrie temporal en estacionària	19
4. Aprenentatge automàtic	21
4.1. Aprenentatge supervisat per a sèries temporals	21
4.1.1. Prediccions en un pas o en múltiples passos	22
4.1.2. Mètode de la finestra lliscant	22
4.1.3. Estratègies de predicció per a múltiples passos	25
4.2. Mètriques per a avaluar sèries temporals	27
5. Exemples pràctics	29
5.1. Exemple 1: anàlisi de la concentració de CO ₂	29
5.1.1. Càrrega de les dades	29
5.1.2. Tendència general	30
5.1.3. Moviments estacionals	32
5.1.4. Estacionarietat de la sèrie temporal	35
5.2. Exemple 2: predicció del nivell d'un embassament	36
5.2.1. Adquisició de dades	36
5.2.2. Anàlisi preliminar	37
5.2.3. Preparació de les dades	38

5.2.4.	Creació del model predictiu	39
5.2.5.	Resultats	40
Resum		42
Glossari		43
Bibliografia		44

Introducció

En aquest mòdul veurem una introducció a l'anàlisi de sèries temporals. Les sèries temporals són un tipus específic de dades que s'apliquen en molts contextos actuals, com l'anàlisi i predicció de dades econòmiques i de consum, de generació i consum d'energia, etc. En general, qualsevol conjunt de dades en què el temps sigui la variable principal que regeix la captura i comprensió de les dades pot ser tractat i analitzat com una sèrie temporal.

Iniciarem aquest mòdul amb una introducció al concepte de *sèrie temporal*, definint què és una sèrie temporal i quines són les principals característiques, objectius i tasques analítiques associades a aquest tipus de dades. Veurem els quatre components principals que formen una sèrie temporal: variacions a llarg termini o tendència general; variacions a curt termini, que poden ser estacionals o cícliques, i, finalment, variacions aleatòries o irregulars. A continuació presentarem el concepte d'*estacionarietat* en les sèries temporals, en discutirem la importància i veurem alguns mètodes bàsics per a determinar si una sèrie és estacionària i, en cas de no ser-ho, com s'hi pot transformar.

Continuarem veient com cal aplicar els mètodes estàndards d'aprenentatge automàtic (*machine learning*) en aquest tipus de dades, que, donades les seves peculiaritats, necessitaran certes transformacions per a poder entrenar un model predictiu d'aprenentatge automàtic. Amb relació als models predictius, també revisarem algunes de les mètriques més emprades per a avaluar la bondat en la predicció de sèries temporals.

En l'últim capítol veurem un exemple de com analitzar i descompondre una sèrie temporal emprant el llenguatge Python i algunes de les llibreries més rellevants per a analitzar sèries temporals i aprenentatge automàtic.

Objectius

En els materials didàctics d'aquest mòdul trobarem les eines indispensables per a assimilar els objectius següents:

- 1.** Entendre què és una sèrie temporal i conèixer-ne les característiques principals.
- 2.** Comprendre quins són els components d'una sèrie temporal i com podem identificar-los.
- 3.** Conèixer els processos de transformació de dades que ens permetran reestructurar una sèrie temporal per poder entrenar un model d'aprenentatge automàtic.
- 4.** Entendre el concepte d'*estacionarietat* en sèries temporals i ser capaç de determinar si una sèrie temporal és estacionària.
- 5.** Conèixer les principals mètriques d'avaluació de sèries temporals amb la finalitat de poder avaluar la bondat d'un model predictiu.

1. Introducció a les sèries temporals

En els últims anys hem estat testimonis de l'aplicació generalitzada d'estadístiques i aprenentatge automàtic per a obtenir informació processable i valor comercial de les dades en gairebé tots els sectors industrials. Els analistes i científics de dades han d'abordar diferents tipus de problemes, escenaris, dominis i també diferents tipus de conjunts de dades.

Les sèries temporals són conjunts de dades amb certes característiques i particularitats que les fan especialment rellevants en moltes àrees de recerca i negoci, com l'anàlisi del producte interior brut, els volums de vendes, els preus de les accions, els atributs climàtics, la generació i el consum d'energia, etc.

1.1. Conceptes preliminars

Els analistes i científics de dades es troben amb molts tipus de dades diferents en els seus projectes d'anàlisi. Comprendre quin tipus de dades es necessiten per a resoldre un problema i quin tipus de dades es poden obtenir de les fonts disponibles és important per a formular el problema i triar la metodologia correcta per a l'anàlisi.

Podem establir una tipologia bàsica que inclou tres tipus primaris de dades tenint en compte la dimensió temps en la seva estructura interna:

- dades transversals
- sèries temporals
- dades de panell

A continuació veurem, des d'un enfocament pràctic i amb alguns exemples, com són i quines són les principals característiques d'aquests tipus primaris de dades.

1.1.1. Dades transversals


Les **dades transversals** (*cross-sectional data* en anglès) d'una població s'obtenen tenint en compte observacions de molts individus en el mateix instant. Alternativament, també poden comprendre observacions fetes en diferents moments, encara que en aquests casos s'assumeix que el temps no té un paper significatiu en l'anàlisi de les dades.

En essència, les dades transversals representen una instantània en un moment concret, encara que es poden obtenir en un període considerable (mesos i fins i tot anys) sempre que el temps no hi tingui un paper important quan s'utilitzin per a finalitats analítiques.

Exemple de dades transversals

La figura 1 il·lustra un exemple de dades transversals univariades del deute públic com a percentatge del producte interior brut (PIB) de vuitanta-cinc països l'any 2016. En prendre les dades d'un sol any, n'assegurem la naturalesa transversal. La figura combina un histograma normalitzat i un gràfic de densitat del nucli per a remarcar diferents propietats estadístiques de les dades.

Figura 1. Deute públic com a percentatge del PIB de vuitanta-cinc països a l'any 2016



A partir de la figura es pot deduir que la majoria de països acumulen un deute públic d'entre el 25% i el 50% del seu PIB, encara que en un bon nombre de països és prop del 100%. També podem observar-hi un pic menor prop del 200% del PIB.

Aquest tipus de dades és molt emprat en tasques de mineria de dades i aprenentatge automàtic. La majoria d'algorismes supervisats i no supervisats han estat desenvolupats explícitament per a aquest tipus de dades.

1.1.2. Sèries temporals

En contraposició amb les dades transversals, les **sèries temporals** (*time series* en anglès) es componen d'observacions quantitatives sobre una o més característiques mesurables d'una entitat individual i fetes en molts punts en el temps.

En els apartats posteriors veurem amb més profunditat que les sèries temporals es caracteritzen típicament per diverses estructures internes, com la tendència, l'estacionalitat, l'estacionarietat, l'autocorrelació, etc. Les estructures internes


de les dades de sèries temporals requereixen una formulació i unes tècniques especials per a analitzar-les.

Exemple de sèrie temporal

Un exemple clàssic de dades de sèries temporals són les dades econòmiques, sia d'empreses, entitats o països. En aquest cas veurem un exemple que inclou dades referents al deute del Govern d'Espanya entre el 1996 i el 2016.

Entre altres dades, es proporcionen els indicadors de desenvolupament mundial que inclouen una multitud de dades anuals agregades per país o regió, com el deute públic o la despesa militar.

Figura 2. Deute del Govern d'Espanya entre els anys 1996 i 2016



Aquestes dades són un exemple clar de sèrie temporal, en la qual veiem com evoluciona una determinada variable (en aquest cas el deute nacional) en funció de la variable temps. En aquest cas concret les dades tenen una periodicitat anual, molt típica de les dades econòmiques.

1.1.3. Dades de panell

Fins ara hem vist dades preses de molts individus o instàncies en un punt temporal —o sense tenir en compte la variable temps— (dades transversals) o preses d'una entitat individual però en molts punts en el temps (sèries temporals). No obstant això, si observem moltes entitats en molts punts temporals, obtenim les **dades de panell** (*panel data* en anglès), també conegudes com a **dades longitudinals**.

Exemple de dades de panell

Estenent el nostre exemple anterior al deute públic, considerem cinc països entre el 1996 i el 2016. Les dades resultants seran un conjunt de dades de panell. La figura 3 il·lustra les dades del panell en aquest escenari.


WDI

Els indicadors del desenvolupament mundial (*world development indicators*, WDI) constitueixen la principal compilació d'estadístiques internacionals sobre desenvolupament global del Banc Mundial. Utilitzant fonts reconegudes oficialment i incloent estimacions nacionals, regionals i mundials, els WDI proporcionen un accés aproximat a mil sis-cents indicadors per a dues-cents disset economies, amb algunes sèries temporals que s'estenen a més de cinquanta anys.

Enllaç d'interès

Les dades emprades són d'accés públic i es poden consultar en la pàgina web del Banc Mundial. A més, es poden descarregar a <https://datacatalog.worldbank.org/dataset/world-development-indicators>.

Figura 3. Deute de cinc països entre els anys 1996 i 2016



Segons la relació entre individus i temps, podem classificar els panells de dades en dos grups:

- Un **panell curt** és aquell en què el nombre d'individus és menor que el temps.
- Un **panell llarg** és aquell en què hi ha més individus que períodes de temps.

Un model de regressió comuna per a analitzar dades de panell té aquesta forma:

$$y_{it} = a_i + bx_{it} + \epsilon_{it}, \quad (1)$$

en què y és la variable dependent, x és la variable independent, a i b són coeficients, i i t són els índexs per als individus i el temps i, finalment, ϵ_{it} és l'error.

1.2. Definició i exemples

Com hem vist en la secció anterior, les sèries temporals són un tipus de dades que mesuren com canvien les coses amb el temps. En les sèries temporals el temps esdevé un eix primari que proporciona una font d'informació essencial per a entendre i processar les dades i que proporciona la disposició cronològica d'aquestes dades.

Les dades d'una sèrie temporal formen una seqüència d'observacions quantitatives sobre un sistema o procés en punts successius en el temps.

Generalment, els conjunts de dades de sèries temporals tenen tres aspectes en comú:

- El temps és un eix primari.
- Les dades es recopilen generalment per ordre temporal.
- Els punts en el temps són equiespaiats, és a dir, mantenen la mateixa distància entre ells.

Hi ha una multitud d'exemples de dades de sèries temporals. Vegem-ne alguns exemples:

- Dades relacionades amb factors econòmics, com el PIB, els volums de vendes o el preu d'unes determinades accions.
- Dades climatològiques, que poden incloure la temperatura, les precipitacions, la humitat, etc.
- Dades de consum en xarxes elèctriques o volum de dades en xarxes de telecomunicacions.

En realitat, qualsevol dada que es pugui registrar o mesurar amb una certa periodicitat (anys, mesos, dies, hores, minuts, segons, etc.) podria constituir una sèrie temporal. La freqüència d'observació depèn de la naturalesa de la dada. Per exemple, el PIB, que s'utilitza per a mesurar el progrés econòmic anual d'un país, es publica anualment. En canvi, la informació sobre el preu de les accions o certes dades climàtiques està disponibles cada segon. En general, quan les dades són preses de manera autònoma per sensors automàtics, com en el cas de les xarxes de comunicacions o IoT, es generen dades de sèries temporals amb periodicitats que poden arribar a diversos ordres de magnitud per sota del segon (centenes, mil·lèsimes, etc.).

IoT

El concepte *internet de les coses* (*Internet of things*, IoT) es refereix a la interconnexió digital d'objectes quotidians amb internet.

Les sèries temporals es poden representar com un conjunt ordenat de tuples (t_i, obs_i) , en què t_i és la marca de temps i i obs_i és el valor de la variable quantitativa al moment i . Addicionalment, també podem representar i emmagatzemar una sèrie temporal com una taula, amb dues columnes com a mínim, en què la primera columna és la marca de temps i la segona és el valor de la variable observada en aquest instant de temps. La taula 1 mostra un exemple de com es representa i emmagatzema la informació d'una sèrie temporal, en el qual cada fila conté la informació sobre la marca de temps i el valor de la variable observada.

Taula 1. Exemple de taula de dades d'una sèrie temporal.

Temps	Observació
1	35
2	42
3	41
4	47
5	45
...	...

Quan una sèrie temporal té una única variable observada, diem que és **univariable**. Per contra, quan una sèrie temporal presenta la forma $(t_i, obs_{i,1}, obs_{i,2}, \dots, obs_{i,m})$ se l'anomena **sèrie temporal multivariant** (en aquest cas concret, amb m observacions en cada instant de temps). La taula 2 mostra un exemple de sèrie temporal multivariant amb m variables o observacions.

Com a exemple de sèrie temporal univariable, podem pensar en dades que registrin el consum d'una xarxa elèctrica cada minut o hora. Un exemple de cas d'una sèrie temporal multivariant pot ser un conjunt de dades climatològiques, que agrupen diverses observacions en cada instant de temps (com la temperatura, la humitat, la pressió de l'aire i la velocitat del vent).

Taula 2. Exemple de taula de dades d'una sèrie temporal

Temps	Obs_1	Obs_2	...	Obs_m
1	35	0.3	...	875.56
2	42	0.5	...	657.82
3	41	0.6	...	756.56
4	47	0.7	...	813.98
5	45	0.8	...	918.01
...	...	...	...	...

1.3. Objectius i tasques analítiques

Amb relació a les dades de sèries temporals, i de manera similar a altres processos de mineria de dades o aprenentatge automàtic, distingim dues tasques principals, encara que amb mètodes i objectius diferenciats clarament:

- **L'anàlisi de sèries temporals** (*time series analysis*, TSA) té com a objectiu principal comprendre i interpretar les forces subjacents que produeixen l'estat observat d'un sistema o procés al llarg del temps. La TSA implica el desenvolupament de models que descriguin una sèrie temporal per a comprendre les causes subjacents, en molts casos emprant eines estadístiques clàssiques. Aquesta tasca busca el perquè d'un conjunt de dades i intenta explicar l'estructura interna subjacent que pugui haver-hi en els punts de dades preses al llarg del temps (com l'autocorrelació, la tendència o la variació estacional). Això implica sovint fer suposicions sobre la forma de les dades i descompondre la sèrie temporal.
- La **predicció de sèries temporals** (*time series forecasting*, TSF) intenta predir observacions futures amb base en les dades històriques contingudes en la sèrie temporal. El seu objectiu principal és crear models que capturin els patrons subjacents a les dades i permetin pronosticar l'estat futur del sistema o procés en termes de característiques observables.

2. Components d'una sèrie temporal

En aquest apartat ens centrarem a definir les característiques particulars de les sèries temporals que requereixen un tractament matemàtic especial. En general, una sèrie temporal pot ser definida com la suma de quatre factors:

$$\text{Components} \left\{ \begin{array}{l} \text{Tendència general (general trend)} \\ \text{Moviments a curt termini} \left\{ \begin{array}{l} \text{Estacionals (seasonal variations)} \\ \text{Cíclics (cyclical variations)} \end{array} \right. \\ \text{Variacions aleatòries o irregulars (random or irregular variations)} \end{array} \right.$$


2.1. Tendència general

La **tendència general**, també coneguda com a **moviment a llarg termini**, es refereix al comportament general de les dades de sèries temporals a augmentar o disminuir durant un període de temps llarg. Encara que podem observar que les tendències canvien de direcció moltes vegades en diferents moments del període de temps que observem, sol haver-hi una tendència general única per a tot el conjunt de dades, que indicarà si els valors tenen un comportament a l'alça, a la baixa o estable de manera global en tota la sèrie temporal.

Exemple de tendència general

Posem que disposem d'una sèrie temporal amb informació sobre la concentració de CO_2 que és a l'aire d'un determinat país o regió durant un període considerable de temps. La figura 4 il·lustra les dades d'aquest escenari.

Figura 4. Exemple de tendència general. Per a les mateixes dades, en la figura de l'esquerra veiem un període de temps molt més llarg que en la figura de la dreta.



Podem veure que, si observem el comportament general d'aquesta variable a llarg termini (figura de l'esquerra), hi ha una clara tendència a l'alça (augment) de la concentració de CO_2 a l'aire. En el cas de no disposar d'un conjunt prou gran de dades, és possible que solament puguem veure una finestra massa petita de les dades, que aquestes no

ens permetin identificar el comportament general i que, per tant, no puguem veure la tendència general. Per exemple, la figura de la dreta mostra les mateixes dades amb una finestra de temps menor, en la qual no és possible determinar el tipus de moviment a llarg termini.

2.2. Variacions estacionals

Les **variacions estacionals**, que formen part dels **moviments a curt termini**, són patrons rítmics que s'observen de manera regular i periòdica (generalment amb una periodicitat anual). És a dir, les variacions estacionals presenten el mateix patró (o similar) durant un període de dotze mesos. Lògicament, aquesta component solament serà present en la sèrie temporal si les dades tenen una freqüència prou petita, com per exemple d'hores, dies o setmanes. Aquestes variacions es deuen principalment a dos factors diferents:


- Les diferents **estacions** o **condicions climàtiques** tenen un paper important en les variacions estacionals. Per exemple, el volum de precipitacions o la temperatura tenen efectes clars sobre la producció de cultius o la venda de determinats productes (com aires condicionats). És a dir, amb una periodicitat anual, les condicions naturals del nostre entorn tenen un efecte importantíssim sobre la nostra activitat i el nostre món.
- Les convencions establertes per l'ésser humà tenen efectes clars sobre els nostres patrons de moviment, consum, etc. Són exemples clars d'aquest component a curt termini els períodes vacacionals, el calendari laboral, etc.

En general, tots dos factors tenen una influència molt important sobre la repetitivitat i la periodicitat de qualsevol activitat natural i humana.

Exemple de variacions estacionals

Seguint amb l'exemple anterior sobre la concentració de CO_2 , la figura 5 mostra que durant la primavera els nivells de concentració de CO_2 augmenten fins a aconseguir els màxims anuals. Per contra, durant la tardor, i especialment durant els mesos de setembre i octubre, els nivells de contaminació de l'aire es redueixen als mínims anuals.

Figura 5. Exemple de variacions estacionals (en aquest cas, d'un període de tres anys)



Encara que la tendència general de la sèrie és augmentar, podem veure que aquest patró es repeteix anualment.


2.3. Variacions cícliques

Les **variacions cícliques**, que també formen part dels **moviments a curt termini**, són oscil·lacions en una sèrie de temps que operen amb una periodicitat superior a l'annual. Un període complet és un cicle, però un cicle no té un període de temps fix específic.

Exemple de variacions cícliques

En l'anàlisi de dades econòmiques o de negocis apareix generalment un moviment cíclic que respon als períodes de prosperitat, recessió, depressió i recuperació que apareixen periòdicament en la majoria d'economies nacionals o globals. Les pujades i baixades en els negocis depenen de la naturalesa conjunta de les forces econòmiques i de la interacció entre elles.

Figura 6. Exemple de variacions cícliques



La figura 6 mostra els canvis cíclics que tenen lloc en la inflació de l'índex de preus al consumidor (IPC) per a l'Índia i els Estats Units durant el període del 1960 al 2016. Tots dos països exhibeixen patrons cíclics en la inflació de l'IPC cada dos o tres anys aproximadament. La periodicitat d'aquests cicles no està fixada i depèn de variables econòmiques nombroses i complexes, tant a escala local com global.

2.4. Variacions aleatòries o irregulars

Finalment, les **variacions aleatòries o irregulars** són l'últim factor que causa fluctuacions en les dades de sèries temporals. Aquestes fluctuacions són imprevisibles, incontrolables, impredictibles i erràtiques (els terratrèmols, les guerres, les inundacions, les fams i qualsevol altre desastre natural).

Les variacions aleatòries o irregulars són estocàstiques i no es poden emmarcar en un model matemàtic per a una predicció futura. Aquest tipus d'error es deu a la falta d'informació sobre variables explicatives que poden modelar aquestes variacions o a la presència d'un soroll aleatori en les dades.

2.5. Descomposició d'una sèrie temporal

Aquests quatre components es combinen per generar les sèries temporals. Es poden fer suposicions sobre aquests components tant en el comportament com en la manera en què es combinen, la qual cosa els permet modelar-se utilitzant mètodes estadístics tradicionals. Aquests components també poden ser la manera més efectiva de fer prediccions sobre valors futurs.

En aquest sentit una sèrie temporal es pot expressar de manera matemàtica:

$$x_t = f_t + s_t + c_t + e_t, \quad (2)$$

en què f , s , c i e representen, respectivament, els components de tendència, estacionalitat, variacions cícliques i variacions aleatòries o irregulars. En la fórmula anterior t és l'índex de temps de la sèrie, que pren valors successius i espaiats igualment en el temps, és a dir, $t = 1, 2, 3, \dots, N$.

L'objectiu de l'anàlisi de sèries temporals és descompondre una sèrie temporal en les seves característiques constitutives i desenvolupar models matemàtics per a cadascuna. Aquests models s'utilitzen per a comprendre què causa el comportament observat de la sèrie temporal i per a predir la sèrie per a futurs punts en el temps.

3. Estacionarietat en sèries temporals

En aquest apartat discutirem el concepte d'*estacionarietat* (*stationarity* en anglès) de les sèries temporals. Aquesta propietat és important en l'anàlisi de sèries temporals, ja que moltes tècniques d'anàlisi estadística parteixen de la suposició que el conjunt de dades que s'analitza és estacionari.

3.1. Definició d'estacionarietat

Una sèrie temporal és **estacionària** si les seves propietats (per exemple, mitjana, variància, autocorrelació, etc.) no canvien amb el temps.

La majoria dels mètodes de pronòstic estadístic es basen en el supòsit que les sèries de temps poden fer-se estacionàries aproximadament mitjançant l'ús de transformacions matemàtiques. L'estacionarietat és un concepte especialment rellevant en les sèries temporals, ja que moltes teories economètriques clàssiques es deriven dels supòsits d'estacionarietat.

A continuació enumerem les dues raons principals que justifiquen la importància del concepte d'*estacionarietat* de les sèries temporals:

- 1) Una sèrie temporal estacionària és relativament fàcil de predir, ja que les seves propietats estadístiques es mantenen constants al llarg del temps.
- 2) Una altra raó per a tractar d'estacionaritzar una sèrie de temps és poder obtenir estadístiques de mostra significatives, com mitjanes, variacions i correlacions amb altres variables, que es poden usar per a obtenir més informació i comprendre millor les seves dades.

Hi ha dues formes d'estacionarietat importants:

- **Estacionarietat forta** (*strongly stationary*). Es diu que una sèrie temporal és fortament estacionària quan totes les seves propietats són invariables pel canvi de l'origen del temps o la traducció del temps.

- **Estacionarietat feble** (*weakly stationary*). Es diu que una sèrie temporal és estacionària de segon ordre o feblement estacionària quan les seves funcions de mitjana i autocovariància són invariants pel canvi de l'origen del temps o la traducció del temps.

En realitat, la majoria de les sèries de temps econòmiques i comercials estan lluny de ser estacionàries quan s'expressen en les seves unitats de mesura originals, i fins i tot després de l'ajustament estacional exhibiran típicament tendències, cicles, aleatorietat i altres comportaments no estacionaris.

3.2. Test de Dickey-Fuller augmentat

El test de Dickey-Fuller augmentat (*augmented Dickey-Fuller*, ADF) està dissenyat per indicar explícitament si una sèrie temporal univariable és estacionària. Aquesta prova es considera una prova d'arrel unitària per a estacionarietat. Una arrel unitària (també anomenada *procés d'arrel unitària* o *procés estacionari de diferència*) és una tendència estocàstica en una sèrie temporal. Si una sèrie temporal té una arrel unitària, mostra un patró sistemàtic que és impredecible.

El test de Dickey-Fuller augmentat utilitza un model autoregressiu i optimitza un criteri d'informació en molts valors de retard diferents. La hipòtesi nul·la de la prova és que la sèrie de temps pot ser representada per una arrel unitària, que no és estacionària (té alguna estructura dependent del temps). La hipòtesi alternativa (que rebutja la hipòtesi nul·la) és que la sèrie temporal és estacionària.

- **Hipòtesi nul·la** (H_0). Si no es rebutja, suggereix que la sèrie temporal té una arrel unitària, la qual cosa significa que **no és estacionària**. Té alguna estructura dependent del temps.
- **Hipòtesi alternativa** (H_1). Rebutja la hipòtesi nul·la; suggereix que la sèrie temporal no té una arrel unitària, la qual cosa significa que **és estacionària**. No té una estructura dependent del temps.

Interpretem aquest resultat utilitzant el valor p de la prova. Un valor p per sota d'un llindar (com 5% o 1%) suggereix que rebutgem la hipòtesi nul·la (estacionària); en cas contrari, un valor p per sobre del llindar suggereix que no rebutgem la hipòtesi nul·la (no estacionària):

- Valor $p > 0,05$: no es pot rebutjar la hipòtesi nul·la (H_0), les dades tenen una arrel unitària i són **no estacionàries**.
- Valor $p \leq 0,05$: rebutja la hipòtesi nul·la (H_0), les dades no tenen una arrel unitària i són **estacionàries**.

Exemple de test de Dickey-Fuller augmentat

Posem que fem el test sobre les dades d'una sèrie temporal, amb el resultat que s'inclou a continuació:

```
ADF Statistic: -6.781424
p-value: 0.000000
Critical Values:
5\%: -2.862
10\%: -2.567
1\%: -3.430
```

El valor estadístic de prova és de $-6,7$. Com més negatiu sigui aquest valor més probable és que rebutgem la hipòtesi nul·la (tenim un conjunt de dades estacionari).

Com a part de la sortida, obtenim una taula de cerca per a ajudar a determinar l'estadística ADF. Podem veure que el nostre valor estadístic de $-6,7$ és menor que el valor de $-3,430$ a l'1%.

Això suggereix que podem rebutjar la hipòtesi nul·la amb un nivell de significació de menys de l'1% (una baixa probabilitat que el resultat sigui una casualitat estadística). Rebutjar la hipòtesi nul·la significa que el procés no té arrel unitària i, al seu torn, que la sèrie temporal és **estacionària** o no té una estructura dependent del temps.

3.3. Convertir una sèrie temporal en estacionària

Els conjunts de dades de sèries temporals poden contenir tendències i estacionalitat, que es poden eliminar abans del modelatge. Hi ha diferents tècniques per a convertir una sèrie temporal no estacionària en una sèrie temporal estacionària. Aquestes tècniques es basen, en essència, a identificar i eliminar tendències i efectes estacionaris d'una sèrie temporal.

Les **tendències** poden donar lloc a una **mitjana variable** al llarg del temps, mentre que l'**estacionalitat** pot donar lloc a una **variància variable** al llarg del temps, la qual cosa defineix una sèrie temporal com a no estacionària. Si la sèrie temporal no és estacionària, sovint podem transformar-la en estacionària utilitzant una tècnica popular anomenada **transformació per diferència** (*difference transform* en anglès).

La diferenciació és una transformació de dades popular utilitzada àmpliament per a fer estacionàries les sèries temporals. Es fa restant l'observació anterior de l'observació actual, tal com s'indica en l'expressió següent:

$$\text{diferència}(t) = \text{obs}(t) - \text{obs}(t - 1), \quad (3)$$

en què $\text{obs}(t)$ indica el valor de l'observació en l'instant de temps t .

En el cas de sèries temporals hem d'agafar la diferència entre observacions consecutives. Aquesta operació es diu **diferència de retard-1** (*lag-1 difference*). La diferència de retard es pot ajustar per adaptar-se a l'estructura temporal específica de cada conjunt de dades. Per a sèries temporals amb un component estacional, es pot esperar que el retard sigui el període (amplada) de l'estacionalitat.

Algunes estructures temporals en una sèrie temporal encara poden existir després de fer una operació de diferenciació, com en el cas d'una tendència no lineal. El procés de diferenciació com a tal es pot repetir més d'una vegada fins que s'hagi eliminat tota la dependència temporal. El nombre de vegades que es fa la diferenciació es denomina **ordre de diferència** (*difference order*).

La diferència es pot utilitzar per a transformar les seves sèries temporals no estacionàries en sèries temporals estacionàries mitjançant aquestes accions:

- Eliminar tendències.
- Eliminar l'estacionalitat.

4. Aprenentatge automàtic

Donades les característiques pròpies d'una sèrie temporal que hem vist fins ara, hem de fer alguns passos preliminars de reestructuració de dades per a poder aplicar els models estàndards d'aprenentatge automàtic en les sèries temporals.

En aquest apartat veurem aquests passos preliminars que ens permetran entrenar els models d'aprenentatge automàtic supervisats amb les dades d'una sèrie temporal i utilitzar-los per a predir valors futurs de la sèrie temporal. Per tant, en aquest apartat ens centrarem en la tasca de **predicció de sèries temporals** (TSF) que hem descrit anteriorment. A més, ens centrarem en el cas de l'aprenentatge **supervisat**; és a dir, emprarem les dades històriques de la sèrie temporal per a generar i entrenar el model, amb l'objectiu final de predir els valors futurs de les observacions de la sèrie temporal de la manera més ajustada possible.

En l'últim subapartat d'aquest apartat revisarem algunes de les mètriques per a avaluar models predictius en sèries temporals.

4.1. Aprenentatge supervisat per a sèries temporals

Generalment, en els mètodes supervisats partirem d'un conjunt de dades etiquetades correctament, D , en el qual distingim l'estructura següent:

$$D_{n,m} = \begin{pmatrix} d_1 = & a_{1,1} & a_{1,2} & \cdots & a_{1,m} & c_1 \\ d_2 = & a_{2,1} & a_{2,2} & \cdots & a_{2,m} & c_2 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ d_n = & a_{n,1} & a_{n,2} & \cdots & a_{n,m} & c_n \end{pmatrix}$$

en què

- n és el nombre d'elements o instàncies.
- m és el nombre d'atributs del conjunt de dades o també la seva dimensionalitat.
- d_i indica cadascuna de les instàncies del joc de dades.
- a_i indica cadascun dels atributs descriptius.
- c_i indica l'atribut objectiu o classe que cal predir per a cada element.

Com podem veure, aquesta estructura difereix sensiblement de l'estructura que presenten les sèries temporals. Per tant, per a poder aplicar els algorismes estàndards d'aprenentatge automàtic a les sèries temporals, haurem d'efectuar una sèrie de transformacions que ens permetin reestructurar les dades en un format similar al que acabem de presentar.

4.1.1. Prediccions en un pas o en múltiples passos

En la predicció de sèries temporals podem estar interessats a crear prediccions a curt termini (per exemple, en l'instant de temps següent) o, per contra, podem voler crear models que facin prediccions a mitjà o llarg terminis.

Segons la necessitat de predicció del model, parlarem de dos tipus bàsics:

- **One-step forecast.** El model prediu l'instant de temps següent, és a dir, $t+1$.
- **Multi-step forecast.** El model prediu valors per a dos o més instants de temps futurs.

Depenent del problema en qüestió, haurem d'escollir entre la predicció d'un pas o de diversos passos, i en aquest segon cas podem escollir el nombre exacte de prediccions futures que volem obtenir del model. En general, les prediccions a valors de futur majors solen ser òbviament menys precises.

4.1.2. Mètode de la finestra lliscant

El procés per a reestructurar una seqüència de dades de sèries temporals perquè semblin un problema d'aprenentatge supervisat és bastant simple. La taula 3 mostra un petit exemple de sèrie temporal amb cinc registres que contenen una informació estàndard d'una sèrie temporal, és a dir, tuples en format (t_i, obs_i) .

Taula 3. Dades d'una sèrie temporal univariant

Temps	Variable
1	35
2	42
3	41
4	47
5	45

Per a reestructurar la informació, creem una nova taula, en què cada fila i conté com a variables conegudes (X) els valors de la sèrie temporal en l'instant $t = i - 1$, i com a valor objectiu o valor a predir (y) el valor de la sèrie temporal en l'instant de temps $t = i$.

La taula 4 mostra el resultat d'aquest procés de reestructuració. Com podem veure, cada fila conté una tupla de valors (obs_x, obs_y) que indiquen el valor d'entrada i de sortida respectivament. D'aquesta manera, el model intentarà

aprendre a generar la sortida en funció del valor d'entrada. És a dir, podem reestructurar aquest conjunt de dades de sèries temporals com un problema d'aprenentatge supervisat mitjançant l'ús del valor en el pas de temps anterior per a predir el valor en el pas de temps següent.

Taua 4. Dades d'una sèrie temporal univariant processades per a un model supervisat

x	y
35	42
42	41
41	47
47	45
45	?

És important notar que, encara que la taula resultant té el mateix nombre de files, l'última fila de les dades reestructurades serà el primer valor que el model haurà de predir, ja que en les dades originals el valor de sortida no està disponible. A més, podem veure que es preserva l'ordre entre les observacions per entrenar un model supervisat. Una vegada que un conjunt de dades de sèries de temps es prepara d'aquesta manera, es pot aplicar qualsevol algorisme d'aprenentatge automàtic estàndard sempre que es preservi l'ordre de les files.

L'ús d'instant de temps anteriors per a predir l'instant de temps següent es denomina **mètode de la finestra lliscant** (*sliding window method* en anglès), encara que també és conegut com a **mètode de retard** (*lag method* en anglès). El nombre de passos de temps anteriors es denomina **amplada de finestra** (*window width*) o grandària del retard (*size of the lag*). Aquesta finestra lliscant constitueix la base de la conversió de qualsevol conjunt de dades de sèries temporals a un problema d'aprenentatge supervisat.

L'enfocament de finestra lliscant es pot usar en una sèrie de temps que té més d'un valor (és a dir, sèries temporals multivariades), que són conjunts de dades en què s'observen dues o més variables a cada moment. Generalment s'escull solament una de les variables com a variable objectiu (*target*), que és la que el model intentarà predir. El procediment és similar utilitzant totes les observacions de l'instant $t = i - 1$ com a variables d'entrada en la fila i , i l'observació seleccionada de l'instant $t = i$ com a variable de sortida o variable objectiu en la fila i .

Taula 5. Dades d'una sèrie temporal multivariant

Temps	Variable 1	Variable 2
1	0.1	35
2	0.2	42
3	0.3	41
4	0.3	47
5	0.4	45

La taula 5 mostra una sèrie temporal multivariant que conté dues observacions per a cada instant de temps.

Taula 6. Dades d'una sèrie temporal multivariant processades per a un model supervisat, en què la variable de sortida correspon a la variable 1 de la taula 5.

X_1	X_2	y_1
0.1	35	0.2
0.2	42	0.3
0.3	41	0.3
0.3	47	0.4
0.4	45	?

Taula 7. Dades d'una sèrie temporal multivariant processades per a un model supervisat, en què la variable de sortida correspon a la variable 2 de la taula 5.

X_1	X_2	y_1
0.1	35	42
0.2	42	41
0.3	41	47
0.3	47	45
0.4	45	?

En cas d'escollir la **variable 1** com a variable de sortida o *target*, el resultat del procés de reestructuració seria el de la taula 6. Podem veure que el conjunt d'entrenament per al model conté dues variables d'entrada (X_1 i X_2) i una variable de sortida (y_1). L'exemple complementari, en el qual se selecciona la variable 2 com a variable de sortida, es representa en la taula 7.

Fins a aquest punt hem vist com usar el mètode de la finestra lliscant per a models basats en prediccions a un pas de distància (*one-step forecast*). Però aquest mètode també pot servir per a fer pronòstics en cas de prediccions a dos o més passos de distància (*multi-step forecast*).

Per a exemplificar aquest procés, considerem el mateix conjunt de dades de sèries temporals univariants de la taula 3. Tal com s'il·lustra en la taula 8, podem emmarcar aquesta sèrie temporal com un conjunt de dades de pronòstic de dos passos per a l'aprenentatge supervisat amb una amplada de finestra igual a u.

Taula 8. Dades d'una sèrie temporal univariant processades per a un model supervisat de pronòstic de dos passos (*multi-step forecast*).

X_1	y_1	y_2
35	42	41
42	41	47
41	47	45
47	45	?
45	?	?

Podem veure que les últimes dues files no es poden usar per a entrenar un model supervisat. En aquest model cal considerar la càrrega sobre les variables d'entrada. Un model supervisat solament té específicament X_1 com a dada d'entrada per a predir dos valors de sortida (y_1 i y_2). Trobar una amplada de finestra que resulti en un rendiment acceptable del model no és tasca fàcil, per la qual cosa generalment s'han de fer moltes proves i experiments.


4.1.3. Estratègies de predicció per a múltiples passos

Hi ha una multitud d'estratègies per al pronòstic de múltiples passos (*multi-step time series forecasting*). Una revisió exhaustiva d'aquests mètodes queda fora de l'abast d'aquest text. Encara així, veurem algunes de les estratègies bàsiques que es poden emprar per a poder generar prediccions a un nombre de dos o més instants de temps en el futur.

Direct multi-step forecast

El mètode directe (*direct multi-step forecast*) implica desenvolupar un model separat per a cada pas de temps de pronòstic. És a dir, si volem fer un pronòstic per als q instants de temps següents, haurem de desenvolupar q models independents, en què cadascun pronosticarà el valor d'un sol instant de temps $t_i \in \{t+1, \dots, t+q\}$. L'esquema de la figura 7 exemplifica el funcionament d'aquesta estratègia en cas de pronòstic de dos passos, en què M_1 i M_2 es refereix a dos models d'aprenentatge automàtic, que hauran de ser entrenats de manera independent per a generar les sortides esperades per als instants de temps $t+1$ i $t+2$ respectivament.

Figura 7. Estructura del mètode *direct multi-step forecast*




Tenir un model per a cada pas de temps és una càrrega addicional de còmput i manteniment, especialment quan el nombre de passos de temps per pronosticar augmenta. A més, en aquesta estratègia no hi ha oportunitat de modelar les dependències entre les prediccions perquè s'utilitzen models independents.

Recursive multi-step forecast

L'estratègia recursiva (*recursive multi-step forecast*) implica usar un model en què es fa un pas diverses vegades de manera iterativa, utilitzant els valors pronosticats en els passos anteriors per a fer la predicció en el pas de temps següent.

Figura 8. Estructura del mètode *recursive multi-step forecast*



Lectura complementària

Per a obtenir més informació sobre les estratègies de *multi-step forecast*, vegeu: G. Bontempi; S. Ben Taieb; Y. A. Le Borgne (2013). "Machine learning strategies for time series forecasting". A: M. A. Aufaure; E. Zimányi (editors) *Business Intelligence. eBISS 2012. Lecture Notes in Business Information Processing* (vol. 138). Heidelberg (Berlín): Springer.


En aquesta estratègia, si volem fer un pronòstic per als q instants de temps següents, haurem d'aplicar de manera iterativa el mateix model q vegades, utilitzant els valors coneguts de la sèrie temporal i les últimes prediccions fetes en els passos anteriors. La figura 8 mostra el funcionament d'aquesta estratègia en cas de pronòstic de dos passos, en què M es refereix a un únic model d'aprenentatge automàtic. M utilitzarà les entrades $\{t-1, t-2, \dots\}$ per a generar el pronòstic de $t+1$ i després emprarà com a entrades els valors $\{\text{predicció}(t+1), t-1, t-2, \dots\}$ per a generar el pronòstic en $t+2$.

Com que les prediccions s'usen en lloc de les observacions, l'estratègia recursiva pot acumular errors de predicció de tal manera que el rendiment es pot degradar ràpidament a mesura que augmenta l'horitzó de predicció.

Direct-recursive hybrid strategy

L'estratègia híbrida (*direct-recursive hybrid*) combina les estratègies directa i recursiva per oferir els beneficis de tots dos mètodes. En essència, aquesta estratègia permet construir un model separat per a cada pas de temps que s'ha de predir, però en aquest cas cada model pot usar les prediccions fetes per models en passos de temps anteriors com a valors d'entrada.


Figura 9. Estructura del mètode *direct-recursive hybrid forecast*



La figura 9 mostra el funcionament d'aquesta estratègia en cas de pronòstic de dos passos, en què M_1 i M_2 són dos models d'aprenentatge automàtic. El model M_1 utilitzarà les entrades $\{t-1, t-2, \dots\}$ per a generar el pronòstic de $t+1$ i, a continuació, el model M_2 emprarà com a entrades els valors $\{\text{predicció}(t+1), t-1, t-2, \dots\}$ per a generar el pronòstic en $t+2$.

Multiple output strategy

L'estratègia de sortida múltiple implica desenvolupar un model que sigui capaç de predir la seqüència de pronòstic completa d'una sola vegada. És a dir, el model generat haurà de tenir una sortida per a cada pas de temps que es vol pronosticar.

Figura 10. Estructura del mètode *multiple output forecast*

La figura 10 mostra el funcionament de l'estratègia de sortida múltiple en cas de pronòstic de dos passos, en què M es refereix al model d'aprenentatge automàtic, que utilitzarà les entrades $\{t-1, t-2, \dots\}$ per a generar els pronòstics de $\{t+1, t+2, \dots\}$.

Els models de sortida múltiple són més complexos, la qual cosa pot significar que són més lents per a entrenar i requereixen més dades per a evitar sobreajustar el problema (*overfitting*).

A més, és important notar que aquest tipus d'estratègia solament es pot aplicar en models d'aprenentatge automàtic que permeten explícitament definir múltiples sortides del model. Per exemple, les xarxes neuronals són un model d'aprenentatge automàtic sobre el qual podem emprar aquest tipus d'estratègia. Per contra, les màquines de vectors de suport (*support vector machine*, SVM) no permeten múltiples sortides, amb la qual cosa no podem emprar l'estratègia de sortida múltiple.

4.2. Mètriques per a avaluar sèries temporals

L'avaluació de models de sèries temporals comparteix el mateix principi que l'avaluació de models de regressió en el sentit que es comparen els valors predits amb els valors reals de les instàncies del conjunt de dades. En aquest apartat veurem algunes de les mètriques més emprades per a avaluar el rendiment d'un model de sèries temporals.

L'**error absolut mitjà** (*mean absolute error*, MAE) és la mètrica més simple i directa per a avaluar el grau de divergència entre dos conjunts de valors, representat per l'equació següent:

$$MAE = \frac{1}{|D|} \sum_{d \in D} |f(d) - h(d)|, \quad (4)$$

en què D és el conjunt d'instàncies, $h : X \rightarrow \mathbb{R}$ és la funció del model i $f : X \rightarrow \mathbb{R}$ és la funció objectiu amb les etiquetes correctes de les instàncies.

En aquest cas, tots els residus tenen la mateixa contribució a l'error absolut final.

L'**error quadràtic mitjà** (*mean square error*, MSE) és probablement la mètrica més emprada per a avaluar models de regressió. Es calcula de la manera següent:

$$MSE = \frac{1}{|D|} \sum_{d \in D} (f(d) - h(d))^2. \quad (5)$$

Utilitzant aquesta mètrica, es penalitzen els residus grans. En aquest sentit, si el model aproxima correctament una gran part de les instàncies del conjunt de dades però comet errors importants en unes quantes, la penalització en aquesta mètrica serà molt superior a la indicada si s'empra la mètrica anterior (MAE).

L'arrel quadrada de l'error quadràtic mitjà (*root mean square error*, RMSE) es defineix aplicant l'arrel quadrada a l'error quadràtic mitjà. Té les mateixes característiques que aquest, però aporta l'avantatge addicional que l'error s'expressa en la mateixa escala que les dades originals. En el cas de l'MSE no era així, ja que la diferència de valors és elevada al quadrat abans de fer la suma ponderada. En alguns casos aquesta diferència pot ser important, mentre que en altres és irrellevant:

$$RMSE = \sqrt{MSE}. \quad (6)$$

L'error percentual absolut mitjà (*mean absolute percentage error*, MAPE) és una mesura de la precisió que s'utilitza com una funció de pèrdua per a problemes de regressió en l'aprenentatge automàtic. En general, expressa la precisió com un percentatge i es defineix amb aquesta fórmula:

$$MAPE = \frac{100}{n} \sum_{t=1}^n \left| \frac{c_t - y_t}{c_t} \right|, \quad (7)$$

en què c_t i y_t són els valors real i pronosticat respectivament en l'instant de temps t ; d'altra banda, n representa el nombre de prediccions efectuades.

Finalment, en alguns models de regressió es poden tolerar diferències importants entre els valors predits i veritables sempre que el model tingui un comportament general similar als valors veritables, prestant especial atenció a la monotonicitat. En aquests casos les mètriques vistes anteriorment poden no ser representatives del rendiment d'un model de regressió. Per contra, els **índexs de correlació** lineal o de rang, com per exemple Pearson o Spearman, poden ser una bona mètrica per a mesurar la bondat del model generat.

5. Exemples pràctics

En aquest últim apartat veurem alguns exemples pràctics de com carregar, processar i analitzar sèries mitjançant el llenguatge Python.

En primer lloc, veurem un exemple d'anàlisi de sèries temporals relacionat amb l'evolució de la concentració de CO₂ a l'aire. En segon lloc, presentarem un exemple relacionat amb la predicció de sèries temporals i ens centrarem en la predicció del nivell d'aigua d'un embassament.

5.1. Exemple 1: anàlisi de la concentració de CO₂

En aquest primer cas analitzarem com evoluciona la concentració de CO₂ en diferents països des d'un punt de vista de l'anàlisi de sèries temporals. És a dir, en aquest exemple intentarem entendre el comportament d'aquesta sèrie temporal i els patrons subjacents, però el nostre objectiu no serà crear un model predictiu que ens permeti predir els comportaments futurs. Les dades emprades en aquests exemples han estat extretes de l'Administració Nacional Oceànica i Atmosfèrica del Departament de Comerç dels Estats Units.

Enllaços d'interès

Dr. Pieter Tans de NOAA/ESRL:
<http://www.esrl.noaa.gov/gmd/ccgg/trends/>; Dr. Ralph Keeling de la Institució d'Oceanografia Scripps:
<http://scrippsco2.ucsd.edu>.

5.1.1. Càrrega de les dades

En primer lloc, s'han de carregar les llibreries necessàries per a executar correctament el codi d'aquests exemples. La versió de Python emprada és la 3.6.

```
1 import os
2 import pandas as pd
3 import numpy as np
4 import seaborn as sns
5 from matplotlib import pyplot as plt
6 %matplotlib inline
```

Lectura complementària

Aquest exemple es basa en Avishek Pal; P. K. S. Prakash (2017), *Practical time series analysis*, Packt Publishing.

A continuació haurem de carregar les dades. En aquest cas emprarem un document en format Microsoft Excel obtingut del repositori de codi associat al llibre de Pal i Prakash, en què es poden trobar diferents conjunts de dades i codi en Python per a dur a terme l'anàlisi.

```
1 data = pd.read_excel('datasets/Monthly_CO2_Concentrations.xlsx', converters={'Year': np.int32,
2                                     'Month': np.int32})
3 data = data.loc[(~pd.isnull(data['CO2'])) & \
4                 (~pd.isnull(data['Year'])) & \
5                 (~pd.isnull(data['Month']))]
6
7 data.sort_values(['Year', 'Month'], inplace=True)
```

Enllaç d'interès

El llibre de Pal i Prakash està disponible a <https://github.com/PacktPublishing/Practical-Time-Series-Analysis>.

En el codi anterior es carreguen les dades del fitxer, i posteriorment s'eliminen les files que continguin valors absents (el valor `NULL`) i s'ordenen segons el valor dels camps any (`Year`) i mes (`Month`).


5.1.2. Tendència general

A continuació creem una gràfica per a poder analitzar de manera visual el comportament de les dades de la sèrie temporal. El resultat es pot veure en la figura 11, en què observem que hi ha una tendència a l'alça de les dades sobre la concentració de CO_2 .

```
1 plt.figure(num=1, figsize=(11, 5.5))
2
3 plt.plot(data['CO2'], color='b')
4 plt.xlabel('Temps')
5 plt.ylabel('Concentració de CO2')
6 ax = plt.gca()
7 ax.set_xticklabels([])
8
9 plt.show()
```

Tal com hem vist anteriorment en aquest mòdul, la tendència general és fàcil d'identificar de manera visual si es disposa d'un conjunt prou gran per a identificar la tendència a llarg termini, però quan no es disposa d'un volum de dades suficient és difícil d'identificar.

Figura 11. Visualització de les dades sobre la concentració de CO_2



La tendència general es pot modelar, entre altres maneres, emprant un model de regressió lineal que ens indiqui el pendent d'inclinació de les dades a llarg termini. A més, la línia de regressió o tendència es pot usar com una predicció del moviment a llarg termini de les sèries temporals.

El fragment de codi següent crea un model de regressió lineal per a les dades de la sèrie temporal i, a continuació, calcula el valor de predicció per a cada punt del conjunt de dades. És a dir, calculem el valor de la predicció per a cadascun dels punts de temps de la sèrie temporal.

```

1 from sklearn.linear_model import LinearRegression
2
3 trend_model = LinearRegression(normalize=True, fit_intercept=True)
4 trend_model.fit(np.arange(data.shape[0]).reshape((-1,1)), data['CO2'])
5
6 print('Trend model coefficient={} and intercept={}'.format(trend_model.coef_[0],trend_model.
    intercept_))
7
8 predictions = trend_model.predict(np.arange(data.shape[0]).reshape((-1,1)))

```


Una vegada tenim els valors de la regressió, podem generar una gràfica que ens permet veure l'aproximació que ha generat la recta de regressió respecte a les dades originals. El codi que es mostra a continuació genera aquesta gràfica, que podem veure en la figura 12. Com es pot observar, en aquest cas una recta de regressió permet ajustar bastant bé la tendència general de les dades originals.

```

1 plt.figure(num=1, figsize=(11, 5.5))
2
3 plt.plot(data['CO2'], color='gray')
4 plt.plot(predictions, color='b')
5 plt.xlabel('Temps')
6 plt.ylabel('Concentració de CO2')
7 ax = plt.gca()
8 ax.set_xticklabels([])
9
10 plt.show()

```

Figura 12. Tendència general de les dades a partir d'una recta de regressió



A partir de les dades de tendència general podem obtenir les **dades residuals**, que es defineixen com les dades obtingudes a partir de sostreure la tendència general de les dades originals, tal com podem veure en el fragment de codi següent.

```

1 residuals = data['CO2'] - predictions

```


Els residus obtinguts en sostreure la línia de tendència de les dades originals s'analitzen a la recerca d'altres propietats interessants, com l'estacionalitat, el comportament cíclic i les variacions irregulars. La figura 13 mostra les dades residuals.

```

1 plt.figure(figsize=(11, 5.5))
2
3 plt.plot(residuals, color='b')
4 plt.xlabel('Temps')
5 plt.ylabel('Concentració de CO2')
6 ax = plt.gca()
7 ax.set_xticklabels(labels)
8 plt.xticks(rotation=90)
9
10 plt.show()

```

Figura 13. Residus generats a partir de sostreure la tendència general de les dades originals



5.1.3. Moviments estacionals

Tal com s'ha comentat anteriorment, podem identificar les variacions estacionals a partir dels patrons observats en una visualització que compregui diversos anys complets i que, per tant, ens permeti identificar patrons subjacents que responguin a moviments estacionals.


En el codi següent es crea una gràfica que mostra les dades filtrades entre els anys 1980 i 1982. El resultat es pot veure en la figura 14. D'una banda, es mostren les dades originals per a aquest període de temps (figura superior); d'altra banda, es mostren les dades residuals per al mateix període de temps (figura inferior).

```

1 # filtrem pels anys 1980-1982
2 data_tmp = data.loc[(data['Year'] == 1980) or (data['Year'] == 1981) or (data['Year'] == 1982)]
3
4 plt.figure(figsize=(11.5, 7.5))
5
6 plt.subplot(211)
7 plt.plot(data_tmp['CO2'], color='b')
8 plt.title('Concentració de CO2')
9 plt.xlabel('Mesos')
10 plt.ylabel('Valors originals')
11 ax = plt.gca()
12 ax.set_xticklabels(data_tmp['Month'])
13 plt.xticks(rotation=90)
14
15 plt.subplot(212)
16 plt.plot(data_tmp['Residuals'], color='r')
17 plt.xlabel('Mesos')
18 plt.ylabel('Residus')
19 ax = plt.gca()
20 ax.set_xticklabels(data_tmp['Month'])
21 plt.xticks(rotation=90)
22
23 plt.show()

```


Figura 14. Dades originals i residuals per al període 1980-1982



Una altra manera de determinar la variació estacional de les dades és agregant les dades individuals en períodes de major envergadura i observant com es comporten valors agregats sobre aquestes dades, com el valor mitjà i la desviació estàndard. En el codi creem una funció (`month_quarter_map`) que assigna el trimestre corresponent a cada fila de dades en una nova columna (`Quarter`).

```
1 # Creem la funció de mapatge: mes => període
2 month_quarter_map = {1: 'Q1', 2: 'Q1', 3: 'Q1',
3   4: 'Q2', 5: 'Q2', 6: 'Q2',
4   7: 'Q3', 8: 'Q3', 9: 'Q3',
5   10: 'Q4', 11: 'Q4', 12: 'Q4'}
6
7 data['Quarter'] = data['Month'].map(lambda m: month_quarter_map.get(m))
```

Seguidament creem les dades agregades per trimestre i calculem el valor mitjà i la desviació estàndard per a cada grup. El primer grup estarà format per les dades dels mesos de gener, febrer i març; el segon per les dades d'abril, maig i juny, i així successivament fins a crear quatre grups per a cobrir els dotze mesos de l'any.

```
1 seasonal_sub_series_data = data.groupby(by=['Year', 'Quarter'])['Residuals'].aggregate([np.
2   mean, np.std])
3 seasonal_sub_series_data.columns = ['Quarterly Mean', 'Quarterly Standard Deviation']
4
5 # Creem índexs de fila per a seasonal_sub_series_data utilitzant el valor de l'any i trimestre
6 seasonal_sub_series_data.reset_index(inplace=True)
7 seasonal_sub_series_data.index = seasonal_sub_series_data['Year'].astype(str) + '-' +
   seasonal_sub_series_data['Quarter']
8 seasonal_sub_series_data.head()
```


El fragment de codi següent genera el gràfic que mostrarà el valor mitjà dels residus segons els valors agregats per trimestre que acabem de generar. La figura 15 presenta la visualització resultant, en què podem veure que el valor mitjà depèn en gran manera del trimestre. També es mostren valors molt semblats en els residus de tots els anys inclosos en les dades originals.

```

1 plt.figure(figsize=(11.5, 5.5))
2
3 plt.plot(seasonal_sub_series_data['Quarterly Mean'], color='b', marker='.')
4 plt.xlabel('Trimestres')
5 plt.ylabel('Valor mitjà del residual de CO2')
6 plt.xticks(rotation=90)
7
8 plt.show()

```

Figura 15. Valor mitjà dels residuals agrupats per trimestre




De manera similar, el fragment de codi següent genera el gràfic que mostrarà la variància dels residus segons els valors agregats per trimestre que acabem de generar. El resultat es pot veure en la figura 16, en què la variància depèn clarament del trimestre. Es mostren valors molt semblats en els residus de tot el conjunt de dades.

```

1 plt.figure(figsize=(11.5, 5.5))
2
3 plt.plot(seasonal_sub_series_data['Quarterly Standard Deviation'], color='b', marker='.')
4 plt.xlabel('Temps')
5 plt.ylabel('Variància del residual de CO2')
6 plt.xticks(rotation=90)
7
8 plt.show()

```

Figura 16. Variància dels valors residuals agrupats



Finalment, podem emprar un diagrama de caixes per a veure de manera unificada els valors mitjana i variància per a una agregació segons trimestre de tots els anys inclosos en l'anàlisi. El codi següent mostra com generar aquest gràfic emprant la funció `boxplot` de la llibreria `seaborn` de Python.


```

1 plt.figure(figsize=(11.5, 5.5))
2
3 g = sns.boxplot(data=data, i='Residuals', x='Quarter')
4 g.set_xlabel('Trimestre')
5 g.set_ylabel('Valor mitjà i variància de la concentració de CO2')
6
7 plt.show()

```

El resultat es pot veure en la figura 17. Com es pot observar, els valors mitjana i variància tenen una clara dependència amb el trimestre independentment de l'any.

Figura 17. Diagrama de caixes dels residuals agrupats per trimestre



5.1.4. Estacionarietat de la sèrie temporal

Per acabar amb aquest exemple, veurem si la sèrie temporal que analitzem és estacionària. Encara que les gràfiques vistes en les seccions anteriors ja ens indiquen que la sèrie temporal no és estacionària, aplicarem el test ADF per comprovar de manera numèrica el resultat d'aquesta prova, que ens indica si una sèrie temporal és estacionària.

El codi següent carrega la funció `adfuller` de la llibreria `statsmodels`, que ens permet fer la prova.

```

1 from statsmodels.tsa.stattools import adfuller
2
3 result = adfuller(data['CO2'])
4
5 print('ADF Statistic: %f' % result[0])
6 print('p-value: %f' % result[1])
7 print('Critical Values:')
8 for key, value in result[4].items():
9     print('\t%s: %.3f' % (key, value))

```

La sortida que ens reporta el test ADF és la següent:

```

ADF Statistic: -0.355668
p-value: 0.917242
Critical Values:
1%: -3.476
5%: -2.882
10%: -2.577

```

Tal com hem vist anteriorment, un valor de $p > 0,05$ indica que no es pot rebutjar la hipòtesi nul·la (H_0), i per tant les dades tenen una arrel unitària i no són estacionàries. A més, el valor estadístic de prova és $-0,35$, la qual cosa indica una probabilitat molt baixa de rebutjar la hipòtesi nul·la.

En resum, podem concloure que la sèrie temporal de concentració de CO_2 no és estacionària.

5.2. Exemple 2: predicció del nivell d'un embassament

En el segon exemple analitzarem com evoluciona el nivell d'aigua d'un embassament des del punt de vista de la predicció de sèries temporals. És a dir, el nostre objectiu principal serà crear un model predictiu que ens permeti predir com evolucionarà el nivell de l'aigua a l'embassament en el futur.

Les dades emprades en aquest exemple han estat extretes de l'Agència Catalana de l'Aigua (ACA). En concret, s'han obtingut les dades sobre l'embassament de Sau, situat a Catalunya, en el període comprès entre els anys 2007 i 2019.

5.2.1. Adquisició de dades

En primer lloc, cal notar que les dades originals obtingudes de l'ACA estan en format XML, amb la qual cosa el primer pas és convertir aquest tipus de document en un format de taula, en què cada fila representa una observació i cada columna és un atribut. En aquest cas concret hem obtingut observacions amb una freqüència diària i cinc atributs diferents de l'embassament. Els atributs es presenten en la taula 9:

Taula 9. Atributs disponibles de l'embassament de Sau

Variable	Descripció	Unitats
4165141	Entrada	m^3/s
4165140	Sortida	m^3/s
4159510	Volum	hm^3
4159547	Capacitat	%
4159509	Nivell	m s. n. m.
3378678	Grups 1 + 2	m^3/s

Com es pot veure en la taula, les dades obtingudes proporcionen informació sobre el volum d'entrada i sortida de l'embassament (hm^3/s), el volum total d'aigua (hm^3), el percentatge de capacitat de l'embassament i el nivell de la superfície de l'aigua de l'embassament (metres sobre el nivell del mar). En aquest cas hem escollit la variable **volum** (hm^3) com a valor de referència per a l'anàlisi.

Enllaç d'interès

Les dades sobre l'embassament de Sau s'han extret de https://es.wikipedia.org/wiki/Embalse_de_Sau.

Lectures complementàries

R. Parada; J. Font; J. Casas-Roma (2019). "Predicting energy generation using forecasting techniques in Catalan reservoirs". *Energies* (núm. 12, pàg. 1832). <https://doi.org/10.3390/en12101832>

```
1 import pandas as pd
2 import numpy as np
3
4 data = pd.read_csv('data_sau.csv', sep=';', header=0, index_col=0)
5 dataframe = pd.DataFrame(data.loc[data.index >= '2007-01-01']['Volum'])
6 dataset = dataframe.values
7 dataset = dataset.astype('float32')
```

En el codi anterior veiem com es carrega el fitxer CSV amb les dades preprocesades i es filtren les dades anteriors a l'1 de gener de 2007. A més, se selecciona únicament l'atribut o la variable `volum` (`volum`), que és la dada que hem seleccionat per analitzar en aquest exemple.

5.2.2. Anàlisi preliminar


A partir de les dades tractades en l'apartat anterior, farem una primera anàlisi de la tendència, variacions estacionals, etc. Aquest tipus d'anàlisi és molt útil per a entendre les dades amb què es treballa.

El codi següent mostra com fer la descomposició de la sèrie temporal emprant la llibreria `statsmodels` de Python. El resultat obtingut inclou quatre subconjunts de dades: les dades originals (`observed`), la tendència general (`trend`), les variacions estacionals (`seasonal`) i els residus (`resid`).

```
1 import statsmodels.api as sm
2
3 # time serie decomposition
4 descomp_serie = sm.tsa.seasonal_decompose(dataset, model='additive', freq=365)
5
6 print(descomp_serie.observed)
7 print(descomp_serie.trend)
8 print(descomp_serie.seasonal)
9 print(descomp_serie.resid)
```

En la figura 18 podem veure els valors originals i els tres components obtinguts en el procés de descomposició de la sèrie temporal. Es pot apreciar una clara variació estacional, produïda sens dubte pels períodes de pluja abundant en aquesta regió del sud d'Europa. També és important notar la variació del conjunt original de dades, amb un valor mínim de 21 hm^3 , un valor màxim de 162 hm^3 i un valor mitjà de 112 hm^3 .

Figura 18. Descomposició de la sèrie temporal



En aquest cas la sortida que ens reporta el test ADF és la següent:

```
ADF Statistic: -3.759525
p-value: 0.003350
Critical Values:
1%: -3.431880
5%: -2.862216
10%: -2.567130
```

Tal com hem vist anteriorment, un valor de $p < 0,05$ indica que es pot rebutjar la hipòtesi nul·la (H_0) i, per tant, les dades són estacionàries.

5.2.3. Preparació de les dades

En aquest exemple tractem un problema univariable, ja que solament hem seleccionat una de les variables o atributs disponibles. Però hem de seleccionar dos paràmetres molt importants:

- El nombre de dies previs que emprarem per al model predictiu.
- El nombre de passos amb què volem formular les prediccions.

Per a aquest exemple, suposarem que volem fer una predicció a quinze dies. És a dir, volem que el model d'aprenentatge automàtic ens mostri els valors futurs per als propers quinze dies. Aquest paràmetre es defineix a partir dels requeriments del problema, però s'ha de tenir en compte lògicament que les prediccions a llarg termini solen tenir un error molt major que les prediccions a curt termini.

Amb relació al nombre de dies previs que emprarà el model per a generar la predicció, aquest paràmetre involucra generalment algunes proves per determinar el valor òptim o, almenys, un valor acceptable. En el nostre cas, després de fer algunes proves hem decidit fixar-lo en quinze dies, com en el cas anterior.

En resum, el model emprarà els valors reals del volum d'aigua dels últims quinze dies per a generar una predicció del volum per als propers quinze dies. El conjunt de dades haurà de tenir l'estructura que es mostra en la taula 10:

Taula 10. Estructura del conjunt de dades preparat per al model predictiu

$X_{(t-15)}$	$X_{(t-14)}$	...	$X_{(t-1)}$	$Y_{(t+1)}$	$Y_{(t+2)}$	...	$Y_{(t+15)}$
112.87	113.15	...	114.10	115.09	118.14	...	113.76

Per a generar aquesta estructura a partir de les dades originals, emprarem el mètode de la finestra lliscant (*sliding window method*) amb una amplada de finestra (*window width*) igual a 15. El codi següent permet generar el conjunt de dades necessàries per a entrenar el model d'aprenentatge automàtic.

```
1 from sklearn.model_selection import train_test_split
2 from numpy import array
3
```

```

4 # split a univariate sequence into samples
5 def split_sequence(sequence, n_steps_in, n_steps_out):
6     X, y = list(), list()
7
8     for i in range(len(sequence)):
9         # find the end of this pattern
10        end_ix = i + n_steps_in
11        out_end_ix = end_ix + n_steps_out
12        # check if we are beyond the sequence
13        if out_end_ix > len(sequence):
14            break
15        # gather input and output parts of the pattern
16        seq_x, seq_y = sequence[i:end_ix], sequence[end_ix:out_end_ix]
17        X.append(seq_x)
18        y.append(seq_y)
19
20    return array(X), array(y)
21
22 # params
23 n_steps_in = 15
24 n_steps_out = 15
25
26 # create sequence
27 X, y = split_sequence(dataset, n_steps_in, n_steps_out)
28
29 # create train and test datasets
30 train_X, test_X, train_I, test_Y = train_test_split(X, y, test_size=0.33)

```

La sortida d'aquest fragment de codi són les quatre variables estàndards per a l'entrenament d'un model predictiu:

- `train_X`: variable amb les dades d'entrada del model (x_i). En aquest cas concret tindrem quinze valors per a cada fila, ja que hem determinat utilitzar els quinze dies anteriors per a fer els pronòstics.
- `test_X`: variables amb les dades d'entrada del model, però reservats per a la fase de test.
- `train_Y`: variables amb les dades de sortida del model (y_i). En aquest cas també tindrem quinze valors, ja que volem que el model faci prediccions en un futur de quinze dies.
- `test_Y`: variables amb les dades de sortida del model, però reservats per a la fase de test.

5.2.4. Creació del model predictiu

Una vegada tenim el conjunt de dades preparat, podem començar amb la creació del model predictiu i el seu entrenament. Hi ha una gran diversitat de models d'aprenentatge automàtic, cadascun amb certes característiques, virtuts i defectes. Queda fora de l'abast d'aquest text revisar aquests models.

En aquest exemple emprarem les màquines de vectors suport (*support vector machines*, SVM). Les SVM són un dels models més emprats en aprenentatge automàtic i, concretament, per a resoldre problemes de regressió com el que plantegem. Les SVM no permeten múltiples sortides, per la qual cosa no és possible emprar l'estratègia MIMO per a generar la predicció a quinze dies. En aquest cas emprarem l'estratègia directa.

```

1 from sklearn.svm import SVR
2 from sklearn.multioutput import MultiOutputRegressor
3
4 model = MultiOutputRegressor(SVR(kernel='rbf', C=20, gamma=0.28, epsilon=0.0125))
5 # train the model
6 model.fit(train_X, train_I)

```

```

7
8 # test the model (new data)
9 pred_I = model.predict(test_X)

```

En el codi anterior s'ha emprat la funció `MultiOutputRegressor` de la llibreria `sklearn`, que permet aplicar el model directe per a generar múltiples sortides en models d'aprenentatge automàtic que no suporten sortides múltiples. La mateixa llibreria s'encarrega d'entrenar els diferents models, un per a cada atribut o variable de sortida.

5.2.5. Resultats

Figura 19. Evolució de l'RMSE en funció del nombre de dies





Figura 20. Comparació de les prediccions i dades reals a un, cinc, deu i quinze dies



A continuació podem veure l'error que ha comès el model en la predicció de valors futurs. La figura 19 mostra com evoluciona l'arrel quadrada de l'error quadràtic mitjà (*root mean square error*, RMSE) segons el nombre de dies que emprem en la predicció. Lògicament, com més gran és el nombre de dies, major és l'error que comet el model.

Finalment, la figura 20 presenta la comparació entre els resultats reals (*actual*) i predits (*prediction*) per a un subconjunt de dos anys, presentant els resultats en funció del pronòstic a un, cinc, deu i quinze dies. Es pot veure clarament que les prediccions a quinze dies tenen un grau de divergència respecte a les dades reals molt major que en els casos d'un i cinc dies.

Resum

En aquest mòdul hem vist una introducció a l'anàlisi de sèries temporals. En primer lloc, hem definit què és una sèrie temporal, n'hem descrit les principals característiques i objectius, i hem presentat les tasques analítiques associades a aquest tipus de dades. També hem definit els quatre components principals que formen una sèrie temporal i que permeten entendre el comportament i els patrons subjacents en les sèries temporals. En concret, els components que hem discutit són: variacions a llarg termini o tendència general; variacions a curt termini, que poden ser estacionals o cícliques, i variacions aleatòries o irregulars. Finalment, hem definit el concepte d'*estacionaritat* en les sèries temporals i hem presentat alguns mètodes bàsics per a determinar si una sèrie és estacionària i, en cas de no ser-ho, com s'hi pot transformar.

A continuació hem revisat algunes tècniques bàsiques per a transformar i reestructurar les dades de sèries temporals perquè puguin ser emprades en algorismes estàndards d'aprenentatge automàtic (*machine learning*). Hem definit els conceptes de *one-step forecast* i *multi-step forecast* i hem vist que la tècnica de la finestra lliscant ens permet adaptar les dades per a generar conjunts d'entrenament en models d'aprenentatge automàtic i algunes tècniques bàsiques per a poder desenvolupar models predictius de múltiples passos (*multi-step forecast*). Seguidament hem revisat algunes de les mètriques més emprades per a avaluar la bondat en la predicció de sèries temporals.

Hem finalitzat aquest mòdul amb dos petits exemples pràctics, en els quals hem aplicat, emprant el llenguatge de programació Python i algunes de les seves llibreries més interessants i populars, alguns dels coneixements adquirits al llarg d'aquest text per a analitzar i predir sèries temporals.

Glossari

indicadors de desenvolupament mundial *m* Principal compilació d'estadístiques internacionals sobre desenvolupament global del Banc Mundial. Proporciona accés a aproximadament 1.600 indicadors per a 217 economies, amb algunes sèries temporals que s'estenen a més de 50 anys, utilitzant fonts reconegudes oficialment i incloent estimacions nacionals, regionals i mundials.

sigla WDI

en world development indicators

internet de les coses *f* Interconnexió digital d'objectes quotidians amb internet.

sigla IoT

en Internet of things

producte interior brut *m* Magnitud macroeconòmica que expressa el valor monetari de la producció de béns i serveis de demanda final d'un país o regió durant un període determinat, normalment d'un any.

sigla PIB

taxonomia *f* Classificació o ordenació en grups de coses que tenen unes característiques comunes.

Bibliografia

Bontempi, G.; Ben, Taieb S.; Le Borgne, Y. A. (2013). "Machine learning strategies for time series forecasting". A: M. A. Aufaure; I. Zimányi (editors) *Business Intelligence. eBISS 2012. Lecture Notes in Business Information Processing*. (vol. 138). Heidelberg (Berlín): Springer.

Lazzeri, F. (2019). *Time series forecasting*. O'Reilly Media, Inc.

Nielsen, A. (2019). *Practical time series analysis*. O'Reilly Media, Inc.

Pal, A.; Prakash, P. K. S. (2017). *Practical time series analysis*. Packt Publishing.